

用于电气阻抗断层成像图像重构的条件扩散模型

Shuaikai Shi, Ruiyuan Kang and Panos Liatsis, *Senior Member, IEEE*

摘要—电气阻抗断层成像 (EIT) 是一种非侵入性成像技术, 能够重构组织和材料的电导率分布。由于其成本低、具备实时能力且不产生电离辐射, EIT 在医学成像、工业过程监测和触觉传感等多个应用领域广受欢迎。EIT 通过测量边界电压来可视化物体内部的电导率分布, 前提是施加了电流激励。然而, 由于电压数据采样不足与高分辨率电导率图像之间的不匹配, EIT 图像重构问题属于病态问题。为此, 已提出多种方法, 包括传统方法和基于深度学习的方法, 这些方法利用空间正则化项以及图像回归范式。在本研究中, 提出了一种基于条件扩散模型的新型 EIT 重构方法, 称为 CDEIT。具体而言, CDEIT 包含前向扩散过程, 该过程首先逐步向干净的电导率图像添加高斯噪声; 以及反向降噪过程, 该过程学习从带噪声版本中预测原始电导率图像, 且以边界电压为条件。模型训练完成后, CDEIT 在测试电压数据上应用条件反向过程, 生成所需的电导率分布。此外, 我们详细介绍了规范化处理流程, 展示了如何将基于模拟数据集训练的 EIT 图像重构模型应用于具有不同大小、激励电流和背景电导率的真实数据集。在合成数据集及两个真实数据集上的实验表明, 所提出的模型优于现有最先进方法。CDEIT 软件作为开源代码 (<https://github.com/shuaikaishi/CDEIT>) 提供, 以确保可复现性。

Index Terms—电阻抗断层成像, 图像重构, 扩散模型, 概率模型, 测量可视化。

I. 引言

TOMOGRAPHIC 成像是一种通过从多个角度扫描物体来重建其内部结构的技术 [1]。它被广泛应用于医学 [2]、[3]、[4]、工业检测 [5]、机器人 [6]、[7] 以及地质探索 [8] 等领域。传统的断层成像方法, 如计算机断层扫描 (CT) 和磁共振成像 (MRI), 在准确率和分辨率方面取得了显著成功, 但也面临挑战, 例如设

备成本高和成像时间长 [9], [10], 以及在可见光波段的脆弱性 [11]。

电气阻抗断层成像 (Electrical Impedance Tomography, EIT) 作为一种新兴的成像技术, 因其无创性、低成本和实时成像能力而受到广泛关注 [12], 并已应用于医学成像、过程断层成像、无损检测等领域 [13]。EIT 通过测量电极之间的电压变化来推断物体内部的阻抗分布, 可用于物体结构的反演。

然而, 由于该逆问题具有高度非线性和不适定性, 传统的 EIT 图像重构方法通常提供的成像质量较差且分辨率较低 [14]。近年来, 基于深度学习 (Deep Learning, DL) 的重构方法展示了直接将电压信号映射到期望的电导率图像的能力, 这得益于其强大的表达能力 [15]。

A. 动机

基于线性反投影的经典图像重构方法 [16] 假设电导率分布与相应的电压测量之间存在线性模型。此外, 通过引入正则化 [17] 来融入空间先验知识, 以提高重构质量。这类方法也可应用于迭代框架中, 以解决非线性逆问题 [18]。然而, 在实际应用中, 传统的 EIT 图像重构优化方法性能有限, 因为它们主要基于简化的线性建模, 无法满足实时成像的需求。

基于深度学习的方法已被用于解决这些局限性。这些方法利用深度神经网络, 如生成对抗网络 (GAN)、卷积神经网络 (CNN) 和注意力模块, 直接从电压信号到电导率图像学习映射关系, 或间接地改进传统方法获得的初始电导率估计。相关研究已证明了电导率图像的高分辨率重构 [12], [15]。

然而, 大多数方法在单步过程中将电压信息映射到输出电导率。通过引入多阶段迭代模型, 这一过程可进一步优化。此外, 基于回归的方法在噪声数据上可能表现出有限的泛化能力, 这是由于在训练指标上出现过拟合。值得注意的是, 这些问题可通过集成生成式模型 [19] 得以缓解, 例如近期流行的扩散模型 [20], [21]。受

This research was supported by ASPIRE UAE under grant AARE20-154.

Shuaikai Shi, Panos Liatsis are with the Department of Computer Science, Khalifa University, Abu Dhabi, United Arab Emirates (e-mail:shuaikai.shi@ku.ac.ae; panos.liatsis@ku.ac.ae), Ruiyuan Kang is with the Wave and Machine Intelligence Department, Technology Innovation Institute, Abu Dhabi, United Arab Emirates (e-mail: ruiyuan.kang@tii.ae.)

此启发,我们提出了一种新颖的多阶段 EIT 图像重构模型。

B. 方法论概述与贡献

最近,降噪扩散概率模型 (DDPM) [21] 在深度生成模型领域引起了广泛关注,并被应用于多种生成任务,例如图像生成 [22] 和音频合成 [23]。此外,带有额外输入的 DDPM 可用于条件生成任务,包括图像超分辨率 [24]、图像融合 [25]、文本到图像生成 [26] 以及图像编辑 [27],涵盖修复、扩展裁剪区域等。

DDPM 通过一系列降噪步骤,学习从其噪声版本生成干净输出。具体而言,DDPM 包含两个过程,即前向扩散过程和反向降噪过程。在训练阶段,扩散过程多次向初始干净图像样本引入独立的高斯噪声,引导输出趋向于标准高斯分布。随后,由深度神经网络实现的降噪过程学习将噪声输入数据映射回原始干净数据。完成训练后,DDPM 可通过对高斯噪声输入 [28] 应用降噪过程来生成新样本。此外,条件扩散模型在反向降噪过程中引入条件输入,为输出生成提供控制器。这种设计降低了生成的随机性,可获得高度相关的结果。受此优势启发,我们提出一种 EIT 图像重构模型,称为 CDEIT。该模型利用电压信号作为条件输入,引导从噪声到期望电导率图像空间细节的生成过程。

本工作的主要贡献可概括如下:

- 1) 与大多数执行图像回归的先进 EIT 图像重构模型不同,我们采用生成扩散模型来解决 EIT 逆问题。所提出的方法直接基于边界电压对电导率图像的概率分布进行建模。该设计从数据中隐式学习电导率图像的先验,并在从条件分布采样时能够从中获益。
- 2) 所提出的 CDEIT 模型通过多次迭代降噪步骤实现图像重构,这使其有别于通用的基于深度学习的 EIT 方法。多阶段过程通过逐步优化电导率图像,提升了模型输出的质量,从而捕捉到更多空间细节并减少噪声。该模型的核心结构为基于 Transformer 的 U-Net,其编码器采用多尺度窗口注意力机制提取特征,并通过残差连接与解码器融合信息,以预测所需输出。
- 3) 我们提出了一种基于电压和电流归一化的泛化框架,支持在模拟数据上训练的 EIT 图像重构模型在真实世界数据上进行测试。该方法能够处理真实场景,其中背景电导率和激励电流值与训练数




图 1. 所提出 CDEIT 框架的概览,包含前向过程和反向过程。在前向扩散过程中,高斯噪声在 T 个时间步内逐步添加到电导率图像 σ_0 上。在反向过程中,降噪网络 $\mu_\theta(\cdot)$ 依据边界电压 $\mathbf{U}$ 条件,逐步恢复原电导率图像的空间细节。

据不同。这使得图像重构模型能够在不同条件下实现自适应,而无需重新训练。

本文结构如下。第 II 节对相关工作进行了综述,涵盖了传统方法、深度学习方法以及基于扩散模型的图像重构方法。第 III 节介绍了所提出的 CDEIT 模型的数学框架。在第 IV 节中,我们详细说明了规范化过程,该过程支持使用模拟数据训练的 EIT 图像重构模型在真实数据集上的泛化能力。第 V 节展示了在一组模拟数据和两组真实世界 EIT 数据集上进行的图像重构实验,以证明所提出模型的有效性。我们还与当前最先进的方法进行了定量和定性比较,并讨论了 CDEIT 在噪声环境下的性能表现以及复杂度分析。最后,第 VI 节总结了本研究,并探讨了该工作的进一步探索方向。

II. 相关工作

电阻率层析成像 (EIT) 被认为是一种有效工具,可基于边界信息获取目标内部电导率分布。在本研究背景下,EIT 图像重构方法大致可分为两类:传统方法通常采用简化的线性模型来估计电导率分布;深度学习方法则通常依赖于电导率图像与其对应边界电压数据的配对,用于监督学习。

A. 传统方法

早期的 EIT 图像重构方法基于反投影算法 [16]。正则化方法有助于解决病态问题。例如,Tikhonov 正则化 (TR) [17],也称为岭回归,假设电导率变化取较小值。在稀疏贝叶斯学习 [29] 中,引入了电导率变化的 ℓ_1 范数以提高对小目标的重构准确率。总变差正则化项 [30] 被引入以保证重构结果的平滑性。此外,已提出

多种物理信息正则化项以提升重构准确率，如拉普拉斯先验 [31]、NOSER 先验 [32] 等。这些方法已被应用于单步及迭代高斯-牛顿 (GN) 技术 [18] 的框架中。除此之外，D-bar 方法 [33] 是一种非迭代重构算法，其利用基于电导率分布势函数的非线性散射变换的低通滤波正则化项。

尽管重构性能有所提升，但性能对超参数选择敏感，且某些方法需要多次前向模型计算以获得电导率分布，导致模型效率较低。

B. 深度学习方法

深度学习具有强大的表示能力，能够以便捷的端到端方式处理问题 [12] 的非线性及病态特性，目前正成为 EIT 重构的新范式。

改进的 LeNet [34]，结合了卷积神经网络 (CNN) 与多层感知机 (MLP)，首次尝试应用于 EIT 重构任务。此后，胡等人等提出了将一维边界电压转换为二维表示并结合 CNN 的方法，即电导率断层成像 (CNN-EIM) [35]，旨在学习电导率空间变化与电极电压位置变化之间的关系。陈等人等借鉴了在分割任务中广泛应用的 U-net 分割网络 [36]，用于 EIT 图像重构，其性能显著优于经典的稀疏回归模型。进一步的发展是结构感知双分支网络 (SADB-Net) [37]，该网络融合了 U-net 结构。其中，一个分支用于分割目标场景中电导率变化的区域，而另一个分支则从输入电压中提取高层特征。两个分支的信息被融合，以实现电导率分布变化的精确估计。在此基础上，余等人等提出了结构感知混合融合学习 (SA-HFL) 模型 [38]，以提高两分支特征的融合效率，从而增强图像分割结果与预测电导率分布变化之间的相关系数。此外，还引入了径向基函数至 CNN (CNN-RBF) 网络 [39]，以加速网络收敛，并提升重构准确率与鲁棒性。残差学习也被引入该领域 [40]，以改善传统方法的初始解，同时获得优于经典 CNN 的性能。类似的思想也应用于双分支 U-net (DHU-Net) 模型 [41]。与此同时，深度图像先验被引入 EIT [42]，使网络能够学习待重构电导率分布的空间先验。然而，该方法需要多次有限元计算以完成正向过程。

总之，用于求解 EIT 逆问题的深度学习方法正变得越来越复杂，导致模型参数数量大幅增加。因此，模型训练的计算成本越来越高，同时需要大量训练数据以减轻过拟合。

udegraphics[width=8cm]fig/ddpm/2deit.jpg

图 2. 16 电极的 2D EIT 前向模型。当一对电极施加电流激励时，目标区域电导率分布的变化将导致边界电极电压的变化。

C. 扩散模型

生成式扩散模型受非平衡统计物理的启发，首次提出于 [20]。后续研究 [21] 对该模型进行了改进，用于图像生成，从而发展出了去噪扩散概率模型 (DDPM)。这种方法的一个引人注目的特点是能够为输入数据附加额外条件，以执行条件生成任务。例如，超分辨率任务可以基于低分辨率图像进行条件化 [24]，或语义可控生成可以基于文本进行条件化 [26]。扩散过程可应用于像素级别 [21], [24]，此时潜在空间的维度与输入数据相同；也可在较低维度上应用，以降低计算负担和扩散步骤数量 [26]。由于其多阶段生成过程，基于 DDPM 的模型在图像生成和修复等领域达到了最先进的模型性能 [22]。DDPM 也被引入到 EIT 图像重构中。Wang 等人 *et al.* 采用基于得分的扩散模型 (CSD) [43] 学习高分辨率电导率图像的无条件分布。随后，将迭代 GN 方法得到的图像重构估计作为采样中点，再通过噪声抑制网络进行优化。尽管该方法能够获得高分辨率电导率图像，但由于模型的学习过程独立于边界电压，无法准确表征电导率变化位置处边界的曲率和锐度。另一种方法提出了结合多种传统方法初始猜测的扩散模型 [44]。同样，该模型在训练过程中未使用边界电压，导致模型性能依赖于经典方法的准确性。从电压信号直接重构电导率图像可避免传统方法固有的累积误差。然而，直接方法由于逆问题的高度不适定性，面临显著挑战。

III. CDEIT: 基于条件扩散模型的电阻抗成像重构

在本节中，我们介绍所提出的 CDEIT，涵盖问题表述、前向和反向过程、损失函数、最优化技术以及快速重构策略。

A. 问题表述

EIT 的正问题是指计算目标区域中由电导率分布引起的电势。在实际应用中，我们关注的是电导率值与边界电极间相应电压之间的关系。在二维 EIT 模型中，当通过一对电极注入电流时，这些物理量之间的关系由以下方程组给出 [12]：




图 3. 去噪网络的框架 $\sigma_\theta(\sigma_t, \mathbf{U}, t)$ 。

$$\nabla \cdot (\sigma \nabla \phi) = 0 \quad \text{in } \Omega, \quad (1)$$

$$\phi + z_l \sigma \frac{\partial \phi}{\partial \mathbf{n}} = \Phi_l \quad \text{on } \partial \Omega \quad (2)$$

$$\int_{e_l} \sigma \frac{\partial \phi}{\partial \mathbf{n}} dS = I_l \quad \text{on } \partial \Omega, \quad (3)$$

$$\sigma \frac{\partial \phi}{\partial \mathbf{n}} \Big|_{\partial \Omega \setminus \cup e_l} = 0 \quad \text{on } \partial \Omega, \quad (4)$$

其中, $\sigma, \phi, \mathbf{n}$ 分别表示区域 Ω 内位置 (x, y) 处的电导率、电势和单位外法线向量, e_l 是边界 $\partial \Omega$ 上第 l 个电极的位置, $l = 1, 2, \dots, L$ 是边界电极数量的索引, Φ_l 是第 l 个电极上的电势, I_l 是第 l 个电极的电流激励。正问题通常采用有限元法求解。

图 2 展示了一个采用相邻激励与相邻测量协议 [4] 的 16 电极二维 EIT 模型。无噪正问题可表示为:

$$\mathbf{U} = f(\sigma), \quad (5)$$

其中 $\mathbf{U}$ 表示边界电压的向量, $f(\cdot)$ 代表非线性前向算子, $\sigma = \{\sigma(x, y) | (x, y) \in \Omega\}$ 是电导率分布。

EIT 图像重构, 即一个逆问题, 包括恢复电导分布内部物体的位置和形状。这是通过求解以下非线性最小二乘问题实现的 [6]:

$$\hat{\sigma} = \arg \min_{\sigma} \|f(\sigma) - \mathbf{U}\|_2^2. \quad (6)$$

为了抑制大部分系统误差并容忍模型中的微小误差, 通常采用时间差 EIT 模型:

$$\mathbf{U}^{(0)} = f(\sigma^{(0)}) \quad (7)$$

$$\mathbf{U}^{(i)} = f(\sigma^{(i)}) \quad (8)$$

其中, 电导率分布的估计值 $\delta \sigma = \sigma^{(i)} - \sigma^{(0)}$ 是从两组测量之间的电压变化值 $\delta \mathbf{U} = \mathbf{U}^{(i)} - \mathbf{U}^{(0)}$ 得到的。通常, $\sigma^{(0)}$ 和 $\mathbf{U}^{(0)}$ 分别是背景的电导率分布和相应的电压测量值。类似地, $\sigma^{(i)}$ 和 $\mathbf{U}^{(i)}$ 分别是包含夹杂物时在时刻 i 的电导率分布和相应的电压测量值。在下文叙述中, 除非另有说明, 所有电压和电导率量均指时间差值。

总之, 逆 EIT 问题旨在利用电压测量信息 $\mathbf{U}$ 重构电导率分布 σ 。在本研究的背景下, EIT 图像重构被表述为建模条件概率分布 $p(\sigma | \mathbf{U})$ 的问题。从这一视角出发, 可以通过对该条件分布进行采样来获得所需的电导率分布。受先进的降噪扩散生成模型 [21] 的启发, 下文小节将详细介绍学习上述条件分布的两个过程。

B. 前向扩散过程

基于 DDPM [21], 采用长度为 T 的马尔可夫链, 并使用高斯扩散核来逐步向电导率值 σ 添加噪声:

$$q(\sigma_t | \sigma_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} \sigma_{t-1}, \beta_t \mathbf{I}), \quad (9)$$

其中 $t \in \{1, 2, \dots, T\}$, $\sigma_0 = \sigma$ 为电导率真实值, σ_T 为最后一次前向步骤后的含噪声电导率图像, $\beta_t \in \{\beta_1, \beta_2, \dots, \beta_T\}$ 为表示高斯噪声方差的超参数序列, $\mathbf{I}$ 表示单位矩阵。

鉴于高斯分布的特性, 可以直接确定每个扩散步骤的输出:

$$q(\sigma_t | \sigma_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \sigma_0, \sqrt{1 - \bar{\alpha}_t} \mathbf{I}) \quad (10)$$

$$\text{or } \sigma_t = \sqrt{\bar{\alpha}_t} \sigma_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad (11)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ 和 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。注意到当 T 趋于无穷大时, $q(\sigma_\infty)$ 收敛到 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 。前向扩散过程如图 1 顶部所示。

C. 反向降噪过程

完成前向扩散过程后, 应用反向降噪过程, 从噪声输入和相应边界电压信息中重建出所需的电导率图像, 如图 1 底部所示。

特别地, 逆过程将标准高斯噪声变换为干净的电导率图像 σ 。假设之前描述的前向扩散步骤 (9) 的逆过程遵循另一个高斯核, 如下所述:

$$p_\theta(\sigma_{t-1}|\sigma_t) = \mathcal{N}(\mu_\theta(\sigma_t, \mathbf{U}, t), \gamma_t^2 \mathbf{I}), \quad (12)$$

其中 $\mu_\theta(\cdot)$ 是由一个由参数 θ 参数化的深度神经网络所建模的函数, 且 γ_t^2 表示一组超参数 $\{\gamma_1^2, \gamma_2^2, \dots, \gamma_T^2\}$ 。这些超参数的具体取值将在下一小节中讨论。

D. 损失函数

在本小节中, 我们介绍所提出的 CDEIT 模型的目标函数。前向过程得到的噪声电导率图像被视为一系列隐变量, 并采用变分推断框架推导损失函数。对数似然的证据下界 (ELBO) 表示为 [45]:

$$\mathcal{L}(\theta) = - \sum_{t=1}^T \text{KL}(q(\sigma_{t-1}|\sigma_t, \sigma_0) || p_\theta(\sigma_{t-1}|\sigma_t)), \quad (13)$$

其中 $\text{KL}(\cdot||\cdot)$ 是条件后验分布与 (12) 之间的 KL 散度。(13) 的完整推导过程详见附录。 $q(\sigma_{t-1}|\sigma_t, \sigma_0)$ 为条件后验分布, 其推导过程如下:

$$\begin{aligned} q(\sigma_{t-1}|\sigma_t, \sigma_0) &\propto q(\sigma_t|\sigma_{t-1}, \sigma_0)q(\sigma_{t-1}|\sigma_0) \\ &= q(\sigma_t|\sigma_{t-1})q(\sigma_{t-1}|\sigma_0). \end{aligned} \quad (14)$$

由于条件分布 (9) 和先验分布 (10) 均为高斯分布, 因此后验分布也保持高斯形式。这是由于高斯分布的共轭性质 [46] 所致。因此, 上述描述的分布 (14) 为:

$$q(\sigma_{t-1}|\sigma_t, \sigma_0) = \mathcal{N}(\tilde{\mu}_t(\sigma_t, \sigma_0), \tilde{\beta}_t \mathbf{I}), \quad (15)$$

在哪里

$$\tilde{\mu}_t(\sigma_t, \sigma_0) = \frac{\sqrt{1-\beta_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \sigma_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \sigma_0, \quad (16)$$

$$\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \beta_t. \quad (17)$$

(13) 中的 KL 散度是易处理的, 因为其仅涉及对角高斯分布。因此, 单个时间步的 KL 散度可表示为:

$$\begin{aligned} \mathcal{L}_t(\theta) &= -\text{KL}(q(\sigma_{t-1}|\sigma_t, \sigma_0) || p_\theta(\sigma_{t-1}|\sigma_t, \mathbf{U})) \\ &= -\frac{1}{2\gamma_t^2} \|\tilde{\mu}_t(\sigma_t, \sigma_0) - \mu_\theta(\sigma_t, \mathbf{U}, t)\|_2^2 + C, \end{aligned} \quad (18)$$

其中 C 是与 θ 无关的常数, 包含了某些固定的超参数。

通过进一步简化, 网络预测 $\mu_\theta(\sigma_t, \mathbf{U}, t)$ 可以写成与 (16) 类似的形式, 即:

$$\begin{aligned} \mu_\theta(\sigma_t, \mathbf{U}, t) \\ = \frac{\sqrt{1-\tilde{\beta}_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \sigma_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\tilde{\beta}_t}{1-\bar{\alpha}_t} \sigma_\theta(\sigma_t, \mathbf{U}, t), \end{aligned} \quad (19)$$

其中 $\sigma_\theta(\cdot)$ 是 $\mu_\theta(\cdot)$ 的一种替代表达形式, 用于在前向过程中估计干净的电导率图像, 将在下一小节中实现。

因此, (18) 中提出的 KL 散度可以进一步简化:

$$\mathcal{L}_t(\theta) = -\frac{\bar{\alpha}_{t-1}\tilde{\beta}_t}{2(1-\bar{\alpha}_t)^2} \|\sigma_0 - \sigma_\theta(\sigma_t, \mathbf{U}, t)\|_2^2 \quad (20)$$

在训练阶段, 我们建立了关系 $\gamma_t^2 = \tilde{\beta}_t$ 。随后, 我们可以沿着时间维度通过逐步过程优化 ELBO, 如 (13) 所示。在每一步中, 我们专注于一个简化的损失函数, 忽略超参数系数, 其形式可表示为:

$$\mathcal{L}_{\text{simple}}(\theta) = \|\sigma_0 - \sigma_\theta(\sigma_t, \mathbf{U}, t)\|_1 \quad (21)$$

在我们的实验协议中, 由于对异常值具有更好的鲁棒性, 使用 ℓ_1 损失函数来替代 ℓ_2 损失函数。

E. 网络 $\mathcal{E}$ 最优化

接下来, 使用基于 Transformer 的 U-net 架构构建条件降噪网络 $\sigma_\theta(\cdot)$ 。整体上, 该网络如图 3 所示。U-net 的输入包含三个部分, $\{\sigma_t, \mathbf{U}, t\}$ 。在每个训练步骤 t 中, 高斯噪声被添加到干净的电导率图像 σ_0 以通过 (11) 的前向扩散过程生成 σ_t 。通过将每种电流激励所产生的电压结果列成一行, 并将与激励电极相关的电压值设为零, 可以构建出包含一定空间信息的二维电学阻抗图 (EIM) $\mathbf{U}$ 。对 EIM 进行插值处理, 以匹配输入图像的空间分辨率。随后, σ_t 与上采样的 $\mathbf{U}_{up}$ 沿通道维度进行连结。这些数据预处理步骤可表示为

$$\mathbf{U}_{up} = \text{Interp.}(\mathbf{U}) \uparrow_{S \times}, \quad (22)$$

$$\mathbf{X} = [\sigma_t, \mathbf{U}_{up}]. \quad (23)$$

在实验中, 电导率图像 σ 的空间分辨率是 128×128 , 该值可被电极数量整除, 即 16。符号 $\uparrow_{S \times}$ 表示通过最




图 4. Transformer 块与 Swin-Transformer 块。(a) 全局注意力与窗口注意力。(b) 涉及时序的 Transformer 块。

近邻插值将二维 EIM 的空间分辨率提高 S 倍。记号 $[\cdot]$ 表示拼接操作，而 $\mathbf{X}$ 表示输入到降噪网络中的数据。输入被嵌入为大小为 2 的块序列，模型维度为 512，随后由后续的基于 Transformer 的块进行处理。

此外，基于 Transformer 的降噪 U-net 包含一系列 Transformer 块、Swin-Transformer 块、块合并、跳跃连接和上采样模块。Transformer 块在特征图上全局计算注意力，而 Swin-Transformer 将特征图分割成小块，在窗口内以节省内存的方式计算注意力，如图 4 (a) 所示。经过特征嵌入后，第 l 层自注意力机制的结果 $\mathbf{H}^{(l+1)}$ 计算如下

$$\mathbf{H}^{(l+1)} = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}, \quad (24)$$

其中 d_k 是键的维度作为规范化因子， $\mathbf{Q}$ 、 $\mathbf{K}$ 和 $\mathbf{V}$ 分别表示查询、键和值。这些通过输入特征 $\mathbf{H}^{(l)}$ 与模型参数 $\mathbf{W}_q$ 、 $\mathbf{W}_k$ 和 $\mathbf{W}_v$ 的线性投影计算得到，即 $\mathbf{Q} = \mathbf{H}^{(l)}\mathbf{W}_q$ 、 $\mathbf{K} = \mathbf{H}^{(l)}\mathbf{W}_k$ 和 $\mathbf{V} = \mathbf{H}^{(l)}\mathbf{W}_v$ 。当前时间步 t 作为全学成的时间嵌入编码为 Transformer [47] 中的位置嵌入，并作为仿射变换系数输入到网络中的每个 Transformer 和 Swin-Transformer 块 [48]，如图 4 (b) 所示。

采用块合并 (Patch Merging) 对上层编码器中的特征图进行下采样，以保留通过传统池化操作可能丢失的信息；而上采样模块则包含最近邻插值和一个线性层，用于特征通道调整，如图 5 所示。最终，网络输出干净电导率图像的估计结果。为适应 EIT 图像重构任务，我们采用 Sigmoid 加权线性单元 (SiLU) 非线性激活函数 [49] 和均方根 (RMS) 规范化 [50]。所提出的 CDEIT 的训练过程如算法 1 所示。




图 5. 尺度变换模块。(a) 图块合并。(b) 通过插值进行上采样。

Algorithm 1: Training algorithm of CDEIT

Input: paired training data: $(\mathbf{U}, \sigma_0)$;
hyperparameter sequence: $\{\beta_1, \beta_2, \dots, \beta_T\}$;
model parameters: θ .

- 1 Initialize θ randomly;
- 2 **repeat**
- 3 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;
- 4 $t \sim U(1, T)$;
- 5 Compute the noisy image through (11):
 $\sigma_t = \sqrt{\alpha_t}\sigma_0 + \sqrt{1 - \alpha_t}\epsilon$
- 6 Compute the gradient of (21) w.r.t. θ :
 $\nabla_{\theta} \|\sigma - \sigma_{\theta}(\sigma_t, \mathbf{U}, t)\|$;
- 7 Update θ via Adam optimizer [51].
- 8 **until training phase end**;

Algorithm 2: Reconstruction of CDEIT

Input: test boundary voltage: $\mathbf{U}'$;
the sub-sequence of $\{1, 2, \dots, T\}$ is denoted as $\{\tau_1, \tau_2, \dots, \tau_d = T\}$

- 1 $\sigma'_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;
- 2 **for** $t = \tau_d, \dots, \tau_1$ **do**
- 3 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\epsilon = \mathbf{0}$
- 4 Compute the denoised result by $\sigma_{\theta}(\sigma'_t, \mathbf{U}', t)$;
- 5 Sample the denoising output σ'_{t-1} from DDIM [52] sampler (25);
- 6 **end**

F. 快速采样 CDEIT

训练完成后，我们可以通过执行反向降噪过程在测试数据上生成图像重构结果。与逐步从 (12) 采样不同，我们采用一种替代的反向采样器以加速重构过程。该采样器由 [52] 提出，基于非马尔可夫前向过程，允许在反向过程实现中跳过某些步骤，称为降噪扩散隐式模型 (DDIM)。具体而言，新的前向过程可表述为：




图 6. 大小、激励电流和背景电导率的变化。(a) 小研究区域。(b) 研究区域放大了 S_A 倍。(c) 模拟数据中无包含体的情况。(d) 模拟数据中有一个包含体的情况。(e) 实测数据中无包含体的情况。(f) 实测数据中有一个包含体的情况。

$$q_{\sigma}(\sigma_{t-1}|\sigma_t, \sigma_0) = \mathcal{N}(\sqrt{\bar{\alpha}_{t-1}}\sigma_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \gamma_t^2} \cdot \frac{\sigma_t - \sqrt{\bar{\alpha}_t}\sigma_0}{\sqrt{1 - \bar{\alpha}_t}}, \gamma_t^2 \mathbf{I}). \quad (25)$$

利用这种关系，我们可以利用 σ_0 的估计值来执行逆过程。具体而言，测试数据上的融合结果可以通过实现如算法 2 所述的逆降噪过程来生成。

IV. 模型泛化

本节提出了一种用于二维 EIT 图像重构的泛化方法，使在仿真数据上训练的模型可直接应用于真实数据，能够适应大小、激励电流和背景电导率的变化。

我们考虑一种传统的圆形传感器设置，电极位于圆周上。我们首先在实际实验的背景下，探讨传感器尺寸（即面积）变化的影响。位于圆盘电极圆周上的两点之间的等效电阻表示为 [53]:

$$R \approx \frac{2}{\pi\sigma} \ln \frac{2d}{\delta}, \quad (26)$$

其中 d 表示连接两个测量点的弦的长度， δ 表示每个点处小圆形接触区域的直径。考虑一种情况：真实数据集的几何形状相对于训练数据集按因子 S_A 进行了缩放。电极之间的电阻值保持不变，因为弦长和接触宽度均按因子 S_A 成比例地缩放，如图 6 (a)-(b) 所示。因此，在真实场景中通过电极对注入相同的电流值时，将产生与仿真研究中观察到的相同电压。换句话说，基于单位长度模拟数据集训练的 EIT 图像重构模型可直接应用于具有不同但成比例缩放维度的真实数据集。

在本小节的剩余部分，我们提出并展示了规范化技术的应用，以应对真实实验环境中激励电流值和背景电导率水平均存在变化的情况。

为了演示原理，我们仅考虑一对相邻电极之间的电压变化。在仿真数据集的情况下， I_0 电流注入到激励电极上。我们假设测量电极之间的有效电流值在无包含物的目标区域和有包含物的区域分别为 I_{00} 和 I_{01} ，相应的电导率分布分别为 σ_{00} 和 σ_{01} 。根据欧姆定律，仿真研究情况下电流的取值为：

$$\begin{aligned} I_{00} &= U_{00}\sigma_{00} \\ I_{01} &= U_{01}\sigma_{01} \end{aligned} \quad (27)$$

其中， U_{00} 和 U_{01} 分别表示无异常区域与存在异常区域时的边界电压，如图 6 (c)-(d) 所示。

训练好的模型 $g(\cdot)$ 可用于通过 $\delta\hat{\sigma}_0 = g(U_{01} - U_{00})$ 预测电导率的变化。对于真实世界数据集的情况，如图 6 (e)-(f) 所示，当前公式保持一致：

$$\begin{aligned} I_{10} &= U_{10}\sigma_{10} \\ I_{11} &= U_{11}\sigma_{11} \end{aligned} \quad (28)$$

其中， U_{10} 和 σ_{10} ， U_{11} 和 σ_{11} 分别为无非均匀体和有非均匀体时的边界电压和电导率分布。

由于领域转换，直接将基于模拟数据训练的 EIT 图像重构模型部署到真实数据上会导致不正确的电导率估计， $\delta\hat{\sigma}_1 \neq g(U_{11} - U_{10})$ 。然而，所提出的规范化过程可用于解决模拟数据与真实世界数据集之间的模型不匹配问题。

具体而言，由于线性关系，当前的缩放因子 S_I 被确定为 $S_I = I_1/I_0 = I_{10}/I_{00} = I_{11}/I_{01}$ 。该因子可用于归一化 (28) 中激励电流的值：

$$\begin{aligned} I_{00} &= U_{10}\sigma_{10}/S_I \\ I_{01} &= U_{11}\sigma_{11}/S_I \end{aligned} \quad (29)$$

然后，将附加项 $U_{00}/U_{10} \cdot U_{10}/U_{00}$ 引入上述方程，可简化为：




图 7. 正向和反向 FEM 网格配置。(a) 正向网格。(b) 像素化反向网格。

$$\begin{aligned} I_{00} &= U_{10} \frac{U_{00}}{U_{10}} \cdot \sigma_{00} \\ I_{01} &= U_{11} \frac{U_{00}}{U_{10}} \cdot \sigma_{11} \frac{U_{10}}{U_{00}} \frac{1}{S_I} \end{aligned} \quad (30)$$

我们继续引入电压缩放因子为 $S_U = U_{10}/U_{00}$ 。这使得 (30) 进一步简化为：

$$\begin{aligned} I_{00} &= U_{10} \frac{1}{S_U} \cdot \sigma_{00} \\ I_{01} &= U_{11} \frac{1}{S_U} \cdot \sigma_{11} \frac{S_U}{S_I} \end{aligned} \quad (31)$$

由于真实数据集已被规范化为背景电导率为 σ_{00} 且激励电流为 I_0 的情况，因此可在模拟数据集上训练的模型用于预测规范化的电导率变化：

$$\delta\hat{\sigma}_1 = g\left(\frac{U_{11} - U_{10}}{S_U}\right) \cdot \frac{S_I}{S_U} \quad (32)$$

在本工作进行的实验中，电压缩放因子近似为 $S_U \approx \bar{U}_r/\bar{U}_s$ ，其中 $\bar{U}_r$ 和 $\bar{U}_s$ 分别为模拟数据和实测数据在无包含物情况下的参考电压平均值。

V. 实验

我们展示了所提出的 CDEIT 在一份模拟数据集和两个公开可用的真实数据集（即 UEF2017）上进行的实验结果。¹ 以及 KTC2023²。为了进行对比分析，我们采用了两种传统算法，即单步 Tikhonov 回归 (TR) [17] 和迭代高斯-牛顿 (GN) [18] 方法，以及几种基于监督深度学习的 EIT 图像重构模型。这些模型包括改进型 LeNet [34]、CNN-EIM [35]、SADB-Net [37]、SA-HFL [38]、Ec-Net [40]、DHU-Net [41] 和 CSD [43]。与深度学习模型不同，前两种方法主要基于线性回归原理，难以生成准确的电导率重构图像，并且需要计算雅克比观测矩阵。这些方法属于一个独立类别，其结果仅作为参考。




图 8. 实验数据集中的示例基准图像。(a) 模拟数据集中三个样本的电导率变化，分别对应一个、两个和三个物体，(b)-(c) UEF2017 数据集中的样本 4_1 和 5_1，(d) KTC2023 数据集中的样本。

A. 数据描述

仿真数据集包含多种形状的不均匀体，即圆形、三角形和方阵。我们研究了 1 到 3 个物体之间的组合情况。背景电导率设定为 1 S/m。包含物随机指定为绝缘材料或导电材料，其电导率分别为 0.01 S/m 和 2 S/m。所有仿真实验均使用 MATLAB 的 EIDORS 完成。³ 开源工具箱 [54]，提供了多种选择，包括传感器几何结构、电流注入与电压测量协议以及材料特性。我们采用了常见的测量设置 [55]：边界上具有 16 个电极的圆形传感器，采用 1 mA 的相邻电流激励和相邻电压测量协议。接下来，使用有限元法 (FEM) 求解 (1)-(4) 中的 EIT 正问题。每个数据样本生成包含 208 个元素的边界电压测量向量。图 7 展示了用于求解正问题和逆问题的网格。对于使用圆形均匀模型的正问题，网格包含 10,496 个结点和 20,230 个单元。由 TR 和 GN 求解逆问题的网格采用规则形状，包含 3,956 个结点和 7,862 个单元。随后，将 FEM 单元的值插值到大小为 128×128 的像素空间，用于基于深度学习模型的训练及所有方法的性能评估。模拟数据随机划分为训练集、验证集和测试集，比例为 8:1:1。resulting datasets 分别包含 46,080、5,760 和 5,760 个样本。图 8 (a) 展示了三个基准电导率图像。

第二个数据集 UEF2017 [56] 于 2017 年在芬兰东部大学采集。实验使用了一个半径为 14 厘米的圆形扁平水箱进行。水箱边缘均匀分布了十六个电极，激励电

¹<https://zenodo.org/records/1203914>

²<https://zenodo.org/records/10418802>

³<https://eidors3d.sourceforge.net>

流为 2 mA。水箱内部注入盐水至 7 厘米高度，其中包含各种导电和阻性异物。去除了背景不均匀且异物结构复杂的样本，剩余 22 个样本用于评估。图 8 (b) 和 (c) 展示了该数据集中两个样本的 RGB 图像。由于缺乏电导率分布变化的真实值，这些图像被用来生成参考电导率。在此设置中，白色异物代表绝缘体，电导率变化值为 -1，而黑色异物代表导体，电导率变化值为 +1。该配置用于评估目的。

第三个数据集是 2023 年库奥皮奥断层扫描挑战赛中的 KTC2023 [57]。测量系统包含一个带有圆形塑料水箱的电阻抗断层成像设备，以及沿其边缘均匀分布的 32 个电极。一半的电极以跳 1 方式依次注入 2 mA 的电流 [58]，即向 $1 - 3, 3 - 5, \dots, 31 - 1$ 个电极注入电流。采集了所有相邻电极之间的电压值。当两个相邻电极对的电压值相加时，所得电压数据等效于使用 16 个电极的相邻电流激励和相邻电压测量模式。该数据集包含用于评估的电导率变化掩码。参考电导率变化参数与 UEF2017 数据集中所用参数一致。

B. 实验设置

1) 超参数设置: 基于 Transformer 的 Unet 用于电导率重构。前向扩散时间步 T 设为 1000。超参数序列 $\{\beta_1, \beta_2, \dots, \beta_T\}$ 设为从 $1 \times e^{-4}$ 到 $2 \times e^{-2}$ 均匀增长的序列。训练迭代次数设为 $150k$ ，批量大小设为 64，此处采用 Adam 优化器 [51]，学习率设为 $1 \times e^{-5}$ 。模型训练完成后，使用 DDIM 采样器进行图像重构，采样步骤为 5 步。对于基于深度学习的方法，我们在配备 32GB 内存的 NVIDIA Tesla V100 GPU 上执行图像重构任务，而两种传统算法则在配备 16GB 内存的 Intel i7-10870H CPU 上运行。

2) 性能指标: 峰值信噪比 (PSNR)、结构相似性指数度量 (SSIM) [59] 以及相关系数 (CC) 被用于定量评估对比方法的重构结果。PSNR 等价于均方误差 (RMSE)。在 SSIM 方面，该指标考虑了亮度、对比度和结构，有助于评估感知质量的变化，例如边缘和纹理的出现情况。而 CC 则提供了像素级的强度值比较，并通过将一幅图像相对于另一幅图像进行线性平移来支持模式检测。所有估计值与真实值均被规范化的至 $[0, 1]$ 以进行准则评估。

C. 模拟数据集上的实验

表 I 总结了所有对比方法在模拟数据集上的性能指标。结果表明，不同方法在重构质量方面存在显著差

表 I

在模拟数据集的 5760 个测试样本上，比较方法的定量指标。最佳结果用粗体表示，第二佳结果用下划线标出。

	PSNR	SSIM	CC
TR [17]	15.02 $\pm$ 10.27	0.608 $\pm$ 0.247	0.797 $\pm$ 0.088
GN [18]	24.97 $\pm$ 3.88	0.852 $\pm$ 0.049	0.895 $\pm$ 0.073
Improved LeNet [34]	26.99 $\pm$ 3.13	0.923 $\pm$ 0.035	0.931 $\pm$ 0.048
CNN-EIM [35]	30.66 $\pm$ 7.88	0.967 $\pm$ 0.036	0.978 $\pm$ 0.025
SADB-Net [37]	25.42 $\pm$ 3.60	0.848 $\pm$ 0.047	0.904 $\pm$ 0.063
SA-HFL [38]	38.05 $\pm$ 6.19	0.990 $\pm$ 0.015	0.990 $\pm$ 0.015
Ec-Net [40]	35.51 $\pm$ 5.10	0.987 $\pm$ 0.014	0.987 $\pm$ 0.014
DHU-Net [41]	<u>38.76 $\pm$ 5.31</u>	<u>0.994 $\pm$ 0.010</u>	<u>0.992 $\pm$ 0.013</u>
CSD [43]	28.19 $\pm$ 5.65	0.953 $\pm$ 0.044	0.922 $\pm$ 0.133
CDEIT	39.57 $\pm$ 4.85	0.998 $\pm$ 0.004	0.999 $\pm$ 0.002

异。TR 作为一种单步线性重构方法，整体表现最差。相比之下，采用迭代最优化策略的 GN 方法取得了显著提升，相较于 TR，PSNR 提升了 9.95 dB。基于深度学习的模型相较于传统方法表现出竞争力。值得注意的是，CNN-EIM 表现更优，相较于改进的 LeNet 架构，PSNR 提升了 3.67 dB。双分支 SA-HFL 模型直接引入掩码信息，并融合了更先进的分割技术，优于 SADB-Net。Ec-Net 和 DHU-Net 设计为图像精炼模型，从 TR 提供的初始猜测中估计电导率图像。然而，其性能受限于传统方法的局限性，导致结果不理想。此外，CSD 模型在训练阶段主要作为无条件扩散模型，学习电导率图像的概率分布。在预测阶段，它利用降噪网络处理 GN 方法生成的结果。这种建模策略得到了清晰度更高的电导率图像，但准确率有所下降。其局限性源于对经典重构方法的直接应用，尽管经过优化，仍未能充分捕捉 EIT 反演问题中的复杂特性。

所提出的 CDEIT 模型在反向降噪过程中引入了多个重构阶段，这些阶段直接由电压信号条件化。我们使用 DDIM 采样器 [52] 获得近似重构图像。所提出的 CDEIT 模型的性能优于本研究中评估的所有其他重构模型。值得注意的是，相较于表现第二好的模型 DHU-Net，CDEIT 在 PSNR 上提升了 0.81 dB。此外，与大多数前沿深度学习模型相比，CDEIT 提供了更稳定的图像重构效果，表现为性能指标的标准差相对较低。这一提升凸显了我们的方法在解决电导率断层成像中固有的复杂逆问题方面的有效性。在 SSIM 和 CC 指标方面，CDEIT 也分别比表现第二好的方法高出 0.004 和 0.006。

图 9 展示了从模拟测试数据中重构得到的电导率




图 9. 从模拟测试数据样本重建的电导率图像。




图 10. 两个真实测试数据样本的重建电导率图像。

图像，比较了各种重构方法的性能表现。如图 9 第一列所示，TR 方法生成的重构图像无法准确描绘包含物的空间分布。GN 方法和改进的 LeNet 模型能够定位包含物的位置，但在精确重构其形态方面仍存在不足，如图 9 中案例 #3 所示。CNN-EIM 在包含物数量较少的图像重构场景中表现出较高的准确率。然而，随着包含物数量增加，重构任务的整体复杂度上升，其性能显著下降，如图 9 所示。这种效能下降是由于 CNN-EIM 的架构相对简单，可能缺乏足够的容量来充分表征并解析更复杂的包含物构型中的精细空间关系。此外，SA-HFL 在重构包含物边缘方面比 SADBnet 提供了更清晰的结果。但如果分割网络产生错误的掩码预测，模型将预测

出不准确的电导率变化位置，如图 9 中案例 #4 所示。DHU-Net 的容量大于 Ec-Net，因此在单个和多个包含物的情况下均能生成更准确的电导率图像。

对于扩散模型，CSD 依赖于 GN 的初始估计来进行图像重构。尽管 CSD 能够重构出高清晰度的电导率图像，但有时会对包含物的形状预测错误。例如，在图 9 的案例 #2 中，真实值在左上角是一个三角形，但 CSD 将其预测为一个方阵。显然，与其它方法相比，所提出的 CDEIT 在与真实值对比时，能够产生最佳的电导率图像重构结果。


D. 真实数据集上的实验

此外，我们利用在仿真数据集上训练的模型，通过第 IV 节所述的泛化方法，在两个真实 EIT 数据集上进行了实验，以进一步评估重构性能。与仿真数据相比，真实数据由于测量噪声、电极移动、域形变以及温度效应等因素，存在领域偏移。由于真实数据缺乏真实的电导率值，我们采用人工标注的参考值来进行定量评估。如图所示，这两个数据集上的测试结果显著劣于表 I 中在仿真数据集上评估的相同指标。为便于视觉比较，我们在图 10 中展示了四种具有不规则几何特征物体的重构电导率图像。这些图像上所有重构方法的对应指标如图 11 所示。所提出的 CDEIT 在 PSNR 和 CC 指标上均表现出具有竞争力的性能。需要强调的是，在真实数据缺乏标准化真实值的情况下，这些定量指标仅作参考之用。


E. 模型讨论

1) 复杂性分析：在本小节中，我们讨论了本研究中所考虑的各类重构模型的计算复杂度，这与参数数量和训练时间/模型收敛性相关。表 II 提供了所提出模型与当前最先进的深度学习方法在使用模拟数据集时的参数数量、单次前向计算的浮点运算量 (FLOPs) 以及训练时间的概览。就模型大小而言（可视为容量的指示），SADB-Net 和 CDEIT 是规模最大的模型，这些模型可能更适合处理复杂任务，但训练时需要更多的资源。相反，Ec-Net 和 CNN-EIM 是轻量级模型，表明其对内存的需求较低。从 FLOPs 数量来看，尽管 Ec-Net 的参数数量较小，但其计算开销最大，达到 16.35 十亿 FLOPs。这与 CDEIT 形成对比，CDEIT 虽然参数量大，但 FLOPs 相对较少 (15.5 亿)。总体而言，CDEIT 在高模型容量与计算效率之间取得了良好的平衡，在内存和推理受限的情况下仍能提供有效的解决方案，同时保持较高的模型复杂度。此外，使用 DDIM 采样器时，CDEIT 的性能与多阶段融合模型相当。


2) 消融研究：我们对 EIT 图像重构任务进行了消融研究，探索了不同类型的规范化层和激活函数，以确定最优情景。该实验在模拟数据集上进行，以节省时间，仅使用 10k 训练步骤。表 III 展示了采用层规范化和 RMS 规范化时，结合 SiLU 和 ReLU 激活函数的 PSNR 结果。显然，这些配置实现了非常相似的重构性能。由于 SiLU 和 RMSNorm 具有简洁性且无需额外超参数，我们在所提出的模型中采用了它们。



(a)



(b)



(c)

图 11. 真实数据集上四种方法在 4 个样本上的重构结果: (a) PSNR (b) SSIM (c) CC.

3) 鲁棒性分析：最后，我们测试了 EIT 重构模型的泛化能力。在模拟测试集中引入了 40 dB 和 30 dB 的高斯白噪声，新数据集分别标记为 “Data 40 dB” 和

表 II
对比模型的参数量、浮点运算次数 (FLOPs) 和训练时间。

	Size ($\times 10^6$)	FLOPs ($\times 10^9$)	Training time (h)
Improved LeNet	10.13	0.01	0.29
CNN-EIM	1.73	0.07	0.80
SADB-Net	176.52	11.38	28.98
SA-HFL	7.84	4.35	25.29
Ec-Net	1.00	16.35	43.48
DHU-Net	2.45	0.89	23.87
CSD	4.04	4.15	5.79
CDEIT	107.52	1.55	43.33

表 III
不同配置的消融实验。

ReLU	LayerNorm	17.10
	RMSNorm	17.10
SiLU	LayerNorm	17.11
	RMSNorm	17.12

表 IV
在模拟数据集上, 不同噪声水平下图像重构结果的 PSNR。

	Data	Data 40 dB	Data 30dB
TR	15.02	14.93	14.28
GN	24.97	22.69	18.60
Improved LeNet	26.99	26.08	22.99
CNN-EIM	30.66	28.31	23.40
SADB-Net	25.42	24.32	19.46
SA-HFL	38.05	33.20	25.11
Ec-Net	35.51	32.41	<u>28.78</u>
DHU-Net	<u>38.76</u>	<u>34.35</u>	28.94
CSD	28.19	26.02	22.36
CDEIT	39.57	35.58	26.70

“Data 30 dB”。原始数据集标记为 “Data”。不同噪声水平下图像重构结果的 PSNR 值如表IV所示。从结果可以看出, 当噪声较小时, CDEIT 实现了较高的重构准确率; 然而随着噪声增加, 其性能相较于依赖经典 TR 方法的 DHU-Net 和 Ec-Net 模型有所下降。

VI. 结论

在本研究中, 我们提出了一种基于条件降噪扩散的新型监督式 EIT 图像重构方法——CDEIT。该方法通过学成的条件生成模型利用电导率图像中的空间细节。采用基于 Transformer 的 U-Net 来建模反向扩散过程

中的去噪步骤。训练完成后, CDEIT 能够通过逐步反向的条件去噪过程, 从电压测量的条件输入中生成 EIT 图像。此外, 我们引入了一种新方法, 以支持在背景电导率和激励电流不同的真实数据上, 将基于模拟数据训练的 EIT 图像重构模型进行泛化应用。在一组模拟数据及两个公开可用的数据集上进行的实验表明, 所提出的模型具有高效性和有效性。

未来的研究将考虑引入基于 RGB 图像的预训练扩散模型, 以提升重建电导率分布的质量。此外, 我们计划探索在低维潜在空间中运行的扩散模型, 以重建高分辨率电导率图像, 并进一步提高模型效率。

附录

在本节中, 我们给出证据下界 (ELBO) (13) 的推导过程。

在 DDPM 模型中, 所有含噪图像 $\sigma_1, \sigma_2, \dots, \sigma_T$ 都被视为潜在矩阵。从变分推断的框架来看, 真实后验分布 $p(\sigma_{1:T}|\sigma_0)$ 由变分分布 $q(\sigma_{1:T}|\sigma_0)$ 近似表示, 其中 $\sigma_{1:T}$ 是 $\sigma_1, \sigma_2, \dots, \sigma_T$ 的简称。通常我们通过最小化这两个分布之间的 KL 散度来实现

$$\begin{aligned}
 & \text{KL}(q(\sigma_{1:T}|\sigma_0)||p(\sigma_{1:T}|\sigma_0)) \\
 &= \int q(\sigma_{1:T}|\sigma_0) \log \frac{q(\sigma_{1:T}|\sigma_0)}{p(\sigma_{1:T}|\sigma_0)} d\sigma_{1:T} \\
 &= \int q(\sigma_{1:T}|\sigma_0) \log \frac{q(\sigma_{1:T}|\sigma_0)p(\sigma_0)}{p(\sigma_{0:T})} d\sigma_{1:T} \\
 &= \int q(\sigma_{1:T}|\sigma_0) \log \frac{q(\sigma_{1:T}|\sigma_0)}{p(\sigma_{0:T})} d\sigma_{1:T} + \log p(\sigma_0) \\
 &= \log p(\sigma_0) - \mathbb{E}_q \left[\log \frac{p(\sigma_{0:T})}{q(\sigma_{1:T}|\sigma_0)} \right] \quad (33)
 \end{aligned}$$

由于 KL 散度的非负性, 我们得到对数似然的 ELBO 为

$$\mathbb{E}_q \left[\log \frac{p(\sigma_{0:T})}{q(\sigma_{1:T}|\sigma_0)} \right] \leq \log p(\sigma_0). \quad (34)$$

因此, 我们可以最大化 ELBO 以获得极大似然估计。注意, 前向扩散和反向降噪中所有变量的联合分布为

$$q(\sigma_1, \sigma_2, \dots, \sigma_T|\sigma_0) = \prod_{t=1}^T q(\sigma_t|\sigma_{t-1}), \quad (35)$$

$$p(\sigma_0, \sigma_1, \sigma_2, \dots, \sigma_T) = p(\sigma_T) \prod_{t=1}^T p_{\theta}(\sigma_{t-1}|\sigma_t). \quad (36)$$

然后, ELBO 可以进一步简化为

$$\begin{aligned}
& \mathbb{E}_q \left[\log \frac{p(\boldsymbol{\sigma}_{0:T})}{q(\boldsymbol{\sigma}_{1:T}|\boldsymbol{\sigma}_0)} \right] \\
&= \mathbb{E}_q \left[\log p(\boldsymbol{\sigma}_T) + \sum_{t=1}^T \log \frac{p_\theta(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t)}{q(\boldsymbol{\sigma}_t|\boldsymbol{\sigma}_{t-1})} \right] \\
&= \mathbb{E}_q \left[\log p(\boldsymbol{\sigma}_T) + \sum_{t=1}^T \log \frac{p_\theta(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t)}{q(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t, \boldsymbol{\sigma}_0)} \cdot \frac{q(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_0)}{q(\boldsymbol{\sigma}_t|\boldsymbol{\sigma}_0)} \right] \\
&= \mathbb{E}_q \left[\log \frac{p(\boldsymbol{\sigma}_T)}{q(\boldsymbol{\sigma}_T|\boldsymbol{\sigma}_0)} + \sum_{t=1}^T \log \frac{p_\theta(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t)}{q(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t, \boldsymbol{\sigma}_0)} \right] \\
&= -\text{KL}(q(\boldsymbol{\sigma}_T|\boldsymbol{\sigma}_0)||p(\boldsymbol{\sigma}_T)) \\
&\quad - \sum_{t=1}^T \text{KL}(q(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t, \boldsymbol{\sigma}_0)||p_\theta(\boldsymbol{\sigma}_{t-1}|\boldsymbol{\sigma}_t)). \tag{37}
\end{aligned}$$

注意, 第一项表示 $\boldsymbol{\sigma}_T$ 的分布 (即前向扩散过程的输出) 与先验分布 $p(\boldsymbol{\sigma}_T)$ 之间的 KL 散度。由于前向过程中使用了高斯扩散核, 第一项接近于 0。因此, 我们可以忽略第一项, 使第二项成为我们期望的结果 (13)。

参考文献

- [1] B. Brazey, Y. Haddab, and N. Zemiti, “Robust imaging using electrical impedance tomography: review of current tools,” *Proc. R. Soc. A*, vol. 478, no. 2258, 2022.
- [2] M. C. Bachmann, C. Morais, G. Bugedo, A. Bruhn, A. Morales, J. B. Borges, E. Costa, and J. Retamal, “Electrical impedance tomography in acute respiratory distress syndrome,” *Critical Care*, vol. 22, pp. 1–11, 2018.
- [3] A. Zifan, P. Liatsis, and H. Almarzouqi, “Realistic forward and inverse model mesh generation for rapid three-dimensional thoracic electrical impedance imaging,” *Computers in Biology and Medicine*, vol. 107, pp. 97–108, 2019.
- [4] P. Kantartzis, M. Abdi, and P. Liatsis, “Stimulation and measurement patterns versus prior information for fast 3d eit: a breast screening case study,” *Signal Processing*, vol. 93, no. 10, pp. 2838–2850, 2013.
- [5] J. Yao and M. Takei, “Application of process tomography to multiphase flow measurement in industrial and biomedical fields: A review,” *IEEE Sensors J.*, vol. 17, no. 24, pp. 8196–8205, 2017.
- [6] Z. Hussain, N. A. Madjid, and P. Liatsis, “Tactile sensing using machine learning-driven electrical impedance tomography,” *IEEE Sensors Journal*, vol. 21, no. 10, pp. 11 628–11 642, 2021.
- [7] Z. Hussain and P. Liatsis, “Improved tactile stimulus reconstruction in electrical impedance tomography using the discrete cosine transform and machine learning,” *IEEE Sensors Journal*, vol. 24, no. 14, pp. 22 884–22 095, 2024.
- [8] X. Liu, Q. Lu, and S. Liu, “Resolution enhancement of electrical resistivity tomography based on deep learning,” *IEEE Geosci. Remote Sens. Lett.*, vol. 20, pp. 1–5, 2023.
- [9] S. Mukhopadhyay, Ed., *Next generation sensors and systems*, ser. Smart Sensors, Measurement and Instrumentation. United States: Springer, Springer Nature, 2016.
- [10] C. Li, T. He, X. Yang, C. Feng, Z. Zhang, J. Zhu, S. Dong, Y. Shi, Z. Wei, H. Jiao, Y. Zhang, H. Liu, Z. Wang, and X. Cheng, “Enhanced circular dichroism for achiral sensing based on a DNA-origami-empowered anapole metasurface,” *Nano Letters*, vol. 24, no. 31, pp. 9451–9458, 2024, pMID: 38976602.
- [11] T. He, Z. Zhang, J. Zhu, Y. Shi, Z. Li, Z. Wei, Y. Li, Z. Wang, C.-W. Qiu, and X. Cheng, “Scattering exceptional point in the visible,” *Light: Science & Applications*, vol. 12, 09 2023.
- [12] C. Dimas, V. Alimisis, N. Uzunoglu, and P. P. Sotiriadis, “Advances in electrical impedance tomography inverse problem solution methods: From traditional regularization to deep learning,” *IEEE Access*, vol. 12, pp. 47 797–47 829, 2024.
- [13] A. Adler and D. Holder, *Electrical impedance tomography: methods, history and applications*. CRC Press, 2021.
- [14] Z. Husain, N. A. Madjid, and P. Liatsis, “Tactile sensing using machine learning-driven electrical impedance tomography,” *IEEE Sensors J.*, vol. 21, no. 10, pp. 11 628–11 642, 2021.
- [15] T. A. Khan and S. H. Ling, “Review on electrical impedance tomography: Artificial intelligence methods and its applications,” *Algorithms*, vol. 12, no. 5, 2019.
- [16] D. C. Barber and B. H. Brown, “Applied potential tomography,” *J. Phys. E, Sci. Instrum.*, vol. 17, no. 9, p. 723, sep 1984.
- [17] G. H. Golub, P. C. Hansen, and D. P. O’Leary, “Tikhonov regularization and total least squares,” *SIAM J. Matrix Anal. Appl.*, vol. 21, no. 1, pp. 185–194, 1999.
- [18] P. Hua, E. Woo, J. Webster, and W. Tompkins, “Iterative reconstruction methods using regularization and optimal current patterns in electrical impedance tomography,” *IEEE Trans. Med. Imag.*, vol. 10, no. 4, pp. 621–628, 1991.
- [19] C. Ledig, L. Theis, F. Huszár, J. Caballero, A. Cunningham, A. Acosta, A. Aitken, A. Tejani, J. Totz, Z. Wang *et al.*, “Photo-realistic single image super-resolution using a generative adversarial network,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2017, pp. 4681–4690.
- [20] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, “Deep unsupervised learning using nonequilibrium thermodynamics,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2015, pp. 2256–2265.
- [21] J. Ho, A. Jain, and P. Abbeel, “Denoising diffusion probabilistic models,” in *Adv. Neural Infor. Process. Syst. (NeurIPS)*, vol. 33, 2020, pp. 6840–6851.
- [22] P. Dhariwal and A. Nichol, “Diffusion models beat GANs on image synthesis,” in *Proc. Annu. Conf. Neural Inf. Process. Syst.*, vol. 34, 2021, pp. 8780–8794.
- [23] N. Chen, Y. Zhang, H. Zen, R. J. Weiss, M. Norouzi, and W. Chan, “Wavegrad: Estimating gradients for waveform generation,” in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2020.
- [24] C. Saharia, J. Ho, W. Chan, T. Salimans, D. J. Fleet, and M. Norouzi, “Image super-resolution via iterative refinement,” *IEEE Trans. Pattern Anal. Mach. Intell.*, pp. 1–14, 2022.
- [25] S. Shi, L. Zhang, and J. Chen, “Hyperspectral and multispectral image fusion using the conditional denoising diffusion probabilistic model,” *arXiv preprint arXiv:2307.03423*, 2023.
- [26] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-resolution image synthesis with latent diffusion models,” in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022.

- [27] C. Saharia, W. Chan, H. Chang, C. Lee, J. Ho, T. Salimans, D. Fleet, and M. Norouzi, "Palette: Image-to-image diffusion models," in *ACM SIGGRAPH 2022 Conference Proceedings*, 2022, pp. 1–10.
- [28] W. Peebles and S. Xie, "Scalable diffusion models with transformers," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 4172–4182.
- [29] S. Liu, J. Jia, Y. D. Zhang, and Y. Yang, "Image reconstruction in electrical impedance tomography based on structure-aware sparse bayesian learning," *IEEE Trans. Med. Imag.*, vol. 37, no. 9, pp. 2090–2102, 2018.
- [30] A. Borsic, B. M. Graham, A. Adler, and W. R. Lionheart, "Total variation regularization in electrical impedance tomography," 2007.
- [31] Y. Wu, B. Chen, K. Liu, S. Huang, Y. Li, J. Jia, and J. Yao, "Bayesian image reconstruction using weighted laplace prior for lung respiratory monitoring with electrical impedance tomography," *IEEE Trans. Instrum. Meas.*, vol. 72, pp. 1–11, 2023.
- [32] M. Cheney, D. Isaacson, J. Newell, S. Simske, and J. Goble, "Noser: An algorithm for solving the inverse conductivity problem," *Int. J. Imag. Syst. Technol.*, vol. 2, no. 2, p. 66–75, 1990.
- [33] D. Isaacson, J. Mueller, J. Newell, and S. Siltanen, "Reconstructions of chest phantoms by the d-bar method for electrical impedance tomography," *IEEE Trans. Med. Imag.*, vol. 23, no. 7, pp. 821–828, 2004.
- [34] C. Tan, S. Lv, F. Dong, and M. Takei, "Image reconstruction based on convolutional neural network for electrical resistance tomography," *IEEE Sensors J.*, vol. 19, no. 1, pp. 196–204, 2019.
- [35] D. Hu, K. Lu, and Y. Yang, "Image reconstruction for electrical impedance tomography based on spatial invariant feature maps and convolutional neural network," in *2019 IEEE International Conference on Imaging Systems and Techniques (IST)*, 2019, pp. 1–6.
- [36] Z. Chen, Y. Yang, J. Jia, and P. Bagnaninchi, "Deep learning based cell imaging with electrical impedance tomography," in *2020 IEEE International Instrumentation and Measurement Technology Conference (I2MTC)*, 2020, pp. 1–6.
- [37] Z. Chen and Y. Yang, "Structure-aware dual-branch network for electrical impedance tomography in cell culture imaging," *IEEE Trans. Instrum. Meas.*, vol. 70, pp. 1–9, 2021.
- [38] H. Yu, H. Liu, Z. Liu, Z. Wang, and J. Jia, "High-resolution conductivity reconstruction by electrical impedance tomography using structure-aware hybrid-fusion learning," *Computer Methods and Programs in Biomedicine*, vol. 243, p. 107861, 2024.
- [39] Y. Wu, B. Chen, K. Liu, C. Zhu, H. Pan, J. Jia, H. Wu, and J. Yao, "Shape reconstruction with multiphase conductivity for electrical impedance tomography using improved convolutional neural network method," *IEEE Sensors J.*, vol. 21, no. 7, pp. 9277–9287, 2021.
- [40] Q. Wang, H. Zhang, X. Li, X. Duan, J. Wang, R. Zhang, H. Zhang, Y. Ma, H. Wang, and J. Jia, "Error-constraint deep learning scheme for electrical impedance tomography (eit)," *IEEE Trans. Instrum. Meas.*, vol. 71, pp. 1–11, 2022.
- [41] Z. Wang, X. Li, Y. Sun, and Q. Wang, "Electrical impedance tomography deep imaging with dual-branch u-net based on deformable convolution and hyper-convolution," *IEEE Trans. Instrum. Meas.*, vol. 73, pp. 1–16, 2024.
- [42] D. Liu, J. Wang, Q. Shan, D. Smyl, J. Deng, and J. Du, "Deepeat: Deep image prior enabled electrical impedance tomography," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 45, no. 8, pp. 9627–9638, 2023.
- [43] H. Wang, G. Xu, and Q. Zhou, "A comparative study of variational autoencoders, normalizing flows, and score-based diffusion models for electrical impedance tomography," *Journal of Inverse and Ill-posed Problems*, vol. 32, no. 4, pp. 795–813, 2024.
- [44] A. Denker, Željko Kereta, I. Singh, T. Freudenberg, T. Kluth, P. Maass, and S. Arridge, "Data-driven approaches for electrical impedance tomography image segmentation from partial boundary data," pp. 119–139, 2024.
- [45] L. Struski, M. Mazur, P. Batorski, P. Spurek, and J. Tabor, "Bounding evidence and estimating log-likelihood in vae," in *Proc. 26th Int. Conf. Artif. Intel. Stat. (AISTATS)*, 2023.
- [46] C. Bishop, *Pattern Recognition and Machine Learning*. Springer, January 2006.
- [47] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Proc. Annu. Conf. Neural Inf. Process. Syst.*, vol. 30, 2017.
- [48] Z. Liu, Y. Lin, Y. Cao, H. Hu, Y. Wei, Z. Zhang, S. Lin, and B. Guo, "Swin transformer: Hierarchical vision transformer using shifted windows," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2021.
- [49] P. Ramachandran, B. Zoph, and Q. V. Le, "Searching for activation functions," *arXiv preprint arXiv:1710.05941*, 2017.
- [50] B. Zhang and R. Sennrich, "Root Mean Square Layer Normalization," in *Proc. Annu. Conf. Neural Inf. Process. Syst.*, Vancouver, Canada, 2019.
- [51] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [52] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," in *Proc. Int. Conf. Learn. Represent. (ICLR)*, 2021.
- [53] J. Jeans, *Mathematical Theory of Electricity and Magnetism*, ser. Cambridge Library Collection - Physical Sciences. Cambridge University Press, 2009.
- [54] A. Adler and W. R. Lionheart, "Eidors: Towards a community-based extensible software base for eit," in *Proc. 6th Conf. Biomed. Appl.*, 2005, pp. 1–4.
- [55] B. H. Brown and A. D. Seagar, "The sheffield data collection system," *Clinical Physics and Physiological Measurement*, vol. 8, no. 4A, p. 91, nov 1987.
- [56] A. Hauptmann, V. Kolehmainen, N. M. Mach, T. Savolainen, A. Seppänen, and S. Siltanen, "Open 2d electrical impedance tomography data archive," *arXiv preprint arXiv:1704.01178*, 2017.
- [57] M. Räsänen, P. Kuusela, J. Jauhainen, M. Arif, K. Scheel, T. Savolainen, and A. Seppänen, "Kuopio tomography challenge 2023 –electrical impedance tomography competition and open dataset," *Applied Mathematics for Modern Challenges*, vol. 2, no. 2, pp. 93–118, 2024.
- [58] M. M. Mellenthin, J. L. Mueller, E. D. L. B. de Camargo, F. S. de Moura, T. B. R. Santos, R. G. Lima, S. J. Hamilton, P. A. Muller, and M. Alsaker, "The ace1 electrical impedance tomography system for thoracic imaging," *IEEE Trans. Instrum. Meas.*, vol. 68, no. 9, pp. 3137–3150, 2019.

- [59] Z. Wang, A. Bovik, H. Sheikh, and E. Simoncelli, “Image quality assessment: from error visibility to structural similarity,” *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, 2004.