



DATA-DRIVEN APPROACHES FOR ELECTRICAL IMPEDANCE TOMOGRAPHY IMAGE SEGMENTATION FROM PARTIAL BOUNDARY DATA

ALEXANDER DENKER^{✉*1}, ŽELJKO KERETA², IMRAJ SINGH²,

TOM FREUDENBERG¹, TOBIAS KLUTH¹, PETER MAASS¹, SIMON ARRIDGE²

¹ 工业数学中心, 不莱梅大学

² 计算机科学系, 伦敦大学学院

(Communicated by Handling Editor)

ABSTRACT. 电气阻抗断层成像 (EIT) 在无创成像中发挥着关键作用, 具有医疗和工业应用前景。本文提出了三种数据驱动的林IT图像重构方法。这三种方法最初提交至2023年库奥皮奥断层成像挑战赛 (KTC2023)。首先, 我们介绍一种后处理方法, 该方法在KTC2023中获得第一名。此外, 我们提出一种完全学成的方法以及一种条件扩散方法。这三种方法均基于相似的神经网络作为主干结构, 并使用合成生成的数据集进行训练, 从而为比较这些不同的数据驱动重构方法提供了公平的基础。

1. 引言. 电气阻抗断层成像 (EIT) 是一种成像模态, 它利用物体边界上的电学测量数据来重构其内部的电学特性。在本文中, 我们考虑导电性的重构, 通过在物体表面附着的电极施加一系列电流。电极测量由此产生的电压, 这些电压被用于生成导电性图像。EIT 在众多领域具有应用, 例如医学诊断[5] 或无损检测[18]。

存在多种用于EIT测量过程物理机制的数学模型。令 Ω 为区域, $\partial\Omega$ 为其边界, $\cup_{l=1}^L e_l \subset \partial\Omega$ 为附着在边界上的 $L \in \mathbb{N}$ 电极集合。电势 $u \in H_1(\Omega)$ 由麦克斯韦方程组导出, 并受以下规律支配

$$-\nabla \cdot (\sigma \nabla u) = 0 \quad \text{in } \Omega, \quad (1a)$$

其中 $\sigma \in L^\infty(\Omega)$ 为电导率分布。完整电极模型 (CEM) [26] 描述了在电流注入电极时边界条件的现实表述。首先, 边界被分解为两个部分: 电极 e_l (与它们所附着的边界部分对应) 以及电极之间的其余空间 $\partial\Omega \setminus \cup_{l=1}^L e_l$ 。其次, 考虑了电极与相应边界部分之间的电导特性。对于给定的电流注入模式 $I \in \mathbb{R}^L$, 可将所得模型表示为

$$\begin{cases} u + z_l \sigma \frac{\partial u}{\partial \nu} = U_l, & \text{on } e_l, \text{ for } l = 1, \dots, L, \\ \sigma \frac{\partial u}{\partial \nu} = 0, & \text{on } \partial\Omega \setminus \cup_{l=1}^L e_l, \\ \int_{e_l} \sigma \frac{\partial u}{\partial \nu} ds = I_l, & \text{on } e_l, l = 1, \dots, L, \end{cases} \quad (1b)$$

2020 *Mathematics Subject Classification.* Primary: 65M32, 68T07; Secondary: 92C55.

Key words and phrases. Inverse problems, Deep Learning, Electrical impedance tomography.

*Corresponding author: Alexander Denker.




FIGURE 1. 图示了EIT测量水箱 (Ω)，电极 e_l ，以及电流注入模式的样本。黑色表示相邻注入；绿色表示全部对 e_1 ；粉色表示全部对 e_9 ；洋红色表示全部对 e_{17} ；橙色表示全部对 e_{25} 。虚线注入在2nd 挑战等级中被移除；点线在4th 中被移除；点划线在6th 中被移除。

其中 $z \in \mathbb{R}^L$ 为接触阻抗，用于量化电极与边界接触点处形成的电阻层的影响， $U \in \mathbb{R}^L$ 为电极上的电压。CEM 包含电荷守恒以及电势的平均自由电流约束，即

$$\sum_{l=1}^L I_l = 0 \text{ and } \sum_{l=1}^L U_l = 0, \quad (1c)$$

分别地。我们将电压记为 $\mathbf{U} = (U_1, \dots, U_L)^\top$ ，电流模式记为 $\mathbf{I} = (I_1, \dots, I_L)^\top$ 。方程(1a) 至(1b) 描述了单一电流注入模式。在实际应用中，会施加多个注入模式，并获得相应的电极测量值。我们将第 k 个注入模式下的电压和电荷分别记为 $\mathbf{U}^{(k)}$ 和 $\mathbf{I}^{(k)}$ ，其中 $k = 1, \dots, K$ 。通过 $\mathbf{U} = (\mathbf{U}^{(1)}, \dots, \mathbf{U}^{(K)})$ 和 $\mathbf{I} = (\mathbf{I}^{(1)}, \dots, \mathbf{I}^{(K)})$ ，我们表示所有电极和所有电流模式下的电压和电荷的堆叠 $\mathbb{R}^{KL}$ 向量。令 $\mathbf{F}(\sigma) = (\mathbf{F}^{(1)}(\sigma), \dots, \mathbf{F}^{(K)}(\sigma))^\top$ 为对应的前向算子，作用于电导率 σ ，适用于所有电极和电流模式。由此产生的非线性逆问题可表示为

$$\mathbf{F}(\sigma)\mathbf{I} = \mathbf{U}. \quad (2)$$

其中的目标是根据电极测量值 $\mathbf{U}$ 重构 σ 。

1.1. KTC 2023 挑战. 我们概述了提交至2023年库奥皮奥断层成像挑战赛 (KTC2023) 的三种方法[21]。KTC2023的目标是从部分边界测量中重建电阻性与导电性包含物的分割图。测量数据来自一个带有32 个等间距不锈钢电极的塑料圆形水箱，这些电极安装在边界上。所有32 个电极用于采集测量数据，而16 个电极（奇数编号的电极）用于电流注入模式。对于每种电流注入模式，在相邻电极之间测量电压，每种注入模式产生31 个测量值。共考虑五种类型的注入模式。测量水箱、电极及注入模式的示意图见图 1.1。

该挑战被分为7 个难度等级，其中第一级包含所有32 个电极的数据。在后续等级中，成对的电极被依次移除。因此，每个等级的测量数量和施加的电流注入模式数量均随之减少。每一级依次移除两个电极，即第2 级移除电极1, 2，在最后一级7 中移除电极1 至12。这意味着，所有来自左上边界的数据均被移除，参见图 1.1。这使得高阶等级下的电导率图和分割图重构问题变得越来越不适定。

1.2. 我们的贡献. 我们提出了三种数据驱动的重构方法，以解决从部分电阻断层成像测量数据中重构分割图的问题：

- **FC U-Net**: 一种完全学成的方法，直接从测量值中进行重建，见第 3.1.1 节。
- **Post-Processing**: 一种从初始重构方法进行重构的方法，见第 3.1.2 节。
- **Conditional-Diffusion**: 一种条件扩散方法，旨在直接建模给定初始重构的后验分布，见第 3.2.1 节。

FC U-Net 和 Post-Processing 均为学成重构方法，而 Conditional-Diffusion 则是一种基于条件生成建模的方法。三种提出的算法在 KTC2023 上取得了三项最高得分，其中 Post-Processing 的整体表现最佳。此外，这三种方法均采用相似的 U-Net 架构，参数数量相近，并使用生成的幻影数据集和模拟测量数据进行训练。

1.3. 相关工作. 深度学习后处理和完全学成的重构是医学图像重构中两种广为人知的数据驱动方法 [2]。这两种框架均已应用于 EIT 图像重构。我们的 FC U-Net 遵循 Chen 等人提出的模型 [6]。然而，在第 3.1.1 节中，我们为这一完全学成模型提出了一种新颖的两步训练方法。后处理方法已被应用于 EIT，例如 Martin 等人 [19] 的工作。我们将此处理后处理框架扩展至处理 KTC2023 中不同层次的局部 EIT 测量数据，其严重程度逐渐增加。据我们所知，我们的提交是首个将条件扩散模型应用于真实世界 EIT 数据的研究。最近，Wang 等人 [31] 提出使用无条件扩散模型，并利用 Chung 等人 [8] 提出的采样框架实现条件采样。然而，他们仅在具有两个或四个圆形包含物的模拟数据上评估其方法，而我们在复杂物体的真实测量数据上评估了我们的方法。

2. 线性化重构. EIT 重构涉及从一组电极测量值 $\mathbf{U}$ 中恢复电导率 σ 。一种常用技术是将非线性前向算子 $\mathbf{F}$ 在均匀背景电导率 σ_{ref} 附近进行线性化，并重构相对于该背景的微小扰动 $\delta\sigma$ [7, 10, 17]。线性化的前向算子表示为

$$\tilde{\mathbf{F}}(\sigma_{\text{ref}} + \delta\sigma; \sigma_{\text{ref}})\mathbf{I} := \mathbf{F}(\sigma_{\text{ref}})\mathbf{I} + \mathbf{J}_{\sigma_{\text{ref}}}\delta\sigma, \quad (3)$$

其中 $\mathbf{J}_{\sigma_{\text{ref}}} := \nabla \mathbf{F}(\sigma_{\text{ref}})$ 是在背景电导率处评估的雅克比。我们进一步假设可获得空水箱的测量值 $\mathbf{U}_{\text{ref}}$ ，使得 $\mathbf{F}(\sigma_{\text{ref}})\mathbf{I} = \mathbf{U}_{\text{ref}}$ 。随后将测量扰动定义为 $\delta\mathbf{U} := \mathbf{U} - \mathbf{U}_{\text{ref}}$ ，对应的线性化问题即为根据 $\delta\sigma$ 确定

$$\mathbf{J}_{\sigma_{\text{ref}}}\delta\sigma = \delta\mathbf{U}. \quad (4)$$

扰动 $\delta\sigma \in \mathbb{R}^M$ 通过分段常数有限元展开的 M 个系数进行离散化。有限元近似中的雅克比和前向算子在第 2.1 和 2.2 节中予以说明。

为求解方程 (4)，我们采用变分正则化框架。

$$\widehat{\delta\sigma} := \underset{\delta\sigma}{\operatorname{argmin}} \frac{1}{2} \|\mathbf{J}_{\sigma_{\text{ref}}}\delta\sigma - \delta\mathbf{U}\|_{\Sigma^{-1}}^2 + \alpha \mathcal{J}(\delta\sigma), \quad (5)$$

其中我们假设一个高斯噪声模型 $\delta\mathbf{U} \sim \mathcal{N}(\mathbf{0}, \Sigma)$ ，且 $\mathcal{J} : \mathbb{R}^M \rightarrow \mathbb{R}_{\geq}$ 为正则项。我们考虑形如 $\mathcal{J}(\delta\sigma) = \frac{1}{2} \|\mathbf{L}\delta\sigma\|_2^2$ 的 Tikhonov 型正则项。对于这种正则项的选择，我们可以恢复方程 (5) 的解。

$$\widehat{\delta\sigma} = (\mathbf{J}_{\sigma_{\text{ref}}}^{\top} \Sigma^{-1} \mathbf{J}_{\sigma_{\text{ref}}} + \mathbf{L}^{\top} \mathbf{L})^{-1} \mathbf{J}_{\sigma_{\text{ref}}}^{\top} \Sigma^{-1} \delta\mathbf{U}. \quad (6)$$

矩阵 $(\mathbf{J}_{\sigma_{\text{ref}}}^{\top} \Sigma^{-1} \mathbf{J}_{\sigma_{\text{ref}}} + \mathbf{L}^{\top} \mathbf{L})^{-1}$ 可以离线计算，从而得到一种计算成本低廉的重构方法，这对于训练后处理和条件扩散网络是必要的。在接下来的章节中，我们将讨论前向算子的实现、雅克比 $\mathbf{J}_{\sigma_{\text{ref}}}$ 的计算以及正则化项 $\mathcal{J}$ 的选择。

2.1. 前向算子. EIT前向算子 $\mathbf{F}$ 定义的CEM是非线性的。对于给定的电导率 σ ，计算 $\mathbf{F}$ 需要求解(1b) 中的微分方程。我们通过将有限元方法应用于CEM的弱形式来近似求解，详见例如[16]。为了引入电荷守恒条件，我们引入一个拉格朗日乘子 $\lambda \in \mathbb{R}$ 。此时CEM的弱形式可表示为：寻找 $(u, \mathbf{U}, \lambda) \in H^1(\Omega) \times \mathbb{R}^L \times \mathbb{R}$ 使得

$$\int_{\Omega} \sigma \nabla u \cdot \nabla v \, dx + \sum_{l=1}^L \frac{1}{z_l} \int_{e_l} (u - U_l)(v - V_l) \, ds + \sum_{l=1}^L (\lambda V_l + \nu U_l) = \sum_{l=1}^L I_l V_l, \quad (7)$$

对于所有 $(v, \mathbf{V}, \nu) \in H^1(\Omega) \times \mathbb{R}^L \times \mathbb{R}$ ，其中 $\mathbf{V} = (V_1, \dots, V_L)^\top$ 且 $\mathbf{U} = (U_1, \dots, U_L)^\top$ 。

为了数值近似前向模型，我们采用有限元法（CEM）的伽辽金近似，参见例如[17] 以下是简要总结。我们使用分段线性基函数 $\{\phi_i\}_{i=1}^N$ 来表示电势 u ，这些基函数张成 $H^1(\Omega)$ 的一个有限维子空间 V_N 。电导率 σ 使用分段常数基函数 $\{\chi_i\}_{i=1}^M$ 表示，其中每个 χ_i 是网格中某个单纯形的指示函数。为简化符号，我们将 u 和 σ 与其各自基展开中的系数等同起来。即， $u \approx \sum_{i=1}^N u_i \phi_i \cong (u_1, \dots, u_N)^\top$ 且类似地，对于 $\sigma \approx \sum_{j=1}^M \sigma_j \chi_j \cong (\sigma_1, \dots, \sigma_N)^\top$ 也成立。

将上述Galerkin近似应用于(7)会导致线性系统

$$\begin{pmatrix} A(\sigma) + B & C & \mathbf{0} \\ C^\top & D & \mathbf{1} \\ \mathbf{0}^\top & \mathbf{1}^\top & 0 \end{pmatrix} \begin{pmatrix} u \\ \mathbf{U} \\ \lambda \end{pmatrix} = \begin{pmatrix} \mathbf{0} \\ \mathbf{1} \\ 0 \end{pmatrix}, \quad (8)$$

使用块矩阵

$$\begin{aligned} A_{ij} &= \int_{\Omega} \sigma \nabla \phi_i \cdot \nabla \phi_j \, dx && \text{for } i, j = 1, \dots, N \\ B_{ij} &= \sum_{l=1}^L \frac{1}{z_l} \int_{e_l} \phi_i \phi_j \, ds && \text{for } i, j = 1, \dots, N \\ C_{ij} &= \frac{1}{z_j} \int_{e_j} \phi_i \, ds && \text{for } i = 1, \dots, N \text{ and } j = 1, \dots, L \\ D_{ii} &= \frac{1}{z_i} \int_{e_i} 1 \, ds && \text{for } i = 1, \dots, L \end{aligned}$$

其中 $\mathbf{U} = (U_1, \dots, U_L)^\top \in \mathbb{R}^L$ 。

线性系统(8) 有两个性质可用于减少计算量。首先，对于固定的电导率 σ ，CEM关于注入模式是线性的。这使得可以复用求解方程(8) 过程中的中间步骤，例如用于计算所有考虑的电流模式 $\mathbf{l}^{(k)}$ 下数值解 $(u, \mathbf{U})$ 的系统矩阵的LU 分解。其次，仅块矩阵 $A(\sigma)$ 依赖于 σ ，需要重新计算。其他所有块矩阵均可离线计算。

由此得到的离散前向算子使用有限元软件FEniCSx [3] 实现，并可在线获取¹。

2.2. 雅克比. 我们使用电势和电导率的离散函数空间来计算雅克比 $\mathbf{J}_{\sigma_{\text{ref}}}$ 。[10, 17] 中展示了使用像素网格或伴随微分等其他计算策略。

给定 K 注入模式和 L 电极，雅克比 $\mathbf{J}_{\sigma_{\text{ref}}}$ 是一个 $LK \times M$ 矩阵。然而，将雅克比视为一个 $L \times K \times M$ 张量可能更为直观。利用[13, Appendix]，雅克比可以表示为

$$(\mathbf{J}_{\sigma_{\text{ref}}})_{\cdot, k, j} = \mathbf{W}_{k, j}, \text{ for } k = 1, \dots, K, j = 1, \dots, M, \quad (9)$$

其中 $(w_{k, j}, \mathbf{W}_{k, j}) \in V_N \times \mathbb{R}^L$ 是方程的解

$$\int_{\Omega} \sigma_{\text{ref}} \nabla w_{k, j} \cdot \nabla \phi_i \, dx + \sum_{l=1}^L \frac{1}{z_l} \int_{e_l} (w_{k, j} - (\mathbf{W}_{k, j})_l)(\phi_i - V_l) \, ds = - \int_{\Omega} \chi_j \nabla u^k \cdot \nabla \phi_i \, dx, \quad (10)$$

¹https://github.com/alexdenker/eit_fenicsx

其中 $\sum_{l=1}^L (\mathbf{W}_{k,j})_l = 0$ ， u^k 为对应于当前模式 l^k 的势函数。与公式 (7) 类似，我们引入拉格朗日乘子来处理约束，从而得到与公式 (8) 相同的系统矩阵，但右侧项不同，

$$\begin{pmatrix} A(\sigma_{\text{ref}}) + B & C & \mathbf{0} \\ C^\top & D & \mathbf{1} \\ \mathbf{0}^\top & \mathbf{1}^\top & 0 \end{pmatrix} \begin{pmatrix} w_{k,j} \\ \mathbf{W}_{k,j} \\ \lambda_{k,j} \end{pmatrix} = \begin{pmatrix} f_{k,j} \\ \mathbf{0} \\ 0 \end{pmatrix}, \quad (11)$$

与

$$(f_{k,j})_i = - \int_{\Omega} \chi_j \nabla u^k \cdot \nabla \phi_i \, dx \quad \text{for } i = 1, \dots, N. \quad (12)$$

利用公式 (9) 中的恒等式，需要求解 $K \cdot M$ 个问题来构造雅克比矩阵 $\mathbf{J}_{\sigma_{\text{ref}}}$ 。然而，由于公式 (11) 右侧的维度，即前向算子的值域，最多为 N ，因此只需计算解 $(w_r, \mathbf{W}_r, \lambda_r) \in V_N \times \mathbb{R}^L \times \mathbb{R}$ 即可。

$$\begin{pmatrix} A(\sigma_{\text{ref}}) + B & C & \mathbf{0} \\ C^\top & D & \mathbf{1} \\ \mathbf{0}^\top & \mathbf{1}^\top & 0 \end{pmatrix} \begin{pmatrix} w_r \\ \mathbf{W}_r \\ \lambda_r \end{pmatrix} = \begin{pmatrix} \delta_r \\ \mathbf{0} \\ 0 \end{pmatrix} \quad (13)$$

其中， $\delta_r = (\delta_{ir})_{i=1}^N \in \mathbb{R}^N$ 是第 r 个单位向量。因此，我们只需求解 N 个线性系统²，而不是 $K \cdot M$ 。由于 $f_{k,j}$ 可以表示为 $\{\delta_r\}_{r=1}^N$ 的线性组合，我们可以恢复雅克比。

$$(\mathbf{J}_{\sigma_{\text{ref}}})_{\cdot, k, j} = \mathbf{W}_{k, j} = \sum_{r=1}^N (f_{k, j})_r \mathbf{W}_r. \quad (14)$$

观察到分段常数元 χ_j 在网格的恰好一个单元上非零。因此，公式 (14) 右边仅剩少数几项求和，进一步降低了计算复杂度。

在更高的挑战等级中，边界电极被移除。这导致电极测量数量减少 $\tilde{L} < L$ 以及注入模式数量减少 $\tilde{K} < K$ ，即，缩减后的雅克比矩阵形状为 $\tilde{L} \tilde{K} \times M$ 。我们可以通过从完整雅克比矩阵 $\mathbf{J}_{\sigma_{\text{ref}}}$ 中移除相应行来计算这个缩减后的雅克比矩阵。

2.3. 正则化。 我们考虑Tikhonov型正则化项 $\mathcal{J}(\delta\sigma) = \frac{1}{2} \|\mathbf{L}\delta\sigma\|_2^2$ 。注意到在公式 (6) 中的重构需要访问 $\mathbf{L}^\top \mathbf{L}$ ，因此我们可以定义 $\mathbf{P} := \mathbf{L}^\top \mathbf{L}$ 而非 $\mathbf{L}$ 。我们使用三种不同的正则化项：

- **一阶平滑先验 (FSM)**：我们定义网格拉普拉斯算子 $\mathbf{P}_{\text{FSM}} \in \mathbb{R}^{M \times M}$ 为

$$(\mathbf{P}_{\text{FSM}})_{i, j} = \begin{cases} \deg(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and } i \text{ is adjacent to } j \\ 0 & \text{else,} \end{cases} \quad (15)$$

其中 $\deg(i)$ 表示网格单元 i 的邻点数量。矩阵 $\mathbf{P}_{\text{FMS}}$ 也可定义为 $\mathbf{P}_{\text{FMS}} = \mathbf{L}_{\text{FMS}}^\top \mathbf{L}_{\text{FMS}}$ ，其中 $\mathbf{L}_{\text{FMS}}$ 按照 [5] 的方式构造。

- **平滑先验(SM)**：通过 $\mathbf{P}_{\text{SM}} := \Sigma_{\text{SM}}^{-1}$ 与 $(\Sigma_{\text{SM}})_{i, j} = a \exp(-\|x_i - x_j\|_2^2 / (2b^2))$ 构建平滑距离矩阵，其中 x_i 和 x_j 是网格单元 i 和 j 的坐标。我们选择 $a = 0.025$ 和 $b = 0.4 \cdot 0.115$ 。该先验在主办方提供的KTC2023 [21] 实现中被使用。
- **Levenberg–Marquardt 正则化项(LM)** [12]：LM 正则化项在NOSER 框架 [7] 中被使用，其定义为 $\mathbf{P}_{\text{LM}} = \text{diag}(\mathbf{J}_{\sigma_{\text{ref}}}^\top \Sigma^{-1} \mathbf{J}_{\sigma_{\text{ref}}})$ 。注意， Σ 为式 (5) 中高斯噪声模型的协方差矩阵。

²此外，我们有 $N < M$ ，即分段线性元的维度低于分段常数元的维度。




FIGURE 2. 挑战等级1和等级6的初始重构示例。选择等级6是因为它最能突出线性化重构之间的差异。我们评估了独立的FSM先验、独立的SM先验、联合的SM+LM先验，以及两种具有不同正则化强度的联合先验FSM+SM+LM。所选图像为验证数据的一个样本。

综上所述，方程 (5) 的正则化解是通过组合三种正则项得到的

$$\mathbf{F}^\dagger(\delta\mathbf{U}) = (\mathbf{J}_{\sigma_{\text{ref}}}^\top \Sigma^{-1} \mathbf{J}_{\sigma_{\text{ref}}} + \alpha_{\text{FSM}} \mathbf{P}_{\text{FSM}} + \alpha_{\text{SM}} \mathbf{P}_{\text{SM}} + \alpha_{\text{LM}} \mathbf{P}_{\text{LM}})^{-1} \mathbf{J}_{\sigma_{\text{ref}}}^\top \Sigma^{-1} \delta\mathbf{U}, \quad (16)$$

其中 α_{FSM} 、 α_{SM} 和 α_{LM} 为正则化强度， $\mathbf{F}^\dagger$ 为线性化的重构算子。正则化强度通过主办方提供的四组测量数据组成的验证集进行选择。所选正则化项会促进重构图像中不同的结构特征。此外，不同的正则化选择会产生明显不同的重构结果及相应的伪影，这在挑战等级较高时尤为显著。对于Post-Processing和Conditional-Diffusion方法，我们采用5种不同的正则化选择，如图2所示。其核心思想是：融合多种重构结果的信息，可提升训练好的卷积神经网络的性能。

由公式 (16) 计算得到的线性化重构位于分段常数网格表示上，而卷积神经网络需要以 256×256 像素网格形式表示的输入。采用双线性插值，记为 $\mathcal{I} : \mathbb{R}^M \rightarrow \mathbb{R}^{256^2}$ ，将网格数据插值到图像。我们将由此得到的五个插值后的线性化重构集合记为

$$\widehat{\delta\sigma} := \{\mathcal{I}(\mathbf{F}_j^\dagger(\delta\mathbf{U}))\}_{j=1}^5 \quad (17)$$

其中下标表示正则化强度的第 j 种选择。实际上，对于所有五种线性化重构，正则化选择随挑战等级而变化，即在全视角情景下，等级1要求较弱的正则化，这意味着共定义了35种正则化强度的变化。为清晰起见，我们省略了挑战等级的索引。

3. 深度学习方法. 我们向KTC2023提交了三种深度学习方法。其中两种是学成重建器，分别为FC U-Net和Post-Processing，另一种是生成方法Conditional-Diffusion。我们所有方法均采用相同的U-Net主干网络。³ [22, 9]。该网络包含一个条件机制，使层级/时间步能够更有效地影响模型的输出。

所有模型均在模拟数据集上进行训练，该数据集的描述见第4.1节。令 $\sigma \in \mathbb{R}^d$ 且 $d = 256^2$ 表示第2.3节讨论的在方阵像素网格上的重构表示，其中水箱外部的像素始终被视为背景类。

³可在<https://github.com/openai/guided-diffusion>处获得

3.1. 学成重构者. 在学成重构中，目标是识别参数 $\hat{\theta}$ 的参数化重构算子 $\mathcal{R}_\theta : \mathbb{R}^{KL} \rightarrow \mathbb{R}^d$ ，使得

$$\mathcal{R}_{\hat{\theta}}(\delta \mathbf{U}) \approx \delta \boldsymbol{\sigma}. \quad (18)$$

给定一个配对数据集 $\{(\delta \mathbf{U}^{(i)}, \delta \boldsymbol{\sigma}^{(i)})\}_{i=1}^n$ 的样本，我们进行计算

$$\hat{\theta} = \operatorname{argmin}_{\theta} \frac{1}{n} \sum_{i=1}^n \mathcal{L}(\delta \boldsymbol{\sigma}^{(i)}, \mathcal{R}_\theta(\delta \mathbf{U}^{(i)})), \quad (19)$$

使用合适的损失函数 $\mathcal{L} : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_{\geq 0}$ 。均方误差损失函数常用于重构任务[20]。然而，本挑战的目标并非重构电导率分布，而是将图像分割为水/背景、电阻性及导电包含物三类。因此，我们采用类别交叉熵（CCE）作为损失函数。CCE 常用于图像分割，也已被应用于计算机断层扫描的分割[1]。设 $\mathcal{R}_{\hat{\theta}}$ 表示学成的重构器。该模型输出Logit，通过使用Softmax 函数将其变换为类别概率。

$$\hat{p}_{i,c} := \operatorname{Softmax}(\mathcal{R}_{\hat{\theta}}(\delta \mathbf{U})_{i,\cdot}) := \frac{\exp(\mathcal{R}_{\hat{\theta}}(\delta \mathbf{U})_{i,c})}{\sum_{c'=1}^C \exp(\mathcal{R}_{\hat{\theta}}(\delta \mathbf{U})_{i,c'})}, \quad (20)$$

对于所有像素 $i = 1, \dots, d$ 和所有类别 $c = 1, \dots, C$ 。令 $p \in \{0, 1\}^{d \times C}$ 为真实值类别的独热编码。CCE 损失定义为

$$\mathcal{L}_{\text{CCE}}(\hat{p}, p) = -\frac{1}{d} \sum_{i=1}^d \sum_{c=1}^C p_{i,c} \log(\hat{p}_{i,c}). \quad (21)$$

训练完成后，通过选择每个像素 $i = 1, \dots, d$ 上概率最高的类别来获得最终的分割结果，即 $\operatorname{argmax}_c \hat{p}_{i,c}$ 。网络直接用于分割训练，从而避免了额外的分割步骤。对于两种学成的重构方法FC U-Net 和Post-Processing，我们向模型提供挑战等级作为附加输入，并为所有等级训练单一模型。它们在重构算子 $\mathcal{R}_\theta$ 的参数化方式上有所不同：其中FC U-Net 直接在测量值上作用神经网络，而Post-Processing 则定义了一个两步法 [20, 24]。

3.1.1. FC U-Net. FC U-Net 的设计紧密遵循了Chen等人 [6]的工作。该模型由两个部分组成：一个初始的学成变换，用于将测量值映射到像素网格，以及后续的分割，由卷积神经网络实现。

我们不再使用第2.3节中的线性重构方法，而是学习一个线性映射（表示为单个全连接线性层），该映射应用于测量值。然而，从维度为 $KL = 2356$ 的测量值学习到像素网格的线性映射，将需要超过150 M个参数，这在计算上是不可行的。为了减少参数数量，我们仅学习到 64×64 个像素网格的映射，并使用双线性插值将其扩展到 256×256 个像素网格。此初始变换的输出用作第二阶段的输入。令 $W \in \mathbb{R}^{64^2 \times KL}$ 表示初始线性层， $\mathcal{S} : \mathbb{R}^{64^2} \rightarrow \mathbb{R}^{256^2}$ 为双线性上采样算子。则FC U-Net 定义为

$$\mathcal{R}_\theta(\delta \mathbf{U}, k) := \tilde{\mathcal{R}}_\theta(\mathcal{S}(W\delta \mathbf{U}), k) \quad k = 1, \dots, 7, \quad (22)$$

其中 k 表示挑战等级， $\tilde{\mathcal{R}}_\theta$ 以注意力U-Net [9]的形式实现。该方法的总体框架如图3所示。对于更高挑战等级的缺失测量值 $\delta \mathbf{U}$ ，使用零进行填充。

为了学习线性映射 W （用于初始重构）以及分割的权重 θ ，我们提出了一种新颖的两阶段训练过程。在第一阶段，仅使用均方误差损失来训练初始线性层。

$$\min_W \sum_{k=1}^7 \sum_{i=1}^{n_k} \|\mathcal{S}(W\delta \mathbf{U}^{(k,i)}) - \delta \boldsymbol{\sigma}^{(k,i)}\|_2^2. \quad (23)$$




FIGURE 3. FC U-Net 网络。我们首先使用一个线性层将测量值映射到 64×64 像素网格，然后将其双线性插值到 256×256 网格。该网络通过分类交叉熵损失来输出类别概率。通过将概率最高的类别分配给每个像素，将类别概率转换为分割图。

此阶段的目标是为 W 提供一个良好的初始化。随后，使用 CCE 损失对完整模型进行训练，以实现分割。

$$\min_{\theta, W} \sum_{k=1}^7 \sum_{i=1}^{n_k} \mathcal{L}_{\text{CCE}}(\hat{p}^{(k,i)}, p^{(k,i)}), \quad (24)$$

其中 $\hat{p}^{(k,i)} = \text{Softmax}(\tilde{\mathcal{R}}_{\theta}(\mathcal{S}(W\delta\mathbf{U}^{(k,i)}), k))$ 。在对 θ 和 W 的联合优化中，我们为线性层 W 使用了比 θ 更小的学习率。

用于训练 FC U-Net 的数据集仅包含随机幻影和模拟测量数据。在评估组织方提供的四个挑战幻影时，我们注意到最终分割性能有所下降。为缓解这一泛化问题，我们增加了一个微调阶段，即在上述 4 个挑战幻影上，使用较小的学习率 1×10^{-6} 对 FC U-Net 进行 1000 次优化步骤的训练，同时针对 W 和 θ 进行训练。

3.1.2. Post-Processing. 学成后处理是深度学习应用于反问题的最早方法之一[2, 20]。在此方法中，一个初始重构（由经典重构方法计算得到）被用作卷积神经网络的输入。更准确地说，重构算子被参数化为 $\mathcal{R}_{\theta}(\delta\mathbf{U}) = \tilde{\mathcal{R}}_{\theta}(\mathbf{F}^{\dagger}(\delta\mathbf{U}))$ ，其中 $\mathbf{F}^{\dagger}(\delta\mathbf{U})$ 表示初始重构。

我们以三种方式改进了这一方法。首先，采用双线性插值步骤将网格值映射到图像，以便输入卷积神经网络。其次，使用五个线性化重构作为初始重构，参见第 2.3 节。最后，网络根据挑战等级进行条件化，如同 FC U-Net 所示，参见第 3.1.1 节。这些改进得到了如下公式：

$$\mathcal{R}_{\theta}(\delta\mathbf{U}, k) = \tilde{\mathcal{R}}_{\theta}(\widehat{\delta\sigma}, k), \quad k = 1, \dots, 7, \quad (25)$$

其中 $\widehat{\delta\sigma}$ 为五个插值的线性化重构结果， k 为挑战等级。Post-Processing 的总体情况如图 4 所示。该网络使用 CCE 损失函数 24 在所有挑战等级和训练样本上进行分割训练，预测类别概率由

$$\hat{p}^{(k,i)} = \text{Softmax}(\tilde{\mathcal{R}}_{\theta}(\widehat{\delta\sigma}^{(k,i)}, k)), \text{ for } k = 1, \dots, 7, \text{ and } i = 1, \dots, n_k. \quad (26)$$

3.2. 条件密度估计. 从反问题的统计视角出发，我们关注的是恢复后验分布 $p^{\text{post}}(\sigma|\mathbf{U})$ ，即给定边界测量值 $\mathbf{U}$ [28] 时电导率 σ 的条件分布。条件密度估计的目标是利用数据集 $\{(\sigma^{(i)}, \mathbf{U}^{(i)})\}, i = 1, \dots, n$ 与 $(\sigma^{(i)}, \mathbf{U}^{(i)}) \sim p(\sigma, \mathbf{U})$ ，通过一个条件概率模型 $p_{\theta}(\sigma|\mathbf{U})$ 来逼近真实的后验分布 $p(\sigma|\mathbf{U})$ 。在本工作中， $p_{\theta}(\sigma|\mathbf{U})$ 使用去噪扩散




FIGURE 4. Post-Processing 网络。五个线性化重构结果按照第 2.3 节所述插值到像素网格上。该网络通过分类交叉熵损失训练以输出类别概率。将类别概率转换为分割图，方法是将概率最高的类别进行分配。

概率模型 (DDPM) [15, 25] 进行建模，该模型在众多图像生成任务中已展现出良好的效果[9]。

3.2.1. 条件扩散模型. 条件扩散模型的变体被提出用于解决各种逆问题，包括超分辨率[23]、时间序列插补 [29] 和图像修复 [4]。具体而言，我们基于[4] 的思想进行构建。

我们采用扩散模型的离散时间公式 [15]。DDPMs 定义了一个前向扩散过程，该过程由一个马尔可夫链给出，该链在 $T = 1000$ 个时间步内逐渐向数据添加噪声。

$$\sigma_t = \sqrt{1 - \beta_t} \sigma_{t-1} + \sqrt{\beta_t} \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (27)$$

方差为 $\beta_1 \leq \dots \leq \beta_T$ 。方差的选择使得终端分布趋近于标准正态分布， $\sigma_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。给定无噪声样本 σ_0 ，时间 t 处的有噪声样本可直接获得为

$$\sigma_t = \sqrt{\bar{\alpha}_t} \sigma_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (28)$$

其中 $\bar{\alpha}_t = \prod_{i=1}^t (1 - \beta_i)$ 。DDPM 的目标是通过学习参数化的转移密度 $p_\theta(\sigma_{t-1} | \sigma_t)$ 来逆转这一扩散过程。训练 DDPM 等价于最小化所谓的 ϵ -匹配损失[15]。该框架可以通过在参数化的转移密度中引入观测值来扩展为条件密度估计，即 $p_\theta(\sigma_{t-1} | \sigma_t, \delta \mathbf{U})$ ，使用条件神经网络 $\epsilon_\theta(\sigma_t, \delta \mathbf{U}; t)$ 并最小化条件 ϵ -匹配损失。

$$\min_{\theta} \mathbb{E}_{t \sim U(\{1, \dots, T\})} \mathbb{E}_{(\sigma_0, \delta \mathbf{U}) \sim p(\sigma_0, \delta \mathbf{U})} \mathbb{E}_{\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\|\epsilon_\theta(\sigma_t, \delta \mathbf{U}; t) - \epsilon\|_2^2], \quad (29)$$

其中 σ_t 由公式 (28) 给出，对 $(\sigma_0, \delta \mathbf{U})$ 的期望通过模拟数据集进行估计。该网络结构概览如图 5 所示，其输入包含线性化重构插值至像素网格的结果、含噪图像 σ_t 以及时间步 t 的拼接。

在[15] 中，作者利用原始采样从学成分布中生成样本。然而，这需要对所有 T 个时间步长进行反向过程的模拟，导致采样方法计算开销较大。为了提高采样速度，我们采用 DDIM 框架中提出的加速采样法[27]。设 τ 为 $\{1, \dots, T\}$ 的长度为 S 的子序列，且满足 $\tau_1 = 1$ 和 $\tau_S = T$ 。以 $\sigma_{\tau_S} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为起点的 DDIM 采样由下式给出

$$\sigma_{\tau_{s-1}} = \sqrt{\bar{\alpha}_{\tau_{s-1}}} \hat{\sigma}_0(\sigma_{\tau_s}, \delta \mathbf{U}) + \sqrt{1 - \bar{\alpha}_{\tau_{s-1}} - \gamma_{\tau_s}^2} \epsilon_\theta(\sigma_{\tau_s}, \delta \mathbf{U}, \tau_s) + \gamma_{\tau_s} \epsilon, \quad (30)$$




FIGURE 5. Conditional-Diffusion 网络。五个线性化重构结果按照第 2.3 节所述插值到像素网格上。将含噪图像和线性化重构结果输入网络，利用 ϵ -匹配损失函数，训练网络以估计噪声。通过采样网络获得分割图，通过对像素级进行绝对多数投票，得到最终的分割图。

其中 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和 $\hat{\sigma}_0(\sigma_{\tau_s}, \delta\mathbf{U})$ 作为Tweedie 估计[11], 定义为

$$\mathbb{E}[\sigma_0 | \sigma_t, \delta\mathbf{U}] \approx \hat{\sigma}_0(\sigma_t, \delta\mathbf{U}) = \frac{1}{\sqrt{\bar{\alpha}_t}} (\sigma_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(\sigma_t, \delta\mathbf{U}; t)). \quad (31)$$

随机性参数 γ_t 在公式 (30) 中被选为

$$\gamma_{\tau_s} = \eta \sqrt{(1 - \bar{\alpha}_{\tau_{s-1}})/(1 - \bar{\alpha}_{\tau_s})} \sqrt{1 - \bar{\alpha}_{\tau_s}/\bar{\alpha}_{\tau_{s-1}}}, \quad (32)$$

带有可调超参数 η , 参见[27]。

在我们的实现中，我们并未直接将 $\delta\mathbf{U}$ 输入到epsilon 模型 ϵ_θ ，而是利用了第 2.3 节引入的初始重构。因此，我们的模型形式为 $\epsilon_\theta(\sigma_t, \widehat{\delta\sigma}, t)$ ，其中 $\widehat{\delta\sigma}$ 表示公式 (16) 中的五个插值线性化重构的集合。通过这种方式，我们并非对真实的后验分布 $p^{\text{post}}(\sigma | \delta\mathbf{U})$ 进行近似，而是对一个条件分布 $p(\sigma | \widehat{\delta\sigma})$ 进行建模。

由于目标是生成分割结果而非重构，我们不使用电导率值表示 σ ，而是将其表示为取值范围在 $[0, 2]$ 的图像。随后通过将重构结果 σ 四舍五入到最近的 $\{0, 1, 2\}$ 整数来获得分割结果，其中0 表示背景类别，1 表示电阻性包含物类别，2 表示导电性包含物类别。对于最终的分割结果，我们使用DDIM 公式 (30) 生成 J 个样本 $\sigma^{(j)}$ ，并进行像素级绝对多数投票，即

$$\hat{\sigma}_i = \underset{c=0,1,2}{\operatorname{argmax}} \# \{ \sigma_i^{(j)} | \sigma_i^{(j)} = c, j = 1, \dots, J \}, \quad (33)$$

对于所有像素 $i = 1, \dots, d$ ，其中 $\#$ 表示该集合的基数。

4. 实际考虑. 在本节中，我们讨论提交方案的实际考虑因素。首先，我们介绍训练数据的生成；其次，详细说明线性化重构的计算过程；最后，讨论神经网络结构的相关方面。




FIGURE 6. 上图：手绘训练幻影。下图：随机生成的训练幻影。
在可视化中，我们仅展示了圆形水箱。然而请注意，所有模型均使用方阵 256×256 像素图像进行训练。

4.1. 数据集. 我们提交工作的一个重要方面是创建一个适用于训练不同深度学习方法的仿真数据集。我们首先在 256×256 像素网格上生成由非重叠多边形、圆形、矩形以及手绘物体组成的随机分割图。图 6 展示了部分模拟体模示例，其中仅展示了圆形水箱。每个物体被指定为电阻性或导电性。物体外部及水箱外部区域被赋予背景类。基于此分割图，我们对物体的电导率进行仿真。电阻性物体的电导率在 $[0.025 \text{ Ohm}^{-1}, 0.125 \text{ Ohm}^{-1}]$ 范围内随机选取，导电性物体的电导率在 $[5.0 \text{ Ohm}^{-1}, 6.0 \text{ Ohm}^{-1}]$ 范围内随机选取。背景区域被赋予恒定的电导率值 0.745 Ohm^{-1} ，该值通过空水箱的参考测量数据采用最小二乘拟合 [30] 计算得到。下一步，将生成的体模从像素网格插值到分段常数有限元表示。利用第 2.1 节中规定的前向算子模拟测量数据。根据空水箱的参考测量数据，添加均值为零、协方差为 $\Sigma = \text{diag}(0.05 \text{ U}_{\text{ref}} + 0.01 \max(\text{U}_{\text{ref}}))$ 的高斯噪声。在测量仿真过程中，所有 32 个电极均采用固定的接触阻抗 $z = 1 \times 10^{-6} \text{ Ohm}$ 。⁴ 每级使用的训练样本数量如表 1 所示。总共我们进行了超过 100 K 组数据对的仿真。第 6 级训练样本较少是由于仿真过程中出现的技术问题。

TABLE 1. 每层级使用的训练样本数量。

Level	1	2	3	4	5	6	7
Training samples	16527	16619	16591	16587	16604	12102	16298

4.2. 初始重构. 第 3.1.2 节中的 Post-Processing 方法和第 3.2.1 节中的 Conditional-Diffusion 方法均需要一个初始重构作为输入。我们尝试了不同的经典重构方法。与第 2.3 节中线性的方法相比，迭代重构方法（如 L1-正则化 [13] 或高斯-牛顿法 [5]）得到了更高品质的重构结果。然而，由于该初始重构需针对训练集中的每一个样本进行计算，即在我们使用的数据集中超过 100 K 个样本，计算成本成为了一项约束。因此，我们决定不采用计算成本更高的迭代方法，而是选择了更快速的线性化重构方法。即便如此，对于线性化重构，测量的仿真以及初始重构的计算仍花费了大约一周时间。

组织方提供了 CEM 的有限元实现。我们决定使用自己的实现，以便更方便地更改离散函数空间并使用不同的网格。我们网格与所提供网格的对比见图 7。所提供的网格在域的中心和顶部存在一些微小的不规则性，这导致正向解和初始重构结果

⁴我们还尝试使用最小二乘拟合来识别接触阻抗，但未获得理想结果。

存在差异。相反，我们采用了一个网格大小为0.005的均匀网格，该网格由Gmsh软件[14]生成。此外，我们将边界单元设置为覆盖电极。




FIGURE 7. 左图：主办方提供的网格。右图：我们为前向算子定制的网络。

4.3. 神经网络结构. 为此，将标量值（层级/时间步）嵌入架构中，根据标量值重新加权残差块，更有效地影响模型的输出。

我们使用了由[9]提出的最小适应性引导扩散模型。该架构包含一个带有注意力块和时间嵌入的U-Net [22]。时间嵌入被调整以适用于Post-Processing 和FC U-Net，使网络能够融入层级信息，即在训练过程中可以使用所有层级的训练数据。时间或层级信息通过自适应组归一化层 [9] 引入网络。U-Net 中的每个组归一化层 [33] 均被替换为

$$\text{AdaGroupNorm}(h, z) = z_s \text{GroupNorm}(h) + z_t, \quad (34)$$

其中 h 为中间特征， $z = (z_s, z_t)$ 为以时间或层级信息作为输入的神经网络的输出。在我们选择的超参数下，例如层数、通道数等，可训练参数的总数为31 M。

不同方法中U-Net的输入和输出通道数有所不同。Post-Processing 和Conditional-Diffusion 有五个输入通道，对应于五个插值后的线性重构结果 $\widehat{\delta\sigma}$ ，而FC U-Net 的输入通道为单个，对应于插值后的学成重构结果 $\mathcal{S}(W\delta\mathbf{U})$ 。对于学成重构器，使用了CCE损失，该损失需要三个类别概率，因此使用了三个输出通道。对于Conditional-Diffusion，使用了 ϵ -匹配损失，需要单个输出通道。由于输入/输出通道数的不同，每个U-Net主干网络的参数数量并不相等，尽管差异可以忽略不计。对于FC U-Net，线性层 W 需要10M个参数；与其它方法相比，这显著增加了可学习参数的数量。

5. 结果与讨论. 在本节中，我们展示了三种方法的最终挑战结果。定量得分是通过结构相似性指数度量（SSIM）[32]在导电和电阻性包含物的二值化图像上分别计算得出的。该得分被平均以得到每个样本的得分。将每个样本的得分在某一等级的所有样本上求和，得到该等级的得分，再对所有等级的得分求和，得到方法的总体得分。⁵ 每个挑战等级下，评估了三种不同的幻影（A、B、C）。视觉结果如图 8、图 9 和图 10 所示。在大多数重构结果中，物体的数量、位置和大致形状均被正确识别。例外情况是当一个小型导电物体位于水箱中央并被其他物体包围时，例如图 8 中的7 等级或图 9 中的7 等级。此外，水箱左上侧物体的重构效果通常较差，因为较高等级时该区域的边界测量数据被移除。例如图 9 中的7 等级，水箱顶部矩形的形状无法恢复。

定量结果如表 2 所示。除了我们的提交结果外，我们还展示了排名第二和第三的团队的结果。在KTC2023中，最终得分为15.24 的Post-Processing 方法表现最

⁵每级评估三个幻影，最高得分为21。

TABLE 2. 通过结构相似性指数度量 (SSIM) 对我们的三个提交结果进行定量比较。这些是官方挑战赛的结果，四舍五入到小数点后两位。第二名由巴西联邦大学的Team ABC团队获得。第三名由丹麦技术大学的Team DTU团队获得。对于给定样本，SSIM在导电包含物和电阻包含物之间取平均值。在每个层级上，SSIM在三个样本上求和，而某种方法的总体总和则在所有样本和层级上求和。

Level	1	2	3	4	5	6	7	Sum
FC U-Net	2.72	2.64	2.31	1.80	2.06	2.07	1.53	15.13
Post-Processing	2.76	2.56	2.54	1.71	2.06	1.92	1.69	15.24
Conditional-Diffusion	2.67	2.49	2.47	1.61	1.94	1.76	1.65	14.60
Team ABC	2.75	2.37	2.07	1.74	1.08	1.53	1.22	12.75
Team DTU	2.28	2.3	1.87	1.55	1.34	1.44	1.60	12.45

佳。然而，在2, 4, 5 和6 水平上，FC U-Net 方法的表现优于该方法。第二名得分为12.75，由ABC 联邦大学的一个团队获得；第三名得分为12.45，由DTU 的一个团队获得。在4 水平上，第二名甚至取得了高于Post-Processing 的得分。我们的FC U-Net 方法（得分为15.13）以及我们的Conditional-Diffusion 方法（得分为14.60）均能赢得本次挑战。

Post-Processing 和FC U-Net 的表现相似，而Conditional-Diffusion 的性能则较差。对于Conditional-Diffusion 方法，每个挑战级别均训练了一个独立的神经网络。因此，每个级别的网络仅使用了所有可用幻影和模拟测量数据的一个子集进行训练。相比之下，Post-Processing 和FC U-Net 方法则利用了所有级别中的训练样本。学成的重建方法采用了针对分割任务的CCE 损失，而Conditional-Diffusion 使用了 ϵ 匹配，这是DDPM 所必需的。与使用单个样本不同，Conditional-Diffusion 从条件分布中抽取了 J 个样本，并通过绝对多数投票确定分割结果，这可以进一步扩展以获得不确定性表示。

Post-Processing 和Conditional-Diffusion 方法均以一组五个线性化重构结果作为输入。通过使用具有不同正则化强度的重构集合，我们试图获得更稳健的分割结果，因为最佳正则化强度是未知的。在类似的意义上，FC U-Net 也可以学习一组重构结果，但这将导致可学习参数数量显著增加。

6. 结论. KTC2023 挑战为评估从EIT测量中重构分割图的最先进方法提供了机会。我们的获奖提交采用了深度学习，包括两种学成重构方法（FC U-Net 和Post-Processing），以及一种Conditional-Diffusion 生成方法。网络结构和数据集的选择对于深度学习方法至关重要；需要结合对问题的理解并具备实用性。在本研究中，所有提交均使用相同的训练数据集和骨干网络结构，从而实现了不同方法之间的比较。FC U-Net 和Post-Processing 提供了相似的结果，而Conditional-Diffusion 的表现较差。学成重构器在所有层级上进行了训练（利用层级条件化），而各个Conditional-Diffusion 网络则针对每个层级单独训练，这实际上减少了训练数据集的大小。FC U-Net 需要在提供的真实测量值和幻影上进行额外的微调阶段，而Post-Processing 网络仅使用模拟测量值和幻影，无需此步骤。Post-Processing 和Conditional-Diffusion 方法以五组Tikhonov正则化的初始重构图像作为输入，而FC U-Net 方法则使用线性层将测量值映射到单张图像。在三种提交的方法中，Post-Processing 方法表现最佳。这表明，基于高质量模拟数据集训练的后处理方法比完全学成的方法更容易泛化到真实数据。仍需进一步工作来全面评估不同数据驱动方法的泛化能力。




FIGURE 8. 三种方法对等级为1 的样本A 进行分割至7。

致谢. Alexander Denker 感谢德国研究基金会 (DFG) 在GRK 2224/1 “ π^3 : 参数识别——分析、算法、应用” 框架内的支持。Tom Freudenberg 感谢DFG 资助项目编号281474342/GRK2224/2。Imraj Singh 受到EPSRC 资助的伦敦大学学院博士培训中心智能集成医学成像 (i4health) (EP/S021930/1) 以及英国卫生部资助的伦敦大学学院医院生物医学研究中心的支持。Željko Kereta 受到英国EPSRC 基金EP/X010740/1 的支持。Simon Arridge 受到英国EPSRC 基金EP/V026259/1 的支持。Peter Maass 受到BMBF 项目“#MOIN - MuKIDERM” 的支持。T. Kluth 感谢德国联邦教育与研究部 (Bundesministerium für Bildung und Forschung, BMBF, 项目编号05M22LBA) 资助的KIWi 项目的支持。




FIGURE 9. 三种方法对级别1 的样本B 进行分割至7 。




FIGURE 10. 三种方法对 C 级别为1 到7 的样本的分割。

REFERENCES

- [1] C. Arndt, A. Denker, S. Dittmer, J. Leuschner, J. Nickel, M. Schmidt, Model-based deep learning approaches to the Helsinki Tomography Challenge 2022, *Applied Mathematics for Modern Challenges* **1.2** (2023): 87–104.
- [2] S. Arridge, P. Maass, O. Öktem, and C. Schönlieb, Solving inverse problems using data-driven models, *Acta Numerica*, **28** (2019): 1–174.
- [3] I. Baratta, J. Dean, J. Dokken, M. Habera, J. Hale, C. Richardson, M. Rognes, M. Scroggs, N. Sime, G. Wells, DOLFINx: the next generation FEniCS problem solving environment, *preprint*, 10.5281/zenodo.10447666 (2023).
- [4] G. Batzolis, J. Stanczuk, C. B. Schönlieb, C. Etmann, Conditional Image Generation with Score-Based Diffusion Models, *arXiv preprint arXiv:2111.13606* (2021).
- [5] A. Borsic, B.M. Graham, A. Adler, W. Lionheart, In vivo impedance imaging with total variation regularization, *IEEE transactions on medical imaging* **29.1** (2009): 44–54.
- [6] Z. Chen, Y. Yang, J. Jia, P. Bagnaninchi, Deep learning based cell imaging with electrical impedance tomography, *2020 IEEE international instrumentation and measurement technology conference (I2MTC)*, (2020): 1–6.
- [7] M. Cheney, D. Isaacson, J.C. Newell, S. Simske, J. Goble, NOSER: An algorithm for solving the inverse conductivity problem, *International Journal of Imaging systems and technology* **2.2** (1990):66–75.
- [8] H. Chung, B. Sim, and J. Ye, Come-closer-diffuse-faster: Accelerating conditional diffusion models for inverse problems through stochastic contraction, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, (2022): 12413–12422.
- [9] P. Dhariwal, A. Nichol, Diffusion models beat gans on image synthesis, *Advances in neural information processing systems* **34** (2021): 8780–8794.
- [10] D.C. Dobson, F. Santosa, An image-enhancement technique for electrical impedance tomography, *Inverse Problems* **10.2** (1994): 317.
- [11] B. Efron, Tweedie’s formula and selection bias, *Journal of the American Statistical Association* 106.496 (2011): 1602–1614.
- [12] R. Fletcher, A modified Marquardt subroutine for non-linear least squares, *Theoretical Physics Division, Atomic Energy Research Establishment Harwell* (1971).
- [13] M. Gehre, T. Kluth, A. Lipponen, B. Jin, A. Seppänen, J. Kaipio and P. Maass, Sparsity reconstruction in electrical impedance tomography: An experimental evaluation, *Journal of Computational and Applied Mathematics* 236 **8** (1012): 2126–2136.
- [14] C. Geuzaine and J. Remacle, Gmsh: A 3-D Finite Element Mesh Generator with Built-in Pre- and Post-Processing Facilities, *Int. J. Numer. Methods. Eng.*, **79** (2009).
- [15] J. Ho, A. Jain, P. Abbeel, Denoising diffusion probabilistic models, *Advances in neural information processing systems* **33** (2020): 6840–6851.
- [16] N. Hyvönen, Complete electrode model of electrical impedance tomography: Approximation properties and characterization of inclusions, *SIAM Journal on Applied Mathematics* **64.3** (2004): 902–931.
- [17] J. Kaipio, V. Kolehmainen, E. Somersalo, M. Vauhkonen, Statistical inversion and Monte Carlo sampling methods in electrical impedance tomography, *Inverse Problems* **16.5** (2000): 1487.
- [18] Electrical resistance tomography imaging of concrete, K. Karhunen, A. Seppänen, A. Lehtikoinen, P. Monteiro, J. Kaipio, *Cement and concrete research* **40.1** (2010): 137–145.
- [19] S. Martin, C.T. Choi, A post-processing method for three-dimensional electrical impedance tomography, *Scientific reports* **7.1** (2017): 7212.
- [20] G. Ongie, A. Jalal, C. Metzler, R. Baraniuk, A. Dimakis, R. Willett, Deep learning techniques for inverse problems in imaging, *IEEE Journal on Selected Areas in Information Theory* **1.1** (2020): 39–56.
- [21] M. Räsänen, P. Kuusela, J. Jauhiainen, M. Arif, K. Scheel, T. Savolainen, A. Seppänen, Kuopio Tomography Challenge 2023 (KTC2023), (2023).
- [22] O. Ronneberger, P. Fischer, T. Brox, U-net: Convolutional networks for biomedical image segmentation, *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015* (2015): 234–241.
- [23] C. Saharia, J. Ho, W. Chan, T. Salimans, D.J. Fleet, M. Norouzi, Image super-resolution via iterative refinement, *IEEE Transactions on Pattern Analysis and Machine Intelligence* **45.4** (2022): 4713–4726.

- [24] J. Schwab, S. Antholzer, M. Haltmeier, Deep null space learning for inverse problems: convergence analysis and rates, *Inverse Problems* **35.2** (2019): 025008.
- [25] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli, Deep unsupervised learning using nonequilibrium thermodynamics, *International conference on machine learning (PMLR)* (2015): 2256–2265.
- [26] E. Somersalo, M. Cheney, and D. Isaacson, Existence and uniqueness for electrode models for electric current computed tomography, *SIAM Journal on Applied Mathematics*, **52.4** (1992): 1023–1040.
- [27] J. Song, C. Meng, S. Ermon, Denoising Diffusion Implicit Models, *International Conference on Learning Representations* (2020).
- [28] A. Stuart, Inverse problems: a Bayesian perspective, *Acta numerica* **19** (2010): 451–559.
- [29] Y. Tashiro, J. Song, Y. Song, S. Ermon, CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation, *Advances in Neural Information Processing Systems* **34** (2021): 24804–24816.
- [30] T. Vilhunen, J.P. Kaipio, P.J. Vauhkonen, T. Savolainen, M. Vauhkonen, Simultaneous reconstruction of electrode contact impedances and internal electrical properties: I. Theory, *Measurement Science and Technology* **13.12** (2002): 1848.
- [31] H. Wang, G. Xu, and Q. Zhou, A comparative study of variational autoencoders, normalizing flows, and score-based diffusion models for electrical impedance tomography, *Journal of Inverse and Ill-posed Problems*, **0** (2024).
- [32] Z. Wang, A. Bovik, H. Sheikh, E. Simoncelli, Image quality assessment: from error visibility to structural similarity, *IEEE transactions on image processing* **13.4** (2004): 600–612.
- [33] Y. Wu, K. He, Group normalization, *Proceedings of the European conference on computer vision (ECCV)* (2018).

收到日期: xxxx年xx月xx日; 修改日期: xxxx年xx月xx日; 提前访问日期: xxxx年xx月xx日。