



基于部分边界数据的电阻抗断层成像图像分割的数据驱动方法

亚历山大·登克*¹, 泽利科·克雷达², 伊姆拉杰·辛格², 汤姆·弗罗伊登贝格¹,
托比亚斯·克卢特¹, 彼得·马阿斯¹, 西蒙·阿里奇²

¹ 不来梅大学工业数学中心 ² 伦敦大学学院计算机科学系

(由青仟编辑传译)

摘要. 电阻抗断层成像 (EIT) 在无创成像中发挥着关键作用, 兼具医疗和工业应用。本文提出了三种用于 EIT 成像的数据驱动重建方法。这三种方法最初是为 2023 年库奥皮奥断层成像挑战赛 (KTC2023) 提交的。首先, 我们介绍一种后处理方法, 该方法在 KTC2023 中获得了第一名。此外, 我们还提出了一种全学习方法和一种条件扩散方法。这三种方法均以类似的神经网络为基础架构, 并使用合成生成的数据集进行训练, 为这些不同的数据驱动重建方法提供了公平比较的机会。

1. 引言. 电阻抗层析成像 (EIT) 是一种成像方式, 它使用在物体边界上进行的电测量来恢复其内部的电特性。在本文中, 我们考虑电导率的重建, 通过连接到物体表面的电极施加一系列电流。电极测量产生的电压, 用于产生电导率的图像。EIT 有许多应用, 例如在医学诊断 [5] 或无损检测 [18] 中。

关于电阻抗断层成像 (EIT) 测量过程的物理原理, 存在多种数学模型。设 Ω 为求解域, $\partial\Omega$ 为其边界, $\cup_{l=1}^L \Gamma_l \subset \partial\Omega$ 为附着在边界上的 $L \in \mathbb{N}$ 电极集合。电势 $u \in H_1(\Omega)$ 由麦克斯韦方程组推导得出, 并受以下方程控制:

$$-\nabla \cdot (\sigma \nabla u) = 0 \text{ in } \Omega, \quad (1a)$$

其中, $\sigma \in L^\infty(\Omega)$ (Ω) 为电导率分布。完整电极模型 (CEM) [26] 描述了向电极施加电流时边界条件的实际表述。首先, 边界被分解为两个部分: 电极 Γ_l (与其所附着的边界部分相对应) 以及电极之间的剩余空间 $\partial\Omega \cup \cup_{l=1}^L \Gamma_l$ 。其次, 电极与其所对应的边界部分之间的导电情况

2020 年数学学科分类 主类· 65M32 68T07· 次类· 92C55

关键词和短语. 反问题, 深度学习, 电阻抗断层成像。

* 通讯作者: 亚历山大·登克。

已被考虑在内。对于给定的电流注入模式 $I \in \mathbb{R}^L$, 所得模型可写为

$$\begin{aligned} u + z_l \sigma \frac{\partial u}{\partial \nu} &= U_l, & e_l & & l = 1, \dots, L, \\ \sigma \frac{\partial u}{\partial \nu} &= 0, & \partial \Omega \setminus \bigcup_{l=1}^L e_l & & , \\ \int_{e_l} \sigma \frac{\partial u}{\partial \nu} ds &= I_l, & e_l & & l = 1, \dots, L, \end{aligned}$$

其中 $z \in \mathbb{R}^L$ 是接触阻抗, 用于量化电极与边界接触点处形成的电阻层的影响, 而 $U \in \mathbb{R}^L$ 是电极处的电压。CEM 包括电荷守恒和电势的平均自由电流约束, 即

$$\sum_{l=1}^L I_l = 0 \text{ and } \sum_{l=1}^L U_l = 0, (1c)$$

。我们将电压记为 $U = (U_1, \dots, U_L)^\top$, 将电流模式记为 $I = (I_1, \dots, I_L)^\top$ 。方程 (1a) 至 (1b) 描述了单一的电流注入模式。在实际应用中, 会采用多种注入模式, 并获得相应的电极测量结果。我们将第 k 种注入模式下的电压和电荷记为 $U^{(k)}$ 和 $I^{(k)}$, 其中 $k = 1, \dots, K$ 。通过 $U = (U^{(1)}, \dots, U^{(K)})$ 和 $I = (I^{(1)}, \dots, I^{(K)})$, 我们表示所有电极和所有电流模式下的 $\mathbb{R}^{KL}$ 电压和电荷的堆叠向量。进一步设 $F(\sigma) = (F^{(1)}(\sigma), \dots, F^{(K)}(\sigma))^\top$ 为应用于电导率 σ 的相应正向算子, 适用于所有电极和电流模式。所得的非线性逆问题可写为

$$F(\sigma)I = U. \quad \text{eqno(2)}$$

其中目标是在给定电极测量值 U 的情况下重建 σ 。

1.1. KTC 2023 挑战赛。我们概述了提交给 2023 年库奥皮奥断层成像挑战赛 (KTC2023) [21] 的三种方法。KTC2023 的目标是通过部分边界测量重建电阻性和导电性内含物的分割图。测量是在一个塑料圆形水箱上进行的, 水箱边界上安装了 32 个等间距的不锈钢电极。所有 32 个电极都用于收集测量数据, 其中 16 个电极 (奇数编号的) 用于电流注入模式。对于每种电流注入模式, 在相邻电极之间测量电压, 每个注入模式可得到 31 个测量值。研究中考虑了五种注入模式。测量水箱、电极和注入模式的示意图见图 1.1。

该挑战被分为 7 个难度等级, 其中第一级包含来自所有 32 个电极的数据。在后续等级中, 电极对被依次移除。因此, 每个等级的测量次数和应用的电流注入模式数量都会减少。每个等级依次多移除两个电极, 即第 2 级移除电极 1、2, 而在最终的第 7 级, 电极 1 至 12 被移除。这意味着, 左上角边界的所有测量数据都被移除, 参见图 1.1。这使得对于更高等级而言, conductivity 图和分割图的重建问题变得越来越不适应。

1.2. 我们的贡献。我们提出了三种数据驱动的重建方法, 以解决从部分电阻断层成像测量中重建分割图的问题。

- FC U-Net: 一种完全可学习的方法, 可直接从测量结果进行重建, 详见第 3.1.1 节。




图 1. EIT 测量槽 (Ω)、电极 e_i 以及注射模式样本的示意图。黑色部分为相邻注射；绿色部分为所有针对 e_1 的注射；粉色部分为所有针对 e_n 的注射；品红色部分为所有针对 e_{17} 的注射；橙色部分为所有针对 e_{25} 的注射。虚线注射在 2^{nd} 挑战级别中被移除；点线注射在 4^{th} 挑战级别中被移除；点划线注射在 6^{th} 挑战级别中被移除。

· 后处理：一种基于初始重建方法进行重建的方法，详见第 3.1.2 节。

- 条件扩散 (Conditional-Diffusion)：一种条件扩散方法，旨在直接对给定初始重建结果的后验进行建模。详见 3.2.1 节。

FC U-Net 和后处理都是基于学习的重建方法，而条件扩散则是一种基于条件生成建模的方法。这三种提出的方法在 KTC2023 中获得了最高的三个分数，其中后处理的整体表现最佳。此外，这三种方法都采用了类似的 U-Net 架构，参数数量相当，并且都是使用生成的体模数据集和模拟测量数据进行训练的。

1.3. 相关工作。深度学习后处理和完全学习重建是医学图像重建中两种著名的数据驱动方法 [2]。这两种框架都已应用于电阻抗断层成像 (EIT) 图像重建。我们的 FC U-Net 遵循 Chen 等人提出的模型 [6]。然而，在 3.1.1 节中，我们为这种完全学习模型提出了一种新颖的两步训练方法。后处理方法已应用于 EIT，例如 Martin 等人的研究 [19]。我们扩展了这一后处理框架，以应对 KTC2023 中不同程度的问题，这些问题对应着严重程度递增的部分 EIT 测量。据我们所知，我们的提交是条件扩散模型在真实世界 EIT 数据中的首次应用。最近，Wang 等人 [31] 提出使用无条件扩散模型，并利用 Chung 等人 [8] 提出的采样框架来实现条件采样。然而，他们仅在具有两个或四个圆形内含物的模拟数据上评估了他们的方法，而我们则在复杂物体的真实测量数据上评估了我们的方法。

线性化重建。EIT 重建涉及从一组电极测量值 U 中恢复电导率 σ 。一种常用技术是围绕均匀背景电导率 σ_{ref} 对非线性前向算子 F 进行线性化，并重建对此的扰动 $\delta\sigma$ 。

背景 [7,10,17]。线性化前向算子给定为

$$\tilde{F}(\sigma_{\text{ref}} + \delta\sigma; \sigma_{\text{ref}})I := F(\sigma_{\text{ref}})I + I_{\text{ref}} \delta\sigma \quad (3)$$

, 其中 $I_{\text{ref}} := \nabla F(\sigma_{\text{ref}})$ 是在背景电导率下评估的雅可比矩阵。我们进一步假设可以获得空水箱的测量值 II_{ref} , 因此 $F(\sigma_{\text{ref}})I = II_{\text{ref}}$ 。然后我们将测量扰动定义为 $\delta II := II - II_{\text{ref}}$ 。相应的线性化问题是从

$$I_{\text{ref}} \delta\sigma = \delta II \quad (4)$$

确定 $\delta\sigma$ 。

扰动 $\delta\sigma \in \mathbb{R}^M$ 通过分段常数有限元展开的 M 个系数进行离散化。雅可比矩阵和前向算子的有限元近似将在 2.1 节和 2.2 节中进行说明。

为求解方程 (4), 我们采用变分正则化框架, 即

$$\hat{\delta\sigma} := \operatorname{argmin}_{\frac{1}{2}} J_{\sigma_{\text{ref}}} \delta\sigma - \delta U \frac{2}{\gamma-1} + \alpha \mathcal{J}(\delta\sigma),$$

其中我们假设存在高斯噪声模型 $\delta II \sim \mathcal{N}(0, \Sigma)$, 且 $\frac{2}{\gamma-1} M \times M$ 为正则化项。我们考虑形式为 $\mathcal{J}(\delta\sigma) = \frac{1}{2} \|\mathcal{J} \delta\sigma\|^2$ 的吉洪诺夫型正则化项。对于这种正则化项的选择, 我们可以将方程 (5) 的解恢复为

$$\hat{\delta\sigma} = (J_{\sigma_{\text{ref}}}^\top \Sigma^{-1} J_{\sigma_{\text{ref}}} + L^\top L)^{-1} J_{\sigma_{\text{ref}}}^\top \Sigma^{-1} \delta U. \quad (6)$$

矩阵 $((J_{\sigma_{\text{ref}}}^\top \Sigma^{-1} J_{\sigma_{\text{ref}}} + L^\top L)^{-1})$ 可离线计算, 这带来了一种计算成本较低的重建方法, 该方法对于训练后处理网络和条件扩散网络是必要的。在接下来的章节中, 我们将讨论前向算子的实现、雅可比矩阵 $(J_{\sigma_{\text{ref}}})$ 的计算以及正则化项 $\mathcal{J}$ 的选择。

2.1. 正向算子。定义 CEM 的 EIT 正向算子 F 是非线性的。要针对给定的电导率 σ 计算 F , 需要求解 (1b) 中的微分方程。我们通过对 CEM 的弱形式应用有限元方法来近似求解, 例如参见 [16]。为了纳入电荷守恒, 我们引入了拉格朗日乘数 $\lambda \in \mathbb{R}$ 。CEM 的弱形式如下: 找到 $((u, U, \lambda) \in H^1(\Omega) \times \mathbb{R}^L \times \mathbb{R})$, 使得

$$\int_{\Omega} \sigma \nabla u \cdot \nabla v dx + \sum_{l=1}^L \frac{1}{\gamma_l} \int_{\Omega_l} (u - U_l)(v - V_l) ds + \sum_{l=1}^L (\lambda V_l + \nu U_l) = \sum_{l=1}^L I_l V_l, \quad (7)$$

对于所有 $((v, V, \nu) \in H^1(\Omega) \times \mathbb{R}^L \times \mathbb{R})$, 其中 $V = (V_1, \dots, V_L)^\top$ 和 $U = (U_1, \dots, U_L)^\top$ 。

为了对正向模型进行数值逼近, 我们使用伽辽金逼近求解 CEM, 例如参见 [17]。下面我们给出一个简短的总结。我们使用分段线性基函数 $\phi_i, i=1, \dots, N$ 来表示电势 u , 这些基函数张成 $H^1(\Omega)$

(Ω) 的一个有限维子空间 V_N 。电导率 σ 使用分段常数基元 $\psi_i, i=1, \dots, M$ 来表示, 其中每个 ψ_i 都是网格中恰好一个单纯形的指示函数。为简化符号, 我们将 u 和 σ 与其各自基展开式中的系数等同起来。也就是说, $u \approx \sum_{i=1}^N u_i \phi_i \cong (u_1, \dots, u_N)^\top$, 对于

$\sigma \approx \sum_{i=1}^M \sigma_i \psi_i \cong (\sigma_1, \dots, \sigma_M)^\top$ 也是类似的情况

将上述伽辽金近似应用于式 (7), 得到线性方程组

$$\begin{pmatrix} A(\sigma) + B & C & 0 \\ C^\top & D & 1 \\ 0^\top & 1^\top & 0 \end{pmatrix} \begin{pmatrix} u \\ U \\ \lambda \end{pmatrix} = \begin{pmatrix} 0 \\ I \\ 0 \end{pmatrix}, \quad (8)$$

with block matrices

$$A_{ii} = \int_{\Omega} \sigma \nabla \phi_i \cdot \nabla \phi_i dx \text{ for } i = 1, \dots, N$$

$$B_{ii} = \sum_{l=1}^L \frac{1}{z_l} \int_{\Gamma_l} \phi_i \phi_i ds \text{ for } i = 1, \dots, N$$

$$C_{ii} = \sum_{l=1}^L \int_{\Gamma_l} \phi_i ds \text{ for } i = 1, \dots, N \text{ and } i = 1, \dots, L$$

$$D_{ii} = \sum_{l=1}^L \int_{\Gamma_l} 1 ds \text{ for } i = 1, \dots, L$$

其中 $U = (U_1, \dots, U_L)^\top \in \mathbb{R}^L$

线性系统 (8) 有两个特性可用于减少计算量。首先, 对于固定的电导率 σ , 计算电磁学 (CEM) 相对于注入模式是线性的。这使得我们能够重用求解方程 (8) 过程中的中间步骤, 例如, 系统矩阵的 LU 分解, 该分解用于计算所考虑的所有电流模式 $l(k)$ 的数值解 (u, U) 。其次, 只有块矩阵 $A(\sigma)$ 依赖于 σ , 需要重新计算。所有其他块矩阵都可以离线计算。

由此得到的离散前向算子通过有限元软件 FEniCSx 实现 [3], 且可在线获取 1。

2.2. 雅可比矩阵。我们使用电势和电导率的离散函数空间计算雅可比矩阵 J_{ref} 。文献 [10, 17] 中展示了使用像素网格或伴随微分的替代计算策略

给定 K 种注入模式和 L 个电极, 雅可比矩阵 J_{ref} 是一个 $L \times K \times M$ 张量。不过, 将雅可比矩阵视为 $L \times K \times M$ 张量可能更直观。利用 [13, 附录], 雅可比矩阵可以表示为

$$(J_{ref})_{k,j,i} = W_{k,j,i} \text{ for } k = 1, \dots, K, i = 1, \dots, M. \quad (9)$$

其中 $(w_{k,j,i}, W_{k,j,i}) \in V_N \times \mathbb{R}^L$ 是以下方程的解

$$\int_{\Omega} \sigma_{ref} \nabla w_{k,j} \cdot \nabla \phi_i dx + \sum_{l=1}^L \frac{1}{z_l} \int_{\Gamma_l} (w_{k,j} - (W_{k,j})_l) (\phi_i - V_l) ds = - \int_{\Omega} \chi_j \nabla u^k \cdot \nabla \phi_i dx. \quad (10)$$

且 $\sum_{l=1}^L (W_{k,j})_l = 0$, 其中 u^k 是对应于电流模式 1^k 的电势。与方程 (7) 类似, 我们引入拉格朗日乘数来处理约束条件, 得到与方程 (8) 相同的系统矩阵, 但右侧不同, 即

$$\begin{pmatrix} A(\sigma_{ref}) + B & C & 0 \\ C^\top & D & 1 \\ 0^\top & 1^\top & 0 \end{pmatrix} \begin{pmatrix} w_{k,j} \\ W_{k,j} \\ \lambda_{k,j} \end{pmatrix} = \begin{pmatrix} f_{k,j} \\ 0 \\ 0 \end{pmatrix}, \quad (11)$$

其中

$$(f_{k,j})_i = - \int_{\Omega} \sigma_{ref} \nabla u^k \cdot \nabla \phi_i dx \text{ for } i = 1, \dots, N. \quad (12)$$

利用式 (9) 中的恒等式, 需要解决 $K \times M$ 问题来构造雅可比矩阵 J_{ref} 。然而, 由于右侧的维度

¹https://github.com/alexdenker/eit_fenicsx

式 (11), 即前向算子的范围, 最多为 N , 因此只需计算

$$\begin{pmatrix} A(\sigma_{ref}) + B & C & 0 \\ C^\top & D & 1 \\ 0^\top & 1^\top & 0 \end{pmatrix} \begin{pmatrix} w_r \\ W_r \\ \lambda_r \end{pmatrix} = \begin{pmatrix} \delta_r \\ 0 \\ 0 \end{pmatrix}$$

的解 $((w_r, W_r, \lambda_r) \in V_N \times \mathbb{R}^L \times \mathbb{R}$, 其中 $\delta_r = (\delta_{ir})_{i=1}^N \in \mathbb{R}^N$ 是第 r 个单位向量。因此, 我们只需求解 N 个线性系统², 而非 $K \cdot M$ 。由于 $f_{k,i}$ 可表示为 $\delta_{r,n=1}^N$ 的线性组合, 我们可将雅可比矩阵恢复为

$$(J_{\sigma_{ref}})_{n,i} = W_{k,i} = \sum_{r=1}^N (f_{k,i})_n W_r. \quad (14)$$

。

注意到分段常数元素 χ_i 仅在网格的一个元素上非零。因此, 式 (14) 右侧仅剩下少数几项, 这进一步降低了计算复杂度。

在更高的挑战级别中, 边界电极会被移除。这导致电极测量值减少 ($\tilde{I} < I$) 和注入模式减少 ($\tilde{K} < K$), 即简化后的雅可比矩阵具有 $\tilde{I} \cdot \tilde{K} \times M$ 这种形状。我们可以通过移除完整雅可比矩阵 $(J_{\sigma_{ref}})$ 的相应行来计算这个简化后的雅可比矩阵。

2.3. 正则化。我们考虑 Tikhonov 型正则化项 $I(\delta\sigma) = \frac{1}{2} \|I\delta\sigma\|_2^2$ 。注意, 对于式 (6) 中的重建, 我们需要访问 $I^\top I$ 。因此, 我们可以定义 $D := I^\top I$ 来代替 L 。我们使用三种不同的正则化器。

- 一阶平滑先验 (FSM): 我们定义网格拉普拉斯算子 $P_{FSM} \in \mathbb{R}^{M \times M}$, 其中

$$(P_{FSM})_{i,j} = \begin{cases} \deg(i) & \text{if } i = j \\ -1 & \text{if } i \neq j \text{ and } i \text{ is adjacent to } j \\ 0 & \text{else} \end{cases}$$

($\deg(i)$) 是网格元素 i 的邻域数量。矩阵 P_{FSM} 也可定义为 $P_{FSM} = L_{FMS}^\top L_{FMS}$,

其中 L_{FMS} 的构造如 [5] 所示。

- 平滑度先验 (SM): 平滑度距离矩阵通过 $P_{SM} := \nabla_{\sigma_{ref}}^{-1}$ 构建, 其中包含 ($(\nabla_{\sigma_{ref}})_{i,j} = a \exp(-\|x_i - x_j\|_2^2 / (2b^2))$), x_i 和 x_j 分别是网格元素 i 和 j 的坐标。我们选择 $a = 0.025$ 和 $b = 0.4 \cdot 0.115 \cdot 115$ 。该先验用于 KTC2023 组织者提供的实现 [21]。

列文伯格 - 马夸尔特正则化器 (LM) [12]: LM 正则化器用于 NOSER 框架 [7], 其定义为 $P_{LM} = \text{diag}(J_{\sigma_{ref}}^\top \nabla^{-1} J_{\sigma_{ref}})$ 。注意, ∇ 是式 (5) 中高斯噪声模型的协方差矩阵。总之, 式 (5) 的正则化解通过组合三个正则化器得到, 即

$$F^\dagger(\delta U) = (J_{\sigma_{ref}}^\top \nabla^{-1} J_{\sigma_{ref}} + \alpha_{FSM} P_{FSM} + \alpha_{SM} P_{SM} + \alpha_{LM} P_{LM})^{-1} J_{\sigma_{ref}}^\top \nabla^{-1} \delta U, \quad (16)$$

其中, α_{FSM} 、 α_{SM} 和 α_{LM} 是正则化强度, $F^\dagger$ 是线性化重建算子。正则化强度是使用组织者提供的四个测量值的验证集来选择的。所选的

²此外, 我们有 $N < M$, 即分段线性元素的维数低于分段常数元素的维数。




图 2. 挑战级别 1 和 6 的初始重建示例。选择级别 6 是因为它最能凸显线性化重建中的差异。我们评估了独立的 FSM 先验、独立的 SM 先验、联合的 SM+LM 先验，以及两种具有不同正则化强度的联合先验 FSM+SM+LM。所选图像是验证数据的一个样本。

正则化器会在重建图像中促进不同的结构。此外，不同的正则化选择会产生明显不同的重建结果，并伴有相应的伪影，这在更高的挑战级别中尤为明显。对于后处理和条件扩散方法，我们使用了 5 种不同的正则化选择，如图 2 所示。其指导思想是，结合来自各种重建结果的信息将提高训练后的卷积神经网络的性能。

由公式 (16) 计算得出的线性化重建结果位于分段常数网格表示上，而卷积神经网络需要以 256×256 像素网格形式表示的输入。双线性插值（记为 $I: \mathbb{R}^M \rightarrow \mathbb{R}^{256^2}$ ）用于从网格插值到图像。我们将得到的五组插值线性化重建结果记为

$$\hat{\delta\sigma} := \{I(F_j^\dagger(\delta U))\}_{j=1}^5, \quad (17)$$

，其中下标表示第 j 种正则化强度选择。实际上，对于所有五组线性化重建结果，正则化的选择会因挑战级别而异，例如，级别 1 的全视角设置需要较弱的正则化，这意味着共定义了 35 种正则化强度变化。为清晰起见，我们省略了挑战级别的索引。

深度学习方法。我们向 KTC2023 提交了三种深度学习方法。两种是学习型重建器，即 FC U-Net 和后处理，还有一种是生成式方法，即条件扩散模型（Conditional-Diffusion）。我们所有的方法都共享相同的 U-Net 骨干网络 [22,9]。该网络包含一种条件机制，使级别 / 时间步能更有效地影响模型输出。

所有模型均在模拟数据集上训练，该数据集在 4.1 节中描述。令 $\pi \in \mathbb{R}^d$ 与 $d = 256^2$ 表示 2.3 节中讨论的表示

3 可在 <https://github.com/openai/guided-diffusion> 获取

在正方形像素网格上的重建中, 圆形水箱外的像素始终被视为背景类别。

3.1. 学习重构器。学习重构的目标是确定参数化重构算子 $R_\theta: \mathbb{R}^{KL} \rightarrow \mathbb{R}^d$ 的参数 $\hat{\theta}$, 使得

$$\mathcal{R}_{\hat{\theta}}(\delta U) \approx \delta \sigma. (18)$$

给定样本的配对数据集 $(\delta U^{(i)}, \delta \sigma^{(i)})_{i=1}^n$, 我们使用合适的损失函数 $L: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_{>0}$ 计算

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \frac{1}{n} \sum_{i=1}^n \mathcal{L}(\delta \sigma^{(i)}, \mathcal{R}_\theta(\delta U^{(i)})),$$

。均方误差损失函数通常用于重建任务 [20]。然而, 本挑战的目标并非重建电导率分布, 而是将其分割为水 / 背景、电阻性内含物和导电性内含物。因此, 我们使用分类交叉熵

(CCE) 作为损失函数。分类交叉熵常用于图像分割, 也已被用于计算机断层扫描分割 [1]。

令 $R_{\hat{\theta}}$ 表示学习到的重建器。该模型输出对数几率, 通过使用 softmax 函数

$$\hat{p}_{i,c} := \operatorname{Softmax}(\mathcal{R}_{\hat{\theta}}(\delta U)_{i,\cdot}) := \frac{\exp(\mathcal{R}_{\hat{\theta}}(\delta U)_{i,c})}{\sum_{c=1}^C \exp(\mathcal{R}_{\hat{\theta}}(\delta U)_{i,c})}, \quad (20)$$

将其转换为所有像素 $i = 1, \dots, d$ 和所有类别 $c = 1, \dots, C$ 的类别概率。进一步令 $p \in [0, 1]^{d \times C}$ 为地面实况类别的独热编码。分类交叉熵损失定义为

$$\mathcal{L}_{CCE}(\hat{p}, p) = -\frac{1}{d} \sum_{i=1}^d \sum_{c=1}^C p_{i,c} \log(\hat{p}_{i,c}).$$

。

训练后, 通过选择每个像素 $i = 1, \dots, d$ 处具有最高概率的类别 (即 $\operatorname{argmax}_c \hat{p}_{i,c}$) 来获得最终的分割结果。该网络直接针对分割任务进行训练, 从而省去了额外的分割步骤。对于两种习得的重建方法 (FC U-Net 和后处理), 我们将挑战等级作为额外输入提供给模型, 并为所有等级训练一个单一模型。它们的区别在于重建算子 R_θ 的参数化方式。FC U-Net 实现了一个直接作用于测量值的神经网络, 而后处理则定义了一种两步法 [20, 24]。

3.1.1. FC U-Net。FC U-Net 的设计紧密遵循 Chen 等人的研究 [6]。该模型由两个部分组成: 一个将测量值映射到像素网格的初始学习转换, 以及一个作为卷积神经网络实现的后续分割。

我们没有使用 2.3 节中的线性重建方法, 而是学习一种应用于测量值的线性映射 (表示为单个全连接线性层)。然而, 学习从维度为 $KL = 2356$ 的测量值到像素网格的线性映射, 需要超过 1.5 亿个参数, 这在计算上是难以处理的。为了减少参数数量, 我们只学习到 64×64 像素网格的映射, 并使用双线性插值将其转换到 256×256 像素网格。这种初始变换的输出被用作一个




图 3. FC U-Net 网络。我们首先使用线性层将测量值映射到 64×64 像素网格，然后将其双线性插值到 256×256 网格。该网络通过训练，利用分类交叉熵损失输出类别概率。通过分配概率最高的类别，将类别概率转换为分割图。

第二阶段的输入。令 $W \in \mathbb{R}^{64^2 \times KL}$ 表示初始线性层， $S: \mathbb{R}^{64^2} \rightarrow \mathbb{R}^{256^2}$ 表示双线性上采样算子。FC U-Net 由

$$\mathcal{R}_\theta(\delta U, k) := \tilde{\mathcal{R}}_\theta(S(W\delta U), k) \quad k = 1, \dots, 7. \quad (22)$$

给出，其中 k 为挑战级别， $\tilde{\mathcal{R}}_\theta$ 实现为注意力 U-Net [9]。图 3 给出了该方法的概述。对于更高挑战级别， δU 中的缺失测量值用零填充。

为了学习用于初始重建的线性映射 W 以及用于分割的权重 θ ，我们提出了一种新颖的两阶段训练过程。在第一阶段，仅使用均方误差损失对初始线性层进行训练

$$\min_W \sum_{k=1}^7 \sum_{i=1}^{n_k} \|S(W\delta U^{(k,i)}) - \delta \sigma^{(k,i)}\|_2^2.$$

此阶段的目的是为 W 提供良好的初始化。之后，训练完整模型以使用 CCE 损失进行分割

$$\min_{\theta, W} \sum_{k=1}^7 \mathcal{L}_{CCE}(\hat{p}^{(k,i)}, p^{(k,i)}),$$

其中 $\hat{p}^{(k,i)} = \text{Softmax}(\tilde{\mathcal{R}}_\theta(S(W\delta U^{(k,i)}), k))$ 。在 θ 和 W 的这种联合优化中，我们为线性层 w 使用了比 θ 更小的学习率

用于训练 FC U-Net 的数据集仅包含随机体模和模拟测量数据。在对组织者提供的四个挑战性体模进行评估时，我们发现最终的分割结果有所恶化。为了缓解这一泛化问题，我们增加了一个微调阶段，在此阶段，FC U-Net 在这 4 个挑战性体模上进行了 1000 步优化训练，对于 W 和 θ ，均使用 1×10^{-6} 这一较小的学习率。

3.1.2. 后处理。学习型后处理是深度学习在逆问题中的首批应用之一 [2, 20]。在这种方法中，初始重建




图 4. 后处理网络。如 2.3 节所述，将五个线性化重建结果插值到像素网格上。该网络通过训练，使用分类交叉熵损失输出类别概率。通过分配概率最高的类别，将类别概率转换为分割图。

(通过经典重建方法计算得出) 被用作卷积神经网络的输入。更准确地说，重建算子被参数化为 $R_{\theta}(\delta U) = \tilde{R}_{\theta}(F^{\dagger}(\delta U))$ ，其中 $F^{\dagger}(\delta U)$ 表示初始重建。我们从三个方面对这种方法进行了调整。首先，使用双线性插值步骤将网格值映射为图像，供卷积神经网络使用。其次，如 2.3 节所述，使用五个线性化重建作为初始重建。最后，如同 FC U-Net 一样，网络以挑战级别为条件，详见 3.1.1 节。这些调整形成了以下公式：

$$\mathcal{R}_{\theta}(\delta U, k) = \tilde{\mathcal{R}}_{\theta}(\hat{\delta\sigma}, k), k = 1, \dots, 7, (25)$$

其中 $\delta\sigma$ 是五个插值后的线性化重建， k 是挑战级别。图 4 给出了后处理的概述。生成的网络通过在所有挑战级别和训练样本上使用 CCE 损失函数 [24] 进行分割训练，预测的类别概率由下式给出：

$$\hat{p}^{(k,i)} = \text{Softmax}(\tilde{\mathcal{R}}_{\theta}(\hat{\delta\sigma}^{(k,i)}, k)), \text{ for } k = 1, \dots, 7, \text{ and } i = 1, \dots, n_k. (26)$$

3.2. 条件密度估计。从逆问题的统计学角度来看，我们感兴趣的是恢复后验分布 $p^{\text{post}}(\sigma|U)$ ，即给定边界测量值 U 时电导率 σ 的条件分布 [28]。条件密度估计的目标是，在给定数据集 $(\sigma^{(i)}, U^{(i)})$ $i = 1, \dots, n$ (其中包含 $(\sigma^{(i)}, U^{(i)})$ $p(\sigma, U)$) 的情况下，用条件概率模型 $p_{\theta}(\sigma|U)$ 逼近真实后验 $p(\sigma|U)$ 。在这项工作中， $p_{\theta}(\sigma|U)$ 采用去噪扩散概率模型 (DDPM) [15,25] 进行建模，该模型在许多图像生成任务中已显示出良好的效果 [9]。

3.2.1. 条件扩散模型。扩散模型的条件变体被提出用于解决各种逆问题，包括超分辨率 [23]、时间序列插补 [29] 和图像修复 [4]。具体而言，我们借鉴了 [4] 中的思想。

我们采用了扩散模型的离散时间公式 [15]。DDPMs 定义了一个前向扩散过程，该过程由马尔可夫链给出，并逐渐添加

在 $T = 1000$ 时间步上给数据添加噪声。

$$\sigma_t = \sqrt{1 - \beta_t} \sigma_{t-1} + \sqrt{\beta_t} \epsilon, \epsilon \sim \mathcal{N}(0, I)$$

具有方差 $\beta_1 < \dots < \beta_T$ 。选择这些方差是为了使终端分布接近标准高斯分布, $\sigma_T \sim \mathcal{N}(0, I)$)。给定无噪声样本 σ_0 , 时间 t 处的噪声样本可直接表示为

$$\sigma_t = \sqrt{\alpha_t} \sigma_0 + \sqrt{1 - \alpha_t} \epsilon, \epsilon \sim \mathcal{N}(0, I)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^T (1 - \beta_s)$ 。DDPM 的目标是通过学习参数化的转移密度来逆转这一扩散过程 $q(\sigma_{t-1} | \sigma_t)$ 。训练 DDPM 相当于最小化所谓的 ϵ 匹配损失 [15]。该框架可以扩展到条件密度估计, 方法是将测量值包含在参数化的转移密度中, 即 $q(\sigma_{t-1} | \sigma_t, \delta U)$, 使用条件神经网络 $\epsilon_\theta(\sigma_t, \delta U; t)$ 并最小化条件 ϵ 匹配损失

$$\min_{\theta} \mathbb{E}_{t \sim T} \mathbb{E}_{(\sigma_0, \delta U) \sim p(\sigma_0, \delta U) \sim q(\sigma_0, \delta U)} \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I)} [\|\epsilon_\theta(\sigma_t, \delta U; t) - \epsilon\|_2^2], \quad (29)$$

其中 σ_t 如公式 (28) 所示, 对 $(\sigma_0, \delta U)$ 的期望使用模拟数据集进行估计。图 5 给出了网络的概述, 其中网络的输入是线性化重建 (插值到像素网格)、噪声图像 σ_t 以及时间步 t 的拼接。

在文献 [15] 中, 作者利用祖先采样从学习到的分布中进行采样。然而, 这需要对所有 T 个时间步模拟反向过程, 导致采样方法计算成本高昂。为了提高采样速度, 我们采用了 DDIM 框架 [27] 中提出的加速采样方案。设 T 是 $1, \dots, T$ 的一个子序列, 长度为 S , 其中包含 $\tau_1 = 1$ 和 $\tau_S = T$ 。DDIM 采样从 $\sigma_{\tau_S} \sim \mathcal{N}(0, I)$ 开始, 由下式给出

$$\sigma_{\tau_{s-1}} = \sqrt{\alpha_{\tau_{s-1}}} \hat{\sigma}_0(\sigma_{\tau_s}, \delta U) + \sqrt{1 - \alpha_{\tau_{s-1}} - \gamma_s^2} \epsilon_\theta(\sigma_{\tau_s}, \delta U; \tau_s) + \gamma_s \epsilon, \quad (30)$$

其中 $\epsilon \sim \mathcal{N}(0, I)$ 和 $\hat{\sigma}_0(\sigma_{\tau_s}, \delta U)$ 是 Tweedie 估计 [11], 定义为

$$\mathbb{E}[\sigma_0 | \sigma_t, \delta U] \approx \hat{\sigma}_0(\sigma_t, \delta U) = \sqrt{\beta_t} (\sigma_t - \sqrt{1 - \alpha_t} \epsilon_\theta(\sigma_t, \delta U; t)). \quad (31)$$

式 (30) 中的随机性参数 γ_t 被选为

$$\gamma_{\tau_s} = \eta \sqrt{(1 - \alpha_{\tau_{s-1}}) / (1 - \alpha_{\tau_s})} \sqrt{1 - \alpha_{\tau_s} / \alpha_{\tau_{s-1}}}, \quad (32)$$

, 其中包含一个可调节的超参数 η , 参见文献 [27]。

在我们的实现中, 我们不会直接将 δU 输入到 epsilon 模型 ϵ_θ 中, 而是利用 2.3 节中介绍的初始重建结果。因此, 我们的模型形式为 $\epsilon_\theta(\sigma_t, \delta \sigma; t)$, 其中 $\delta \sigma$ 表示式 (16) 中的五个插值线性化重建集合。通过这种方式, 我们不是对真实后验 $q^{post}(\sigma | \delta U)$ 进行近似, 而是对条件分布 $q(\sigma | \delta \sigma)$ 进行近似。

由于目标是生成分割结果而非重建结果, 我们没有使用电导率值来表示 σ , 而是将其表示为取值范围在 $[0, 2]$ 内的图像。然后, 通过将重建的 σ 四舍五入到最接近的 $\{0, 1, 2\}$ 整数来获得分割结果, 其中 0 代表背景类别, 1 代表电阻性内含物类别, 2 代表导电性内含物类别。对于最终的分割, 我们使用 DDIM 公式 (30) 抽取 J 个样本 $\sigma^{(j)}$, 并执行逐像素多数投票, 即

$$\hat{\sigma}_i = \underset{\sigma \in \{0, 1, 2\}}{\operatorname{argmax}} \# \{ \sigma_i^{(j)} | \sigma_i^{(j)} = c, j = 1, \dots, J \},$$




图 5. 条件扩散网络。如 2.3 节所述，将 5 个线性化重建结果插值到像素网格上。噪声图像和线性化重建结果被输入到网络中。利用 ϵ 匹配损失函数，训练网络以估计噪声。通过对网络进行采样，得到分割图。通过多次采样并进行逐像素多数投票，得到最终的分割图。

对于所有像素 $i = 1, \dots, d$ ，其中 $\#$ 表示集合的基数。

实际考量。在本节中，我们将介绍本提交的实际考量因素。首先，我们会阐述训练数据的生成；其次，我们会详细说明线性化重建的计算；最后，我们会讨论神经网络架构的相关方面。

4.1. 数据集。我们提交内容的一个重要方面是创建一个适用于训练不同深度学习方法模拟数据集。我们首先在 256×256 像素网格上生成由非重叠多边形、圆形、矩形和手绘对象组成的随机分割图。示例模型如图 6 所示，其中我们只可视化了圆形水箱。每个对象都被指定为电阻性或导电性。对象外部以及水箱外部的区域被指定为背景类别。基于此分割图，我们模拟了对象的电导率值。电阻性对象的电导率随机选择在 $[0.025 \text{ Ohm}^{-1}, 0.125 \text{ Ohm}^{-1}]$ 范围内，导电性对象的电导率在 $[5.0 \text{ Ohm}^{-1}, 6.0 \text{ Ohm}^{-1}]$ 范围内。背景被赋予恒定的电导率值 0.745 Ohm^{-1} ，该值是通过最小二乘拟合使用空水箱的参考测量值计算得出的 [30]。在下一步中，将生成的模型从像素网格插值到分段常数有限元表示。使用第 2.1 节中指定的前向算子模拟测量结果。根据空水箱的参考测量值，添加了均值为零、协方差为

$\Sigma = \text{diag}(0.05 U_{ref} + 0.01 \max(U_{ref}))$ 的高斯噪声。为了模拟测量结果，为所有 32 个（电极）选择了固定的接触阻抗 $z = 1 \times 10^{-6} \text{ Ohm}$ 。




图 6. 上图：手绘训练体模。下图：随机生成的训练体模。为便于可视化，我们仅展示了圆形水箱。但请注意，所有模型均使用 256×256 像素的方形图像进行训练。

电极 4。每个级别的训练样本数量如表 1 所示。总的来说，我们模拟了超过 10 万个数据对。第 6 级训练样本数量较少是由于模拟过程中出现的技术问题。

表 1. 每个级别使用的训练样本数量。

Level	1	2	3	4	5	6	7
Training samples	16527	16619	16591	16587	16604	12102	16298

4.2. 初始重建。第 3.1.2 节中的后处理方法和第 3.2.1 节中的条件扩散方法都需要以初始重建结果作为输入。我们对不同的经典重建方法进行了实验。迭代重建方法，例如 L_1 正则化 [13] 或高斯 - 牛顿法 [5]，与第 2.3 节中的线性化方法相比，能得到质量更高的重建结果。然而，由于需要为训练集中的每个样本（即我们所用数据集中的 10 多万个样本）计算初始重建结果，计算成本成为了一项制约因素。因此，我们决定不采用计算成本更高的迭代方法，而是使用速度更快的线性化重建方法。但即便是线性化重建，测量值的模拟和初始重建的计算也花费了大约一周时间。

组织者提供了 CEM 的有限元实现。我们决定使用自己的实现，以便更轻松地更改离散函数空间并使用不同的网格。我们的网格与所提供网格的对比如图 7 所示。所提供的网格在域的中心和顶部存在一些小不规则性，这导致正演解和初始重建存在一些差异。相反，我们使用由 Gmsh 软件创建的网格尺寸为 0.005 的均匀网格 [14]。此外，我们设置边界元素以覆盖电极。

我们还尝试过使用最小二乘法拟合来识别接触阻抗，但没有得到理想的结果。




图 7. 左图：组织者提供的网格。右图：我们为前向算子定制的网格。

4.3. 神经网络架构。为此，标量值（级别 / 时间步）被嵌入到架构中，以根据标量值重新加权残差块，从而更有效地影响模型输出。

我们使用了 [9] 提出的经过最小化调整的引导扩散模型。该架构包含一个带有注意力块和时间嵌入的 U-Net [22]。时间嵌入经过调整，适用于后处理和 FC U-Net，使网络能够整合级别信息，这意味着训练过程中可以使用所有级别的训练数据。时间或级别信息通过自适应组归一化层 [9] 引入网络。U-Net 中的每个组归一化层 [33] 都被替换为

$$AdaGroupNorm(h, z) = z_s GroupNorm(h) + z_t, (34)$$

其中 h 是中间特征， $z = (z_s, z_t)$ 是将时间或级别信息作为输入的神经网络的输出。根据我们选择的超参数（例如层数、通道数等），可训练参数的总数为 3100 万。

不同方法中 U-Net 的输入和输出通道数量有所不同。后处理和条件扩散方法有 5 个输入通道，对应 5 个插值线性化重建 ($\tilde{\delta\sigma}$)，而 FC U-Net 则有 1 个通道输入，用于插值学习重建 ($S(W\delta U)$)。对于学习型重建器，使用了 CCE 损失，这需要三个类别概率，因此使用了三个输出通道。对于条件扩散方法，使用了 ϵ 匹配损失，需要单个通道输出。由于输入 / 输出通道的差异，每个 U-Net 主干的参数数量并不相同，尽管这种差异可以忽略不计。对于 FC U-Net，线性层 w 需要 1000 万个参数；与其他方法相比，这是可学习参数的显著增加。

结果与讨论。在本节中，我们展示了三种方法的最终挑战结果。使用结构相似性指数测量 (SSIM) [32] 分别对导电和电阻内含物的二元图计算定量分数。将其取平均值以得到每个样本的分数。将每个级别的所有样本的每个样本分数相加，得到级别分数，然后将所有级别的分数相加，得到这些方法的总分 5。对于每个挑战级别，评估了三种不同的模型 (A、B、C)。可视化结果如下

图 8、图 9 和图 10。在大多数重建结果中，物体的数量、位置和大致形状都能被正确识别。例外情况是当一个小的导电物体被放置在水箱中间并被其他物体包围时，例如图 8 中的第 7 层或图 9 中的第 7 层。此外，水箱左上角物体的重建结果往往较差，因为对于更高的层级，该部分边界的测量数据会被移除。例如，图 9 中的第 7 层，水箱顶部矩形的形状无法恢复。

定量结果如表 2 所示。除了我们提交的结果外，我们还展示了表现第二和第三的团队的结果。后处理方法以 15.24 的最终得分成为 KTC2023 中表现最佳的方法。然而，FC U-Net 在 2、4、5 和 6 级上的表现优于该方法。巴西联邦 ABC 大学的一个团队以 12.75 分获得第二名，丹麦技术大学的一个团队以 12.45 分获得第三名。在第 4 级中，第二名的得分甚至高于后处理方法。我们的 FC U-Net 方法（得分 15.13）和条件扩散方法（得分 14.60）都本可以赢得这项挑战赛。

后处理方法和 FC U-Net 的表现相近，而条件扩散模型的表现则较差。对于条件扩散方法而言，每个挑战级别都需要训练一个独立的神经网络。因此，每个级别的网络仅使用所有可用的模拟体模和测量数据中的一个子集进行训练。而后处理方法和 FC U-Net 方法均利用了所有级别的训练样本。习得重构器方法采用了针对分割任务的 CCE 损失函数，而条件扩散模型则使用了 DDPM 所需的 ϵ 匹配。条件扩散模型没有使用单一样本，而是抽取了 J 个条件样本，并通过多数投票来确定分割结果，这一点可以进一步扩展以获得不确定性的概念。

后处理方法和条件扩散方法均以一组五个线性化重建结果作为输入。通过使用一组具有不同正则化强度的重建结果，我们试图获得更稳健的分割结果，因为最佳的正则化强度是未知的。同理，全连接 U 型网络也可以学习一组重建结果，但这需要大幅增加可学习参数的数量。

结论。KTC2023 挑战赛为评估从 EIT 测量结果重建分割图问题的最先进方法提供了机会。我们的获奖方案采用了深度学习，包括两种习得的重建器方法（FC U-Net 和后处理），以及一种条件扩散生成方法。网络架构和数据集的选择对于深度学习方法至关重要，这需要具备相关问题的知识，同时还要切合实际。在这项研究中，所有方案都使用了相同的训练数据集和骨干网络结构，以便进行方法之间的比较。FC U-Net 和后处理方法得出的结果相近，而条件扩散方法的表现则稍逊一筹。习得的重建器在所有层面上进行训练（利用层面条件），而各个条件扩散网络则针对每个层面单独训练，这实际上减小了训练数据集的规模。FC U-Net 需要在提供的真实测量数据和体模上进行额外的微调阶段，而这一点对于

表 2. 通过结构相似性指数 (SSIM) 对我们三个提交结果的定量比较。这些是官方挑战赛结果, 四舍五入到小数点后两位。第二名由巴西 ABC 联邦大学的 ABC 团队获得。第三名由丹麦技术大学的 DTU 团队获得。SSIM 是在给定样本的导电内含物和电阻内含物之间取平均值。在每个级别, SSIM 是三个样本的总和, 而一种方法的总总和是所有样本和级别的总和。

Level	1	2	3	4	5	6	7	Sum
FC U-Net	2.72	2.64	2.31	1.80	2.06	2.07	1.53	15.13
Post-Processing	2.76	2.56	2.54	1.71	2.06	1.92	1.69	15.24
Conditional-Diffusion	2.67	2.49	2.47	1.61	1.94	1.76	1.65	14.60
Team ABC	2.75	2.37	2.07	1.74	1.08	1.53	1.22	12.75
Team DTU	2.28	2.3	1.87	1.55	1.34	1.44	1.60	12.45

后处理网络仅使用模拟测量值和体模。后处理方法和条件扩散方法将一组五个蒂霍诺夫正则化初始重建结果作为输入, 而 FC U-Net 方法则使用线性层将测量值映射到单幅图像。在提交的三种方法中, 后处理方法的性能最佳。这表明, 在高质量模拟数据集上训练的后处理方法比完全学习的方法更容易泛化到真实数据。有必要开展进一步工作, 以全面评估不同数据驱动方法的泛化能力。

致谢。亚历山大·登克感谢德国研究基金会 (DFG) 在 GRK 2224/1^{2224/1\pi^3}: 参数识别——分析、算法、应用”框架内提供的支持。汤姆·弗罗伊登贝格感谢 DFG 的资助——项目编号 281474342/GRK2224/2。因拉杰·辛格得到了由英国工程与物理科学研究委员会 (EPSRC) 资助的伦敦大学学院医疗智能集成成像博士培训中心 (i4health) (项目编号 EP/S021930/1) 以及伦敦大学学院医院国家健康研究所 (NIHR) 资助的生物医学研究中心的支持。热利科·克热塔得到了英国 EPSRC 基金 EP/X010740/1 的支持。西蒙·阿里奇得到了英国 EPSRC 基金 EP/V026259/1 的支持。彼得·马斯得到了德国联邦教育与研究部 (BMBF) “#MOIN - MuKIDERM”项目的支持。T. 克卢特感谢由德国联邦教育与研究部 (Bundesministerium für Bildung und Forschung, BMBF, 项目编号 05M22LBA) 资助的 KiWi 项目提供的支持。




图 8. 1 至 7 级样本 A 的三种方法分割结果。




图 9. 1 至 7 级样本 B 的三种方法的分割结果。




图 10.1 至 7 级样本 C 的三种方法分割结果。

参考文献

- [1] C. 阿恩特、A. 登克、S. 迪特默、J. 洛伊施纳、J. 尼克尔、M. 施密特, 《基于模型的深度学习方法在 2022 年赫尔辛基断层成像挑战赛中的应用》, 《现代挑战应用数学》1.2 (2023) : 87-104。
- [2] S. 阿里奇、P. 马斯、O. 厄克泰姆和 C. 舍恩利布, 《使用数据驱动模型解决反问题》, 《数值学报》, 28 (2019) : 1-174
- [3] I. Baratta、J. Dean、J. Dokken、M. Habera、J. Hale、C. Richardson、M. Rognes、M. Scroggs、N. Sime、G. Wells, DOLFINx: 下一代 FEniCS 问题求解环境, 预印本, 10.5281/zenodo.10447666 (2023) 。
- [4] G. Batzolis, J. Stanczuk, C. B. Sch ö nlieb, C. Etmann, 基于分数的扩散模型的条件图像生成, arXiv 预印本 arXiv:2111.13606 (2021)
- [5] A. 博尔西奇、B.M. 格雷厄姆、A. 阿德勒、W. 莱昂哈特, 《采用全变分正则化的在体阻抗成像》, 《IEEE 医学成像汇刊》29.1 (2009) : 44-54
- [6] 陈 Z、杨 Y、贾 J、巴格纳宁奇 P, 基于深度学习的电阻抗断层成像细胞成像, 2020 年 IEEE 国际仪器与测量技术会议 (I2MTC) , (2020) : 1-6。
- [7] M. Cheney, D. Isaacson, J.C. Newell, S. Simske, J. Goble, NOSER: 一种求解逆传导问题的算法, 《国际成像系统与技术杂志》2.2 (1990) : 66-75。
- [8] H. Chung、B. Sim 和 J. Ye, 《靠近 - 扩散 - 更快: 通过随机收缩加速用于逆问题的条件扩散模型》, 《IEEE/CVF 计算机视觉与模式识别会议论文集》, (2022) : 12413-12422。
- [9] P. Dhariwal, A. Nichol, 《扩散模型在图像合成上击败生成对抗网络》, 《神经信息处理系统进展》34 (2021) : 8780-8791
- [10] D.C. 多布森、F. 桑托萨, 《电阻抗断层成像的图像增强技术》, 《逆问题》10.2 (1994) : 317。
- [11] B. 埃弗龙, 《特威迪公式与选择偏差》, 《美国统计协会期刊》106.496 (2011) : 1602-1614。
- [12] R. 弗莱彻, 《用于非线性最小二乘的改进型马夸尔特子程序》, 理论物理部, 英国原子能研究机构哈维尔 (1971)
- [13] M. Gehre、T. Kluth、A. Lipponen、B. Jin、A. Seppänen、J. Kaipio 和 P. Maass, 《电阻抗断层成像中的稀疏重建: 实验评估》, 《计算与应用数学杂志》236 卷 8 期 (1012) : 2126-2136。
- [14] C. 格扎因和 J. 雷马克勒, 《Gmsh: 一款内置预处理和后处理功能的三维有限元网格生成器》, 《国际工程数值方法杂志》第 79 卷 (2009 年) 。
- [15] J. Ho、A. Jain、P. Abbeel, 去噪扩散概率模型, 《神经信息处理系统进展》33 (2020) : 6840-6851。
- [16] N. Hyvönönen, 《电阻抗断层成像的完整电极模型: 逼近特性和内含物表征》, 《工业与应用数学学会应用数学期刊》64.3 (2004) : 902-931。
- [17] J. 凯皮奥、V. 科莱迈宁、E. 索梅萨洛、M. 沃赫科宁, 《电阻抗断层成像中的统计反演和蒙特卡洛采样方法》, 《逆问题》16.5 (2000) : 1487。
- [18] 混凝土的电阻层析成像, K. 卡尔胡宁、A. 塞帕宁、A. 莱希科宁、P. 蒙泰罗、J. 凯皮奥, 《水泥与混凝土研究》40.1 (2010) : 137-145。
- [19] S. 马丁、C.T. 崔, 三维电阻抗断层成像的后处理方法, 《科学报告》7.1 (2017) : 7212。
- [20] G. 翁吉、A. 贾拉勒、C. 梅茨勒、R. 巴拉纽克、A. 迪马基斯、R. 威利特, 《成像中逆问题的深度学习技术》, 《IEEE 信息论选域期刊》1.1 (2020) : 39-56。
- [21] M. Räsänen、P. Kuusela、J. Jauhainen、M. Arif、K. Scheel、T. Savolainen、A. Seppänen, 《库奥皮奥断层扫描挑战赛 2023 (KTC2023) 》。 (2023) 。
- [22] O. Ronneberger、P. Fischer、T. Brox, U 型网络: 用于生物医学图像分割的卷积网络, 《医学图像计算与计算机辅助干预——MICCAI 2015》 (2015) : 234-241。
- [23] C. 萨哈里亚、J. 何、W. 陈、T. 萨利曼斯、D.J. 弗利特、M. 诺鲁兹, 《基于迭代优化的图像超分辨率》, 《IEEE 模式分析与机器学习汇刊》45.4 (2022) : 4713-4726。

- [24] J. Schwab, S. Antholzer, M. Haltmeier, 《逆问题的深度零空间学习: 收敛性分析与速率》, 《逆问题》35.2 (2019) : 025008.
- [25] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, S. Ganguli, 《基于非平衡热力学的深度无监督学习》, 国际机器学习会议 (PMLR) (2015) : 2256–2265.
- [26] E. 萨默萨洛, M. 切尼和 D. 艾萨克森, 《电流计算机断层扫描电极模型的存在性和唯一性》, 《工业与应用数学学会应用数学期刊》, 第 52 卷第 4 期 (1992) : 1023–1040.
- [27] 宋佳, 孟晨, 厄尔蒙 · S., 《去噪扩散隐式模型》, 国际学习表征会议 (2020) 。
- [28] A. Stuart, 《后问题: 贝叶斯视角》, 《数值学报》19 (2010) : 451–559.
- [29] 田代裕 (Y. Tashiro)、宋佳 (J. Song)、宋阳 (Y. Song)、埃尔蒙 · 萨米尔 (S. Ermon), 《CSDI: 用于概率时间序列插补的条件分数扩散模型》, 《神经信息处理系统进展》34 (2021) : 24804–24816.
- [30] T. 维尔胡宁, J.P. 凯皮奥, P.J. 沃赫科宁, T. 萨沃莱宁, M. 沃赫科宁, 《电极接触阻抗与内部电特性的同步重建: I. 理论》, 《测量科学与技术》13.12 (2002) : 1848.
- [31] 王浩、徐刚、周强, 《变分自编码器、归一化流和基于分数的扩散模型在电阻抗断层成像中的比较研究》, 《逆问题与不适定问题杂志》, 0 (2024) 。
- [32] 王 Z、博维克 A、谢赫 H、西蒙切利 E, 《图像质量评估: 从误差可见性到结构相似性》, 《IEEE 图像处理汇刊》13.4 (2004) : 600–612.
- [33] 吴彦祖, 何恺明, 组归一化, 《欧洲计算机视觉会议论文集》(ECCV) (2018) 。

20xx 年 xxxx 日收到 · 20xx 年 xxxx 日修订 · 20xx 年 xxxx 日提前获取