

# MR-EIT：基于数据驱动和无监督的电阻抗断层成像多分辨率重建

双模神经网络

施方明，刘金珍，孟向前，周亚鹏，熊辉

**摘要**——本文提出了一种用于电阻抗断层成像（EIT）的多分辨率重建方法，称为 MR-EIT，该方法能够在有监督和无监督学习模式下运行。MR-EIT 集成了有序特征提取模块和无序坐标特征表达模块。前者通过预训练实现从电压到二维电导率特征的映射，后者利用对称函数和局部特征提取机制，实现了与输入序列的顺序和大小无关的多分辨率重建。在数据驱动模式下，MR-EIT 通过预训练和联合训练两个阶段，从有限元网格的低分辨率数据中重建高分辨率图像，并在仿真实验中表现出优异的性能。在无监督学习模式下，MR-EIT 不需要预训练数据，仅基于测量电压进行迭代优化，快速实现从低分辨率到高分辨率的图像重建。在仿真和真实水箱实验中，它都表现出对噪声的鲁棒性和高效的超分辨率重建能力。实验结果表明，MR-EIT 在结构相似性（SSIM）和相对图像误差（RIE）方面优于对比方法，特别是在无监督学习模式下，它能显著减少迭代次数并提高图像重建质量。

**关键词**——神经网络、图像连续表示、无监督学习、电阻抗成像。

电阻抗断层成像（EIT）是一种基于电学原理的成像技术，具有成本低、无创等显著优势。其核心原理是通过测量被测区域边界上的电压分布，来推断该区域内的电导率分布。经过数十年的发展，EIT 技术已在多个领域得到广泛应用 [1,2,3,4,5,6,7]，包括脑卒中成像、乳腺癌检测和肺部成像等。然而，EIT 图像重建面临诸多挑战。首先，

物体内部电流的传播路径会受到电导率分布的影响，这使得图像重建问题具有高度的非线性。这不仅使重建过程变得复杂，还增加了计算难度。为实现电阻抗断层成像（EIT）的图像重建，通常会在成像区域周围安装多个电极。通过在一对电极之间施加低频电流，并测量其他电极对之间的电压，来获取数据。利用这些测得的电压数据，结合复杂的数学模型和算法，最终推导出被测区域的电导率分布，从而完成图像重建。

近年来，许多方法都采用神经网络来实现电阻抗断层成像（EIT）图像重建。Zhang 等人 [8] 提出了一种新颖的密集注意力网络，用于精确重建肺部轮廓和病变结构。该密集注意力网络（DA-Net）将密集网络（DenseNet）的密集连接与注意力机制相结合，增强了信息流并提高了重建精度。Huang 等人 [9] 开发了一种基于混合精度非对称神经网络的二维 EIT 图像重建方法。Ma 等人 [10] 提出了一种用于 EIT 触觉传感的模型驱动深度学习重建网络，名为 PDCISTA-Net。该网络将预处理滤波模块与双通道迭代收缩阈值算法（ISTA）相结合，能够捕捉阻抗变化分布中的块相关性和稀疏性。Sun 等人 [11] 提出了一种利用深度相似性先验的多模态 EIT 图像重建算法。他们设计了一个自监督网络，该网络包含两个具有共享权重的结构编码网络，并通过神经网络正则化构建了多模态 EIT 重建。

在三维重建领域，神经辐射场（NeRF）已被广泛用于生成空间场景的逼真新视角。NeRF 通过优化一个连续的体积场景函数来合成复杂场景的新视图，该函数以空间位置和观察方向为输入，并输出这些位置的体积密度和与视图相关的发射辐射度。这种方法利用经典的体绘制技术来投射输出的颜色和

本研究得到国家自然科学基金（项目编号：62071329）、天津市自然科学基金（项目编号：18JCYBJC90400、18JCQNJC84000）以及天津市教委高等学校科技发展基金（项目编号：2019KJ014）的部分资助。

石方明就职于天津工业大学智能电器装备智能控制重点实验室，中国天津市 300387。

刘进珍就职于天津工业大学控制科学与工程学院，天津 300387。

孟向前就职于天津工业大学电气设备智能控制重点实验室，中国天津 300387。


熊辉就职于天津工业大学人工智能学院，天津 300387，中国（电子邮箱

周亚鹏就职于天津工业大学智能电器装备智能控制重点实验室，天津 300387。

将密度转换为图像，从而从稀疏的输入视图中合成高质量的新视图。这种连续空间表示能力还可应用于图像超分辨率任务 [12,13,14]，将图像视为连续函数而非离散像素。在图像生成和三维重建领域，分割模型与生成模型之间从未有过明确的界限。有效的像素或点云分割方法通常只需稍作修改，就能适用于执行高级生成任务。例如，UNet [15] 的经典结构可用于构建扩散模型 [16] 的生成网络。同样，点云分割的经典结构也可用于实现重建任务。在医学影像领域，各种隐式神经表示方法已被应用于 CT 和 MRI 图像 [17,18]。

图 1 MR-EIT 的整体结构

大多数采用深度学习技术的电阻抗断层成像（EIT）图像重建方法，都是利用神经网络建立从电压到电导率的端到端映射。由于神经网络的设计通常是针对特定数量的元素或像素量身定制的，因此重建不同分辨率的图像会很不方便。当改变场域形状或在相同的重建场域中使用不同数量的网格元素时，也难以快速适配。当神经网络使用与序列长度无关的算子时，它们能够对不同数量的元素进行重建，但无法利用像卷积这样的局部特征提取方法。为了使重建算法能够便捷地处理多分辨率下的 EIT 图像重建，并在与序列顺序无关的条件下受益于基于局部特征的出色特征提取，我们提出了 MR-EIT 方法。该方法受图像超分辨率方法 LIIF [14] 以及点云分割领域经典的 PointNet 系列 [19,20,21] 的启发，涵盖了两种利用神经网络进行 EIT 重建的方式。



在驱动条件下，设计了适用于电压特征提取的有序特征提取模块，通过条件隐式神经表示实现多网格单元图像重建。在无监督学习条件下，MR-EIT 不再需要训练数据，仅需测量电压即可通过最小化误差进行图像重建，且无序坐标特征表达模块可作为隐式正则化项。

本文的主要贡献如下：

- 我们提出了 MR-EIT 方法，该方法能够重建不同分辨率的图像。
- 构建了一种适用于数据驱动和无监督学习模式的神经网络架构。
- 通过仿真和物理实验验证了该算法在两种模式下的性能，特别是在无监督模式下，无需对神经网络进行预训练就能实现高质量的图像重建。


本文的第二节介绍了相关工作。第三节阐述了 MR-EIT 两种模式的算法原理和神经网络架构。第四节通过模拟数据和真实实验，验证了该模型在数据驱动和无监督学习模式下的图像重建性能。

## II. 相关工作

### A. 局部隐式图像函数

局部隐式图像函数（LIIF）是一种用于连续图像表示的方法 [14]，旨在解决传统基于像素的图像表示在分辨率转换方面的局限性。LIIF 将图像编码为一组在空间维度上分布的潜在编码，并使用一个共享的

## Data-driven Mode: C = 11



## Unsupervised learning mode: C = 2

图2 无序坐标特征表达模块

解码函数用于预测给定坐标处的 RGB 值，从而实现任意分辨率的图像渲染。在对特定坐标的特征进行采样时，采用特征展开的方式，通过结合相邻像素的特征来构建某个像素的特征向量：

$$\hat{M}_{ii} = \text{Concat}(\{M_{i+l,i+m}\}_{l,m \in [-1,0,1]}) \quad (1)$$

其中  $\Omega$  表示该场的域。随后，边界电位值使用有限元法计算

单元法。上述拉普拉斯方程可以用矩阵形式表示为：

$$A_{ii} = \sum_{\text{Thecelle containing vertex } i} C_{ii}^e, A_{ij} = \sum_{\text{Thecelle}} C_{ij}^e \quad (5)$$

$$[C]_e =$$

$$\frac{1}{4\Delta} \begin{bmatrix} y_j - y_m & x_m - x_j \\ y_m - y_i & x_i - x_m \\ y_i - y_j & x_j - x_i \end{bmatrix} \begin{bmatrix} y_j - y_m & y_m - y_i & y_i - y_j \\ x_m - x_j & x_i - x_m & x_j - x_i \end{bmatrix}$$

在有限元法中，三角形单元的索引在哪里？C 是单元系数矩阵， $\epsilon$  是单元 e 的电导率， $\Delta$  表示三角形单元的面积，x 和 y 是三角形单元三个顶点的坐标。通过将电流密度的边界条件应用于方程（4），可以计算出场中每个节点的电势矩阵  $\Phi$ 。此外，通过测量节点之间的电势差可以得到电压。

## III. 方法

MR-EIT 是一种双模式框架，它可以采用数据驱动模式，也可以采用直接基于电压值损失迭代的无监督学习模式。如图 1 所示，该框架由有序特征提取模块和无序坐标特征表达模块组成。在数据驱动模式下，两个模块同时使用；而在无监督学习模式下，仅需使用无序坐标特征表达模块。

### A. 有序特征提取模块

在 MR-EIT 的有序特征提取模块中，电压数据通过神经网络被表示为二维电导率特征。在数据驱动的图像重建模式下，设计有序特征提取模块的主要目的是利用不具备对称性质的局部算子，对电压序列进行一系列变换和映射。受 LIIF 的启发，采用一种自编码器结构的神经网络，将电压数据端到端映射至二维像素域，以查询该框架对称部分中每个坐标的初始特征。该神经

Conv1d (130,256,1) Conv1d (256,256,1) Conv1d (258,256,1) Conv1d (256,256,1) Conv1d (258,256,1) Conv1d (256,256,1)

伊赫霍伊

(B




图 3 特征融合块的具体结构。

有序特征提取模块的网络结构采用 Transformer - Encoder 和二维卷积作为编码器。在此过程中的特征图

卷积下采样过程用于与解码器建立跳跃连接，解码器中采用双线性插值进行上采样。最终得到形状为 (1,256,256) 的特征图，用于后续采样。

对于常见的三角形有限元网格，每个三角形的重心坐标用于表示整个单元。在使用数据驱动方法时，会利用这些坐标查询预训练模型输出特征图中对应像素的值。由于二维特征图的坐标是离散的，因此采用最近邻采样 (nearest) 方法来获取坐标对应的特征值。此外，电阻抗断层成像 (EIT) 中的有限元单元数量远小于预训练模型输出特征图的总像素数。因此，使用式 (1) 中的特征展开 (Feature Unfold) 方法来扩大所选特征的范围。在数据驱动模式下，对称模块的输入为  $X_i, Y_i, \bar{M}X_i, \bar{M}Y_i$ ，即每个坐标与查询到的特征拼接后形成输入。相应地，在无监督学习模式下，仅使用  $X_i, Y_i$  作为对称模块的输入。如图 2 所示，在数据驱动模式下，由于拼接了额外的坐标属性数据，第一个一维卷积操作的核大小为 11。其余计算过程与无监督学习模式相同。

#### B. 无序坐标特征表达模块

无序坐标特征表达模块是使 MR-EIT 能够在多个位置重建图像的关键。

分辨率。其计算完全独立于输入数据的顺序和数量，确保在不同分辨率或元素数量下进行图像重建时能实现高效的零样本迁移。具体而言，该模块主要由一个通过一维卷积构建的多层感知机 (MLP)、方程式 (2) 中的对称函数以及邻近坐标特征压缩机制组成。如图 2 所示，除了第一个一维卷积层因输入维度不同而有所差异外，两种模式下的模型设计完全相同。为确保同一组神经网络参数可用于具有不同输入顺序和数量的坐标属性特征向量，该模块中的所有计算机制对每个输入特征向量都是相同的，且不涉及任何依赖于输入顺序的局部算子计算。所有一维卷积操作均以特征向量的长度作为通道数，核大小固定为 1，并通过改变通道数来改变特征向量的长度。然而，仅使用由一维卷积组成的多层感知机无法捕捉输入特征向量之间的关系。

为了获取对图像重建至关重要的局部关系，设计了一种由对称函数和邻近坐标特征压缩机制组成的局部信息提取方法。邻近元素 (坐标) 特征选择机制用于选取给定一点的 N 个最近坐标点，并将这些 N 个坐标点的特征向量进行拼接。为了支持不同的有限元网格单元数量，同样地，必须采用一种独立于向量序列顺序的计算方法来获取这 N 个特征向量的局部信息，并将该信息表示为一维向量。然后，如图 3 所示，将最大池化用作对称函数来

对这  $N$  个向量的特征进行压缩，仅保留每个维度在这  $N$  个向量中的最大值。然后将这  $N$  个向量重新压缩为一个一维向量，该向量代表对应坐标点的局部特征信息。将对称函数与邻近坐标特征压缩机制相结合，能够在从二维平面提取局部信息方面达到与二维卷积类似的效果。此外，这种方法对输入数据没有特定的序列顺序要求。在该模块中，通过持续使用局部特征压缩，可以扩大感受野。由于这种计算机制仅涉及选择邻近坐标向量和通过最大池化来压缩向量，不包含任何参数化计算，因此在多分辨率零样本迁移图像重建任务中，无需训练额外参数，只需在数据驱动模式下修改所选邻近元素的数量，就能轻松扩大局部特征提取范围。在迭代模式下，它可以为每个元素提供邻近元素的特征向量作为补充，有效增强图像的平滑度和边界的区分度。

### C. 数据驱动模式

数据驱动模式包括两个阶段。第一阶段涉及对有序特征提取模块进行预训练，而第二阶段则同时训练这两个模块。在第一阶段，使用自动编码器建立从电压到二维图像域的特征映射。该自动编码器被定义为如下函数：

$$M = f_{\theta}(v) \quad (7)$$

根据这一定义， $v$  表示电压， $M$  是二维特征图。该特征图中的每个像素定义在像素域中，代表一个电导率特征。为了使定义在连续二维坐标域中的单元质心坐标能够从定义在像素域中的二维特征图中查询并获取特征，需要对单元质心坐标的连续坐标域进行归一化处理：

$$(x', y') = \left( 2 \cdot \frac{x - x_{\min}}{x_{\max} - x_{\min}} - 1, 2 \cdot \frac{y - y_{\min}}{y_{\max} - y_{\min}} - 1 \right) \quad (8)$$

其中， $(x', y')$  代表归一化坐标， $(x, y)$  代表原始坐标。随后，通过缩放或平移可以很容易地得到与像素坐标范围相对应的查询坐标。然后，根据公式 (1)，从像素域特征  $M \in \mathbb{R}^{H \times W}$  中获得查询点的特征向量。预训练数据集包含 20000 对电压数据和对应的二维像素域电导率数据。其中，16000 对用作训练集，2000 对用作验证集，2000 对用作测试集。损失函数采用均方误差 (MSE)：

$$L_{\text{pretrain}} =$$

$$\frac{1}{N \cdot H \cdot W} \sum_{i=1}^N \sum_{j=1}^H \sum_{k=1}^W (I_i(i, k) - M_i(i, k))^2 \quad (9)$$

第二阶段包括训练无序坐标特征表达模块，其定义如下：

$$\hat{\epsilon} = p_{\psi}(x, y, \hat{M}) \quad (10)$$

在这种模式下，无序坐标特征表达模块  $p_{\psi}$  的输入包括通过方程

(2) 获得的坐标和电导率特征向量，输出为预测的元素电导率  $\hat{\epsilon}$ 。神经网络参数的优化目标是：

$$L_{\text{train}}(\theta, \psi) = \operatorname{argmin}_{\theta, \psi} \frac{1}{N} \sum_{i=1}^N \|\epsilon - \hat{\epsilon}\|^2 \quad (11)$$

在第二阶段，两个模块的参数同时进行训练，其中代表真实的单元电导率。该阶段使用的数据集与预训练阶段使用的电压数据相同，一维形式的电导率数据对应每个单元的电导率。模拟数据集是利用 COMSOL 和 Matlab 创建的。为避免所谓的“反问题伪影”，所有模拟电压数据均采用包含 5696 个单元和 2927 个节点的有限元网格生成。为便于验证模型的零样本多分辨率重建性能，训练过程中使用了包含 636 个单元和 345 个节点的低分辨率有限元网格，以对应与电压相关的单元电导率数据。

### D. 无监督学习模式

在这种模式下，采用无监督学习，无需训练数据。如图 3 所示，无序坐标特征表达模块的输入是每个网格单元的质心坐标。对称函数和相邻单元特征选择机制为每个坐标 - 电导率编码过程提供局部信息，并具备在同一领域的多网格场景中存储和更新参数的功能。由于获取局部特征的机制不涉及可训练参数，参数数量较少，能够以更少的迭代次数获得优良的重建结果。该模式还采用两阶段执行过程。对于待重建的场，使用单元数量既有少又有多网格划分。根据公式 (6)，单元数量越多，计算时间越长。对于典型的电阻抗断层成像 (EIT) 逆问题，电导率值本身通常被视为待优化的参数：



$$\sigma = \underset{\sigma}{\operatorname{argmin}} \{ \|V - U(\sigma)\|^2 \}$$

其中  $U$  是用于计算 EIT 正向问题中电压的函数。当需要增加重建元素的数量时,  $\sigma$  必须重新初始化, 且无法利用上一次迭代的优化参数。然而, 无序坐标特征表达模块用于在神经网络中存储参数更新的结果。对于同一区域内的不同网格, 坐标会作为输入被送入神经网络。

$$\hat{\epsilon} = \underset{\epsilon}{\operatorname{argmin}} \{ \|V - U(\epsilon)\|^2 \} \quad (13)$$

$$\phi = \underset{\phi}{\operatorname{argmin}} \{ \|V - U(\hat{\epsilon})\|^2 \} \quad (14)$$

参数优化过程使用相同的神经网络。由于无序坐标特征表达模块设计中的所有算子都与输入数据的数量和顺序无关, 因此对于相同的待优化领域, 神经网络参数可以直接复用。总体而言, 本模式采用的两阶段执行方式如下: 第一阶段使用单元数量较少的网格进行重建, 目的是使神经网络参数  $\phi$  在更短时间内收敛。在本研究的实验中, 该阶段的平均迭代次数为 200 次。第二阶段采用单元数量明显多于第一阶段的网格进行重建, 并利用第一阶段得到的神经网络参数  $\phi$ 。在实验中, 该阶段所需的平均迭代次数仅为 50 次左右。

#### E. 实验平台

本研究中的所有实验和训练均在 Linux 系统上部署。神经网络模型采用 Pytorch 2.0 构建, 并使用 CUDA 构建了自定义的刚度矩阵并行计算算子。所使用的硬件设备为 NVIDIA GEFORCE RTX 4070。

### IV. 结果

MR-EIT 是一种可在有监督和无监督学习模式下运行的方法。本节设计了仿真实验, 以验证该方法在有监督学习条件下的图像重建性能, 以及改变网格单元数量后的重建效果。由于无监督学习的应用范围比有监督学习更广泛, 因此专门设计了仿真和物理实验, 以验证基于无监督学习的 MR-EIT 图像重建性能以及超分辨率后的图像重建效果。

#### A. 评估指标

结构相似性 (SSIM) 被用作一种评估指标, 用于衡量重建图像与对比图像之间的差异, 以及结构上的 (差异)。

重建图像中目标的相似性。相对图像误差 (RIE) 用于比较图像之间的差异。RIE 和结构相似性指数 (SSIM) 的定义如下:

$$RIE = \frac{\|I - \hat{I}\|_2^2}{\|I\|_2^2}$$

$$SSIM(I, \hat{I}) =$$

$$SSIM(I, \hat{I}) = \frac{(2\mu_I\mu_{\hat{I}} + C_1)(2\sigma_{I\hat{I}} + C_2)}{(\mu_I^2 + \mu_{\hat{I}}^2 + C_1)(\sigma_I^2 + \sigma_{\hat{I}}^2 + C_2)} \quad (16)$$

其中,  $\hat{I}$  表示重建图像,  $I$  表示真实图像数据,  $\mu_I$  表示  $I$  的平均值,  $\mu_{\hat{I}}$  表示  $\hat{I}$  的平均值,  $\sigma_I$  是  $I$  的标准差,  $\sigma_{\hat{I}}$  是  $\hat{I}$  的标准差,  $\sigma_{I\hat{I}}$  是  $I$  和  $\hat{I}$  这两个图像的协方差,  $C_1$  和  $C_2$  表示两个常数。

#### R 数据驱动模式的性能验证

在本小节中, 将 MR-EIT 的数据驱动模式与不同类型的图像重建算法进行了比较。第一类方法使用由序列算子构建的神经网络, 包括最常见的 U-Net 结构以及较新的基于扩散模型的 DiffusionEIT 算法。这些方法的显著特点是对特定的确定性序列具有很强的学习能力。然而, 当序列发生变化时, 它们无法直接迁移到新的序列中。例如, 对于本文中的电导率序列, 若直接打乱该序列或使用新的序列长度, 就需要重新构建数据集并从头开始训练。第二类对比方法采用完全与序列无关的算子, 如多层感知机 (MLP) 或 Transformer 中的交叉注意力 (Cross-Attention) 方法, 并结合无序坐标特征表达模块。对比这些方法的主要目的是探究如何将电压数据用作图像重建的条件。本文主要比较了将电压数据融入坐标隐式神经表示模块的两种常见方式: 一种是为每个坐标直接拼接一致的电压数据; 另一种是采用交叉注意力计算方法, 将坐标的隐藏变量作为查询 (Q), 电压的隐藏变量作为键 (K) 来计算注意力分数, 然后对注意力分数进行解码, 得到坐标对应的最终电导率值。




图 4 636 个单元条件下使用数据驱动模型的 MR-EIT 重建结果比较。

图 4 展示了在与训练数据集一致的分辨率下的图像重建结果。使用直接电压拼接的图像重建效果并不理想，尤其是在图像平滑度方面。表达每个坐标 - 电压序列极具挑战性。这是因为全局 MLP 无法有效捕捉电压数据中的局部相关性。尽管能够重建出大致位置和目标物体值，但形状细节的丢失非常严重。使用交叉注意力机制输出注意力分数的方法，其图像平滑度达到了惊人的程度。这种直接将注意力分数用于后续计算的方法，在一定程度上能够规范输出电导率值的差异。然而，它无法准确识别目标物体的位置和形状。




图 5 测试集上的平均结构相似性指数 (SSIM) 和相对强度误差 (RIE)，该测试集的元素数量与训练数据集相同。

与基于序列的方法进一步对比表明，MR-EIT 能够实现比 U-Net 更好的图像重建效果，但略逊于先进的基于序列的 EIT 图像重建方法 DiffusionEIT。这一结果并不令人意外。扩散模型使用的算子适用于特定序列，能够轻松学习局部序列信息，而无需考虑序列相对顺序发生变化的可能性。此外，扩散模型的图像生成能力已得到广泛认可。图 5 展示了在 636 个元素条件下测试集的平均 SSIM 和平均 RIE。MR-EIT 的数据驱动模式能够反映目标物体的正确位置和形状，与基于拼接和交叉注意力的坐标隐式表达方法相比，取得了更好的效果。




图 6 1752 个单元条件下，数据驱动模式下 MR-EIT 的重建性能比较。

由于 U-Net 和 DiffusionEIT 在网格单元数量变化时都不具备零样本多分辨率图像重建能力，因此针对不同单元数量的实验仅比较了基于拼接和交叉注意力的坐标隐式表达式。该实验设计对比了在 636 个单元上训练后直接在 1752 个单元上的重建效果。如图 6 所示，MR-EIT 无需额外的训练样本，就能直接在单元数量更多但形状相同的区域上进行图像重建，且几乎能保持原有的性能。目标物体的位置和形状未呈现明显差异。相比之下，基于拼接和交叉注意力的方法无法准确重建目标。图 7 展示了测试数据集上的性能指标。MR-EIT 在零样本迁移到 1752 个单元的图像重建任务时，性能损失相对较小。而对比方法由于对电压表征的学习不足，在原始单元数量和更高单元数量的图像重建中表现都不够理想。




图 7 测试集上的平均结构相似性 (SSIM) 和相对强度误差 (RIE)，该测试集的元素数量多于训练数据集 (1752 个元素)。

### C. 无监督学习模式的性能验证

为了验证 MR-EIT 无监督学习模式的性能，设计了仿真实验和真实水箱实验。MR-EIT 的无监督学习模式无需使用数据集进行预训练，因此在物理实验中具有更大的应用潜力。所选的对比方法是广泛使用的 L2 正则化方法和高斯 - 牛顿法。实验中，MR-EIT 不仅实现了精确的图像重建，而且所需的更新迭代次数更少。在本研究的硬件平台上，采用并行计算方法求解 EIT 正向问题所需的刚度矩阵，对于 636 个单元的图像重建，参数单次更新的平均时间约为 120 毫秒。相比之下，对于 5696 个单元的图像重建，参数单次更新的平均时间约为 1500 毫秒。实验中的总平均迭代次数通常不超过 300 次。




图 8 MR-EIT 无监督学习模式在模拟样本上的重建性能。

仿真数据的结果如图 8 所示。与对比方法相比，MREIT 在目标物体的位置和形状方面取得了显著更好的重建结果。此外，目标物体与背景之间的过渡存在明显差异。表 I 展示了评估指标的定量对比结果。

表 I 样本 (A) 和样本 (B) 的评估指标

|      | (A)    |        |        | (B)    |        |        |
|------|--------|--------|--------|--------|--------|--------|
|      | MR-EIT | GN     | L2     | MR-EIT | GN     | L2     |
| SSIM | 0.9114 | 0.9001 | 0.8603 | 0.9208 | 0.8822 | 0.8131 |
| RIE  | 0.0580 | 0.1107 | 0.2145 | 0.0530 | 0.1217 | 0.3801 |




图 9 新建实验装置

为了验证 MR-EIT 在实际条件下的性能，设计了一项真实世界的水箱实验。电压测量数据采集系统由以下组件构成：一块 NI USB-6281 数据采集卡、一个由四个 16 通道多路复用器（型号 ADG1606）组成的开关阵列、一个电流源、导线、电极夹以及一台个人计算机。系统运行时，电流源会将数据采集卡生成的控制电压转换为频率 1kHz、振幅 0.5mA 的激励电流。数据采集卡控制开关阵列，以选择向哪些电极注入激励电流。最后，个人计算机通过控制 NI USB-6281 数据采集卡来采集电极上的电压信号。如图 9 所示，测量场是一个类人头骨形状的水箱，其长约 22 厘米、宽约 20 厘米，以生理盐水作为背景导电介质，电导率约为 1.5 西门子 / 米。

实际实验中图像重建面临的主要挑战是测量电压中包含的噪声，且测量过程中来自水面波动和电极的噪声尤为严重。因此，实际实验能够很好地反映重建算法对噪声的敏感性及其应用的可行性。本部分实验中 MR-EIT 所采用的重建策略与方法部分所述一致。它首先使用具有快速迭代速度的 636 元素重建图像。由于无序坐标特征表达模块能够处理任意数量元素的坐标并采用共享参数，其神经网络参数迭代速度更快。图 10 展示了 636 元素上的图像重建结果对比。MR-EIT 能够准确重建目标物体，而直接将元素电导率值作为优化参数的对比方法则无法重建出正确的基本形状。值得注意的是，在 636 元素的情况下，应用式 (2) 从 16 个最近邻元素中提取局部信息。




图 11 在具有 5696 个单元（高分辨率）的网格上，MREIT 无监督学习模式对实际电压样本的重建结果。

进入无监督模式的超分辨率阶段，前一阶段已完成 636 个元素的图像重建，无序坐标特征表达模块已能取得良好的



单元坐标数据的转换。此时，网格变为 5696 个单元，提取的单元信息数量也相应地从 16 个增加到 48 个。再次启动参数优化。由于神经网络参数是共享的，平均只需不到 50 次迭代就能实现更高单元数量的图像重建。更高的分辨率带来了更细腻的边缘表现。在实际实验中，能够实现更精确的形状表达，而且得益于单元数量的增加，即使不使用任何插值方法来增强图像，重建效果仍然较为平滑。图 11 展示了 5696 个单元上的电导率单元重建结果。与 636 个单元的重建图像相比，更多的单元数量补充了因单元形状限制而缺失的边缘形状细节，显著提高了图像的清晰度和准确性。

## V. 结论

在本研究中，我们提出了用于电阻抗断层成像（EIT）中多分辨率重建的 MR-EIT 方法。该方法集成了数据驱动和无监督学习两种模式，以实现不同分辨率下高效且灵活的图像重建。有序特征提取模块采用卷积与 Transformer 编码器相结合的混合架构，能够从电压数据中提取局部和全局特征。同时，无序坐标特征表达模块利用对称函数和邻近坐标特征压缩机制来实现多分辨率图像重建。这种双模式设计使 MR-EIT 能够在数据驱动模式下利用预训练模型完成高质量图像重建，而在无监督模式下，无需任何数据集训练即可实现多分辨率图像重建。

通过全面的模拟实验和真实的水箱实验，我们验证了 MR-EIT 在精确重建目标物体的位置和形状方面的优越性能，即使在不同的网格分辨率下也是如此。该方法对噪声表现出很强的鲁棒性，并且能够以最小的计算开销生成平滑、清晰的图像。其在数据驱动模式和无监督模式之间切换的能力，使 MR-EIT 能够适应各种实际应用场景。

## 参考文献

- [1] B. Schullcke, B. Gong, S. Krueger-Ziolek, M. Soleimani, U. Mueller-Lisse 和 K. Moeller, “结合 CT-EIT 和离散余弦变换重建方法的肺结构 - 功能成像”, 《科学报告》, 第 6 卷, 第 25951 页, 2016 年 5 月. doi: 10.1038/srep25951.
- [2] S. 拉纳、R. 汉普森和 G. 多比, 《乳腺癌: 基于视觉和力分析的分割变形图像模型重建与图像配准》, 发表于《IEEE 医学成像汇刊》, 第 39 卷, 第 5 期, 第 1295-1305 页, 2020 年 5 月, 数字对象标识符: 10.1109/TMI.2019.2946629.
- [3] T. 道里克、C. 布洛谢和 D. 霍尔德, “大鼠出血性和缺血性中风期间的在体生物阻抗变化: 利用电阻抗断层扫描实现 3D 中风成像,” 《生理测量》, 第 37 卷, 第 6 期, 第 765-784 页, 2016 年。
- [4] B. 麦克德莫特、A. 埃拉希、A. 桑托雷利、M. 奥哈洛伦、J. 埃弗里和 F. 波特, “多频对称差分电
- “结合机器学习的阻抗断层成像用于人类中风诊断”, 《生理测量》, 第 41 卷, 第 7 期, 2020 年 8 月. 文章编号: 075010.
- [5] N. Goren 等人, “中风患者的多频电阻抗断层扫描和神经影像数据”, 《科学数据》, 第 5 卷, 第 1 期, 2018 年 7 月, 文章编号: 180112.
- [6] B. 舒尔克、B. 龚、S. 克吕格尔 - 齐奥莱克、M. 索莱马尼、U. 米勒 - 利塞和 K. 莫勒, “结合 CT-EIT 和离散余弦变换重建方法的肺结构 - 功能成像”, 《科学报告》, 第 6 卷, 第 25951 页, 2016 年 5 月。
- [7] V. A. Cherepenin 等人, “乳腺组织的三维电阻抗断层成像: 系统设计与临床测试”, 《IEEE 医学成像汇刊》, 第 21 卷, 第 6 期, 第 662-667 页, 2002 年. doi: 10.1109/TMI.2002.800602.
- [8] 张 H、王 Q、李 N, “DA-Net: 用于肺部电阻抗断层成像（EIT）的密集注意力重建网络”, 《IEEE 物联网期刊》, 第 11 卷, 第 12 期, 第 22107-22115 页, 2024 年 6 月. doi: 10.1109/IOT.2024.3380845.
- [9] 黄 J 等人, “EIT-MP: 一种基于混合精度非对称神经网络的二维电阻抗断层成像重建方法, 用于软硬件协同优化平台”, 《IEEE 传感器期刊》, 第 24 卷, 第 23 期, 第 39947-39957 页, 2024 年 12 月, doi: 10.1109/ISFN.2024.3476189.
- [10] 马国 (G. Ma)、陈华 (H. Chen)、董思 (S. Dong)、王鑫 (X. Wang) 和张思 (S. Zhang), 《PDCISTA-Net: 基于模型驱动的深度学习方法重建网络在电阻抗断层成像触觉传感中的应用》, 《IEEE 工业信息学汇刊》, 第 21 卷, 第 1 期, 第 633-642 页, 2025 年 1 月, doi: 10.1109/TH.2024.3456443.
- [11] 孙佳等, “基于深度相似先验的多模态电阻抗断层成像重建”, 《2024 年 IEEE 国际仪器与测量技术会议论文集》(I2MTC), 2024 年 5 月, 第 1-6 页. doi: 10.1109/I2MTC60896.2024.10560635.
- [12] 唐 K. 和王 C., “STSR-INR: 基于隐式神经表示的多变量时变体数据时空超分辨率”, 《计算机与图形学》, 第 119 卷, 第 103874 页, 2024 年 4 月. doi: 10.1016/i.cag.2024.01.001.
- [13] 韩亚等, “Super-NeRF: 用于 NeRF 超分辨率的视图一致细节生成”, 《IEEE 可视化与计算机图形学汇刊》, 第 1-14 页, 2024 年, doi: 10.1109/TVCG.2024.3490840.
- [14] 陈宇、刘思、王鑫, “利用局部隐式图像函数学习连续图像表示”, 《IEEE/CVF 计算机视觉与模式识别会议论文集》, 2021 年, 第 8628-8638 页。
- [15] O. Ronneberger、P. Fischer 和 T. Brox, “U-Net: 用于生物医学图像分割的卷积网络”, 国际医学图像计算与计算机辅助干预会议论文集, 2015 年, 第 234-241 页。
- [16] J. Ho、A. Jain 和 P. Abbeel, “去噪扩散概率模型”, 《神经信息处理系统讲习班会议论文集》第 33 卷, 2020 年, 第 6840-6851 页。
- [17] 韩旭等, “基于隐式神经表征和互学习的半监督模型 (SIMN) 用于多中心鼻咽癌 MRI 分割”, 《计算机在生物学与医学中的应用》, 第 175 卷, 第 108368 页, 2024 年 6 月, doi: 10.1016/i.combiomed.2024.108368.
- [18] 冯 J 等, “用于无监督动态磁共振成像重建的时空隐式神经表示”, 《IEEE 医学成像汇刊》, 第 1-1 页, 2025 年, doi: 10.1100/TMI.2025.3526452.
- [19] C. R. Qi、H. Su、K. Mo 和 L. J. Guibas, “Pointnet: 用于 3D 分类和分割的点集深度学习”, 收录于《IEEE 计算机视觉与模式识别会议论文集》, 2017 年, 第 652-660 页。
- [20] C. R. Qi、L. Yi、H. Su 和 L. J. Guibas, “Pointnet++: 度量空间中点集的深度学习层次特征学习”, 《神经信息处理系统进展》, 第 30 卷, 2017 年。
- [21] 钱 G. 等, “Pointnext: 结合改进的训练和缩放策略重新审视 Pointnet++”, 《神经信息处理系统进展》, 第 35 卷, 第 23192-23204 页, 2022 年。