

神经逆算子求解偏微分方程反问题

Roberto Molinaro¹ Yunan Yang² Björn Engquist³ Siddhartha Mishra^{1,4}

Abstract

对于偏微分方程 (PDE) 的大量反问题, 其定义仅作为从算子到函数的映射。现有的算子学习框架将函数映射为函数, 需要进行修改才能从数据中学习反向映射。我们提出一种称为神经反算子 (Neural Inverse Operators, NIOs) 的新架构来解决这些 PDE 反问题。受潜在数学结构的启发, NIO 基于 DeepONets 和 FNOs 的适当组合, 以逼近从算子到函数的映射。通过多种实验表明, NIO 显著优于基准方法, 能够稳健、准确地解决 PDE 反问题, 并且比现有的直接方法和 PDE 约束优化方法快几个数量级。

1. 简介。

偏微分方程 (PDEs) 在科学和工程中的数学模型中无处不在 (Evans, 2010)。通常, 求解 PDE 涉及求解所谓的正问题。也就是说, 给定输入, 如初始条件、边界条件、系数和源项, 计算 (解的) 可观测量。然而, 在许多重要的应用背景下, 人们更感兴趣的是求解所谓的反问题 (Isakov, 2017)。也就是说, 给定 PDE 解的 (可观测量) 观测数据, 推断其潜在的输入。

一类大规模的此类反问题具有以下抽象形式: 给定

作为算子 (函数空间之间的映射) 的可观测量, 推断与相关偏微分方程 (PDE) 对应的潜在输入系数 (函数)。一个典型的例子是医学成像中电气阻抗断层扫描 (EIT) 所涉及的广泛研究的 *Calderón* 问题 (Uhlmann, 2009)。在此问题中, 可观测量是狄利克雷到诺伊曼 (DtN) 算子, 它将边界上的电压映射为电流, 而人们感兴趣的是推断潜在的导电性场。另一个相关例子是地球物理应用中的反波散射问题。其他例子还包括光学断层扫描 (Lai et al., 2019), 其中可观测量是所谓的阿尔贝多算子, 需要推断介质的潜在散射和吸收系数。另一个显著的例子出现在地球物理学中的地震成像 (Yilmaz, 2011), 其中可观测量是源到接收器 (StR) 算子, 而任务是推断潜在的地下特性, 如波速或材料密度。在许多这些例子中, 只有当反问题被表述为从算子到函数的映射时, 其解才具有唯一性和稳定性。

由于大多数反问题具有非线性特征, 除了某些简单情况外, 通常无法获得解析解公式。相反, 通常采用基于偏微分方程 (PDE) 约束优化的迭代数值算法来近似求解 (Chavent, 2010)。这些算法反复调用前向和伴随 PDE 求解器, 以收敛至未知系数。然而, 可能需要大量迭代次数, 导致计算成本过高, 因为频繁调用 PDE 求解器非常昂贵, 尤其是在二维和三维空间维度中。此外, 这些迭代算法对初始系数的选择较为敏感。鉴于上述因素, 设计求解反问题的替代方法显得尤为迫切。

数据驱动的偏微分方程近似正迅速成为一种强大的范式。现有的大多数研究成果集中于偏微分方程的前向问题。一种特别流行的框架是算子学习, 其中旨在从数据中学习偏微分方程的潜在前向解算子。现有的算子学习方法包括深度算子网络 (DeepONet) (Lu et al., 2021; Mao et al., 2020; Cai et al.,

¹Seminar for Applied Mathematics (SAM), ETH, Zürich. ²Institute for Theoretical Studies (ITS), ETH Zürich. ³Department of Mathematics and the Oden Institute, The University of Texas at Austin, USA. ⁴ETH AI Center, ETH, Zürich. Correspondence to: Roberto Molinaro <roberto.molinaro@sam.math.ethz.ch>.

2021) 及其变体, 以及所谓的神经算子 (Kovachki et al., 2021b), 其中包括广泛应用的傅里叶神经算子 (FNO) 及其变体 (Li et al., 2021b; Pathak et al., 2022)。基于图神经网络的算法 (Boussif et al., 2022; Brandstetter et al., 2022) 也正作为一种替代方案逐渐兴起。

鉴于算子学习及其他基于深度学习的算法在偏微分方程前向问题中的广泛应用并取得显著成功, 自然地, 人们会探究这些方法从数据中学习对应逆问题解的可行性。然而, 这一任务极具挑战性, 因为现有的算子学习算法将函数映射为函数, 而上述逆问题仅能作为从算子到函数的映射来良好定义。因此, 需要对现有的算子学习架构进行非平凡的修改以处理逆问题。这正是本文的研究动机, 我们的主要贡献如下。

- 受所考虑的一类反问题潜在数学结构的启发, 我们提出了一种新颖的架构, 称为神经反算子 (NIOs), 用于从数据中学习这些反问题的解。NIOs 通过组合 (堆叠) 两种现有架构——DeepONet 和 FNO——来实现算子到函数的映射。
- 我们在一系列问题上对 NIO 进行了广泛测试, 包括 EIT 中的 Calderón 问题、用于目标检测的逆波散射、光学断层成像中吸收系数和散射系数的重建, 以及用于推断地下属性的地震波迁移。我们展示了 NIO 在所有这些基准上均显著优于基准方法。
- 由于 PDE 反问题对噪声和扰动具有固有的敏感性, 我们还通过实验表明, NIO 在这些因子以及传感器的数量和位置、潜在网格分辨率方面同样具有鲁棒性。此外, 我们还证明, 与基准方法不同, NIO 能够处理输入测量数量的波动, 并且在分布外的情况下仍能实现良好的泛化能力, 而准确率几乎没有下降。此外, 发现 NIO 的速度比传统 PDE 约束优化方法快几个数量级, 同时仍保持更高的准确率。

因此, 我们提出了一种新的学习框架, 用于快速、稳健且准确地求解偏微分方程逆问题。

2. 一类逆问题。

2.1. 数学框架。

设 $D \subset \mathbb{R}^d$ 为有界开集, 其边界 ∂D 光滑。令 $T > 0$ 和 $\Omega = D$ 或 $\Omega = D \times (0, T)$, 取决于该偏微分方程是否具有时间 (不) 依赖性。相应地, $\partial\Omega = \partial D$ 或 $\partial\Omega = \partial D \times (0, T)$, 分别对应。设 $a \in \mathcal{A}(D)$, 其中 $\mathcal{A}$ 表示定义在 D 上的适当函数空间, 为一个系数。则抽象的偏微分方程可表示为

$$\mathcal{D}_a(u) = s, \quad \mathcal{B}(u) = g, \quad (1)$$

其中, $u \in \mathcal{U}(\Omega)$ 为解, $s \in \mathcal{S}(\Omega)$ 为源项, $g \in \mathcal{G}(\partial\Omega)$ 为边界条件, 针对偏微分方程 (1)。此处, $\mathcal{D}_a : \mathcal{U} \mapsto \mathcal{F}$ 与 $\mathcal{B} : \mathcal{U} \mapsto \mathcal{G}$ 分别为微分算子和边界算子, $\mathcal{U}, \mathcal{S}, \mathcal{G}$ 为定义在其各自领域上的合适函数空间。

抽象偏微分方程 (1) 的正问题为: 给定系数 $a \in \mathcal{A}$ 、源项 $s \in \mathcal{S}$ 和边界条件 $g \in \mathcal{G}$, 求解偏微分方程 (1) 的解 $u \in \mathcal{U}$ 。通常, 人们不仅关心解本身, 还关心解的可观测量, 这些可观测量在实际中可以被测量。由于测量通常在边界上更容易进行, 因此一类特别相关的可观测量由以下边界观测算子给出,

$$\Lambda_a : \mathcal{G}(\partial\Omega) \mapsto \mathcal{H}(\partial\Omega), \quad (2)$$

将边界数据 $g \in \mathcal{G}(\partial\Omega)$ 映射为测量值 $\Lambda_a(g) = h(u) \in \mathcal{H}(\partial\Omega)$, 即定义在 $\partial\Omega$ 上的函数空间中的一个映射。因此, 对于固定的系数 a (以及源项 s), 求解正问题等价于求解偏微分方程 (1), 给定边界数据 g 以得到解 u , 然后对 u 进行后处理, 计算边界观测算子 $h(u) = \Lambda_a(g)$ 。因此, 可以将与偏微分方程 (1) 相关的正问题重写为该映射形式,

$$\mathcal{F} : \mathcal{A}(D) \mapsto \mathcal{L}(\mathcal{G}(\partial\Omega), \mathcal{H}(\partial\Omega)), \quad a \mapsto \mathcal{F}(a) = \Lambda_a, \quad (3)$$

其中 Λ_a 是边界观测算子 (2), $\mathcal{L}(X, Y)$ 表示函数空间 X 和 Y 之间的连续算子。

在实际应用中, 人们通常关注与偏微分方程 (1) 相关的逆问题。例如, 在层析成像 (医学影像) 中, 需要从解 u 的某些测量值推断未知系数 a 。一般而言, 该问题为不适定问题, 仅凭单次 (或少量) 边界条件 g 及其对应解 u 的测量值 $h(u)$, 不足以推断出潜

在的系数 a 。相反，许多深刻的数学成果已提供了合适的框架，使得此类逆问题可以成为适定的。正问题的逆映射形式如 (3) 所示

$$\mathcal{F}^{-1} : \mathcal{L}(\mathcal{G}(\partial\Omega), \mathcal{H}(\partial\Omega)) \mapsto \mathcal{A}(D), \Lambda_a \mapsto a = \mathcal{F}^{-1}(\Lambda_a), \quad (4)$$

该逆映射 $\mathcal{F}^{-1}$ 在一大类偏微分方程中的存在性，更关键的是唯一性，其严格的保证是反问题数学理论的一项杰出成就 (Isakov, 2017)。此外，通过证明如下形式的估计，还可以进一步表明反问题的 Lipschitz 或 Hölder-稳定性，

$$\|\mathcal{F}^{-1}(a) - \mathcal{F}^{-1}(\bar{a})\|_{\mathcal{L}} \sim \|a - \bar{a}\|_{\mathcal{A}}^{\alpha}, 0 < \alpha \leq 1. \quad (5)$$

在某些情况下，上述稳定性估计的右端项被替换为 $\|a - \bar{a}\|_{\mathcal{A}}$ 的对数，这仅能保证（弱）对数稳定性。

在介绍了这一抽象框架之后，我们提供了四个具体的偏微分方程反问题的例子（详见 SM 图3-8的图示），该抽象框架适用于这些例子。

2.2. 柯达尔松问题（电阻抗成像）.

令系数 $0 < a \in C^2(D)$ 表示潜在介质（领域 $D \subset \mathbb{R}^d$ ）的电导率，相应的偏微分方程 (1) 为以下椭圆方程，

$$\begin{aligned} -\nabla \cdot (a(z)\nabla u) &= 0, \quad z \in D, \\ u(z) &= g(z), \quad z \in \partial D, \end{aligned} \quad (6)$$

其中 Dirichlet 边界值 $g \in H^{\frac{1}{2}}(\partial D)$ 代表电压，电流源项为 $s = 0$ 。相关的边界观测算子 Λ_a 是著名的 *Dirichlet-to-Neumann* (DtN) 映射，

$$\begin{aligned} \Lambda_a : H^{1/2}(\partial D) &\mapsto H^{-1/2}(\partial D), \\ \Lambda_a[g] &= a \frac{\partial u}{\partial \nu} \Big|_{\partial D}, \quad \forall g \in H^{1/2}(\partial D), \end{aligned} \quad (7)$$

将输入电压 g 映射为边界处的电流 $a(z) \frac{\partial u}{\partial \nu} = a \nabla u \cdot \nu$ （其中 ν 为单位外法向量），而 u 是 (6) 的解。

反问题，常被称为 Calderón 问题，构成了 EIT (Uhlmann, 2009) 的基础。它旨在根据介质的不同 DtN（电压-电流）测量值来确定电导率 a 。因此，该反问题属于所考虑的抽象形式框架，反演映

射(4)由下式给出，

$$\begin{aligned} \mathcal{F}^{-1} : \mathcal{L}(H^{1/2}(\partial D), H^{-1/2}(\partial D)) &\mapsto C^2(D), \\ \mathcal{F}^{-1} : \Lambda_a &\mapsto a = \mathcal{F}^{-1}(\Lambda_a), \end{aligned} \quad (8)$$

其中 $\mathcal{L}(\cdot, \cdot)$ 表示相应的有界线性算子。该逆问题被证明是良定义的，并且具有（对数）稳定性 (Clop et al., 2010)。

2.3. 逆波散射。

在许多感兴趣的领域中，利用频域中的波传播来推断介质的材料特性，这些特性由平方慢度 $0 < a \in L^\infty(D)$ 描述。相关的偏微分方程是亥姆霍兹方程，

$$\begin{aligned} -\Delta u - \omega^2 a(z)u &= 0, \quad z \in D, \\ u(z) &= g(z), \quad z \in \partial D, \end{aligned} \quad (9)$$

对于某些频率 ω 和 Dirichlet 边界条件 $g \in H^{\frac{1}{2}}(\partial D)$ ，所得的边界观测算子仍然是 Dirichlet-to-Neumann (DtN) 映射

$$\begin{aligned} \Lambda_a : H^{1/2}(\partial D) &\mapsto H^{-1/2}(\partial D), \\ \Lambda_a[g] &= \frac{\partial u}{\partial \nu} \Big|_{\partial D}, \quad \forall g \in H^{1/2}(\partial D), \end{aligned} \quad (10)$$

其中 u 是方程 (9) 关于系数 a 的解。相应的反问题即是从 DtN 映射 (10) 推断波动系数 a 。因此，它可以类似地表述为反映射 (8)。其适定性和稳定性已在文献 (Nachman, 1988) 及其中参考文献中针对 Helmholtz 方程得到证明。

2.4. 辐射传输与光学成像。

在光学成像或层析成像中，介质的材料特性 $D \subset \mathbb{R}^d$ 用散射系数和吸收系数 $0 \leq a, \sigma_a \in C(D)$ 表示。相关的偏微分方程是粒子密度 $u(z, v)$ 在位置 $z \in D$ 和速度 $v \in V \subset \mathbb{R}^d$ 处的著名辐射传输方程 (RTE)，其表达式为

$$\begin{aligned} v \cdot \nabla_z u(z, v) + \sigma_a(z)u(z, v) &= \frac{1}{\varepsilon} a(z) \mathcal{Q}[u], \quad z \in D, \\ u(z, v) &= \phi(z, v), \quad z \in \Gamma_-, \end{aligned} \quad (11)$$

其中 $\mathcal{Q}[u] = \int k(v, v')u(z, v')dv' - u(z, v)$ 为碰撞项， ε 为克努森数， $\Gamma_{\pm} = \{(z, v) \in \partial D \times V : \pm n_z \cdot v \geq 0\}$

为流入（流出）边界， n_z 为 $z \in \partial D$ 处的单位外法向量。因此，该问题的输入由流入边界上的粒子密度 $u_{\Gamma_-} \in L^1(\partial D)$ 给出。相关的边界观测算子 Λ_a 定义在 (2)，称为 阿尔贝多算子，

$$\Lambda_a : L^1(\Gamma_-) \mapsto L^1(\Gamma_+), \Lambda_a : u|_{\Gamma_-} = \phi \mapsto u|_{\Gamma_+}, \quad (12)$$

将入射边界上的边界值 Γ_- 映射到流出边界 Γ_+ 上的观测边界值。

相应的反问题旨在从阿尔卑德算子的测量值推断由散射系数和吸收系数 a, σ_a 所表征的介质特性。它导致如下反演映射，

$$\begin{aligned} \mathcal{F}^{-1} : \mathcal{L}(L^1(\Gamma_-), L^1(\Gamma_+)) &\mapsto C(D), \\ \mathcal{F}^{-1} : \Lambda_a &\mapsto a = \mathcal{F}^{-1}(\Lambda_a). \end{aligned} \quad (13)$$

该逆映射的适定性及 Lipschitz 稳定性在 (Bal & Jollivet, 2008) 中得到证明。

2.5. 地震成像。

地震成像在地球物理学中被广泛应用于推断和重建地下介质的物性，以满足诸如 CO₂ 储存监测和地震灾害评估等多种应用需求。给定一个区域 $D \subset \mathbb{R}^d$ ，我们希望通过从上边界向介质发射声波，并在时域中测量响应，来重构速度系数 $0 < a \in L^\infty(D)$ 。相关的偏微分方程是声学波动方程，

$$u_{tt}(t, z) + a^2(z)\Delta u = s, \quad (z, t) \in D \times [0, T], \quad (14)$$

带有时间依赖的源项 s 。这里， u 为压力变化。波动方程补充了零初始条件，即 $u(\cdot, 0) = u_t(\cdot, 0) = 0$ 以及适当的边界条件。特别地，源被放置在边界的一个子集上，通常考虑点源 $s(t, z) = g(t)\delta_S(z)$ ，其中 $g(t) \in L^2([0, T])$ 与 $\delta_S(z)$ 为集中在集合 $S \subset \partial D$ 上的 Dirac 测度。这些波在介质中传播、反射和折射。在某些假设下（见 Symes (2009) 中第 2.3 节），有效源 s 可以按 $L^2([0, T] \times D)$ 处理，从而保证偏微分方程的适定性。所得信号在边界上的一组接收器 $\mathcal{R} \subset \partial D$ 处被记录，接收器对时间进行连续测量 $[0, T]$ 。该波动反问题的边界观测算子 (2) 为 源到接

收器 (StR) 算子，

$$\begin{aligned} \Lambda_a : L^2([0, T] \times D) &\mapsto L^2([0, T]; X_{\mathcal{R}}), \\ \Lambda_a : s &\mapsto u|_{[0, T] \times \mathcal{R}}, \end{aligned} \quad (15)$$

其中 $X_{\mathcal{R}}$ 是离散集 $\mathcal{R}$ 的度量空间。支撑地震成像的反问题为

$$\begin{aligned} \mathcal{F}^{-1} : \mathcal{L}(L^2([0, T] \times D), L^2([0, T]; X_{\mathcal{R}})) &\mapsto L^\infty(D), \\ \mathcal{F}^{-1} : \Lambda_a &\mapsto a = \mathcal{F}^{-1}(\Lambda_a), \end{aligned} \quad (16)$$

其中 Λ_a 为 StR 算子 (15)。因此，地震成像旨在从时空 StR 信号中推断地下介质的空间属性。该过程在文献中也称为 偏移，或 全波形反演 (FWI) (Deng et al., 2021)。尽管已有研究探讨了波动方程逆问题的适定性 (14) (Liu & Oksanen, 2016; Stefanov et al., 2016; Caday et al., 2019)，但这些结果并不直接适用于此处的 *Setting*。

3. 神经逆算子。

在本节中，我们介绍了所提出的神经逆算子 (NIOs) 的神经网络结构。

3.1. 学习任务与挑战。

前面一节中描述的四个例子都是 (4) 所总结的抽象框架的具体实例。因此，求解逆问题 (4) 归结为从相关数据中推断（学习）逆映射 $\mathcal{F}^{-1}$ 。在拥有足够训练数据的情况下，以数据对 $(\Lambda_a, \mathcal{F}^{-1}(\Lambda_a))$ 的形式（或在前向映射具有单射性的情况下，以数据对 (a, Λ_a) 的形式），我们旨在学习逆映射 $\mathcal{F}^{-1}$ 并在测试（未见过的）数据上进行评估。由于以下因子，这一任务极具挑战性：

1. 逆映射 $\mathcal{F}^{-1}$ (4) 的输入在边界 $\partial\Omega$ 上指定，而输出是定义在潜在域 D 内部的系数 a 。因此，逆映射 $\mathcal{F}^{-1}$ 的输入和输出在定义域上存在不匹配。
2. 学习任务要求我们学习从算子到函数的映射，这些映射是针对 (4) 中定义的 $\mathcal{F}^{-1}$ 。
3. 一般情况下，逆映射 $\mathcal{F}^{-1}$ (4) 可能仅是弱稳定的，例如，在 Hölder 指数 α 的值较小时 (5)，

甚至仅具有对数稳定性。在这些情况下，学习任务可能对输入中的噪声非常敏感，因此可能需要额外的正则化项。

3.2. 现有的算子学习架构。

在提出适用于学习逆映射 $\mathcal{F}^{-1}$ (4) 的合适架构之前，我们简要总结现有的算子学习架构，以检查它们在此情境下是否适用。为此，设 $D \subset \mathbb{R}^{d_x}, U \subset \mathbb{R}^{d_u}$ 、 $\mathcal{X} = \mathcal{X}(D)$ 和 $\mathcal{Y} = \mathcal{Y}(U)$ 为合适的函数空间。那么，一个 **DeepONet** (Lu et al., 2021) 是由 $\mathcal{N}^{\text{DON}} : \mathcal{X} \rightarrow \mathcal{Y}$ 给出的算子。

$$\mathcal{N}^{\text{DON}}(\bar{u})(y) = \sum_{k=1}^p \beta_k(\bar{u}) \tau_k(y), \quad \bar{u} \in \mathcal{X}, y \in U, \quad (17)$$

其中，**branch-net** β 是一个神经网络，将输入 $\bar{u}$ 在传感器点 $\mathbf{x} := (x_1, \dots, x_m) \in D$ 处的评估 $\mathcal{E}(\bar{u}) = (\bar{u}(x_1), \dots, \bar{u}(x_m)) \in \mathbb{R}^m$ 映射到 $\mathbb{R}^p$ ：

$$\beta : \mathbb{R}^m \rightarrow \mathbb{R}^p, \mathcal{E}(\bar{u}) \mapsto (\beta_1(\mathcal{E}(\bar{u})), \dots, \beta_p(\mathcal{E}(\bar{u}))), \quad (18)$$

并且 **主干网络** $\tau(y) = (\tau_1(y), \dots, \tau_p(y))$ 是另一个神经网络映射，

$$\tau : U \rightarrow \mathbb{R}^p, y \mapsto (\tau_1(y), \dots, \tau_p(y)). \quad (19)$$

因此，DeepONet 通过将分支网络（作为系数函数）与主干网络（作为基函数）相结合，实现了函数之间的映射。

另一方面，傅里叶神经算子 (**FNO**) $\mathcal{N}^{\text{FNO}}$ (Li et al., 2021a) 是一个复合结构

$$\mathcal{N}^{\text{FNO}} : \mathcal{X} \mapsto \mathcal{Y} : \mathcal{N}^{\text{FNO}} = Q \circ \mathcal{L}_T \circ \dots \circ \mathcal{L}_1 \circ R. \quad (20)$$

为简便起见，我们定义 $\mathcal{M} = Q \circ \mathcal{L}_T \circ \dots \circ \mathcal{L}_1$ ，和 $\mathcal{N}^{\text{FNO}} = \mathcal{M} \circ R$ ，其中 $R : (x, \bar{u}) \mapsto R(\bar{u}(x), x)$ 是一个“提升算子”，由线性变换 $R : \mathbb{R}^{d_u \times d} \rightarrow \mathbb{R}^{d_v}$ 表示， d_u 是输入函数的分量个数， d 是领域的维度， d_v 是“提升维度”（一个超参数）。算子 Q 是一个非线性投影，由浅层神经网络实现，使得 $v^{T+1}(x) \mapsto \mathcal{N}^{\text{FNO}}(\bar{u})(x) = Q(v^{T+1}(x))$ 。每个隐

藏层 $\mathcal{L}_\ell : v^\ell(x) \mapsto v^{\ell+1}(x)$ 的形式为

$$v^{\ell+1}(x) = \sigma(W_\ell \cdot v^\ell(x) + b_\ell(x) + (K_\ell v^\ell)(x)),$$

其中 $W_\ell \in \mathbb{R}^{d_v \times d_v}$ 为权重矩阵（残差连接）， $b_\ell(x) \in \mathbb{R}^{d_v}$ 为偏置函数， σ 为激活函数，以及非局部傅里叶层，

$$K_\ell v^\ell = \mathcal{F}_N^{-1}(P_\ell(k) \cdot \mathcal{F}_N v^\ell(k)),$$

其中 $\mathcal{F}_N v^\ell(k)$ 表示 $v^\ell(x)$ 的离散傅立叶变换 (DFT) 的 (截断)-傅立叶系数，该系数基于每个方向上给定的 N 网格值计算得到。这里， $P_\ell(k) \in \mathbb{C}^{d_v \times d_v}$ 是一个由 $k \in \mathbb{Z}^d$ 索引的复傅立叶乘法矩阵，而 $\mathcal{F}_N^{-1}$ 表示逆 DFT。

两种算子学习框架 (DeepONet 和 FNO) 及其变体均实现从函数到函数的映射。因此，它们无法直接用于学习逆映射 $\mathcal{F}^{-1}$ (4)，该映射将算子映射到函数。为此，我们需要对这些架构进行修改和调整，以学习逆映射。接下来的章节将介绍我们提出的方法。

3.3. 一个激励性的（形式上的）计算。

我们首先为所提出的架构学习逆映射 (4) 提供一个启发式的动机。为此，并为了明确起见，我们考虑亥姆霍兹方程 (9) 的逆波散射问题，如第 2.3 节所述。给定区域 $D \subset \mathbb{R}^d$ ，我们考虑如下具有诺伊曼边界条件的特征值问题，

$$\begin{aligned} -\Delta \varphi_k &= \lambda_k \varphi_k, \quad \forall z \in D. \\ \frac{\partial \varphi_k}{\partial \nu} \Big|_{\partial D} &= 0, \quad \int_D \varphi_k dz = 0. \end{aligned} \quad (21)$$

根据标准的偏微分方程理论 (Evans, 2010)，存在特征值 $0 \leq \lambda_k \in \mathbb{R}$ 对于 $k \in \mathbb{N}$ ，相应的特征函数 $\{\varphi_k\}$ 构成 $L^2(D)$ 的标准正交基。我们固定 $K \in \mathbb{N}$ 足够大，不失一般性，假设在亥姆霍兹方程 (9) 中 $\omega = 1$ ，以考虑以下狄利克雷边界值问题，

$$\begin{aligned} -\Delta u_k - a(z)u_k &= 0, \quad z \in D, \quad 1 \leq k \leq K, \\ u(z) &= g_k(z), \quad z \in \partial D, \end{aligned} \quad (22)$$

其中 $g_k = \varphi_k|_{\partial D}$ 。利用 (21) 和 (22)，我们在 **SM B** 中证明了以下针对所有 $1 \leq k \leq K$ 的形式化表

示公式,

$$\int_D a u_k \varphi_k dz = \int_D \lambda_k u_k \varphi_k dz - \int_{\partial D} g_k \frac{\partial u_k}{\partial \nu} d\sigma(z). \quad (23)$$

公式 (23) 可用于以如下方式构造对系数 $a \in L^2(D)$ 的近似。将 $a \approx \sum_{\ell=1}^K a_\ell \varphi_\ell$ (利用 φ 的标准正交性) 对于足够大的 K , 我们可以通过求解以下矩阵方程来计算系数 a_ℓ , 其中未知量为 $A = \{a_\ell\}_{\ell=1}^K$ 。

$$\begin{aligned} \mathbf{C}A &= B, \quad \mathbf{C}_{k\ell} = \int_D u_k \varphi_k \varphi_\ell dx, \quad \forall k, \ell, \\ B_k &= \int_D \lambda_k u_k \varphi_k dz + \int_{\partial D} g_k \frac{\partial u_k}{\partial \nu} d\sigma(z), \quad \forall k. \end{aligned} \quad (24)$$

进一步设定 $\Psi_k = \frac{\partial u_k}{\partial \nu}$, 我们观察到系数 a 的形式近似依赖于以下构建块,

- **基的构造:** 运算 $\mathcal{B}_k : z \mapsto (\varphi_k(z), \lambda_k)$, $1 \leq k \leq K$, 构成一组基。注意它们与系数 a 无关。
- **偏微分方程求解:** 对操作 $\mathcal{E}_k : (g_k, \Psi_k) \mapsto (\{u_j^k\}_{j=1}^K, \int_{\partial D} g_k \Psi_k d\sigma(z))$, 其相当于 (近似) 推断出给定 Dirichlet g_k 和 Neumann Ψ_k 边界值时 Helmholtz 方程 (22) 解 u_k 的系数。该操作还附带了右端项 B_k 的一部分。一旦计算出系数 u_j^k , 即可通过设定 $u_k \approx \sum_{j=1}^K u_j^k \varphi_j$, 利用基 $\{\varphi_k\}$ 迅速计算出 (22) 解的近似 u_k 。
- **混合模式:** 前两个操作仅限于单个模式, 即对每个 k , 针对 $1 \leq k \leq K$ 。然而, 为了构造 (24) 中的系数 $\mathbf{C}_{kl}$, 我们需要混合不同的模式。一种实现方法是通过乘法。我们将此操作记为 $\mathcal{M} : (\{\varphi_k\}_{k=1}^K, \{u_k\}_{k=1}^K) \mapsto (\{u_k \varphi_k \varphi_\ell\}_{k,\ell=1}^K, \{\lambda_k u_k \varphi_k\}_{k=1}^K)$ 。
- **逆矩阵:** 在最后一步中, 我们需要在 (24) 中构建矩阵 $\mathbf{C}$ 并 (近似) 求逆。此操作可通过 $\mathcal{J} : (\{u_k \varphi_k \varphi_\ell\}_{k,\ell=1}^K, \{\lambda_k u_k \varphi_k\}_{k=1}^K) \mapsto \sum_{j=1}^K a_j \varphi_j$ 概括, 其中 $A = \{a_j\}$ 是 (24) 的解。

3.4. 架构。

对于亥姆霍兹方程的逆映射 $\mathcal{F}^{-1}$ (4) 的形式近似, 通过公式 (23)-(24) 实现, 在实际应用中无法直接使用, 因为若不知道系数 a , 便无法求解偏微分方程 (22)。然而, 上述构建模块启发我们采用迭代不动点过程, 或在本研究中, 采用一种从数据中近似 $\mathcal{F}^{-1}$ 的学习算法。为此, 我们观察到基构造 $z \mapsto \varphi_k(z)$ 相当于 DeepONet (19) 的一个特定实例化, 而偏微分方程求解映射 $\mathcal{E}_k : (g_k, \Psi_k) \mapsto \{u_j^k\}_{j=1}^K$ 是 DeepONet (18) 的分支网络应用的一个特定实例。此外, 它们可以在 DeepONet (17) 中结合, 以近似偏微分方程 (22) 的解 u_k 。然而, DeepONet (17) 在其基函数上是线性的, 因此无法表示非线性模式混合算子 $\mathcal{M}$ 。相反, 可以通过将 DeepONet 的输出传递给 FNO (20) 的非线性层, 来实现这一点, 该 FNO (20) 同时也执行最终的逆运算算子 $\mathcal{J}$ 。

这些启发性考虑被推广到逆问题的抽象形式化 (4), 并促使我们提出将 DeepONets 与 FNO 进行组合 (堆叠), 从而得到如下映射,

$$\begin{aligned} \mathcal{N}_{NIO} : \left(\begin{array}{c} z \\ \{\Psi_\ell\}_{\ell=1}^L \end{array} \right) &\xrightarrow{\tau, \beta} \left(\begin{array}{c} \{\tau_k(z)\}_{k=1}^p \\ \{\beta_k\}_{k=1}^p \end{array} \right) \cdots \\ \cdots &\xrightarrow{\mathcal{N}^{DON}} \{f_\ell(z)\}_{\ell=1}^L \xrightarrow{R} h(z) \xrightarrow{\mathcal{M}} a^*(z), \end{aligned} \quad (25)$$

用于逼近抽象逆映射 $\mathcal{F}^{-1}$ (4)。其中, 线性映射 R 可以显式地定义为

$$h(z) = R(f_1, \dots, f_L, z) = \frac{1}{L} \sum_{\ell=1}^L D_\ell f_\ell + E z, \quad (26)$$

通过 $E, D_\ell \in \mathbb{R}^{d_v}$ 。换句话说, 输入 $z \in D$ 和 $\Psi_\ell = \Lambda_a(g_\ell)$ (2), 对于 $1 \leq \ell \leq L$, 分别输入到 DeepONet $\mathcal{N}^{DON}$ (17) 的主干网络和分支网络中, 以生成定义在潜在域内部的 L 表示 $\{f_\ell\}_{\ell=1}^L$ 。这些表示首先通过 R 进行线性变换, 得到 $h(z)$, 最后由 FNO 的非线性组件 $\mathcal{M}$ 进行混合, 从而得到对潜在系数 a^* 的近似。我们观察到, $\mathcal{N}^{NIO}$ (25) 中的 DeepONet $\mathcal{N}^{DON}$ 足够灵活, 能够处理定义在边界上的输入, 即 Ψ_ℓ , 并生成定义在潜在域内部的输出 f_ℓ 。

需要注意的是, 该模型仅以 z 和 $\{\Psi_\ell\}_{\ell=1}^L$ 作为输入, 而非 z 和输入输出对 $\{(g_\ell, \Psi_\ell)\}_{\ell=1}^L$ 。这一选择的动




Figure 1. 神经逆算子 (NIO) 架构的示意图, 其中 R 由公式 (27) 给出, 并采用随机批量处理。

机如下: 设 μ_g 为边界数据 g 上的潜在测度 (分布), 其中 $g_\ell \sim \mu_g$, 且 $\mu_\Psi = \Lambda_a \# \mu_g$ 表示在边界算子 Λ_a 作用下的像测度。因此, 对所有 $\ell = 1, \dots, L$, 有 $\Psi_\ell \sim \mu_\Psi$, 其中 $\{\Psi_\ell\}_{\ell=1}^L$ 代表近似 μ_Ψ 的经验分布。结合边界观测算子 (2) 的单射性, 这意味着 $\{\Psi_\ell\}_{\ell=1}^L$ 已足以提供关于算子 Λ_a 的统计信息, 前提是 μ_g 满足某些性质。我们记 L 为离散化测度 μ_Ψ 的样本数量, 或按惯例记为算子 Λ_a 的样本数量。

上述构造解决了第 3.1 节中的问题 (1)。然而, 以当前形式, 它未必满足问题 (2)。为了使模型能够有效处理 μ_Ψ 作为输入, 而非其某个特定的离散实现, 应满足以下理想性质:

- 该架构应表现出对输入测量值 $\{\Psi_\ell\}_{\ell=1}^L$ 的排列不变性, 因为它们是 μ_Ψ 的独立同分布样本。
- 学习框架必须能够处理具有任意样本大小 $\tilde{L}$ 的分布 μ_Ψ 的经验测度。特别是, 训练阶段和测试阶段的输入样本大小可以不同。
- 模型的性能应该独立于用于离散化 μ_Ψ 的样本大小 $\tilde{L}$ 。

为解决前两点, 我们可以通过对架构进行修改, 将线性变换 R 重新定义如下:

$$h(z) = R(f_1, \dots, f_L, z) = \frac{D}{L} \sum_{\ell=1}^L f_\ell + Ez, \quad E, D \in \mathbb{R}^{d_v} \quad (27)$$

为了确保性能与 $\tilde{L}$ 无关, 一种简单但低效的方法是为所有 $\tilde{L} = 2, \dots, L$ 构造出 $\{\Psi_\ell\}_{\ell=1}^{\tilde{L}}$ 的所有可能排列, 其大小为 $\hat{L}$, 并将它们作为输入提供给模型。然而, 受到机器学习中广泛使用的著名 袋装算法的启发, 我们提出了一种高效且新颖的方法来解决这一问题, 称之为 随机批量。在此方法中, 给定序列 $\{\Psi_\ell\}_{\ell=1}^L$, 在每次训练迭代中, 从集合 $\{2, \dots, L\}$ 中随机抽取一个整数 $\hat{L}$ 。然后, 从 $\{\Psi_\ell\}_{\ell=1}^L$ 中随机选取 $\hat{L}$ 个样本, 并将新序列 $\{\Psi_k\}_{k=1}^{\hat{L}}$ 在每次训练迭代中输入模型。

我们将具有线性变换 R 的架构 (25) (如 (27) 所给), 并结合 随机批量算法的模型, 称为 神经逆算子 (详见图 1 中该架构的示意表示)。

4. 实证结果。

我们通过以下基准偏微分方程反问题对 NIO 进行经验测试。训练的详细信息, 以及架构和超参数的选择, 均在 **SM D** 中给出。

在后续的实验, 我们选择两种模型作为基准。首先, 我们考虑一个以 CNN 作为分支网络的 DeepONet, 如 (17) 所示, 该模型在分支内部对输入函数进行混合。

$$\mathcal{N}_{DONet} : \begin{pmatrix} z \\ \{\Psi_\ell\}_{\ell=1}^L \end{pmatrix} \xrightarrow{\tau, \beta_{cqn}} \begin{pmatrix} \{\tau_k(z)\}_{k=1}^p \\ \{\beta_k\}_{k=1}^p \end{pmatrix} \xrightarrow{\mathcal{N}^{DON}} a^*(z). \quad (28)$$

其次，我们考虑一种全卷积的图像到图像神经网络架构（详细信息见 **SM D.1**）。该架构的一种变体已在地震成像（全波形反演）中使用过（Deng et al., 2021）。我们对该架构进行了显著扩展，以将其应用于抽象逆问题（4）。

4.1. EIT 的 Calderón 问题。

我们从计算域 $D = [0, 1]^2$ 上椭圆方程（6）的 Calderón 问题出发，源项为 $s = 0$ 。训练（及测试）数据通过从电导系数 a 的概率分布中采样生成。一旦抽取一个样本电导率，便从边界值的概率分布中抽取一组狄利克雷边界条件 $\{g_\ell\}_{\ell=1}^L$ 。对于每个 g_ℓ ，使用标准的五点有限差分法数值求解对应的椭圆方程，并在边界上评估电流 $\Psi_\ell = a \frac{\partial u}{\partial \nu}$ 。我们选择边界数据 g_ℓ ，其中 $1 \leq \ell \leq L = 20$ 为 $\cos(\omega(x \cos(\theta_\ell) + y \sin(\theta_\ell)))$ 的边界值，且 $\theta_\ell = \frac{2\pi\ell}{20}$ 。对于系数 a ，我们通过设置 $a(x, y) = \exp(\sum_{k=1}^m c_k \sin(k\pi x) \sin(k\pi y))$ ，从三角函数中采样，其中 $m = \text{mod}(\bar{m})$ ， $\bar{m} \sim \mathcal{U}([1, 5])$ 且 $\{c_k\} \sim \mathcal{U}([-1, 1]^m)$ 。所有模型均使用 4096 个训练系数样本进行训练，表 1 展示了 NIO（及基准模型）在 L^1 与 L^2 范数下的相对（百分比）测试误差（基于 2048 个测试样本）。如表所示，NIO 是表现最佳的模型，其误差几乎比次优的 FCNN 模型减少了一半。此外，NIO 的总误差非常小（ $< 1\%$ ）。

作为 EIT 的第二个实验，我们考虑了一个在文献（Muller & Siltanen, 2012）中提出的更实际的例子，其中作者使用体表电极对患者的心脏和肺部进行 EIT 成像建模。该不连续的心脏和肺部幻影如 **SM 图4**所示。潜在域是单位圆，椭圆方程（6）采用标准有限元方法求解。边界条件由 $g_\ell(\theta) = \frac{1}{2\pi} \exp(i2\pi\theta f_\ell)$ 给出，其中 $\ell = 1, \dots, 32$ 和 $f = [-16, \dots, -1, 1, 14, 15, 16]$ 。系数 a 通过在心脏和肺部配置的位置、形状以及电导率上添加 8% 白噪声来建模，该配置如 **SM 图4**所示。学习算子的输入是通过计算在频率 f 处的 PDE 解的诺伊曼迹与系数 a 对应的解的诺伊曼迹和单位系数 $a = 1$ 对应的解的诺伊曼迹之差的傅立叶变换得到的。同样，表1和2中展示的结果表明，NIO 模型表现最佳，且

重构误差极低，以高准确率解决了这一实际问题。相比之下，传统的直接方法如 D-bar 方法（Muller & Siltanen, 2012）在此数值反演测试中的误差较大，达到 8.75%（详见 **SM 第E.8节**）。

4.2. 逆波散射。

在此问题中，考虑在域 $D = [0, 1]^2$ 上的 Helmholtz 方程（9），任务是学习从分布中采样的系数， $a(x, y) = \sum_{k=1}^m \exp(-c(x - c_{1,k})^4 - c(y - c_{2,k})^4)$ ，其中 $c = 2 \times 10^4/3$ 。它表示一个具有方形包含物的均匀介质，这些包含物随机分布在域内（见 **SM 图 5**）。此处， $m = \text{mod}(\bar{m})$ ， $\bar{m} \sim \mathcal{U}([1, 4])$ 和 $\{(c_{1,k}, c_{2,k})\} \sim \mathcal{U}([0, 1]^{m \times 2})$ 。对于每次系数的抽取，均设定 20 个 Dirichlet 边界值，与带有三角函数系数的 EIT 实验完全相同。相应的（近似）Helmholtz 方程（9）解通过中心有限差分格式计算，并评估 Neumann 迹以表示 DtN 映射。我们使用 4096 个训练样本进行模型训练，并在包含 1600 个样本的测试集上展示相对（中位数）测试误差，结果见表 1。再次表明，NIO 是表现最佳的模型，其性能显著优于次优的 FCNN。

4.3. 辐射传输方程与光学成像。

接下来，我们考虑在域 $X \times V$ 内的辐射传输方程（11），其中 $X = [0, 1]$ 且 $V = [-1, 1]$ ， $\varepsilon = 1$ 。因此， $\Gamma_- = \{(0, v), v \in [0, 1]\} \cup \{(1, v), v \in [-1, 0]\}$ 。任务是从阿尔卑德算子（12）推断吸收系数和散射系数。为此，我们固定 $k(v, v') = 1$ 、 $\sigma_a = 1 - a$ 在（11）内，从分布 $a(x) = c\chi_{[-1/2, 1/2]}(rx - x_0) + 1$ 中抽取吸收系数 a ，其中 χ 表示特征函数，且 $c \sim \mathcal{U}([0.5, 1])$ 、 $x_0 \sim \mathcal{U}([0, 1])$ 及 $r \sim \mathcal{U}([0, 0.8])$ 。一旦系数被抽取，便在流入边界 Γ_- 上施加边界条件：若 $v_\ell > 0$ ，则设定 $\phi_\ell(0, v) = \exp(-200(v - v_\ell)^2)$ 且 $\phi_\ell(1, v) = 0$ ；若 $v_\ell < 0$ ，则设定 $\phi_\ell(0, v) = 0$ 且 $\phi_\ell(1, v) = \exp(-200(v - v_\ell)^2)$ ，其中 v_ℓ 为用于近似（11）、 $1 \leq \ell \leq 32$ 中积分项的第 ℓ 个求积点。随后，采用有限元方法对辐射传输方程进行逼近，得到的解 u_ℓ 在流出边界 Γ_+ 处求值，作为阿尔卑德算子（12）的输出。所有模型均在 4096 个训练样本上




Figure 2. 逆散射波。左图：测试中值 L^1 -误差与输入样本数 $\tilde{L}$ 的关系（左： $\tilde{L} < L$ ，右： $\tilde{L} > L$ ）。黑点表示训练样本数 L 。右图：真实值（左）、NIO 重构结果（中）以及使用 PDE 约束优化方法的重构结果（右），针对一个分布外的测试样本

进行训练，测试集包含 2048 个样本，其相对中位数测试误差如表 1 所示，表明 NIO 显著优于 FCNN 和 DeepONet，即使在潜在不连续吸收系数的情况下也表现出较低的测试误差。

4.4. 地震成像。

在最终测试中，我们通过考虑声学波动方程 (14) 在时空域 $[0, 1]^2 \times [0, T]$ 中来建模地震成像，当前任务是从源到接收器映射 (15) 学习潜在的平方慢度系数 a 。为此，我们从 (Deng et al., 2021) 中选择两类系数，即所谓的 *Style-A* 和 *CurveVel-A* 数据集。对于每个介质，波在垂直边界上的源位置 $(x_{s\ell}, 0)$ 生成，持续时间为 $\ell = 1, \dots, 5$ 。对应的声学波动方程使用有限差分法求解，并在垂直边界上的接收器处记录时间数据。我们遵循 (Deng et al., 2021) 并使用 55000 和 22000 个训练样本分别对 *Style-A* 和 *CurveVel-A* 数据集进行模型训练，并在表 1 中展示了测试集为 7000 和 6000 个样本时的（中位数）相对测试误差。从表中我们可以观察到，即使在这个问题上，NIO 要么优于 FCNN，要么与之相当。这一点尤其值得注意，因为 FCNN 架构已在 (Deng et al., 2021) 中被证明是该问题上的最先进机器学习模型之一。

4.5. NIO 的鲁棒性与计算效率。

在 SM E 中，我们进一步详细介绍了 NIO 的性能及其与所考虑基准方法在多个因子上的比较。此处，我们对这些结果进行简要总结。首先，反问题的特点是对外部扰动具有敏感性。因此，测试所提出的 NIO 框架对这些因子的鲁棒性至关重要。为此，我们在测试阶段向每个基准的输入添加噪声，并在 SM

表 8 中展示相应的测试误差，以观察到 NIO（以及基线方法）对该噪声不敏感。

接着，在 SM 表 9 中，我们绘制了当测试阶段潜在网格分辨率发生变化时各模型的测试误差，以观察到 NIO 对输入网格分辨率的变化不敏感。最后，在 SM 表 10 中，我们展示了当测试阶段输入传感器的位置随机选取（而非训练阶段位于均匀网格上）时的误差，以观察到 NIO 对该变化也具有鲁棒性。然而，相较于输入边界观测算子的离散化，这些因子在此情境下的影响较小。该离散化的关键要素是输入样本的数量。如前一节所述，NIO 的设计旨在对离散化边界观测算子的样本数量保持独立。我们针对反波散射问题进行了此项测试（其他基准详见 SM E.2），并在图 2 中展示了测试阶段输入样本数量减少（左侧）和增加（右侧）时的误差。我们清晰地看到，NIO 对此波动表现出极强的鲁棒性，而基线方法的表现则显著下降，测试误差几乎增加了一个数量级。这表明，NIO 真正学习到了潜在的逆映射，而不仅仅是其离散表示。最后，在 SM E.6 中显示，NIO 在多种问题上表现出极佳的分外泛化能力，显著优于基线方法。

我们通过将 NIO 与已建立的偏微分方程约束优化算法进行比较来结束本节。为此，我们考虑逆波散射基准的一个分布外示例，并在图 2（右）中对比了 NIO 与偏微分方程约束优化的结果（详见 SM E.8），观察到 NIO 在重建散射体方面远比偏微分方程约束优化更准确。NIO 的 L^1 -测试误差为 2.3%，而偏微分方程约束优化的测试误差为 11.1%。此外，NIO 的推理时间（在 CPU 上）不到 1 秒，相比之下，偏微分方程约束优化问题的单次 GPU 训练时间为 8.5 小时。因此，该实验展示了 NIO 的实际效

率：其精度高出 5 倍，同时速度比偏微分方程约束优化算法快 4 个数量级。

5. 相关工作

这里所考虑的 PDE 反问题类的现有方法包括所谓的直接方法，例如用于 EIT 的 D-bar 方法 (Isaacson et al., 2004) 和用于地震反演的所谓成像条件 (Claerbout, 1985)。迭代方法通过逼近不动点 (Bakushinsky & Kokurin, 2005) 也被使用，包括非常流行的基于梯度的 PDE 约束优化方法 (Chavent, 2010)。另一种方法属于反问题的贝叶斯公式化 (Tarantola, 2005; Stuart, 2010)，该方法同样能够量化解的不确定性。最后，直接从数据中学习某些 PDE 反演算子已被考虑在 (Maarten et al., 2022) 及其参考文献中。

Table 1. 不同基准和模型在测试样本上计算的相对中位数 L^1 -误差和 L^2 -误差，表现最佳的模型以粗体突出显示。

	DONet		FCNN		NIO	
	$L^1 \downarrow$	$L^2 \downarrow$	$L^1 \downarrow$	$L^2 \downarrow$	$L^1 \downarrow$	$L^2 \downarrow$
Calderón Problem Trigonometric	1.97%	2.36%	1.49%	1.82%	0.85%	1.05%
Calderón Problem Heart&Lungs	0.95%	3.69%	0.27%	1.62%	0.18%	1.16%
Inverse Wave Scattering	3.83%	7.41%	2.53%	7.55%	1.07%	2.94%
Radiative transport	2.35%	4.35%	1.46%	3.71%	1.1%	2.9%
Seismic Imaging CurveVel - A	3.98%	5.86%	2.65%	5.05%	2.71%	4.71%
Seismic Imaging Style - A	3.82%	5.17%	3.12%	4.63%	3.04%	4.36%

6. 讨论。

对于偏微分方程 (PDEs)，以抽象形式表示为 (1)，我们考虑一类广泛的逆问题，这些逆问题仅在潜在的逆算子 (4) 将算子 (边界观测算子 (2)) 映射到潜在系数 (一个函数) 时才有良好定义。由此产生的逆问题等价于从数据对 $(\Lambda_a, \mathcal{F}^{-1}(\Lambda_a))$ (代表观测算子) 中推断未知系数 a 。现有的算子学习框架，如 DeepONets (17) 和 FNOs (20)，仅能将函数映射到函数。因此，必须对其加以改进，使其能够学习算子与函数之间的映射，从而解决逆问题 (4)。为

此，我们提出了一种新颖的架构，称为神经逆算子 (NIO)，该架构基于 DeepONets 与 FNOs 的组合，并引入适当的架构先验 (R 的定义见 (27))，同时采用随机批量训练方法，以确保泛化误差对输入算子的不同离散化具有不变性。我们的架构设计受到逆映射潜在结构的启发。我们在多种基准逆问题上测试了 NIO。这些包括电导率断层成像中的 Calderón 问题、由亥姆霍兹方程建模的逆波散射模型、基于辐射传输方程的光学成像，以及使用声学波动方程的地震成像。在所有这些问题中，NIO 显著优于基准方法，并提供了准确且更为重要的是鲁棒的未知系数近似，误差极小 (参见 SM E)。最后，一系列实验还展示了 NIO 在不同因素下的鲁棒性，包括传感器位置的变化、网格分辨率的变化、噪声以及输入算子的离散化变化，同时具备出色的分布外泛化能力，并且比直接方法和基于 PDE 约束优化的算法更准确、快得多。由于这是首篇提出端到端机器学习框架以学习算子与函数之间映射的论文，因此存在多种可能的扩展方向。例如，可将其其他架构 (如最近提出的 LOCA (Kissas et al., 2022)、VIDON (Prasthofer et al., 2022)，或基于图形的方法 (Boussif et al., 2022; Brandstetter et al., 2022)) 适配到这一情境中。还需考虑更高维度 (特别是地震成像) 的问题，以探究 NIO 随问题规模增大时的扩展性能。最后，需要在 (Lanthaler et al., 2022; Kovachki et al., 2021a) 的精神指导下推导出近似界和普遍性结果，以使 NIO 建立在坚实的理论基础上。

致谢

我们谨向尼古拉斯·内尔森和托比亚斯·罗纳表示最诚挚的感谢，感谢他们提出的建设性意见。

参考文献

- Bakushinsky, A. B. and Kokurin, M. Y. *Iterative methods for approximate solution of inverse problems*, volume 577. Springer Science & Business Media, 2005.
- Bal, G. and Jollivet, A. Stability estimates in stationary inverse transport. *Inverse Problems & Imaging*, 2(4):427, 2008.
- Boussif, O., Assouline, D., Benabbou, L., and Bengio, Y. MAgNet: Mesh Agnostic Neural PDE solver. *arXiv preprint arXiv:2210.05495*, 2022.
- Brandstetter, J., Worrall, D. E., and Welling, M. Message Passing Neural PDE solvers. *arXiv preprint arXiv:2202.03376*, 2022.
- Caday, P., de Hoop, M. V., Katsnelson, V., and Uhlmann, G. Scattering control for the wave equation with unknown wave speed. *Archive for Rational Mechanics and Analysis*, 231(1):409–464, 2019.
- Cai, S., Wang, Z., Lu, L., Zaki, T. A., and Karniadakis, G. E. DeepM&Mnet: Inferring the electroconvection multiphysics fields based on operator approximation by neural networks. *Journal of Computational Physics*, 436:110296, 2021.
- Chavent, G. *Nonlinear least squares for inverse problems: theoretical foundations and step-by-step guide for applications*. Springer Science & Business Media, 2010.
- Claerbout, J. F. *Imaging the earth’s interior*, volume 1. Blackwell scientific publications Oxford, 1985.
- Clop, A., Faraco, D., and Ruiz, A. Stability of Calderón’s inverse conductivity problem in the plane for discontinuous conductivities. *Inverse Problems & Imaging*, 4(1):49, 2010.
- Deng, C., Feng, S., Wang, H., Zhang, X., Jin, P., Feng, Y., Zeng, Q., Chen, Y., and Lin, Y. OpenFWI: Large-Scale Multi-Structural Benchmark Datasets for Seismic Full Waveform Inversion. *arXiv preprint arXiv:2111.02926*, 2021.
- Evans, L. C. *Partial differential equations*, volume 19. American Mathematical Soc., 2010.
- Goodfellow, I., Bengio, Y., and Courville, A. *Deep learning*. MIT press, 2016.
- Isaacson, D., Mueller, J. L., Newell, J. C., and Siltanen, S. Reconstructions of chest phantoms by the D-bar method for electrical impedance tomography. *IEEE Transactions on medical imaging*, 23(7):821–828, 2004.
- Isakov, V. *Inverse Problems for Partial Differential Equations*. Springer, 2017.
- Kissas, G., Seidman, J. H., Guilhoto, L. F., Preciado, V. M., Pappas, G. J., and Perdikaris, P. Learning operators with coupled attention. *Journal of Machine Learning Research*, 23(215):1–63, 2022.
- Kovachki, N., Lanthaler, S., and Mishra, S. On universal approximation and error bounds for Fourier Neural Operators. *Journal of Machine Learning Research*, 22:Art–No, 2021a.
- Kovachki, N., Li, Z., Liu, B., Azizzadensheli, K., Bhattacharya, K., Stuart, A., and Anandkumar, A. Neural operator: Learning maps between function spaces. *arXiv preprint arXiv:2108.08481v3*, 2021b.
- Lai, R.-Y., Li, Q., and Uhlmann, G. Inverse problems for the stationary transport equation in the diffusion scaling. *SIAM Journal on Applied Mathematics*, 79(6):2340–2358, 2019.
- Lanthaler, S., Mishra, S., and Karniadakis, G. E. Error estimates for DeepONets: A deep learning

- framework in infinite dimensions. *Transactions of Mathematics and Its Applications*, 6(1):tnac001, 2022.
- Li, Z., Kovachki, N. B., Azizzadenesheli, K., Liu, B., Bhattacharya, K., Stuart, A., and Anandkumar, A. Fourier neural operator for parametric partial differential equations. In *International Conference on Learning Representations*, 2021a.
- Li, Z., Zheng, H., Kovachki, N., Jin, D., Chen, H., Liu, B., Azizzadenesheli, K., and Anandkumar, A. Physics-informed neural operator for learning partial differential equations. *arXiv preprint arXiv:2111.03794*, 2021b.
- Liu, S. and Oksanen, L. A Lipschitz stable reconstruction formula for the inverse problem for the wave equation. *Transactions of the American Mathematical Society*, 368(1):319–335, 2016.
- Lu, L., Jin, P., Pang, G., Zhang, Z., and Karniadakis, G. E. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3(3):218–229, 2021.
- Maarten, V., Lassas, M., and Wong, C. A. Deep learning architectures for nonlinear operator functions and nonlinear inverse problems. *Mathematical Statistics and Learning*, 4(1):1–86, 2022.
- Mao, Z., Lu, L., Marxen, O., Zaki, T., and Karniadakis, G. E. DeepMandMnet for hypersonics: Predicting the coupled flow and finite-rate chemistry behind a normal shock using neural-network approximation of operators. Preprint, available from arXiv:2011.03349v1, 2020.
- Muller, J. and Siltanen, S. *Linear and nonlinear inverse problems with practical applications*. SIAM, 2012.
- Nachman, A. Reconstructions from boundary measurements. *Ann. Math.*, 128(3):531–576, 1988.
- Pathak, J., Subramanian, S., Harrington, P., Raja, S., Chattopadhyay, A., Mardani, M., Kurth, T., Hall, D., Li, Z., Azizzadenesheli, K., Hassanzadeh, p., Kashinath, K., and Anandkumar, A. Fourcastnet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv preprint arXiv:2202.11214*, 2022.
- Prasthofer, M., De Ryck, T., and Mishra, S. Variable input deep operator networks. *arXiv preprint arXiv:2205.11404*, 2022.
- Stefanov, P., Uhlmann, G., and Vasy, A. On the stable recovery of a metric from the hyperbolic DN map with incomplete data. *Inverse Problems & Imaging*, 10(4):1141, 2016.
- Stuart, A. M. Inverse problems: a Bayesian perspective. *Acta numerica*, 19:451–559, 2010.
- Symes, W. W. The seismic reflection inverse problem. *Inverse problems*, 25(12):123008, 2009.
- Tarantola, A. *Inverse problem theory and methods for model parameter estimation*. SIAM, 2005.
- Uhlmann, G. Electrical impedance tomography and Calderón’s problem. *Inverse problems*, 25(12):123011, 2009.
- Yilmaz, O. *Seismic Data Analysis*. Society for exploration geophysicists, 2011.

补充材料：

用于求解偏微分方程逆问题的神经反向算子。

A. PDE 逆问题的描述。

在下述图表中，我们展示了正文中所考虑的不同偏微分方程逆问题。




Figure 3. 图示为具有三角函数系数的 EIT 卡尔德隆问题的典型输入（左）和输出（右）样本。输入为狄利克雷-诺伊曼（DtN）映射 (7)，此处以三个狄利克雷边界条件（电压）与电流对表示，输出为电导率系数 a 。




Figure 4. (Muller & Siltanen, 2012) 的不连续心肺幻影的 EIT 示意图。左图：通过 DtN（电压到电流）映射输入。右图：显示心肺幻影的电导率场。




Figure 5. 通过亥姆霍兹方程的逆波散射检测夹杂物的示意图。左图：通过 DtN 算子的 3 个样本表示的输入。右图：系数 a 。

B. 正文中的公式 (23) 的证明。

下面，我们证明正文中的表示公式 (23)。




Figure 6. 通过辐射传输方程实现最优成像的示意图。左图：输入为反照率算子 (12)，用流入边界与流出边界之间的三个映射表示。右图：输出为散射系数。




Figure 7. 地震成像示意图。左图：输入为从源到接收点的波场映射 (15)，表示由源产生的入射波在接收点记录的时序信号。右图：输出为速度系数，对应于 (Deng et al., 2021) 的 *Style A* 数据集。

证明. 将 u_k (方程 (22) 的解) 乘以式 (21) 并对空间积分, 得到,

$$\int_D u_k \Delta \varphi_k dz + \lambda_k \int_D \varphi_k dz = 0$$




Figure 8. 地震成像示意图。左图：输入为从源到接收点的波场映射 (15)，表示由源产生的入射波在接收点记录的时序信号。右图：输出为速度系数，对应于 *CurveVel A* 数据集的 (Deng et al., 2021)

对上述方程进行分部积分，并应用高斯-格林公式，可得，

$$-\int_D \langle \nabla u_k, \nabla \varphi_k \rangle dz + \int_{\partial D} u_k \underbrace{\frac{\partial \varphi_k}{\partial \nu}}_{=0} ds(z) + \lambda_k \int_D u_k \varphi_k dz = 0. \quad (29)$$

请注意，上述的 Neumann 边界条件来自 (21)。

类似地，将诺伊曼问题 (21) 的解 φ_k 与方程 (22) 相乘，并重复上述积分步骤，可得，

$$-\int_D \langle \nabla u_k, \nabla \varphi_k \rangle dz + \int_{\partial D} g_k \frac{\partial u_k}{\partial \nu} ds(z) + \int_D a(z) u_k \varphi_k dz = 0. \quad (30)$$

公式 (23) 通过从 (30) 中减去 (29) 得到。 $\square$

C. 心脏与肺部假体的数学描述

为了描述心脏和肺部的幻影，我们在域 D 上定义以下点集：

$$\begin{aligned} s_h &= \left\{ (x, y) \in D \text{ s.t. } \sqrt{e_{h,1}(x - c_{h,1})^2 + e_{h,2}(y - c_{h,2})^2} < 0.2 \right\} \\ s_{l_1} &= \left\{ (x, y) \in D \text{ s.t. } \sqrt{e_{l_1,1}((\cos(\alpha)x_1 + \sin(\alpha)x_2) - c_{l_1,1})^2 + e_{l_1,2}((-\sin(\alpha)x + \cos(\alpha)y) - c_{l_1,2})^2} < 0.5 \right\} \\ s_{l_2} &= \left\{ (x, y) \in D \text{ s.t. } \sqrt{e_{l_2,1}((\cos(\alpha)x_1 + \sin(\alpha)x_2) - c_{l_2,1})^2 + e_{l_2,2}((-\sin(\alpha)x + \cos(\alpha)y) - c_{l_2,2})^2} < 0.4 \right\} \end{aligned} \quad (31)$$

此处， $e_{h,1} = 0.8$ 、 $e_{h,2} = 1$ 、 $e_{l_1,1} = 3$ 、 $e_{l_1,2} = 1$ 、 $e_{l_2,1} = 3$ 和 $e_{l_2,2} = 1$ 分别表示描述心脏和肺部椭圆的偏心率。心脏和肺部的中心位置由 $c_{h,1} = -0.1$ 、 $c_{h,2} = 0.4$ 、 $c_{l_1,1} = 0.5$ 、 $c_{l_1,2} = 0.2$ 、 $c_{l_2,1} = -0.6$ 和 $c_{l_2,2} = 0.1$

给出，肺部的方向由 $\alpha = \frac{\pi}{7}$ 给出。随后，体导电性定义为，

$$a(x, y) = \begin{cases} a_h & (x, y) \in s_h \\ a_{l_1} & (x, y) \in s_{l_1} \\ a_{l_2} & (x, y) \in s_{l_2} \\ a_b & \text{else} \end{cases}$$

使用 $a_h = 2$ 、 $a_{l_1} = a_{l_2} = 0.7$ 、 $a_b = 1$ 。

训练系数是通过对上述所有参数添加 8% 白噪声获得的。具体而言，给定 $y = [e_{h,1}, e_{h,2}, e_{l_1,1}, e_{l_1,2}, e_{l_2,1}, e_{l_2,2}, c_{h,1}, c_{h,2}, c_{l_1,1}, c_{l_1,2}, c_{l_2,1}, c_{l_2,2}, a_h, a_{l_1}, a_{l_2}]$ ，我们将参数向量 y 的扰动版本定义为 $\tilde{y} = y(1 + 0.08\xi)$ ，其中 $\xi \sim \mathcal{N}(0, 1)$ 是从标准正态分布中抽取的随机变量。该系数随后定义为：

$$\tilde{a}(x, y) = \begin{cases} \tilde{a}_h & (x, y) \in \tilde{s}_h \\ \tilde{a}_{l_1} & (x, y) \in \tilde{s}_{l_1} \\ \tilde{a}_{l_2} & (x, y) \in \tilde{s}_{l_2} \\ \tilde{a}_b & \text{else} \end{cases}$$

其中， $\tilde{s}_h$ 、 $\tilde{s}_{l_1}$ 和 $\tilde{s}_{l_2}$ 定义如上，但参数替换为 $\tilde{y}$ 中对应的扰动值。

D. 架构和训练细节

以下将讨论模型架构和训练的详细信息。本文实验的实现基于 PyTorch 框架，相关代码已公开。

■ <https://github.com/mroberto166/nio.git>

D.1. 架构详情

D.1.1. 前馈稠密神经网络

给定一个输入 $y \in \mathbb{R}^m$ ，前馈神经网络（也称为多层感知机）通过一层单元（神经元）将其转换为输出，这些单元由层间单元之间的仿射线性映射或单元内的标量非线性激活函数组成 (Goodfellow et al., 2016)，从而得到表示，

$$u_\theta(y) = C_{L_t} \circ \sigma \circ C_{L_t-1} \dots \circ \sigma \circ C_2 \circ \sigma \circ C_1(y). \quad (32)$$

此处， $\circ$ 表示函数的复合，而 σ 是一个标量（非线性）激活函数。对于任意 $1 \leq \ell \leq L_t$ ，我们定义

$$C_\ell z_\ell = W_\ell z_\ell + b_\ell, \text{ for } W_\ell \in \mathbb{R}^{d_{\ell+1} \times d_\ell}, z_\ell \in \mathbb{R}^{d_\ell}, b_\ell \in \mathbb{R}^{d_{\ell+1}}, \quad (33)$$

并记作，

$$\theta = \{W_\ell, b_\ell\}_{\ell=1}^{L_t}, \quad (34)$$

为网络的（可调）权重的连结集合。因此，在机器学习术语中，前馈神经网络 (32) 由一个输入层、一个输出层以及 L_t 个隐藏层组成，每个隐藏层包含 d_ℓ 个神经元， $1 < \ell < L_t$ 。在所有数值实验中，DeepONet 的主干网络是一个前馈神经网络。此外，我们考虑网络中所有层具有均匀数量的神经元 $d_\ell = d_{\ell-1} = d$ ， $1 < \ell < L_t$ 。

D.1.2. 全卷积神经网络

全卷积神经网络是一类特殊的卷积网络，可以在几乎任意输入分辨率下进行评估。我们在表1所展示的结果中将其用作偏微分方程反问题的强基准。这些网络由一个编码器和一个解码器组成，两者均由线性与非线性变换的组合定义：

$$\begin{aligned} E_{\theta_e}(y) &= C_L^e \circ \sigma \circ C_{L-1}^e \dots \circ \sigma \circ C_2^e \circ \sigma \circ C_1^e(y), \\ D_{\theta_d}(z) &= C_L^d \circ \sigma \circ C_{L-1}^d \dots \circ \sigma \circ C_2^d \circ \sigma \circ C_1^d(z), \\ u_{\theta}(y) &= D_{\theta_d} \circ E_{\theta_e}(y). \end{aligned} \quad (35)$$

仿射变换 C_ℓ 通常在编码器中对应于 卷积操作，在解码器中对应于 转置卷积（也称为 反卷积）。

卷积（反卷积）使用核 $W_\ell \in \mathbb{R}^{k_\ell \times k_\ell}$ 、步幅 s 和填充 p 执行。其输入为一个张量 $z_\ell \in \mathbb{R}^{w_\ell \times h_\ell \times c_\ell}$ ，其中 c_ℓ 表示输入通道数，并计算 $z_{\ell+1} \in \mathbb{R}^{w_{\ell+1} \times h_{\ell+1} \times c_{\ell+1}}$ 。因此，卷积（反卷积）仿射变换可唯一地由元组 $(k_\ell, s, p, c_\ell, c_{\ell+1})$ 确定。

用于基准问题的卷积架构的可视化表示如图 9、10、11、12 所示。卷积块（或 转置卷积块）由卷积（或转置卷积）操作、批量规范化和激活函数（Leaky ReLU）组成。裁剪操作涉及在张量边缘添加负填充，以实现所需的输出宽度和高度。通道数 c 通过交叉验证选定。用于地震成像的架构在 (Deng et al., 2021) 中被称为 InversionNet。




Figure 9. 用于柯达罗问题（具有三角系数）及亥姆霍兹方程的逆波散射问题的全卷积神经网络（FCNN）架构的示意表示。

D.1.3. 深度 ONET

分支和主干的架构根据所处理的基准进行选择。特别是，在所有实验中，我们采用标准的前馈神经网络作为主干网络。相比之下，分支由全卷积网络的编码器（如图 9、10、11 和 12 所示）与从 $\mathbb{R}^n$ 到 $\mathbb{R}^p$ 的线性变换组合而成，其中 n 表示编码器最后一层的通道数， p 表示基函数的数量。此外，地震成像使用 $c = 32$ ，其余所有基准使用 $c = 64$ 。

因此，分支的架构是固定的。主干隐藏层的数量 L_t 、单元数 d 以及 p 通过交叉验证来选择。另一方面，分支和主干的激活函数 σ 均选择为 Leaky ReLU。




Figure 10. 用于心脏和肺部幻影的 Calderón 问题光学成像的全卷积神经网络结构的示意图。




Figure 11. 用于辐射传输方程光学成像的全卷积神经网络结构示意图。




Figure 12. 用于地震成像问题的全卷积神经网络结构示意图。




Figure 13. NIO-BranchNet 架构的示意图，用于具有三角系数的 Calderón 问题以及亥姆霍兹方程的逆波散射问题




Figure 14. 用于辐射传输方程与心脏和肺部幻影的 Calderón 问题的光学成像的 NIO-BranchNet 架构示意图。




Figure 15. 用于地震成像的 NIO-BranchNet 架构的示意图。

D.1.4. 傅里叶神经算子

我们使用了 (Li et al., 2021a) 提供的 FNO 模型实现。具体来说，投影 Q 到目标空间是通过一个浅层神经网络完成的，该网络包含一个隐藏层，其中有 128 个神经元和 $GeLU$ 激活函数。所有傅里叶层也使用相同的激活函数。此外， $b_\ell(x) = 0$ 对所有 $\ell = 1, \dots, T$ 成立，残差连接中使用的权重矩阵 W_ℓ 来自由 $(k_\ell = 1, s = 1, p = 0, c_\ell = d_v, c_{\ell+1} = d_v)$ 定义的卷积层，对所有 $1 < \ell < T$ 成立。

D.1.5. 神经逆算子

在所有数值实验中，所提出的架构通过将 DeepONet 与傅里叶神经算子结合，并利用方程 (27) 中定义的提升算子 R 构建。

DeepONet 的实现遵循第 D.1.3 节中的描述。然而，分支结构与图 9、10、11 和 12 中所示的编码器结构不同。在所提出的 NIO 架构中，通道混合通过算子 $\mathcal{M}$ 在下游执行。关于 NIO 在基准问题中使用的分支网络架构的具体细节，可在图 13、14 和 15 中找到。例如，对于地震成像问题，分支架构与图 12 所示的编码器相同，但仅使用单个输入通道，而非五个通道，这与上述理由一致。

总体而言，该模型包含以下超参数：DeepONet 主干的层数 L_t 与神经元数 d ，基函数数量 p 以及提升维度 d_v ，FNO 的傅里叶层数量 T 与（截断）傅里叶系数数量 k 。

D.2. 训练细节

模型的训练（包括基准模型）使用 ADAM 优化器，学习率为 η ，进行 1000 轮次（地震成像问题中为 250 轮次），并最小化 L^1 损失函数。我们还使用了分步学习率调度器，每轮次将每个参数组的学习率降低因子 γ 。模型在批量大小为 256 的迷你批次中进行训练，并采用权重衰减幅度为 w 。此外，训练前对输入和输出数据使用适当的映射进行变换。注意，表 1 中报告的测试误差是在未变换的输出数据上获得的。我们考虑两种不同的数据变换来预处理数据：

1. *MinMax*。此变换涉及将输入和输出都缩放到 -1 到 1 之间的值域：

$$\tilde{f} = 2 \frac{f - m}{M - m} - 1, \quad (36)$$

其中 M 和 m 分别是 f 在所有训练样本中的最大值和极小点。

2. *log-MinMax*。此变换专门用于地震成像问题。输入数据根据以下公式进行变换：

$$\tilde{f} = \log(|f|) \operatorname{sign}(f), \quad (37)$$

然后，将获得的输入和输出在 -1 到 1 之间进行缩放。

上述提到的所有参数，包括数据转换类型（*Identity*、*MinMax*、*log-MinMax*），均通过交叉验证选择。

每轮次，都在验证集上计算相对 L^1 误差，并保存整个过程中产生最低误差的可训练参数集合以用于测试。若最佳验证误差在 50 个轮次内未得到改善，则使用早停机制中断训练。

通过在选定的超参数值域内进行随机搜索，并选择在验证集上实现最低相对 L^1 误差的配置，完成交叉验证。总体而言，NIO 测试了 50 种超参数配置，而基准模型测试了 30 种。本次搜索覆盖的模型大小（可训练参数的极小点和极大点）如表 2 所示。

随机搜索的结果，即每个模型和每个基准表现最佳的超参数配置，报告在表格 3、4 和 5 中。表中针对地震成像问题报告的 FCNN 超参数是 (Deng et al., 2021) 中所使用的。

D.2.1. 可训练参数初始化的敏感性

接下来，我们考虑与表 5 中报告的超参数相对应的最佳性能的 NIO 模型。随后，我们使用模型参数的多次初始化重新训练该模型，每个模型总共训练 10 次。表 6 展示了在各种基准实验中，10 次测试中位误差的均

	Calderón Problem Trigonometric	Calderón Problem Heart&Lungs	Inverse Wave Scattering	Radiative Transport	Seismic Imaging CurveVel - A	Seismic Imaging Style - A
DONet	4.6M	4.6M	9.54M	9.54M	12.01M	12.01M
	9.07M	9.07M	14.01M	14.01M	15.85M	15.85M
FCNN	1.07M	1.07M	4.31M	2.48M	24.4M	24.4M
	68.32M	68.32M	275.37M	39.53M	24.4M	24.4M
NIO	7.95M	10.6M	7.95M	9.6M	13.07M	13.07M
	27.79M	50.76M	27.79M	10.3M	32.91M	32.91M

Table 2. 极小点（顶子行）和极大点（底子行）：在主文中表 1 报告的每个问题中，所有模型在随机搜索超参数配置下的可训练参数数量的最小值和最大值。

	η	γ	w	Data Trans	p	L_t	d	Trainable Params
Calderón Problem Trigonometric	0.001	1.0	0.0	Identity	25	8	200	4.84M
Calderón Problem Heart&Lungs	0.001	1.0	0.0	MinMax	100	15	500	13.1M
Inverse Wave Scattering	0.001	1.0	1e-06	Identity	1000	12	500	8.32M
Radiative transport	0.001	1.0	0.0	MinMax	100	15	500	13.1M
Seismic Imaging CurveVel - A	0.001	0.98	1e-06	log-MinMax	400	12	500	15.09M
Seismic Imaging Style - A	0.001	0.98	1e-06	log-MinMax	400	12	500	15.09M


Table 3. 用于不同基准问题的 DeepONet 最佳超参数配置。

值和标准差。


从表6所示的结果可以看出，NIO 在随机初始化方面表现出显著的鲁棒性，对于所选基准，其标准差与均值之比显著偏低。然而需要注意的是，带有三角函数的 Calderón 问题是一个例外，其对模型参数的不同初始化表现出较强的敏感性。

D.2.2. 对训练样本数量的敏感性


再次，我们回顾了在不同基准问题中表现最佳的 NIO 架构，并重点关注训练样本数量的变化以及相应地重新训练选定的模型。随后，我们在图16 中绘制了测试误差的中位数随训练集基数变化的情况。我们观察到，即使在 512 个训练样本的情况下，除了逆波散射问题外，其他模型的准确率依然非常令人满意。应当注意到，这些基准所使用的训练样本数量与该背景下最先进的数据驱动模型相比极为有限。




(a) Calderón Problem 三角函数



(b) Calderón 问题心脏 & 肺



(c) 逆波散射



(d) 辐射传输

Figure 16. 不同基准下，基于 NIO 的测试样本的 L^1 -误差中位数随训练样本数量的变化。

	η	γ	w	Data Trans	c	Trainable Params
Calderón Problem Trigonometric	0.001	1.0	0.0	MinMax	16	1.07M
Calderón Problem Heart&Lungs	0.001	1.0	0.0	MinMax	128	275.37M
Inverse Wave Scattering	0.001	1.0	0.0	MinMax	128	68.32M
Radiative transport	0.001	1.0	1e-06	MinMax	16	2.48M
Seismic Imaging CurveVel - A	0.001	1	1e-04	log-MinMax	64	24.4M
Seismic Imaging Style - A	0.001	1	1e-04	log-MinMax	64	24.4M

Table 4. 针对不同基准问题，性能最佳的全卷积神经网络超参数配置。




Figure 17. 确切的和预测的系数针对两个不同的测试样本（行）的 Calderón 问题，具有三角函数系数。左列：真实值。中列：NIO 重构。右列：FCNN 重构。

	η	γ	w	Data Trans	p	L_t	d	k	d_v	L	Trainable Params
Calderón Problem Trigonometric	0.001	1.0	1e-06	Identity	100	8	100	25	32	4	12.06M
Calderón Problem Heart&Lungs	0.001	1.0	1e-06	MinMax	100	8	100	25	32	4	14.74M
Inverse Wave Scattering	0.001	0.98	0.0	Identity	100	8	200	16	64	4	15.57M
Radiative transport	0.001	0.98	1e-06	MinMax	400	4	100	32	64	4	10.3M
Seismic Imaging CurveVel - A	0.001	0.98	1e-06	MinMax	25	4	200	16	32	3	16.49M
Seismic Imaging Style - A	0.001	0.98	1e-06	log-MinMax	100	8	200	16	64	2	16.49M

Table 5. 神经逆算子在不同基准问题上表现最佳的超参数配置。

Calderón Problem Trigonometric	Calderón Problem Heart&Lungs	Inverse Wave Scattering	Radiative Transport
1.03 $\pm$ 0.45%	0.19 $\pm$ 0.03%	1.08 $\pm$ 0.16%	1.14 $\pm$ 0.18%

Table 6. 均值 $\pm$ 标准差的相对中位数 L^1 测试误差，基于不同基准的 10 次不同的 NIO 重新训练计算得出。

E. 进一步的实验结果

E.1. 表 1 中所报告结果的图示。

我们首先详细阐述在基准测试中获得的结果，这些结果如表1所示。在图17中，我们展示了通过电阻率断层成像（EIT）反演具有三角函数系数的电导率时，从 Calderón 问题中随机抽取的两个测试样本。对于这两个测试样本，我们观察到 NIO（以及 FCNN）能够准确逼近真实值，且没有任何可见伪影。这一现象与 NIO 极小的测试误差相吻合。至少对于这两个样本而言，NIO 与 FCNN 之间似乎几乎没有可见差异。然而，表1中的结果表明，NIO 在此问题上显著优于 FCNN，测试误差几乎降低了一半。

接下来，在图26中，我们关注通过 EIT 重建的不连续心肺幻象。同样地，在此情况下，NIO 与 FCNN 之间在视觉上没有差异，两者在重构真实值方面都非常准确，这确实与两个模型所达到的极低泛化误差一致。

在图19中，我们展示了逆波散射问题中两个随机选取的测试样本的结果，并将真实值与 NIO 和 FCNN 的重构结果进行了比较。在第一个样本（上行）中，两种模型都能准确重构真实值系数，两种模型之间的差异几乎不可见。相比之下，在第二个样本中，NIO 和 FCNN 的重构结果存在明显差异。特别是，FCNN 无法重构位于方阵域右上角的小矩形散射体，而 NIO 可以成功重构该散射体。这可能解释了为何在此实验中，NIO 在重构散射体方面显著更准确（参见表1）。

在图 20 中，我们绘制了两个随机选择的测试样本，以通过光学成像恢复辐射传输方程 (11) 的吸收系数。展示了真实值以及使用 NIO 和 FCNN 得到的重构结果。对于第一个测试样本，两种模型均可提供准确的重构，能够清晰分辨吸收系数中不连续性的尖锐特征。另一方面，对于第二个样本（图 20 右侧），我们发




Figure 18. 两个不同测试样本（行）的确切系数与预测系数（卡尔达隆问题，心脏与肺部幻影）。左列：真实值。中列：NIO 重构。右列：FCNN 重构。

现 FCNN 虽然得到了正确的不连续位置，但其幅度错误，而 NIO 则能同时准确逼近两者，这可能解释了该问题上准确率的显著提升（见正文表 1）。

在图 21 和 22 中，我们展示了两个随机选取的测试样本，用于通过声学波方程 (14) 进行地下属性（平方慢度）的地震成像，分别对应于 *CurveVel-A* 和 *Style A* 数据集（如 (Deng et al., 2021) 所考虑）。两幅图均表明，NIO 和 FCNN 能够合理准确地重建系数，尽管模型之间存在细微差异。然而，结合表 1 中的定量结果，我们可以得出结论：NIO 至少与 FCNN 相当，而 FCNN 在此背景下被证明是最先进的模型之一 (Deng et al., 2021)。

E.2. 重构对 Λ_a -离散化的鲁棒性。

如第 3.4 节所述，模型应具备的一个关键特性是对于用于近似推送测度 μ_Ψ 的样本数量 $\tilde{L}$ 具有鲁棒性。为评估这一点，我们进行了两项不同的实验。

在第一个实验中，我们考虑用于计算主表格 1 中报告误差的测试集，该测试集由输入输出对 $(\{\Psi_\ell\}_{\ell=1}^L, a)$ 组成。对于每个模型（NIO 和基准）以及每个基准，我们通过从 $\{\Psi_\ell\}_{\ell=1}^L$ 随机选取 $\tilde{L}$ 个样本， $\tilde{L} \leq L$ 构造一个新的测试集，并计算相应的测试误差。需要指出的是，NIO 可以直接对任意输入 $\{\Psi_k\}_{k=1}^{\tilde{L}}$ 进行评估，




Figure 19. 两个不同测试样本（行）在亥姆霍兹方程逆波散射中的确切值与预测系数。左列：真实值。中列：NIO 重构结果。右列：FCNN 重构结果。






Figure 20. 通过光学成像获得的辐射传输方程下，两种不同测试样本的确切和预测吸收系数。




(a) 测试样本 1




(b) 测试样本 2

Figure 21. 两个不同测试样本（行）的准确系数与预测系数（地震成像，声学波方程，*CurveVel A* 数据集）。左列：真实值。中列：NIO 重构。右列：FCNN 重构。



(a) 测试样本 1



(b) 测试样本 2

Figure 22. 确切的和预测的系数针对两种不同的测试样本（行）的地震成像，使用声学波方程与 *Style A* 数据集。左列：真实值。中列：NIO 重构。右列：FCNN 重构。

	DONet		FCNN		NIO	
	$L^1 \downarrow$	$L^2 \downarrow$	$L^1 \downarrow$	$L^2 \downarrow$	$L^1 \downarrow$	$L^2 \downarrow$
Calderón Problem	1.3%	1.58%	1.08%	1.33%	0.56%	0.7%
Trigonometric	3.19%	3.75%	2.24%	2.7%	1.21%	1.47%
Calderón Problem	0.87%	3.32%	0.25%	1.37%	0.16%	0.88%
Heart&Lungs	1.42%	4.11%	0.44%	3.5%	0.2%	1.53%
Inverse Wave Scattering	2.28%	4.37%	0.84%	2.08%	0.3%	1.08%
	5.55%	11.0%	4.98%	13.47%	2.15%	5.92%
Radiative transport	1.56%	2.72%	1.0%	2.02%	0.74%	1.82%
	3.38%	6.5%	2.26%	6.0%	1.63%	4.86%
Seismic Imaging	3.25%	4.79%	2.01%	3.98%	2.16%	3.83%
CurveVel - A	4.93%	7.4%	3.53%	6.52%	3.36%	5.81%
Seismic Imaging	2.97%	4.02%	2.39%	3.49%	2.4%	3.4%
Style - A	4.88%	6.61%	4.1%	6.09%	3.83%	5.6%

Table 7. 不同基准和模型在测试样本上计算的相对 L^1 -误差和 L^2 -误差的 0.25 和 0.75 分位数。

且无需改变其架构。而为了评估基准方法，必须使用插值（我们选择最近邻插值）来获得恰好包含 L 个样本的输入。


在图 23 中，我们绘制了不同模型和基准下，中位数 L^1 -误差随样本数量 $\tilde{L}$ 变化的函数关系。我们观察到，NIO 的性能相对于 $\tilde{L}$ 保持不变，测试误差仅在 $\tilde{L}$ 减少时表现出轻微增加，这通常是预期的，因为随着样本数量减少，测度 μ_Ψ 对经验分布的近似会变得不准确。相比之下，当样本数量 $\tilde{L}$ 非常接近训练集大小时，基准方法的性能仍然显著下降。这表明基准方法对样本的排列 $\{\Psi_\ell\}_{\ell=1}^L$ 并不具有不变性。

接下来，我们考虑带有三角函数的 Calderón 问题以及逆波散射问题。我们从头开始生成一个新的测试集，该测试集由输入输出对 $(\{\Psi_\ell\}_{\ell=1}^L, a)$ 组成，其中 $L = 100$ （相较于用于模型训练的 $L = 20$ 个样本）。随后，我们进行与之前相同的实验，并在图 24 中展示结果。这些结果进一步证实了 NIO 对于输入测度 μ_Ψ 的离散化具有不变性。


E.3. 重构对噪声的鲁棒性

反问题，例如抽象的偏微分方程反问题 (4)，对噪声非常敏感，正如稳定性估计 (5) 所示，重构方法必须在面对噪声测量时表现出一定的鲁棒性，才能在实际中具有应用价值。为了测试 NIO（以及对比模型）对噪声的鲁棒性，我们采用正文表 1 中报告的所有基准测试问题，并在测试时向每个模型的输入添加 1% 噪声。表 8 展示了由此产生的测试误差。该表表明，NIO（以及 DONet 和 FCNN）对这种测量噪声具有很强的鲁棒性。


此外，通过更仔细地分析结果可以明显看出，对额外噪声表现出最高鲁棒性的模型是使用 *log-MinMax* 数据缩放变换训练得到的。为了验证这一观察结果，我们考虑逆波散射问题，并使用表 5 中报告的超参数训练 NIO，但采用数据的 *log-MinMax* 缩放。此外，我们不再监控在无噪声数据上计算的验证误差，而是监控在受 10% 噪声污染的数据上计算的验证误差，并根据该指标中断训练。最终在 1% -噪声数据上的中位测试误差为 1.64%，比表 8 中报告的数值低两倍。此外，无噪声数据上的测试误差仅略有增加至 1.61%。这些




(a) Calderón Problem 三角函数




(b) Calderón 问题心脏 & 肺




(c) 逆波散射



(d) 辐射传输




(e) 地震成像曲线速度 - A




(f) 地震成像速度模型 - A

Figure 23. 在不同基准和模型下，对测试样本 $(\{\Psi_k\}_{k=1}^{\tilde{L}}, a)$ 计算的 L^1 -误差的中位数与 $\tilde{L}$ 的对比 ($\tilde{L} < L$)。



(a) Calderón Problem 三角函数



(b) 逆波散射

Figure 24. 在不同基准和不同模型下，对测试样本 $(\{\Psi_k\}_{k=1}^{\tilde{L}}, a)$ 计算的 L^1 -误差的中位数与 $\tilde{L}$ 的对比 ($\tilde{L}$ 跨越整个值域 10-100)。

发现表明，采用 *log-MinMax* 缩放并可能在污染数据上监控验证误差，可以显著提升模型对噪声的鲁棒性，同时无噪数据上的性能损失极小。

	DONet	FCNN	NIO
Calderón Problem Trigonometric	2.02%	1.51%	0.91%
Calderón Problem Heart&Lungs	0.95%	0.27%	0.18%
Inverse Wave Scattering	3.83%	2.54%	3.72%
Radiative transport	2.38%	1.47%	1.1%
Seismic Imaging CurveVel - A	3.98%	2.65%	2.73%
Seismic Imaging Style - A	3.82%	3.13%	3.09%

Table 8. 针对不同基准和不同模型，在 1% -含噪测试样本上计算得到的相对 L^1 -误差的中位数。

E.4. 重构结果对不同网格大小的鲁棒性。

尽管反问题 (4) 的输入和输出在理论上是连续对象，但在实际应用中，必须处理其离散化版本的输入和输出。当真实值由数值仿真生成并通过其他形式的测量获得时，这一情况尤为明显。期望一种算子学习算法在不同测试分辨率下具有鲁棒性；有关该主题的进一步讨论见 (Kovachki et al., 2021b)。为测试所提出的 NIO 架构对分辨率的鲁棒性，我们聚焦于亥姆霍兹方程下的逆波散射问题，其中 NIO 使用在均匀 70×70 网格上通过有限差分法获得的数据进行训练。为测试分辨率的鲁棒性，我们使用该训练好的模型在两种不同分辨率下进行推断，即 50×50 和 100×100 ，并将结果与 DeepONet 和 FCNN 基准模型一起列于表 9 中，以观察 NIO（以及基准模型）对变化分辨率的鲁棒性。

	DONet		FCNN		NIO	
Resolution	50×50	100×100	50×50	100×100	50×50	100×100
Inverse Wave Scattering	3.74%	3.63%	1.81%	1.66%	0.93%	0.95%

Table 9. 在不同分辨率（网格大小）生成的测试样本上计算的相对中位数 L^1 -误差。

E.5. 随机传感器位置对重构鲁棒性。

尽管训练数据通常假设传感器在方阵域边界上等距分布（因为它们是使用标准数值方法合成生成的），但现实场景中传感器往往随机分布在边界上。因此，学习模型必须对这些随机的传感器布置具有鲁棒性。

我们的实验旨在评估这种鲁棒性，重点关注两个具体问题：带有三角函数的 Calderón 问题和逆波散射问题。我们使用从 200 个传感器在域边界上随机分布获取的输入数据进行测试。注意到训练数据对应的是 272 个传感器。因此，在将数据输入 NIO（以及基准方法）之前，我们将其插值到原始的等距点集上。对

于这两个问题，我们考察了 L^1 误差，如表10 所示。

结果表明，与原始设置中误差分别为 0.86% 和 1.11% 的情况相比， L^1 -误差仅增加至 1.18% 和 1.43% 。这些发现突显了 NIO 模型在边界传感器放置位置不同时仍能保持稳健性能的能力。

	DONet	FCNN	NIO
	$L^1 \downarrow$	$L^1 \downarrow$	$L^1 \downarrow$
Calderón Problem Trigonometric	3.39%	1.88%	1.18%
Inverse Wave Scattering	3.84%	2.53%	1.43%

Table 10. 不同模型和不同基准下，对测试样本的边界测量值随机位置计算得到的相对中位数 L^1 -误差。

E.6. 分布外重构

除了分布内测试外，我们还考虑了分布外测试任务。这将使我们能够评估模型对具有与训练数据不同特征的输入（和输出）进行泛化的能力。

首先，我们考虑了 Calderón 问题（三角函数）基准。训练分布中的系数是从正弦函数之和的指数中采样得到的，最多包含 4 个频率模态（最多 8π ）。我们现在测试以下分布：

- 分布 A: $a(x, y) = \exp\left(\sum_{k=1}^6 c_k \sin(k\pi x) \sin(k\pi y) / k^{\frac{3}{2}}\right)$
- 分布 B: $a(x, y) = \exp\left(\sum_{k=1}^6 c_k \sin(k\pi x) \sin(k\pi y) / k\right)$

此处， c_k 是在范围 $[0, 1]^m$ 内均匀分布的随机变量。系数包含了最高至 6 频率模式，且高阶模式具有不同的衰减特性（1.5 和 1）。因此，在测试时，该模型必须推断出频率显著高于训练数据的数据。

接下来，我们考虑心脏和肺部的 Calderón 问题。这里的训练分布基于心脏和肺部幻影的正态分布扰动，扰动幅度最多为幻影值的 8%（见 **SM 4**）。在测试时，我们现在考虑幅度为 12% 的扰动，因此是从一个不同的分布中采样。例如，这种更高的幅度可能用于模拟患有某些疾病的个体。需要注意的是，更高的变化可能是不现实的，因为该问题建模的是人体器官，必须施加一定的生物约束。


作为第三个基准，我们考虑反散射问题。在此，训练分布中的系数包含 1 至 4 个散射体，形状相同，其位置随机选取（见 **SM 5**）。我们选择现在在两种不同的测试分布上对该模型进行测试

- 分布 A: $a(x, y) = \sum_{k=1}^5 \exp\left(-c(x - c_{1,k})^4 - c(y - c_{2,k})^4\right)$ 。在此情况下，我们使用一组包含固定数量的系数，其包含数等于五。
- 分布 B: $a(x, y) = \sum_{k=1}^m \exp\left(-b_k^4(x - c_{1,k})^4 - b_k^4(y - c_{2,k})^4\right)$ ，伴有 $b_k \sim \mathcal{U}[5, 15]$ ， $m = \text{mod}(\bar{m})$ ， $m \sim \mathcal{U}([1, 4])$ 以及 $\{(c_{1,k}, c_{2,k})\} \sim \mathcal{U}([0, 1]^{m \times 2})$ 。这对应于具有一个至四个散射体且形状各异的介质。


不同模型和不同分布外测试的相对中位数 L^1 误差如表 11 所示。我们观察到，NIO 在未见数据上具有良好的泛化能力，测试误差最多仅增加约 4 倍，且在所有情况下仍优于基准方法。

	DONet	FCNN	NIO
	$L^1 \downarrow$	$L^1 \downarrow$	$L^1 \downarrow$
Calderón Problem Trigonometric Distribution A	1.37%	1.27%	1.2%
Calderón Problem Trigonometric Distribution B	1.62%	1.28%	0.91%
Calderón Problem Heart&Lungs	1.05%	0.28%	0.19%
Inverse Wave Scattering Distribution A	4.61%	3.84%	3.0%
Inverse Wave Scattering Distribution B	8.61%	8.98%	4.54%


Table 11. 不同模型和不同基准下的分布外测试样本的相对中位数 L^1 -误差。




(a) Calderón Problem 三角函数



(b) Calderón Problem 心脏 & 肺



(c) 逆波散射



(d) 辐射传输

Figure 25. 在不同基准测试和不同模型（NIO 和消融实验）上，对测试样本 $(\{\Psi_k\}_{k=1}^{\tilde{L}}, a)$ 计算的 L^1 -误差的中位数，与 $\tilde{L}$ 的对比。

E.7. 消融研究

我们进行了两项消融实验，重点关注神经逆算子的两个关键要素。首先，我们关注图1所示的架构，其中我们移除了 FNO 的非线性部分 $\mathcal{M}$ ，并设置 $d_v = 1$ 。在此情况下，我们有：

$$a^*(z) = R(f_1, \dots, f_L, z) = \frac{D}{L} \sum_{\ell=1}^L f_{\ell} + Ez, \quad (38)$$

其中 E 和 D 是实数值参数。通过这些实验，我们旨在评估使用 $\mathcal{M}$ 实现的通道混合是否能够提升模型性能。其次，我们通过在不包含算法的情况下训练 NIO 来检验随机批量对结果的影响。

为了保持一致性，我们为消融模型使用与表现最佳的 NIO 模型相同的超参数配置（具体数值参见表5）。

消融实验针对三角函数系数的 Calderón 问题、心肺幻像、逆波散射以及辐射传输问题展开。我们采用与第E.2节中概述的相同实验设置，并在图25中报告相应结果。该图显示，非线性项 $\mathcal{M}$ 和随机批量处理显著提升了模型性能。对于具有三角函数系数的 Calderón 问题，移除 $\mathcal{M}$ 导致泛化误差几乎增加两倍；而对于其余问题，改进效果更为显著，逆波散射问题的提升幅度最高可达六倍。

应当注意，在所有实验中，仅使用 $L = 20$ 和 $L = 32$ 边界测量值进行训练。在此情况下，有限的测量数据构成了准确重建目标系数的瓶颈。当数量更大时，非线性部分可能导致泛化误差进一步减小。

关于随机批量处理，其在 Calderón 问题和辐射传输问题上的改进非常显著，相比消融版本提升了 5 到 10 倍。另一方面，在逆波散射问题上，改进则较为有限，且该算法似乎并未明显提升泛化能力。然而，考虑到随机批量处理算法几乎零成本的特性，这些结果尤为突出。

E.8. 反问题的数值方法比较标准

在本节中，我们从准确率和推理时间两个方面，将所提出的架构与标准数值方法，特别是偏微分方程约束优化技术进行了性能对比。

E.8.1. CALDERÓN 问题心脏 & 肺

我们首先考虑不连续心肺幻影的 Calderón 问题，并对所提出的算法与广泛应用于 EIT 领域的经典 D-bar 方法 (Muller & Siltanen, 2012) 进行比较分析。在图 4 中，我们展示了随机选取的一组测试样本的真实值以及 NIO 的重构结果。作为对比，我们还包含了使用 D-bar 方法获得的重构结果。如图所示，NIO 以极高的准确率重构了真实值，这与表 1 中呈现的极小误差一致。

另一方面，D-bar 方法相对不够精确，其形状重构呈现出模糊且扩散的特征。事实上，D-bar 方法的 L^1 -测试误差高达 8.75%，而 NIO 的测试误差几乎为 0.15%，差距显著。当考虑到运行时间时，这种优势更加突出：D-bar 方法处理单个样本需要约 2 小时，而 NIO 的推理时间仅为 0.1 秒（在 CPU 上）。因此，我们提出的方法在准确率上比传统直接方法高出两个数量级，同时运行速度加快了四个数量级。这凸显了基于机器学习的方法（如 NIO）相较于传统直接方法在性能上的巨大提升。

E.8.2. 逆波散射

接下来，我们研究逆波散射问题，并将 NIO 重构结果与通过偏微分方程约束优化获得的结果进行比较。为此，我们考察了一个分布外（分布 A）的测试样本。

对于偏微分方程约束优化，我们采用具有可训练参数 θ 的前馈神经网络，该网络用于参数化系数 a 。神经网络结构遵循公式 32 中指定的形式，包含 L 层、 d 个神经元，以及激活函数 σ 。模型参数 θ 随机初始化，对 $L = 20$ 个边界条件 g_ℓ 的实际实现数值求解亥姆霍兹方程 (9)，其中 $\ell = 1, \dots, L$ 且 L^2 -损失

$$J(\theta) = \sum_{\ell=1}^L \|\Psi_\ell - \tilde{\Psi}_\ell\|_2^2 \quad (39)$$

计算完成。此处， $\tilde{\Psi}_\ell$ 、 $\ell = 1, \dots, L$ 表示目标数据。可训练网络参数使用 LBFG 在 $J(\theta)$ 梯度方向上进行更新。该过程迭代直至收敛（共 1000 次迭代，对应 1000×20 次 PDE 求解）。

观察到网络的超参数是通过随机搜索选择的，即选取使 $J(\theta)$ 最小化的那个。

通过偏微分方程约束优化得到的重构系数，以及通过直接向模型输入 $\tilde{\Psi}_\ell$ （针对 $\ell = 1, \dots, L$ ）得到的 NIO 预测，显示在图2的右侧面板中。NIO 重构显著比通过偏微分方程约束优化得到的重构更准确，相应的 L^1 误差（分别等于 2.3% 和 11.1%）进一步验证了这一点。重构系数所需的总时间方面，NIO 在 CPU 上的重构时间不到 1 秒，而传统方法则需要 8.5 小时。值得注意的是，用于求解方程的有限差分（FD）求解器在 PyTorch 框架内的 GPU 上实现。通过在 20 个不同的 GPU 上并行求解针对 $L = 20$ 个边界测量的偏微分方程，计算时间可能减少到 30 分钟，但这仍然比 NIO 的推理慢三个数量级。

最后，另一种方法是用学习模型替代前向求解器，而不是直接学习逆映射。尽管代理模型在学习前向映射时可能达到较低的误差（相较于逆映射），但该模型的推理时间约为 0.1 秒（在 CPU 上）。如果我们要求在优化过程中调用该模型 1000 次，这将导致整体推理时间比 NIO 长两个数量级。此外，重构准确率也无法超过使用 FD 前向求解器所获得的结果，而后者本身已比 NIO 的准确率差四倍。

E.8.3. 地震成像

我们还在地震成像背景下，使用 CurveVel-A 数据集测试了偏微分方程约束优化方法。与 NIO 方法不同，在偏微分方程约束优化方法中，我们首先使用分段常数参数化对速度系数 $a(z)$ 进行离散化，将参数记为 θ 。随后，我们采用有限差分法求解波动方程 (14)。因此，该方法自然依赖于 $a(z)$ 的离散化方式以及用于评估源到接收器算子的偏微分方程求解器。我们采用与 (Deng et al., 2021) 中提供的实验设置相同的配置。使用与 (39) 类似的平方 L^2 损失作为目标函数，以衡量观测数据与基于当前 $a(z)$ 预测的模拟接收器数据之间的不匹配程度。我们还求解相应的伴随波动方程，其解用于计算目标函数 $J(\theta)$ 相对于 θ 的梯度。我们采用标准的梯度下降法进行最优化。每次梯度评估需要两次时间相关的偏微分方程求解，这是该偏微分方程约束最优化方法中最昂贵的部分。

该方法在相同测试样本下产生的误差（在 L^1 中）比 CNIO 高 2.5 -4 倍，同时在 8 核 M1 芯片 CPU 上运行时间约为 30 分钟。图 27 展示了两个测试样本的结果。使用 NIO 实现的 L^1 误差分别为样本 1 和样本 2 的 2.03% 和 4.84%，而通过 PDE 约束优化获得的误差分别为 5.05% 和 16.9%。






Figure 26. 确切的和预测的系数针对两个不同的测试样本（行）的 Calderón 问题，其系数为三角函数形式。左列：真实值。中列：NIO 重构。右列：使用 (Muller & Siltanen, 2012) 的 D-bar 直接方法的重构。



(a) 测试样本 1



(b) 测试样本 2

Figure 27. 针对曲率速度族两个不同测试样本（行）的准确系数与预测系数。左列：真实值。中列：NIO 重建结果。右列：基于 PDE 约束优化方法的重建结果。