



目录列表可在 ScienceDirect 上获取

神经网络

期刊主页: www.elsevier.com/locate/neunet



全文文章



用于电阻抗层析成像的物理信息神经网络

丹尼·斯密尔, 泰勒·N·塔尔曼, 劳拉·霍玛, 切诺亚·弗劳诺伊, 莎拉·J·汉密尔顿, 约翰·沃茨

a 佐治亚理工学院, 亚特兰大, GA, 30332, 美国 b 普渡大学, 西拉法叶, IN, 47907, 美国 c 代顿大学研究学院, 代顿, OH, 45469, 美国 d 马凯特大学, 密尔沃基, WI, 53233, 美国 e 空军研究实验室, WPAFB, OH, 45433, 美国

文章信息

摘要

关键词:
神经网络
机器学习 电阻抗层析成像 EIT ERT 无损检测 传感 物理信息神经网络

电阻抗层析成像 (EIT) 是一种成像方式, 通过边界电压测量来重建一个区域的内部电导率分布。在本文中, 我们提出了一种利用物理信息神经网络 (PINNs) 对复合结构进行集成传感的新型 EIT 方法。与传统仅依赖数据驱动模型不同, PINNs 将控制 EIT 的基本物理原理直接整合到学习过程中, 从而实现精确和快速的重构。我们展示了 PINNs 在集成传感中结合各种物理约束的有效性。所提出的方法有望提升材料表征和状态监测能力, 为经典的 EIT 方法提供一种可靠的替代方案。

1. 引言

物理信息神经网络 (PINNs) 是一类强大的深度学习算法, 它们将物理定律直接融入神经网络训练过程中。与传统数据驱动模型不同, 后者完全依赖于大型数据集, PINNs 利用控制偏微分方程 (PDEs) 或其他已知的物理约束 (如与系统状态对应的物理数据) 来正则化网络的训练 (Hu, Shukla, Karniadakis, & Kawaguchi, 2024; Rasht-Behesht, Huber, Shukla, & Karniadakis, 2022)。这使得 PINNs 即使在数据有限或存在噪声的情况下也能有效运行, 因此特别适用于解决获取高质量训练数据困难或昂贵的问题 (Abbasi & Andersen, 2024)。通过将物理定律嵌入损失函数 (并反向传播这些损失), PINNs 在优化过程中强制遵守这些方程, 从而得到准确且物理上一致的解 (Karniadakis et al., 2021; Raissi, Perdikaris, & Karniadakis, 2019)。

在逆问题的背景下, PINNs 具有特别的优势, 但在 EIT 文献中缺乏实验验证 (我们参考 Bar 和 Sochen (2021)、Pokkunuru、Rooshenas、Strauss、Abhishek 和 Khan (2023)、Yang、Zhang、Chen、Ma 和 Wang (2024) 进行数值研究)。逆问题涉及根据观测结果确定系统未知参数或输入。

(测量数据)。这些问题通常是非适定的, 这意味着它们可能没有唯一或稳定的解, 导致传统数值方法容易产生不稳定性 (Gallet et al., 2022)。物理信息神经网络 (PINNs) 通过将物理定律直接纳入学习框架来处理这类非适定问题, 有助于正则化反问题, 并引导网络朝向具有物理意义的解——从而促进具有所需 (物理) 特性的解。数据和物理的这种耦合可能使 PINNs 在数据稀疏或噪声时优于纯数据驱动模型。

此外, PINNs 在处理正向和逆向问题上的灵活性使它们成为多功能的工具。对于逆向问题, PINNs 可以训练以最小化一个综合损失, 该损失测量预测数据与观测数据之间的差异, 同时强制满足控制方程。这导致发现未知参数 (在 EIT 的情况下, 电导率场)、边界条件, 甚至与观测数据及基础物理一致的源项。将这些物理原理集成到机器学习框架中不仅增强了结果的解释性, 还提高了模型的鲁棒性和泛化能力, 使 PINNs 成为计算物理和工程领域的最先进方法。在下文中, 我们将首先概述用于 EIT 成像和集成传感的 PINN 方法。

* 通讯作者。

邮箱地址: dsmyl3@gatech.edu (D. Smyl)

<https://doi.org/10.1016/j.neunet.2025.107410> 收到日期: 2024 年 11 月 12 日; 收到修改稿日期: 2025 年 2 月 12 日; 接受日期: 2025 年 3 月 14 日

2025 年 3 月 23 日在线发布 0893-6080/© 2025 Elsevier Ltd. 保留所有权利, 包括文本和数据挖掘、AI 训练以及类似技术的权利。

复合材料与结构，突出关键实验细节，提供简洁的结果，最后呈现结论和未来研究方向。这项工作的最终目标是通过实验测量来确定 PINN 能否（a）超越传统的纯数据驱动 NN，以及（b）达到经典 EIT 成像的保真度。这将使用从受损复合材料结构中获得的实验测量结果进行测试。

2. 方法论：PINN 方法

2.1. 概述存在许多解决逆问题的可能学习方法（Hauptmann, Adler, Arridge, & Öktem, 2020）。在集成传感的 EIT 背景下，目标是开发一个函数 $\hat{\sigma}$ ，它将电压信息直接映射到电导率以进行快速解释（例如，用于复合材料结构的状况监测）。在这里，可学习的 EIT 问题旨在训练一个 PINN 来生成以下近似：

$$\hat{\sigma}(\hat{V}) \approx \hat{\sigma} \quad (1)$$

其中 ΔV 是差分电极电位（在参考状态下测量的电压与状态变化后测量的电压之差），用于提高对系统误差的鲁棒性（Candiani, Hyvönen, Kaipio, & Kolehmainen, 2021），而 σ 是真实电导率场的表示，该电导率场被归一化到 [0, 1] 范围内。选择此范围是因为在此考虑的实验测试用例中，电导率分布是二元的，这是由于局部结构损伤造成的。在我们的方法中，这是通过最小化形式为混合分类-回归损失来实现：

$$L = \frac{1}{n} \sum_{i=1}^n \text{BCE}(\sigma - \hat{\sigma}) + L \quad (2)$$

在

$$L = \beta \left\| \nabla V - \nabla \hat{V} \right\| + \beta \left\| u - \hat{u} \right\| + \beta \left\| \frac{\partial V}{\partial (\Delta V)} - \frac{\partial \hat{V}}{\partial (\Delta \hat{V})} \right\| \quad (3)$$

其中下标 p 和 t 分别指预测和训练，上标 i 是包含 n 个样本的数据集中的数据索引，‘BCE’ 指二元交叉熵损失， σ 是二元电导率， V 是电极电势， u 是内部节点电势， β 、 β 和 β 是作为可学习参数的加权系数，并初始化为使损失项具有相同的数量级。为确保稳定性，加权系数（ β 、 β 和 β ）通过对其取对数进行转换以保证正值，在训练过程中通过指数化进行投影，并使用 L 范数进行正则化以避免显著偏离其初始值。这些实现的数值细节在算法 1 中提供。此外，损失函数中 L 范数的选取有两个原因：(a) 它们先前证实的在复合材料中基于 EIT 的损伤定位方面的益处（Tallman 等人，2024 年），以及 (b) 与 L 范数相比，它们对离群数据具有较低的敏感性。未应用权重衰减或权重正则化。

2.2. 损失函数和网络考虑 通过对多种可能的物理损失函数的初步探索，发现以下几种为这项工作中的成像提供了合适的约束。

电极电势损失函数：或许是物理损失函数中最直接的一种
电极电势损失函数，它强制 PINN 遵守正向模型。产生的损失项如下：

$$\text{电极电势 PINN 损失} = \frac{\beta}{n} \sum_{i=1}^n \left\| V - \hat{V} \right\|. \quad (4)$$

内部势能损失函数：以下内部势能
损失项，同时强制 PINN 遵守 EIT 正向模型（内部）的公式为：

$$\text{空间势能 PINN 损失} = \frac{\beta}{n} \sum_{i=1}^n \left\| u - \hat{u} \right\|. \quad (5)$$

该函数考虑了势场中可能的内部尖峰，迫使 PINN 在成像域内保持物理真实性。
兼容性损失函数：所使用的最终损失项确保了网络输入和输出之间的兼容性。这一约束源于电压项的静态特性，即状态变化后的电压相对于电压差是固定的，由此产生以下损失：

$$\text{兼容性损失} = \frac{\beta}{n} \sum_{i=1}^n \left\| \frac{\partial V}{\partial (\nabla V)} - \frac{\partial \hat{V}}{\partial (\nabla \hat{V})} \right\|. \quad (6)$$

这是由于认识到 V 不能相对于

一个固定的输入 ΔV ，因此我们旨在强制
$$\sum_{i=1}^n \left\| \frac{\partial V}{\partial (\Delta V)} - \frac{\partial \hat{V}}{\partial (\Delta \hat{V})} \right\| \rightarrow 0.$$

通用网络参数和训练。所有回归损失
范数选择为 L 以避免异常值冲击。选择了批大小为 16、初始学习率为 10 并具有指数衰减的设置， $\gamma = 0.99$ ，以及 50% 的 dropout 率、LeakyReLU 激活函数和卷积输入特征层。为避免电导率和物理参数之间的串扰，输入层被分为三个相邻的网络——使用具有跳跃连接的更深网络进行电导率预测以提高保真度——如图 1 所示。
为了训练在接下来的章节中考虑两种实验情况下遵循算法 1 中伪代码的神经网络，每个情况生成了总共 50,000 个训练样本，这些样本使用随机低电导率场生成（在均匀背景下计算的团状包含物——见图 2 为代表图像），并在输入数据中添加了 0.1% 标准偏差的高斯噪声以进行正则化。在生成训练数据时，使用了实现 EIT 正向问题的完整电极模型公式（Somersalo, Cheney, & Isaacson, 1992）的有限元模拟。为此，每个随机生成的团状样本被输入到与实验中详细描述的实验所使用的相同电流注入模式、电流注入幅度和测量模式相同的正向模型中。由于正向模拟使用了电导率场的逐元素连续表示，因此在此考虑的各个实验中元素总数和电导率值是相同的。从这些数据集中移除了 10,000 个样本用于验证。在每个 epoch 中，从整个数据集中随机抽取 10,240 个样本，以改善泛化能力并更好地处理数据吞吐量。然后使用 PyTorch（Paszke 等人，2019）在 Nvidia GPU（RTX 4090/A2000）上进行训练，每个试验进行 300 个 epoch（以防止过拟合）。为了计算 PINN 损失项中的导数，使用了 AutoGrad 函数。

3. 实验研究

3.1. 损坏的碳纤维桁架 首个实验研究是在 Impossible Objects 生产的增材制造碳纤维桁架结构上进行的。制造过程在 Kim 等人（2020）中有描述。通过手锯引入了三个缺口损伤，缺口位置根据离散损伤模型确定的四点弯曲时可能的损伤形成情况选择（larve, Hoos, Nikishkov, & Makeev, 2018）。总共在桁架外边缘大致等距地放置了 16 个电极。电极是通过将银漆（Ted Pella 16040-30）和银环氧树脂（mg Chemicals 8331D）结合使用，将电线粘附到桁架上。然后使用 Mastech HY3005D-3 电源为 0.5 DC 注入电流。




图 1. 本研究使用的三层混合分类/回归 PINN 架构和方法示意图。




图 2. 随机二进制电导率训练数据样本。




图 3. 顶部：碳纤维桁架样品。底部：碳纤维/环氧 NACA 4424 样品。




图 4. 损坏桁架的重建：顶行，一个缺口；底行，三个缺口。尺寸以米为单位，重建结果以 [1,0] 的比例表示。损伤位置在经典重建图顶部用红色圆圈标出。

算法 1 基于 PINN 的 EIT 重建

1: 过程 TrainPINN(电压差 ΔV , 真实数据 (σ, V, u) , 网格数据) 2: 预处理: 3: 加载数据并计算单元质心 4: 将数据划分为训练/验证集 5: 构建模型: 6: 从 ΔV 构建共享卷积特征提取器 7: 分支 1: 预测电导率 σ (sigmoid 激活) 8: 分支 2: 预测电极电势 V 9: 分支 3: 预测内部电势 u 10: 初始化可训练权重 $\{\log \beta, \log \beta, \log \beta\}$ 11: 对于 epoch = 1 到 E 执行 12: 对于每个小批量 $(\Delta V, \sigma, V, u)$ 执行 13: 前向传播: 计算输出 (σ, V, u) 14: 计算损失: 15: $\mathcal{L} \leftarrow \text{BCE}(\sigma, \sigma)$ 16: $\mathcal{L} \leftarrow \mathcal{L} + \mathcal{L}_V$ 17: $\mathcal{L} \leftarrow \mathcal{L} + \mathcal{L}_u$

18: $\mathcal{L} \leftarrow \mathcal{L} + \sum_{i=1}^N \left\| \frac{\partial \sigma}{\partial V} \right\|_2^2$

19: $\mathcal{L} \leftarrow \mathcal{L} + \sum_{i=1}^N \left\| \frac{\partial V}{\partial \sigma} \right\|_2^2$

20: $\mathcal{L} \leftarrow \mathcal{L} + \sum_{i=1}^N \left\| \frac{\partial u}{\partial \sigma} \right\|_2^2$

21: 反向传播: 通过 Adam 算法反向传播 $\mathcal{L}$ 并更新所有参数 22: end for 23: 验证模型并更新学习率调度器 24: end for 25: 返回训练好的 PINN 模型 26: end procedure

在实验中使用了 National Instruments 设备，配备一个 PXI-8386 卡和两个 PXI-6123 卡来测量电压。采用相邻-相邻注入测量模式。实验装置如图 3 左侧所示。有关更多实验细节，感兴趣的读者可参考 Tallman、Homa、Flores 和 Wertz (2023) 的研究。

3.2. 损坏的碳纤维翼型 第二项实验研究是在一个平纹碳纤维 (Fiber Glast) /环氧树脂 (Fiber Glast System 2000 Laminating Epoxy Resin) 复合材料层压板上进行的，该层压板形状为具有 4 英寸宽度和 5 英寸弦长的代表性 NACA 4424 翼型。该层压板使用了总共 15 层碳纤维。堆叠是在一个由铝制成的阳模上通过湿铺层和真空袋技术完成的。固化翼型并将其修整成最终形状后，在 CEAST 9340 自由落体塔上进行了两次冲击 (在不同位置)。第一次冲击能量为 15 焦耳，第二次冲击能量为 12 焦耳。冲击位置如图 3 右侧所示。总共在顶部表面贴了 20 个电极，使用银漆 (Ted Pella 16040-30) 进行粘贴。使用 BK Precision 9131 B 电源注入 0.8 安培的直流电，同时使用 National Instruments PXIe-6368 数据采集系统测量电压。

电流注入和电压测量采用“蛇形”模式进行。有关注入-测量模式和实验细节的更多信息，感兴趣的读者可参考 Sannamani、Gao、Chen 和 Tallman (2022) 的研究。

4. 结果与讨论

4.1. EIT 成像结果 为了回答第 1 节中强调的研究问题，我们将 PINN 重建结果与仅数据驱动的神经网络和线性差分成像重建 (NLDI——经典成像，遵循 (Smyl、Pour-Ghaz 和 Seppänen, 2018) 的方法，使用平滑先验来处理背景电导率，以及拉普拉斯正则化的电导率变化， $\Delta \sigma$)。为确保公平比较，仅数据驱动的网络采用了与 PINN 电导率分类器相同的架构，并使用了相同的 BCE 损失函数。

我们首先分析了受损桁架的情况，其中使用三种 EIT 方法得到的重建结果如图 4 所示。在这个实验中，我们观察到三种 EIT 重建框架都能捕捉到所考虑的两种情况下的损伤。然而，PINN 重建最清晰地定位了缺口，并提供了最少的背景伪影。相比之下，经典方法和数据驱动方法在背景电导率中存在明显波动。在比较 PINN 和数据驱动重建时，我们注意到 PINN 图像在缺口位置 (这些区域应接近零，因为它们没有导电材料) 提供了显著较低的电导率值。

在更高维 (输出) 的实验案例中，我们考察了三维翼型重建结果，其包含的逆自由度数量比桁架实验大约多 10 倍。这些成像结果报告在图 5 中，其中，所有三种框架均能很好地捕捉双重损伤。初步观察显示，PINN 重建比纯数据驱动方法更精确地定位了 15 焦耳冲击，并更清晰地呈现了 12 焦耳冲击。相比之下，经典重建与数据驱动方法在捕捉 15 焦耳冲击损伤方面表现相当，但观察到一些稀疏的背景伪影。以下将对此结果进行进一步讨论。

4.2. 讨论 本文旨在确定 PINNs 是否能够 (a) 优于传统的纯数据驱动 NN，以及 (b) 达到经典 EIT 成像方法的保真度。对这些问题的回答是定性的肯定，这在第 4.1 节提供的实验研究中得到了证明。虽然经典反演方法的保真度差异很大，并受到参数化、正则化、离散化以及其他超出本工作范围众多因素的影响，但仍有疑问：PINNs 为何优于数据驱动 NN？

对于这个问题，我们可以从图 6 所示的损失图中获得一些见解，其中展示了 PINN 损失与总损失的叠加。我们观察到，在我们的 PINN 公式中，物理项 (图 6 中的橙色线) 对




图 5. 双重冲击下受损翼型的重建。尺寸以米为单位，图像以[1,0]比例显示，颜色与图 4 相同。

损伤位置用红色圆圈标出。

学习过程中，尤其是在训练的初始阶段。这意味着网络必须在显著最小化数据损失之前遵循问题的物理规律。这种正则化明显改善了验证曲线，该曲线在初始训练后平滑收敛。基于这些发现，我们推断，PINN 中基于物理的正则化带来的改进，在电导率训练样本稀疏二值性质（参见图 2）的背景下，具有更好的泛化能力。最终，PINN 的泛化能力增强，使其在损伤位置实现了比纯数据驱动模型更好的定位和更真实的电导率估计。

除了上述几点外，PINN 框架为适应训练动态提供了途径，而当前数据驱动方法不具备这一特点。例如，有人可能会认为自动化损失系数的能力提高了网络避开局部最小值的能力，兼容性约束确保了输入和输出之间的物理真实性连接，而包含内部信息（即 u ）则提供了将空间物理依赖与感兴趣的反因果关系（在本工作中为 σ ）联系起来的信息。然而，最终，需要研究诸如 u 的空间梯度、高阶导数和其他兼容性项等附加项，以全面理解物理约束对使用 PINN 进行 EIT 重建保真度的影响。




图 6. PINN 训练损失区分各个物理项。

最后，从数值角度来看，值得指出的是，本文采用的 PINN 方法在计算上比数据驱动的 NN 方法要求高得多。实际上，PINN 进行估计所需的参数大约是数据驱动 NN 的五倍，导致训练时间几乎也增加了同样的倍数（在 RTX-4090 机器上）。这种计算障碍可以在未来的工作中得到缓解，届时仅进行回归预测，当不使用 BCE 损失时，可以使用自动混合精度。然而，最终，PINN 在训练时间上的权衡被利用，使得解决 EIT 问题的速度比经典方法提高了约 80,000 倍。

5. 结论这项工作通过实验研究复合结构损伤重建，证实了物理信息神经网络（PINNs）在电阻抗断层成像（EIT）成像中的可行性。研究发现，PINNs 能够（a）优于传统数据驱动神经网络，并且（b）达到经典 EIT 反演方法的保真度。讨论了促进 PINNs 相对于纯数据 EIT 成像泛化能力提升的关键特征，并为 PINNs 在 EIT 成像中的应用研究提供了未来方向。

CRediT 作者贡献声明

Danny Smyl: 撰写——审阅与编辑，撰写——原始草稿，可视化，验证，软件，方法学，研究，形式分析，概念化。Tyler N. Tallman: 撰写——审阅与编辑，研究，数据管理。Laura Homa: 撰写——审阅与编辑，方法学，概念化。Chenoa Flournoy: 撰写——审阅与编辑，概念化。Sarah J. Hamilton: 撰写——审阅与编辑，研究。John Wertz: 撰写——审阅与编辑，数据管理，概念化。

利益冲突声明

作者声明他们没有已知的利益冲突或个人关系可能影响本论文中报告的工作。

致谢

通讯作者感谢佐治亚理工学院的支持。所有作者感谢美国空军研究实验室及支持人员提供的支持。

D. Smyl 等人

神经网络 188 (2025) 107410

Data availability

Data will be made available on request.

参考文献

Abbasi, J., & Andersen, P. Ø. (2024). Physical activation functions (PAFs): an approach for more efficient induction of physics into physics-informed neural networks (PINNs). *Neurocomputing*, 608, Article 128352. Bar, L., & Sochen, N. (2021). Strong solutions for PDE-based tomography by unsupervised learning. *SIAM Journal on Imaging Sciences*, 14(1), 128–155. Candiani, V., Hyvönen, N., Kaipio, J. P., & Kolehmainen, V. (2021). Approximation error method for imaging the human head by electrical impedance tomography.

Inverse Problems, 37(12), Article 125008.

Gallet, A., Rigby, S., Tallman, T. N., Kong, X., Hajirasouliha, I., Liew, A., et al. (2022). Structural engineering from an inverse problems perspective. *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 478(2257), Article 20210526. <http://dx.doi.org/10.1098/rspa.2021.0526>.

Hauptmann, A., Adler, J., Arridge, S., & Öktem, O. (2020). Multi-scale learned iterative reconstruction. *IEEE Transactions on Computational Imaging*, 6, 843–856. Hu, Z., Shukla, K., Karniadakis, G. E., & Kawaguchi, K. (2024). Tackling the curse of dimensionality with physics-informed neural networks. *Neural Networks*, 176, Article 106369. Jarve, E. V., Hoos, K. H., Nikishkov, Y., & Makeev, A. (2018). Discrete damage modeling of static bearing failure in laminated composites. *Composites Part A: Applied Science and Manufacturing*, 108, 30–40.

Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021).

Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422–440.

Kim, D., Lee, J., Nomura, T., Dede, E. M., Yoo, J., & Min, S. (2020). Topology optimization of functionally graded anisotropic composite structures using homogenization

design method. *Computer Methods in Applied Mechanics and Engineering*, 369, Article 113220.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. (2019). Pytorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32.

Pokkunuru, A., Rooshenas, P., Strauss, T., Abhishek, A., & Khan, T. (2023). Improved training of physics-informed neural networks using energy-based priors: a study on

electrical impedance tomography. In *The eleventh international conference on learning representations*.

Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707. Rasht-Behesht, M., Huber, C., Shukla, K., & Karniadakis, G. E. (2022). Physics-informed neural networks (PINNs) for wave propagation and full waveform inversions.

Journal of Geophysical Research: Solid Earth, 127(5), Article e2021JB023120.

Sannamani, M., Gao, J., Chen, W. W., & Tallman, T. N. (2022). Damage detection in non-planar carbon fiber-reinforced polymer laminates via electrical impedance tomography with surface-mounted electrodes and directional sensitivity matrices.

Composites Science and Technology, 224, Article 109429.

Smyl, D., Pour-Ghaz, M., & Seppänen, A. (2018). Detection and reconstruction of complex structural cracking patterns with electrical imaging. *NDT & E International*, 99, 123–133. Somersalo, E., Cheney, M., & Isaacson, D. (1992). Existence and uniqueness for electrode models for electric current computed tomography. *SIAM Journal on Applied Mathematics*, 52(4), 1023–1040. Tallman, T. N., Homa, L., Flores, M., & Wertz, J. (2023). Damage mapping via electrical impedance tomography in complex AM shapes using mixed smoothness

and Bayesian regularization. *Computer Methods in Applied Mechanics and Engineering*, 414, Article 116185.

Tallman, T. N., Homa, L., Lesthaeghe, T., Schehl, N., Flores, M., & Wertz, J. (2024). Detection of indentation damage in carbon fiber/epoxy composites via EIT during the application of bending loads. *NDT & E International*, 147, Article 103206.

Yang, X., Zhang, Y., Chen, H., Ma, G., & Wang, X. (2024). A two-stage imaging framework combining CNN and physics-informed neural networks for full-inverse tomography: A case study in electrical impedance tomography (EIT). *arXiv preprint arXiv:2407.17721*.