



爱思唯尔

ScienceDirect 上提供的目录列表

神经网络

期刊主页: www.elsevier.com/locate/neunet

全文文章



用于电阻抗断层成像的物理信息神经网络

丹尼·斯迈尔^{a,*}, 泰勒·N·塔尔曼^b, 劳拉·霍马^{c,e}, 切诺阿·弗卢努瓦^c, 萨拉·J·汉密尔顿^d, 约翰·沃茨^e

^a 佐治亚理工学院, 美国佐治亚州亚特兰大, 30332

^b 普渡大学, 美国印第安纳州西拉斐特, 47907

^c 代顿大学研究所, 美国俄亥俄州代顿, 45469

^d 马凯特大学, 美国威斯康星州密尔沃基, 53233

^e 美国空军研究实验室 美国佛罗里达州赖特-帕特森空军基地 45433

文章信息

关键词: 神经网络 机器学习 电阻抗断层成像 EIT ERT 无损评估 传感 物理神经网络

摘要

电阻抗断层成像 (EIT) 是一种通过边界电压测量来重建某一区域内部电导率分布的成像方式。在本文中, 我们提出了一种新颖的 EIT 方法, 该方法利用物理信息神经网络 (PINNs) 对复合结构进行集成传感。与传统的纯数据驱动模型不同, PINNs 将支配 EIT 的基本物理原理直接融入学习过程, 从而实现精确且快速的重建。我们通过多种物理约束展示了 PINNs 在集成传感方面的有效性。所提出的方法有望增强材料表征和状态监测能力, 为传统的 EIT 方法提供了一种稳健的替代方案。

引言

物理信息神经网络 (PINNs) 是一类强大的深度学习算法, 它将物理定律直接融入神经网络的训练过程中。与仅依赖大型数据集的传统数据驱动模型不同, 物理信息神经网络利用主导的偏微分方程 (PDEs) 或其他已知的物理约束 (如与系统状态相对应的物理数据) 来规范网络的训练 (Hu, Shukla, Karniadakis 和 Kawaguchi, 2024; Rasht-Behesht, Huber, Shukla 和 Karniadakis, 2022)。这使得物理信息神经网络即使在数据有限或存在噪声的情况下也能有效运行, 使其特别适合解决获取高质量训练数据困难或成本高昂的问题 (Abbasi 和 Andersen, 2024)。通过将物理定律嵌入损失函数 (并反向传播这些损失), 物理信息神经网络在优化过程中确保符合这些方程, 从而得到准确且物理一致的解决方案 (Karniadakis 等人, 2021; Raissi, Perdikaris 和 Karniadakis, 2019)。

在反问题背景下, 物理信息神经网络 (PINNs) 具有显著优势, 然而在电阻抗断层成像 (EIT) 文献中, 其实实验验证尚属空白 (关于数值研究, 我们可参考 Bar 和 Sochen (2021)、Pokkunuru, Rooshenas, Strauss, Abhishek 及 Khan (2023)、Yang, Zhang, Chen, Ma 和 Wang (2024) 的研究)。反问题涉及基于观测结果确定系统的未知参数或输入。

(测量值)。这些问题通常是不适定的, 这意味着它们可能没有唯一或稳定的解, 使得传统数值方法容易出现不稳定性 (Gallet 等人, 2022)。物理信息神经网络 (PINNs) 通过将物理定律直接纳入学习框架来处理这类不适定问题, 有助于正则化反问题, 并引导网络朝着具有物理意义的解方向发展, 从而得到具有理想 (物理) 属性的解。这种数据与物理的结合可能使物理信息神经网络 (PINNs) 优于纯数据驱动模型, 尤其是在数据稀疏或存在噪声的情况下。

此外, 物理信息神经网络 (PINNs) 在处理正问题和反问题时所具备的灵活性, 使其成为用途广泛的工具。对于反问题, 物理信息神经网络可以通过训练来最小化综合损失, 这种损失既用于衡量预测数据与观测数据之间的差异, 同时又能确保满足控制方程。这使得我们能够发现未知参数 (就电阻抗断层成像而言, 即电导率场)、边界条件, 甚至是与观测数据和基础物理规律都相符的源项。将这些物理原理整合到机器学习框架中, 不仅提高了结果的可解释性, 还增强了模型的鲁棒性和泛化能力, 使得物理信息神经网络成为计算物理和工程领域的一种最先进方法。接下来, 我们将首先概述用于电阻抗断层成像和集成传感的物理信息神经网络方法, 以及

* 通讯作者

电子邮箱: dsmvl3@gatech.edu (D. Smvl)。

<https://doi.org/10.1016/j.neunet.2025.107410>

2024 年 11 月 12 日收到; 2025 年 2 月 12 日收到修订稿; 2025 年 3 月 14 日接受

2025 年 3 月 23 日在线发布

0893-6080/© 2025 爱思唯尔有限公司。保留所有权利。包括文本和数据挖掘。人工智能训练及类似技术的相关权利。

复合材料与结构，强调关键的实验细节，提供简明的结果，最后呈现结论和未来的研究方向。本研究的最终目的是确定物理信息神经网络 (PINNs) 是否能够 (a) 优于传统的纯数据驱动神经网络，以及 (b) 达到经典电阻抗断层成像 (EIT) 的保真度。这将通过从受损复合材料结构获取的实验测量数据进行验证。

方法：物理信息神经网络 (PINN) 方法

2.1. 概述

存在许多可能的习得方法来解决反问题 (Hauptmann、Adler、Arridge 和 Öktem, 2020)。在用于集成传感的电阻抗断层成像 (EIT) 背景下，目标是开发一个函数 A ，该函数将电压信息直接映射到电导率，以便快速解读 (例如，用于复合材料结构的状态监测)。在这里，可学习的 EIT 问题旨在训练一个物理信息神经网络 (PINN) 来生成以下近似：

$$\begin{array}{l} \{r\} \backslash \mathcal{A}(\Delta V) \approx \sigma \end{array}$$

其中，为了对系统误差具有鲁棒性而选择的 ΔV (Candiani、Hyvönen、Kaipio 和 Kolehmainen, 2021) 是电极电位差 (从状态变化后测量的电压中减去参考状态下测量的电压)， σ 是真实电导率场的表示，已归一化到 $[0, 1]$ 范围。选择这个范围是因为本文所考虑的实验测试案例中，由于局部结构损伤，电导率分布是二元的。在我们这里概述的方法中，这是通过最小化以下形式的混合分类 - 回归损失来实现的：

$$L = \frac{1}{n} \sum_{i=1}^n BCE(\sigma^i - \hat{\sigma}^i) + L_{\text{regression}}(2)$$

其中

$$L_{PINN} = \beta_1 \|V_p^i - V_t^i\|_1 + \beta_2 \|u_p^i - u_t^i\|_1 + \beta_3 \left\| \frac{\partial V_p^i}{\partial (\Delta V^i)} \right\|_2$$

其中下标 p 和 t 分别指预测值和训练值，上标 i 是包含 n 个样本的数据集中的数据索引，“BCE” 分别指二元交叉熵损失， σ 是二元电导率， V 是电极电位， u 是内部节点电位， β_1 、 β_2 和 β_3 是作为可学习参数处理的加权系数，其初始化使得损失项处于相同的数量级。为确保稳定性，对加权系数 (β_1 、 β_2 和 β_3) 进行了对数变换以确保其为正值，在训练期间通过指数运算进行投影，并使用 L_1 范数进行正则化，以避免与初始值产生显著偏差。这些实现的数值细节在算法 1 中提供。此外，在损失函数中选择范数有两个原因：(a) 它们先前在基于 EIT 的复合材料损伤定位中被证明的优势 (Tallman 等人, 2024)；(b) 与其他范数相比，它们对异常值数据的敏感性更低。未应用权重衰减或权重正则化。

2.2. 损失函数和网络考量

通过对众多可能的物理损失函数的初步探索，发现以下函数可为本文所考虑的成像提供适当的约束。

电极电势损失函数：在物理损失中，或许最直接的就是电极电势损失函数，它促使物理信息神经网络遵循正向模型。由此产生的损失项如下：

$$ElectrodenpotentialPINNLoss = \frac{\beta_1}{n} \sum_{i=1}^n \|V_{\alpha}^i - V_{\beta}^i\|_1$$

内部势损失函数：下面的内部势损失项，也强制物理信息神经网络 (PINN) (在内部) 遵循电阻抗断层成像 (EIT) 正向模型，其表达式为：

$$SpatialpotentialPINNLoss = \frac{\beta_2}{n} \sum_{i=1}^n \|u_{\alpha}^i - u_{\beta}^i\|_1$$

i 此函数考虑了势场中可能存在的内部峰值，从而确保物理信息神经网络 (PINN) 在成像区域内具有物理真实性。

兼容性损失函数：所使用的最终损失项确保了网络输入和输出之间的兼容性。这一约束源于电压项的静态特性，即状态变化后的电压相对于电压差是固定的，由此产生以下损失：

$$CompatibilityLoss = \frac{\beta_3}{n} \sum_{i=1}^n \left\| \frac{\partial V_p^i}{\partial (\Delta V^i)} \right\|_2 \quad (6)$$

这是因为人们意识到，对于固定输入 ΔV^i ， V^i 不会发生变化，因此我们旨在实施 $\beta_3 \sum_{i=1}^n \left\| \frac{\partial V_p^i}{\partial (\Delta V^i)} \right\|_2$ 。

通用网络参数与训练。所有回归损失范数都是为了避免异常值峰值。选择了 16 的批量大小、初始学习率为 10^{-5} (采用指数衰减)、 $\gamma = 0.99$ 的 dropout 率

(50%)、LeakyReLU 激活函数以及卷积输入特征层。为避免电导率和物理参数之间的串扰，输入层被拆分为三个相邻的网络——其中用于电导率预测的网络更深且带有跳跃连接，以提高保真度——其示意图如图 1 所示。

在后续章节所考虑的两个实验案例中，为了按照算法 1 中提供的伪代码训练网络，每个案例通过随机化低电导率场 (在均匀背景中加入团块状内含物，该背景采用最佳均匀估计计算——代表性图像见图 2) 生成了共 50,000 个训练样本，并在输入数据中添加了 0.1% 标准差的高斯噪声以进行正则化。在生成训练数据时，使用了有限元模拟，该模拟采用了电阻抗断层成像 (EIT) 正问题的完整电极模型公式 (Somersalo、Cheney 和 Isaacson, 1992)。为此，每个随机生成的团块状样本都被输入到正演模型中，所使用的电流注入模式、电流注入幅度和测量模式与下一节详细介绍的实验中所使用的相同。由于正演模拟采用了电导率场的单元级连续表示，因此本文所考虑的各个实验的单元总数和电导率值是相同的。从这些数据集中，抽取了 10,000 个样本用于验证。在每个时期，从整个数据集中随机抽取 10,240 个样本，以提高泛化能力并更好地处理数据吞吐量。然后，使用 PyTorch (Paszke 等人, 2019) 在 Nvidia GPU (RTX 4090/A2000) 上进行训练，每个试验训练 300 个时期 (以防止过拟合)。为了计算物理信息神经网络 (PINN) 损失项中的导数，使用了 AutoGrad 函数。

实验研究

3.1. 受损碳纤维桁架

第一项实验研究是在 Impossible Objects 公司增材制造的碳纤维桁架结构上进行的。其制造过程在 Kim 等人 (2020 年) 的研究中已有描述。使用钢锯制造了三处缺口损伤，缺口位置是根据离散损伤模型 (Iarve、Hoos、Nikishkov 和 Makeev, 2018 年) 确定的四点弯曲过程中可能形成损伤的位置来选择的。沿桁架外边缘大致等距放置了 16 个电极。电极是通过将银漆 (Ted Pella 16040-30) 和银环氧树脂 (mg Chemicals 8331D) 结合使用，将导线粘接到桁架上制成的。随后使用 Mastech HY3005D-3 电源注入 0.5 直流电流。




图 1. 本研究使用的三层混合分类 / 回归物理信息神经网络架构及方法的示意图。




图 2. 随机二进制导电性训练数据样本。





图 3. 上图: 碳纤维桁架试样。下图: 碳纤维 / 环氧树脂 NACA 4424 试样。




图 4. 受损桁架的重建：上排为单缺口，下排为三缺口。尺寸单位为米，重建结果以 [1,0] 的比例呈现。在传统重建图的顶部，损伤位置用红色圆圈标出。

Algorithm 1 PINN-Based EIT Reconstruction

```

1: procedure TRAINPINN(Voltage differences  $\Delta V$ , true data  $(\sigma_t, V_t, u_t)$ , mesh data)
2:   Preprocess:
3:   Load data and compute element centroids
4:   Partition data into training/validation sets
5:   Build Model:
6:   Construct shared convolutional feature extractor from  $\Delta V$ 
7:   Branch 1: Predict conductivity  $\sigma_p$  (sigmoid activation)
8:   Branch 2: Predict electrode potentials  $V_p$ 
9:   Branch 3: Predict internal potentials  $u_p$ 
10:  Initialize trainable weights  $\{\log \beta_1, \log \beta_2, \log \beta_3\}$ 
11:  for epoch = 1 to  $E$  do
12:    for each mini-batch  $(\Delta V, \sigma_t, V_t, u_t)$  do
13:      Forward: Compute outputs  $(\sigma_p, V_p, u_p)$ 
14:      Compute Losses:
15:       $\mathcal{L}_{\text{BCE}} \leftarrow \text{BCE}(\sigma_p, \sigma_t)$ 
16:       $\mathcal{L}_V \leftarrow \|V_p - V_t\|_1$ 
17:       $\mathcal{L}_u \leftarrow \|u_p - u_t\|_1$ 
18:       $\mathcal{L}_{\text{comp}} \leftarrow \left\| \frac{\partial V_p}{\partial (\Delta V)} \right\|_1$ 
19:       $\mathcal{L}_\beta \leftarrow \sum_{i=1}^3 \|e^{\log \beta_i} - e^{\log \beta_{i,0}}\|_1$ 
20:       $\mathcal{L} \leftarrow \mathcal{L}_{\text{BCE}} + e^{\log \beta_1} \mathcal{L}_V + e^{\log \beta_2} \mathcal{L}_u + e^{\log \beta_3} \mathcal{L}_{\text{comp}} + \mathcal{L}_\beta$ 
21:      Backward: Backpropagate  $\mathcal{L}$  and update all parameters
    via Adam
22:  end for
23:  Validate model and update learning rate scheduler
24: end for
25: return Trained PINN model
26: end procedure

```

同时，使用了一台配备有一块 PXI-8386 卡和两块 PXI-6123 卡的美国国家仪器设备来测量电压。采用了相邻-相邻注入测量模式。实验装置如图 3 左侧所示。有关更多实验细节，感兴趣的读者可参考 Tallman、Homa、Flores 和 Wertz (2023 年) 的研究。

3.2. 受损碳纤维翼型

第二项实验研究是在一种平纹碳纤维 (Fiber Glast) / 环氧树脂 (Fiber Glast System 2000 层压环氧树脂) 复合材料层压板上进行的，该层压板被制成具有代表性的 NACA 4424 翼型，宽度为 4 英寸，弦长为 5 英寸。该层压板共使用了 15 层碳纤维。铺层是在一个铝制阴模中进行的，采用湿法铺层加真空袋封装技术。翼型固化并修整至最终形状后，在 CEAST 9340 落锤冲击试验机上进行了两次冲击 (在不同位置)。第一次冲击能量为 15 焦耳，第二次为 12 焦耳。冲击位置如图 3 右侧所示。使用银漆 (Ted Pella 16040-30) 在顶面粘贴了总共 20 个电极。通过 BK Precision 9131 B 电源注入 0.8 安培的直流电，同时使用 National Instruments PXIe-6368 数据采集系统测量电压。电流注入和

电压测量采用“蛇形”模式进行。有关注入-测量模式及一般实验细节的更多信息，感兴趣的读者可参考 Sannamani、Gao、Chen 和 Tallman (2022 年) 的研究。

结果与讨论

4.1. 电阻抗断层成像结果

为回答第 1 节中强调的研究问题，我们将物理信息神经网络 (PINN) 重建结果与纯数据驱动神经网络重建结果以及非线性差分成像重建结果 (NLDI——一种经典成像方法，遵循 Smyl、Pour-Ghaz 和 Seppänen 于 2018 年提出的方法，其中背景电导率采用平滑先验，电导率变化采用拉普拉斯正则化，即 $\Delta\sigma$) 进行了比较。为确保比较的公平性，纯数据驱动网络采用了与 PINN 电导率分类器相同的架构以及相同的二元交叉熵 (BCE) 损失函数。

我们首先分析受损桁架的情况，图 4 中报告了使用三种电阻抗断层成像 (EIT) 方法进行的重建结果。在该实验中，我们观察到所考虑的两种情况下，三种 EIT 重建框架都能捕捉到损伤。然而，物理信息神经网络 (PINN) 重建能最清晰地定位缺口，且产生的背景伪影最少。相比之下，经典方法和数据驱动方法的背景电导率都存在明显波动。在对比物理信息神经网络 (PINN) 和数据驱动方法的重建结果时，我们注意到物理信息神经网络 (PINN) 图像在缺口位置的电导率值显著更低 (由于这些区域没有导电材料，电导率值本应接近零)。

在高维 (输出) 实验案例中，我们研究了三维翼型重建，其包含的逆自由度大约是桁架实验的 10 倍。这些成像结果如图 5 所示，同样，所有三个框架都很好地捕捉到了双重损伤。初步观察发现，与纯数据驱动方法相比，物理信息神经网络 (PINN) 重建能更精确地定位 15 焦耳的冲击，且对 12 焦耳的冲击呈现更清晰。相比之下，经典重建方法对 15 焦耳冲击损伤的捕捉与数据驱动方法相当，但存在一些稀疏的背景伪影。下面将对这些结果进行进一步讨论。

4.2. 讨论

本文的目的是确定物理信息神经网络 (PINNs) 是否能够 (a) 优于传统的纯数据驱动神经网络，以及 (b) 达到经典电阻抗断层成像 (EIT) 方法的保真度。这些问题的答案在定性上是肯定的，这在 4.1 节的实验研究中得到了证明。虽然经典反演方法的保真度差异很大，并且受参数化、正则化、离散化以及许多其他超出本研究范围的因素影响，但仍有待探讨的是：物理信息神经网络 (PINNs) 为何能优于数据驱动神经网络？

从图 6 所示的损失曲线图中可以对这个问题获得一些见解，图中展示了物理信息神经网络 (PINN) 损失与总损失的叠加情况。我们注意到，在我们的物理信息神经网络 (PINN) 公式中，物理项 (图 6 中的橙线) 对其施加了显著约束。




图 5. 双冲击损伤翼型的重建。尺寸单位为米，图像以 [1,0] 范围呈现，着色方式与图 4 相同。损伤位置用红色圆圈标出。

学习过程，尤其是在训练的初始阶段。这意味着在显著减小数据损失之前，网络被迫遵循问题的物理规律。这种正则化明显改善了验证曲线，验证曲线在初始训练后呈现出平稳收敛的趋势。基于这些认识，我们推断，在电导率训练样本具有稀疏二进制特性的情况下（参见图 2），物理信息神经网络（PINNs）中基于物理的正则化所带来的改进提供了更优的泛化能力。最终，与仅数据驱动模型相比，物理信息神经网络（PINNs）增强的泛化能力使得损伤位置的定位更准确，电导率估计更符合实际情况。

除了前面几点，物理信息神经网络（PINN）框架还提供了适应训练动态的途径，这是当前数据驱动方法所不具备的。例如，有人可能会认为，自动调整损失系数的能力提高了网络避开局部最小值的能力，兼容性约束确保了输入和输出之间具有物理真实性的联系，而内部信息（即 u ）的纳入则提供了将空间物理依赖性与所关注的逆因果关系（在本研究中为 σ ）相关联的信息。然而，归根结底，还需要研究其他项，如 u 的空间梯度、高阶导数和其他兼容性项，以充分理解物理约束对使用物理信息神经网络进行电阻抗断层成像（EIT）重建精度的影响。




图 6. 划分各个物理项的物理信息神经网络（PINN）训练损失。

最后，从数值角度来看，值得注意的是，本文采用的物理信息神经网络（PINN）方法在计算需求上远高于数据驱动的神经网络（NN）方法。事实上，PINN 所需的待估计参数大约是数据驱动 NN 的五倍，这导致其训练时间也几乎是后者的五倍（在 RTX-4090 机器上）。这一计算障碍在未来的研究中可以得到缓解，例如在仅进行回归预测的情况下，当不使用二元交叉熵（BCE）损失时，自动混合精度技术便可应用。然而，归根结底，与传统方法相比，PINN 在训练时间上的付出换来了求解电阻抗断层成像（EIT）问题时约 80,000 倍的速度提升。

结论

本研究通过实验研究探索复合材料结构损伤的重建，证实了物理信息神经网络（PINNs）在电阻抗断层成像（EIT）中的可行性。研究发现，物理信息神经网络（PINNs）能够（a）优于传统的数据驱动神经网络，（b）达到经典电阻抗断层成像（EIT）反演方法的保真度。文中讨论了与纯数据驱动电阻抗断层成像（EIT）相比，促进物理信息神经网络（PINNs）泛化能力提升的关键特征，并为物理信息神经网络（PINNs）在电阻抗断层成像（EIT）中的应用研究提供了未来方向。

CRediT 作者贡献声明

丹尼·斯迈尔：写作——评审与编辑、写作——原始草稿、可视化、验证、软件、方法学、调查、形式分析、概念构思。泰勒·N·塔尔曼：写作——评审与编辑、调查、数据整理。劳拉·霍马：写作——评审与编辑、方法学、概念构思。切诺阿·弗卢努瓦：写作评审与编辑、概念构思。萨拉·J·汉密尔顿：写作评审与编辑、调查。约翰·沃茨：写作——评审与编辑、数据整理、概念构思。

利益冲突声明

作者声明，他们没有已知的竞争性经济利益或可能影响本文所报道工作的个人关系。

致谢

通讯作者感谢佐治亚理工学院的支持。所有作者感谢美国空军研究实验室及其工作人员的支持。

数据可用性

数据将根据请求提供。

参考文献

Abbasi, J., & Andersen, P. Ø. (2024). 物理激活函数 (PAFs): 一种将物理学更高效地引入物理信息神经网络 (PINNs) 的方法。《神经计算》, 608, 第 128352 篇。

巴尔, L., & 索琴, N. (2021)。基于无监督学习的 PDE 断层成像强解。《工业与应用数学学会影响科学期刊》, 14 (1), 129-155。

Candiani, V., Hyvönen, N., Kapiro, J.P., & Kolehmainen, V. (2021)。近似电阻抗断层成像技术用于人体头部成像的误差方法。《逆问题》, 37 (12), 125008 号文章。

加勒特 (A.)、里格比 (S.)、塔尔曼 (T. N.)、孔 (X.)、哈吉拉苏里哈 (I.)、刘 (A.) 等 (2022)。从反问题视角看结构工程。《英国皇家学会会刊 A 辑: 数学、物理及工程科学》, 478 (2257), 第 20210526 篇。http://dx.doi.org/10.1098/rspa.2021.0526。

豪普特曼、阿德勒、阿里奇与厄克特姆 (2020)。多尺度学习迭代重建。IEEE Transactions on Computational Imaging, 6, 843-856。

胡志、舒克拉 (K. Shukla)、卡尼亚达基斯 (G. E. Karniadakis) 和川口 (K. Kawaguchi) (2024)。利用物理信息神经网络解决维度灾难。《神经网络》, 176 卷, 106369 号文章。

亚尔韦、E.V.、胡斯、K.H.、尼基什科夫、Y.、马基耶夫、A. (2018)。层合复合材料静态承载失效的离散损伤建模。《复合材料 A 辑: 应用科学与制造》, 108, 30-40。

卡尼亚达基斯, G. E., 凯夫雷基迪斯, I. G., 卢, L., 佩尔迪卡里斯, P., 王, S., & 杨, L. (2021)。物理知情机器学习。《自然评论·物理学》, 3 (6), 422-440。

Kim, D., Lee, I., Nomura, T., Dede, E. M., Yoo, I., & Min, S. (2020)。拓扑优化使用均质化设计方法分析功能梯度各向异性复合材料结构。《应用力学与工程计算方法》, 369 期, 113220 文章。

帕斯克 (A.)、格罗斯 (S.)、马萨 (F.)、勒雷尔 (A.)、布拉德伯里 (J.)、钱南 (G.) 等 (2019)。PyTorch: 一种命令式风格的高性能深度学习库。《神经信息处理系统进展》, 32。

Pokkunuru, A., Rooshenas, P., Strauss, T., Abhishek, A. 与 Khan, T. (2023)。利用基于能量的先验改进物理信息神经网络的训练: 电阻抗断层成像研究。发表于《第十一届国际学习表征会议》。

Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019)。物理信息神经网络: 一种用于求解涉及非线性偏微分方程的正问题和反问题的深度学习框架。《计算物理杂志》, 378, 686-707。

拉什特 - 贝赫什特 (M.)、胡贝尔 (C.)、舒克拉 (K.) 和卡尼亚达基斯 (G. E.) (2022)。物理信息神经网络 (PINNs) 在波传播和全波形反演中的应用。《地球物理研究杂志: 固体地球》, 127 (5), 文章编号 e20211R023120。

桑纳马尼 (M.)、高 (J.)、陈 (W. W.) 和塔尔曼 (T. N.) (2022)。基于表面安装电极和方向灵敏度矩阵的电阻抗断层成像技术在非平面碳纤维增强聚合物层合板损伤检测中的应用。《复合材料科学与技术》, 224 卷, 109429 号文章。

Smyl, D., Pour-Ghaz, M. 和 Seppänen, A. (2018)。利用电学成像检测和重建复杂结构裂纹模式。《无损检测与评价国际期刊》, 99, 123-133。

Somersalo, E., Cheney, M., 及 Isaacson, D. (1992)。电流计算机断层扫描电极模型的存在性与唯一性。《工业与应用数学学会应用数学期刊》, 52 (4), 1023-1040。

托尔曼、T.N.、霍马、L.、弗洛雷斯、M. 和韦茨、J. (2023)。利用混合平滑度和贝叶斯正则化在复杂增材制造形状中通过电阻抗断层扫描进行损伤映射。《应用力学与工程计算方法》, 414, 第 116185 篇。

托尔曼、T.N.、霍马、L.、莱斯泰赫、T.、谢尔、N.、弗洛雷斯、M. 和韦尔茨、J. (2024)。弯曲载荷作用下通过电阻抗断层扫描检测碳纤维 / 环氧树脂复合材料的压痕损伤。《国际无损检测与评价》, 147, 第 103206 篇。

杨晓、张宇、陈华、马刚、王晓 (2024)。结合 CNN 和物理信息神经网络的两阶段成像框架用于全逆断层成像: 电阻抗断层成像 (EIT) 案例研究。arXiv 预印本 arXiv:2407.17721。