


密 级_____



桂林电子科技大学
GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

硕 士 学 位 论 文

(全日制专业学位硕士)

题目 基于电阻抗成像技术的图像重构算法研究

(英文) Research on Image Reconstruction Algorithms Based
on Electrical Impedance Imaging Technology

研 究 生 学 号: 20172301003

研 究 生 姓 名: 林泽姿

指导教师姓名、职称: 汪杰君 正高级实验师

申 请 学 位 类 别: 机械硕士

领 域: 机械

论 文 答 辩 日 期: 2023 年 5 月 21 日

摘要

海上的特殊环境对长时间在海上作业的人员的健康造成一定的损伤,目前对身体健康监测主要采用传统的生理指标监测方法,而常用的 CT(Computed Tomography)成像设备由于体积大、设备复杂、价格昂贵,不便于应用在船舶上,因此研究一种便于在海上应用的医疗检测技术尤为重要。电阻抗成像(Electrical Impedance Tomography, EIT)技术通过成像算法重建敏感场内介质电阻率分布情况,不仅具有无辐射、无创、响应快的优点,还具备便携性、价格低廉、使用范围广等优势,受到了许多科学工作者的关注。

EIT 逆问题存在病态性以及严重的不适定性,使得其求解精度不理想,重建的图像分辨率低,因此需要寻找一种新的成像方法以改善图像重建质量。以提高图像重建质量为目的,本文对 EIT 图像重建算法进行了深入研究,具体研究内容如下:

1.对 EIT 正问题进行有限元剖分和求解,建立场域仿真模型。在场域放置不同的目标物,改变其形状、位置以及电导率,以此生成神经网络训练所需的数据集。

2.提出了一种粒子群算法(Particle Swarm Optimization, PSO)与 Tikhonov 正则化(Tikhonov Regularization, TR)相结合的 PSO-TR 算法,通过在目标函数上增加正则项对逆问题进行约束,有效地降低了解的不稳定性,提高了重建图像的精度和鲁棒性。

3.设计了全连接神经网络(Full Connect Neural Network, FCNN)模型,并在其基础上进行改进,提出了一种残差全连接神经网络(Fully-Connected Residual Network, FCRN)算法。该算法是在 FCNN 中添加跨层连接和捷径分支来构建残差结构,加深了网络,使网络能够更好地学习 EIT 问题中边界电压与阻抗之间的映射关系,实现了更深层次的网络训练和更高精度的结果预测。同时,针对 EIT 数据集的类别不平衡问题,提出了 Focal Loss 与 L1 Loss 相结合的总损失函数,使网络更倾向于目标物样本的学习,从而使得网络可以更好的对目标物进行定位,提高了模型的泛化能力和鲁棒性。

4.将 PSO-TR 算法和 FCNN 算法进行仿真实验,并与经典图像重构算法进行比较。实验结果表明,PSO-TR 算法能够大致识别到目标物,FCRN 相较于其他算法,能更准确的定位目标区域,且成像清晰无伪影,提高了成像精度。

关键词: 电阻抗成像; 有限元剖分; 粒子群算法; Tikhonov 正则化; 神经网络

Abstract

The special environment at sea causes certain damage to the health of personnel working at sea for a long time, and at present, traditional physiological index monitoring methods are mainly used to monitor physical health, while the commonly used CT (Computed Tomography) imaging equipment is difficult to be used on ships due to its large size, complex equipment and high price. Therefore, it is especially important to study a medical detection technology that can be easily applied at sea. Electrical Impedance Tomography (EIT) technology reconstructs the resistivity distribution of the medium in the sensitive field by imaging algorithms, which not only has the advantages of non-radiation, non-invasive and fast response, but also has the advantages of portability, low price and wide range of use, and has received the attention of many scientists.

The pathological nature of the EIT inverse problem as well as its severe discomfort make its solution accuracy unsatisfactory and the reconstructed image resolution low, so a new imaging method needs to be found to improve the image reconstruction quality. With the aim of improving the image reconstruction quality, this paper conducts an in-depth study on the EIT image reconstruction algorithm as follows:

1. Finite element dissection and solution of the EIT positive problem are performed to establish a field simulation model. Different targets are placed in the field and their shapes, positions and conductivities are changed to generate the data set required for neural network training.

2. A PSO-TR algorithm combining Particle Swarm Optimization (PSO) and Tikhonov Regularization (TR) is proposed to effectively reduce the instability of the solution by adding a regular term to the objective function to constrain the inverse problem. The accuracy and robustness of the reconstructed images are improved.

3. The Full Connect Neural Network (FCNN) model is designed, and a Fully-Connected Residual Neural Network (FCRN) algorithm is proposed based on its improvement. The algorithm is to add cross-layer connections and shortcut branches to the FCNN to build the residual structure, deepening the network so that the network can better learn the mapping relationship between boundary voltage and impedance in the EIT problem, achieving deeper network training and higher accuracy result prediction. Meanwhile, the total loss function combining Focal Loss and L1 Loss is proposed for the category imbalance problem of EIT

dataset, which makes the network more inclined to the learning of target samples, thus enabling the network to better localize the targets and improve the generalization ability and robustness of the model.

4. The PSO-TR algorithm and FCNN algorithm are simulated and compared with the classical image reconstruction algorithm. The experimental results show that the PSO-TR algorithm can roughly identify the target object, and FCRN can locate the target area more accurately compared with other algorithms, and the imaging is clear without artifacts, which improves the imaging accuracy.

Keywords: Electrical impedance imaging; finite element discretization; particle swarm algorithm; Tikhonov regularization; neural network

目 录

第一章 绪论.....	1
§1.1 EIT 技术的背景及研究意义	1
§1.2 EIT 技术研究现状	2
§1.2.1 图像重建算法研究发展现状.....	2
§1.2.2 EIT 在生物医学领域的应用	5
§1.3 论文的主要研究内容.....	6
§1.4 论文的组织框架.....	7
第二章 EIT 成像技术的理论基础	8
§2.1 EIT 成像技术的基本原理	8
§2.2 EIT 的数学模型	10
§2.3 EIT 正问题	11
§2.4 EIT 逆问题	12
§2.5 经典的图像重建算法.....	14
§2.5.1 Newton-Raphson 算法.....	14
§2.5.2 NOSER 算法.....	15
§2.6 本章小结.....	16
第三章 EIT 正问题研究	17
§3.1 EIT 正问题的求解	17
§3.1.1 等价变分问题.....	18
§3.1.2 有限元计算方法.....	19
§3.1.3 变分问题求解.....	20
§3.2 基于 COMSOL 建立 EIT 模型.....	21
§3.2.1 COMSOL 软件的使用	21
§3.2.2 建立场域模型.....	22
§3.2.3 有限元剖分	23
§3.2.4 有限元求解.....	24
§3.3 数据集的获取.....	27
§3.3.1 有限元区域设置目标物.....	27
§3.3.2 数据集的生成.....	27
§3.4 本章小结.....	28
第四章 基于 PSO-TR 的 EIT 成像算法研究	29
§4.1 粒子群算法.....	29
§4.1.1 粒子群算法的基本原理.....	29
§4.1.2 粒子群算法流程.....	30

§4.2 Tikhonov 正则化	32
§4.3 基于 PSO-TR 的 EIT 成像算法	32
§4.4 实验结果及分析.....	34
§4.4.1 算法的评价指标.....	34
§4.4.2 仿真结果.....	34
§4.5 本章小结.....	37
第五章 基于 FCRN 的 EIT 成像算法研究.....	38
§5.1 神经网络的介绍.....	38
§5.1.1 感知机与深层神经网络.....	38
§5.1.2 神经网络的训练.....	40
§5.1.3 激活函数.....	41
§5.2 基于残差全连接神经网络的 EIT 成像算法	43
§5.2.1 全连接神经网络.....	43
§5.2.2 残差网络.....	45
§5.2.3 残差全连接神经网络模型.....	46
§5.3 损失函数.....	47
§5.4 EIT 成像实验结果分析	49
§5.5 本章小结.....	52
第六章 总结与展望	53
§6.1 本文工作总结.....	53
§6.2 未来工作展望.....	54
参考文献.....	55

第一章 绪论

§ 1.1 EIT 技术的背景及研究意义

随着海洋经济的快速发展，船舶已经成为海上交通的主要运输工具之一。然而，海上作业人员的身体健康状况一直是海事领域的一个重要议题。由于需要长时间处于相对封闭、潮湿、高温的环境，以及还会面临海上恶劣天气的挑战，海上作业人员的身体健康容易受到许多方面的影响，例如，他们的饮食习惯、生活方式、心理以及职业危害等。因此，他们经常会受到各种疾病的困扰，例如呼吸道以及心血管等方面的疾病^[1]。

在海上，由于设备和医疗资源的缺乏，及时获得有效的医疗服务和诊断非常困难，这给海上作业人员的身体健康和航海安全都带来了巨大的隐患。目前，对于海上作业人员的身体监测主要手段采用的是传统的生理指标监测方法，如心电图、脉搏、血压等^[2]，尽管这些方法简单易操作，但并不能对海上作业人员的身体状况进行全面、深入的监测和诊断。

在医疗领域中，核磁共振（Magnetic Resonance Imaging, MRI）是除了 X 射线（X-CT）和超声波 CT（Ultrasound CT）以外，被广泛使用的 CT 成像设备。拥有丰富临床经验的 X-CT 技术是成像技术上发展最成熟的。尽管 X-CT 设备是使用最广泛的，但它即昂贵又复杂，对身体的组织也造成一定的损伤。虽然超声波 CT 具有一定的安全性，但在传播过程中不可避免地对人体组织介质相互作用，即在体内传播时，人体组织会吸收其能量导致能量衰减，而由于反射、散射等导致的能量分散也会产生各种效应，进而成像效果不理想。MRI 是对质子成像，无电离辐射和放射损伤，对人体不会造成损伤，对软组织的成像比较清晰且空间分辨率高。但与其他 CT 技术相比，它的成像速度比较慢，且其结构复杂、设备庞大、价格昂贵等不足限制了其在船舶上诊断方面的应用。因此，探求一种新的、低成本和便携的 CT 技术具有重要的意义。

电阻抗成像（Electrical Impedance Tomography, EIT）技术作为一种备受关注的新型成像技术应运而生。已有研究表明^[3]，人体各组织导电性（电阻）各有不同，在不同的健康状况状态下，其电导率也会发生相应的改变。因此，人体的某些生理或病理改变，都会在某种程度上影响体内各组织的导电性。EIT 技术的基本原理是根据人体内部不同组织的电阻抗差异，通过施加对人体无害的低频的小电流，并通过采集边界电极上测得的电位信息进行逆问题求解，获取人体内部的阻抗分布图像。通过 EIT 技术对图像进行重构，医生不用外科手术，就能无创地检测人体内部的各个组织，从

而判断体内是否有组织发生异变,包括异变的位置和程度,进而对症下药,为患者提供更好的医疗服务。这种非侵入性的技术大大提升了诊断的准确性和可靠性^[4]。表 1-1 为 EIT 技术与传统 CT 技术的比较。

表 1-1 各种成像技术的比较

技术	设备造价	检查费用	便携性	创伤性	分辨率
X 射线	较高	较高	复杂	细胞损害	较好
超声波	高	较高	较复杂	无创伤	较好
核磁共振	昂贵	高	复杂	有创	好
EIT	较低	低	简便	无创伤	较低

EIT 技术是采用低频的边界激励测量,不会产生辐射危险,安全隐患小,且该技术的系统组成相对简单,便于安装和携带。在船舶等海上特殊环境下,由于空间狭小、移动性强等特点,传统医疗设备的安装和使用受到了很大的限制。EIT 技术在成像分析具有无创、便携、低成本、安全、实时性好等诸多优势,可满足海上作业人员的身体检查需求,为海上作业人员提供及时、准确的医疗服务,同时也为海上作业保障提供了强有力的支持。由此,EIT 技术有着广泛的应用前景。

§ 1.2 EIT 技术研究现状

EIT 技术最初是 1930 年地质工作者用来预测矿藏分布情况的^[5],直到 1976 年,美国 Swanson D.K 首次在他的论文里提出该技术,EIT 技术才开始受到研究者的关注。图像重建算法是 EIT 技术的关键内容^[6]。本节主要从 EIT 的图像重建算法研究以及在生物医学领域的应用性两个方面叙述 EIT 技术的发展现状。

§ 1.2.1 图像重建算法研究发展现状

图像重建算法是 EIT 技术的关键内容,也是决定重建图像分辨率的重要因素。目前,EIT 图像重建算法主要有两类,一类是非智能算法,一类是智能优化算法。其中,非智能算法又可分为迭代与非迭代两种方法,智能优化算法可分为进化算法和神经网络,如图 1-1 所示^[7]。




图 1-1 图像重建算法种类

（1）非迭代法

线性反投影（Linear Back Projection, LBP）算法是非智能算法中发展较早的典型代表，于 1983 年由 Barber 和 Brown 等提出^[8]，具有原理简单和速度快的优势。尽管该算法有较好的鲁棒性，但重建图像分辨率较低。2009 年，罗辞勇等^[9]对 LBP 算法结果进行修正，提高了重构的效果^[10]。

灵敏度系数算法（Sensitivity Matrix method, SM）^[11]基于 Geselowitz 提出的灵敏度理论^[12]，由 Muria 等提出的。该算法是在假设场域基本稳定的情况下，求解灵敏度系数矩阵，并由其转置代替其逆矩阵。该算法精确度不高，但大多数迭代算法是在其基础上改进的，SM 为这些算法奠定了基础。

牛顿一步迭代法(Newton's One-Step Error Reconstructor, NOSER) 算法是在 1990 年，由美国仁斯利尔理工大学的 Cheney 等^[13]提出的。NOSER 基于 Newton-Raphson（NR）算法，不用迭代，只需求 NR 算法的第一步。相较于 NR 算法，提高了实时性，但计算值不精确，与真实解有较大的误差。

由于非迭代算法采用近似于线性化的方法，因此其计算效率相对较高，但是线性化方法会造成某些重要信息的丢失，从而影响到图像重建结果的准确性。而 EIT 逆问题是非线性问题，需要用迭代法进行求解。

（2）迭代法

Newton-Raphson（NR）迭代法是 1987 年，Yorkey 等^[14]通过修改提出的一种修正的 Newton-Raphson 图像重建算法，该算法给出了两种计算 Jacobian 矩阵的方法。相较于 LBP，该算法的逆问题求解精度高，但算法的计算量较大。

Newton 类算法需要计算条件数大的 Jacobi 矩阵，以至于导致逆问题病态。正则化技术的提出是用来降低其条件数的，使得解稳定。

1998 年，Vauhkonen^[15]提出一种 Tikhonov 正则化方法，通过在适应度函数中添

加罚函数来降低解的病态性。2004 年, Fang^[16]提出了一种非线性迭代算法, 该算法基于 Total Variation, 可在迭代时修正灵敏度矩阵。同年, 黄嵩等^[17]提出了一种可改善图像对比度的变差正则化算法。2011 年, 张玲玲等^[18]提出了一种基于 1 范数的图像重建算法。该算法是将 2 范数罚函数改为 1 范数, 并与其他经典算法进行比较, 证明了该算法能有效提高图像重建质量。2012 年, 范文茹等提出了两步迭代 TV 正则化法^[19]。

在 EIT 图像重建的历程中, 非迭代法速度快, 迭代法通过不断迭代可获得相对较高的求解精度, 但也存在一些缺陷, 如计算量大且过程复杂、图像含有伪影导致精确度不高和分辨率较低等。智能优化算法具有较强的自适应能力, 可以有效的提高逆问题求解的精度和成像分辨率。智能优化算法的出现, 为 EIT 图像重建带来了新的可能性。

(3) 进化算法

1989 年, Clark 和 Janday^[20]提出了最大熵估计方法来解决生物电磁逆问题。随后, 随机理论的方法被引入 EIT 成像技术, 例如遗传算法 (Genetic Algorithm, GA) 和粒子群算法 (Particle Swarm Optimization, PSO) 等。

2000 年, Kim 等用遗传算法解决静态 EIT 逆问题^[21]。2008 年, 石天明等^[22]提出了一种组合图像重建算法, 该算法基于 LBP 算法、修正 NR 算法以及遗传算法, 充分发挥各个算法的优势, 逐步提取测量数据中的信息量, 有效地提高了重建图像的分辨率。2010 年, 肖理庆等^[23]提出了一种基于遗传算法的组合算法。该算法是在初始化 GA 算法种群时, 引入 LBP 算法、修正的 NR 算法与区间剖分。同时, 为了解决 GA 算法局部搜索能力差, 以及未成熟收敛的缺点, 在 GA 算法的变异操作中引入 PSO 算法。2020 年, Yijia Zhang 等^[24]提出了一种比例遗传算法 (pGA), 该算法是将 GA 算法与比例目标函数相结合。通过实验证明, 该算法有更好的重建图像质量和更快的收敛速度。

(4) 神经网络

随着深度学习的迅速发展, 神经网络被应用于 EIT 技术, 且取得了不错的成果。

2001 年, 魏颖等^[25]提出了基于径向基函数 (Radical Basis Function, RBF) 神经网络图像重建算法。该算法用于解决 EIT 图像重建非线性问题, 有效解决了迭代类算法计算量大、实时性差的缺点, 有效提高了 EIT 逆问题求解精度。

2009 年, 谢莉莉提出一种基于 PSO 优化 BP (Back Propagation) 神经网络的 EIT 图像重建算法。该算法在基本 BP 算法的误差反向传播调整权值的基础上, 再引入 PSO 算法进行权值修正。该算法不仅能很好地适应 EIT 的病态非线性特性, 而且可以克服基本 BP 算法收敛速度慢和易陷于局部极值的局限, 但该算法仍存在伪影^[26]。

2018 年, Fernández-Fuentes X 等^[27]提出了一种基于 ML 技术的逆问题求解法来重建 EIT 图像, 能够从定量的角度更准确地重建 EIT 图像。

2019 年, Tan Chao 等^[28]提出了一种基于卷积神经网络(CNN)的图像重建算法。该算法的重建结果证明了网络的稳健性和泛化能力, 比传统算法有更高的准确性。

综上所述, 与传统的非智能算法相比, 智能优化算法能够取得较好的结果。但智能优化算法也存在一些挑战和限制, 例如算法设计难度大、参数选择问题、鲁棒性不高等。因此设计一种新的、有效的算法仍是研究的重点。总的来说, 在 EIT 图像重建中, 智能优化算法的出现为 EIT 图像重建带来了新的发展机遇, 有望在该领域得到广泛应用。

§ 1.2.2 EIT 在生物医学领域的应用

从生物电学特性的角度对人体进行非侵入性成像的最早研究是在 1978 年 Henderson 和 Webster 构建的“阻抗相机”, 他们在胸背上安装矩形电极阵列, 将一个电压源通过电极施加到人体胸部, 建立等电位面, 测量该阵列上每个电极的电流数据, 根据电流数据生成胸阻抗图像, 但这只是类似 X 胸片的透视图片。虽然结果图像中的低导电区可以清楚地显示肺部, 却不是断层图像。

1987 年, Brown 研究小组研制出 MK1 系统^[29], 这是第一个商业化的 EIT 系统。1995 年, 他们在其基础上研制了第一个供临床研究用的 MK2 系统^[30]。随后, 他们又研制了 MK3a 和 MK3b 系统^[31], 这两个系统采用复频谱阻抗成像(EITS)。

1988 年, Newell 等设计了 ACT2 系统^[32]。1994 年, R.D. Cook 基于 ACT2 系统设计了 ACT3 系统, 该仪器能够自动校准电压表和电流源, 并在计算机控制下调整电流源输出阻抗^[33]; 2005 年, 后续团队设计了更先进的 72 电极的 ACT4 系统, 用于检测乳腺癌, 能对其进行 2D 和 3D 的成像^[34]。

1994 年, 牛津大学的 Chris McLeod 在成功开发了具有用于体外研究的电压驱动电流方法的多驱动电阻抗断层成像系统 OXPACT-II 之后, 他们又研究开发一种实时多驱动自适应系统, 即自适应电流断层成像系统(OXBACT-III)^{[35][36]}。2005 年, 在其基础上研制出了基于 FPGA 的 OXBACT-V 系统, 其采集速度达到每秒 25 帧^[37]。

2010 年, 韩国 Kyung Hee 大学的研究团队改进了 KHU Mark1 系统, 在其基础上研制出了 KHU Mark2 系统, 它与 KHU Mark1 的不同在于, 它是一个真正的并行系统, 可以组装在 1 到 64 之间的任何通道中, 最大数据采集速度为 100 帧每秒, 能够检测呼吸和心脏活动期间的快速生理变化, 比 KHU Mark1 更加灵活^[38]。

与国外研究相比, 国内对 EIT 技术的研究相对滞后, 但目前已有多个高校和单位设立了电阻抗研究小组, 例如第四军医大学、天津大学、重庆大学、中国医学科学院生物医学工程研究所^[29]。

第四军医大学开展了一系列物理模型和动物模型实验, 董秀珍、付峰等设计了基于物理模型的硬件系统, 并提出了广义逆动态重构算法^[39]。该大学现在已经成功研制

了一个脑部电阻率分布仿真模型实验水槽^[40]，他们的研究成果促进了我国 EIT 技术的发展。

天津大学王华祥教授研究团队针对人体肺部疾病的 EIT 成像算法进行研究，研制出了 MEIT_TJU 硬件系统，该系统主要应用于人体肺部呼吸过程的监测^{[41][42]}。重庆大学自主研制了一维无创脑水肿动态监护仪和二维脑电阻抗地形图仪，并进行了临床应用研制^[4]。

目前，我国 EIT 技术的研究已取得了较大进展，众多学者正致力于该领域的研究。EIT 技术的应用在实验室已经有一定的研究成果，但在临床应用方面还有很多挑战，特别是应用于船舶上还有待研究。目前 EIT 技术存在的问题是成像分辨率和精确度不高。因此，引入有效的算法，改善图像的分辨率、提高精确度是 EIT 图像重建算法研究的重要方向。

§ 1.3 论文的主要研究内容

本文主要研究 EIT 技术的图像重建算法，旨在提高 EIT 成像的精度和稳定性。针对 EIT 技术中存在的问题，提出了两种新的成像算法，分别是基于 PSO 算法和 Tikhonov 正则化相结合的 PSO-TR 算法，以及基于残差全连接神经网络的 EIT 成像算法。在课题研究过程中，主要完成以下工作：

(1) 首先对 EIT 正问题的有限元求解方法进行分析，通过有限元仿真软件 COMSOL 建立仿真模型，该模型包括均匀放置的 16 电极，最后再通过 MATLAB 计算获取边界电压数据；设计了三种不同目标物模型，获取不同的电导率分布结果和边界电压测量值，目的是为验证算法提供数据集。

(2) 提出了一种基于粒子群算法和 Tikhonov 正则化相结合的 PSO-TR 算法成像算法，该算法是将粒子群算法与 Tikhonov 正则化相结合，首先定义目标函数，通过在目标函数上增加正则项用来约束解的平滑性或稀疏性，避免求解过程中产生过拟合现象，同时保留 PSO 算法的全局搜索能力，提高成像效果。

(3) 设计了一种全连接神经网络模型进行 EIT 逆问题的求解，将仿真数据集输入到全连接神经网络中，然后通过对数据集进行训练，使其能够预测目标物。然后在全连接神经网络基础上进行改进，通过引入残差网络，提出了一种残差全连接神经网络 (FCRN) 模型。利用该网络逐级对测量数据进行特征提取，学习模型中的非线性关系，从而提高模型的预测精度。为进一步提高图像重建精度，选用 Focal Loss 以及一范式的组合作为网络的总损失函数，通过调节参数来最小化损失函数。最后，把测试集数据输入到训练好的模型中进行重建图像，并将结果与传统的算法做分析和对比。

§ 1.4 论文的组织框架

本文各章的具体内容如下:

第一章, 绪论。本章主要介绍了 EIT 技术的背景以及研究意义, 综述了 EIT 图像重建算法研究现状以及 EIT 技术在生物医学领域的应用。

第二章, EIT 成像技术的理论基础。本章首先从 EIT 成像的基本原理出发, 描述了 EIT 成像的数学模型, 进而分析正问题和逆问题的原理, 最后, 介绍了 Newton-Raphson 算法和 NOSER 算法两种经典图像重建算法。

第三章, EIT 正问题研究。本章首先对 EIT 正问题的求解方法, 即有限元法进行介绍, 接着简单介绍了 COMSOL 软件, 并利用该软件建立模型, 联合 MATLAB 仿真获取数据; 最后, 设计三种不同目标物模型获取数据集。

第四章, 基于 PSO-TR 的 EIT 成像算法研究。本章分别介绍了粒子群算法和 Tikhonov 正则化算法, 将粒子群与 Tikhonov 正则化相结合, 提出了一种 PSO-TR 的图像重建算法, 并进行了仿真验证, 与 NOSER 和 PSO 算法进行比较分析。

第五章, 基于 FCRN 的 EIT 成像算法研究。首先介绍了神经网络的基本理论, 接着提出全连接神经网络模型, 在其基础上引入残差网络, 提出一种残差全连接神经网络 FCRN 算法, 并将 Focal Loss 损失函数与一范式相结合作为网络的总损失函数。进行 EIT 图像重建, 与前文的算法比较分析。

第六章, 总结与展望。总结本文的主要工作, 并对未来研究提出展望。

第二章 EIT 成像技术的理论基础

EIT 可以通过测量物体内部电导率变化所引起的电阻抗变化来揭示物体内部结构和性质。稳定电磁场理论是 EIT 成像技术的理论依据,该技术依据介质具有独特的电特性这一物理基础,通过向表面提供激励和检测边界电压,可以计算出敏感场域内的电导率分布。通过使用成像算法,重构被测场内介质的分布情况。在 EIT 成像技术中,可将问题分为正问题和逆问题,正问题是指给定电流分布和电极电势,计算电阻抗分布的过程^[43]。正问题的求解是逆问题的基础,逆问题是指根据电极电势数据反推出电阻抗分布的过程。

§ 2.1 EIT 成像技术的基本原理

电阻抗是指物质对交流电信号的阻碍程度,是由电导率和介电常数共同组成的。电流在物体内部运动时会由于电子的撞击而减小,同时还会受到物体内部的阻碍,导致电流的分布变化。如果在物体表面上放置电极,并施加一定的交流电信号,测量得到其表面的电压信号,利用这些信号通过图像重构算法获得物体内部的电阻抗分布,从而得到物体内部的结构信息。

为说明 EIT 的基本原理,将物体表面等效成表面绝缘的矩形导体模型^[44]。设导体的电导率 σ 是均匀分布的,在导体表面接上电极 e1、e2、e3 和 e4,激励源 I 注入电极 e1,从电极 e4 流出。此时,电流密度均匀分布在导体中,如图 2-1 所示,电势线正交于垂直分布的电流线。




图 2-1 导体内部电流和电位线分布图

设导体横截面面积为 S , 电极 e2、e3 之间的距离为 L , 测得其两端的电压 V_{14} , 根据欧姆定律, 得到两个电极之间的电阻:

$$R_{23} = \frac{V_{14}}{I} = \frac{L}{\sigma S} \quad (2-1)$$

当在上述导体之间放入其他物体时，其电导率会发生改变，电流线和电势线也会产生不同的变化，如图 2-2 所示。




图 2-2 不同物体的电流和电位线分布图

具体表现为，电极 e2、e3 之间的电阻在放置良导体时减小，在放置绝缘体时增大。由于施加的是恒流激励，因此，测得放置良导体的 e2、e3 间的电压对应减小，放置绝缘体的 e2、e3 间的电压对应增加。假设在两种情况下，e2、e3 间的平均电导率分别为 σ_1 和 σ_2 ，根据欧姆定律，可计算得到对应的 e2、e3 间的电阻：

$$R_{23}' = \frac{V_{14}'}{I} = \frac{L}{\sigma_1 A} \quad (2-2)$$

$$R_{23}'' = \frac{V_{14}''}{I} = \frac{L}{\sigma_2 A} \quad (2-3)$$

根据 (2-1) 到 (2-3) 可得到：

$$\sigma_1 = \sigma \frac{V_{14}}{V_{14}'} \quad (2-4)$$

$$\sigma_2 = \sigma \frac{V_{14}}{V_{14}''} \quad (2-5)$$

通过上式可知，根据放置不同物体前后的边界电压变化，以及未放置物体时的电导率，可推断出物体内部电导率的变化。

人体是一个复杂而多变的生物导体，其各脏器、各组织的阻抗特性也各不相同。同一生物体的正常组织中，其电学性质（电阻性和电导性）也会在持续地发生变化，病理组织的阻抗也与正常组织存在显著不同^[45]。因此，可以利用上述 EIT 技术的基本原理，向生物体注入一定的激励信号，通过测量体表的电压信号，并经过算法处理得到生物体内部的阻抗信息重构图像。

施加 20-100kHz 的激励信号频率，人体组织的阻抗分布值如表 2-1 所示。从表中可以看出，由于不同的器官组织的组织结构、电离能力以及含水量等特性的不同，他们之间的阻抗有着显著的差异，特别是含水量越高的组织，例如血液、脑髓，其阻抗越小，而含水量越低的组织，例如骨骼，其阻抗最大。

表 2-1 人体组织的阻抗分布值

组织	阻抗/ (Ω/m)
骨骼	166
血液	1.5
脂肪	21-28
肺	7.3-24
肝脏	3.5-5.5
脑髓	0.65
神经组织	5.8

§ 2.2 EIT 的数学模型

用 Maxwell 方程组描述 EIT 电磁场原理^[46]，其微分形式为：

$$\nabla \times \mathbf{H} = \mathbf{J} + \frac{\partial \mathbf{D}}{\partial t} \quad (2-6)$$

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t} \quad (2-7)$$

$$\nabla \cdot \mathbf{B} = 0 \quad (2-8)$$

$$\nabla \cdot \mathbf{D} = \rho \quad (2-9)$$

式中， ∇ 为矢量微分算子(泊松算子)， $\mathbf{H}$ 为磁场强度， $\mathbf{J}$ 为传导电流密度， $\mathbf{D}$ 为电感应强度， $\mathbf{E}$ 为电场强度， $\mathbf{B}$ 为磁感应强度， ρ 为体电荷密度。

在 (2-6) 到 (2-9) 的方程组中，场量之间的关系为：

$$\mathbf{B} = \mu \mathbf{H} \quad (2-10)$$

$$\mathbf{J} = \sigma \mathbf{E} \quad (2-11)$$

$$\mathbf{D} = \varepsilon \mathbf{E} \quad (2-12)$$

式中， ε 为复介电常数； σ 为电导率； μ 为导磁率。

EIT 成像敏感场数学模型构建了敏感场域内介质电导率的分布与其边界电压值间的对应关系。在 EIT 系统中，场域通常被假设为准静态的，来简化求解正问题的过程：此时的电场呈无旋，场域内各处库伦电场 $\mathbf{E}_c$ 远大于感应电场 $\mathbf{E}_i$ ，即：

$$\nabla \times \mathbf{E} = \nabla \times (\mathbf{E}_i + \mathbf{E}_c) \approx 0 \quad (2-13)$$

EIT 是一个恒定电流场模型。向场域内施加电流，其频率为 ω ，则电场强度可表示为：

$$\mathbf{E} = \hat{\mathbf{E}}e^{j\omega t} \quad (2-14)$$

场域内电场强度与电势分布的关系为：

$$\mathbf{E} = -\nabla \phi \quad (2-15)$$

由 Maxwell 方程组可得：

$$\nabla \times \mathbf{H} = \sigma \mathbf{E} + \varepsilon \frac{\partial \mathbf{E}}{\partial t} \quad (2-16)$$

将公式 (2-14)、(2-15) 代入 (2-16) 可得：

$$\nabla \cdot ((\sigma + j\omega\varepsilon)\nabla \phi) = 0 \quad (2-17)$$

该式即为 EIT 数学模型。将复电导率记为 $\tilde{\sigma} = \sigma + j\omega\varepsilon$ ，则 (2-17) 可以表示为：

$$\nabla \cdot (\tilde{\sigma} \nabla \phi) = 0 \quad (2-18)$$

将其进行展开可得：

$$\nabla \cdot (\tilde{\sigma} \nabla \phi) = \nabla \tilde{\sigma} \cdot \nabla \phi + \tilde{\sigma} \nabla^2 \phi = 0 \quad (2-19)$$

在均匀、线性、各向同性的介质中， $\tilde{\sigma}$ 为常数，即 $\nabla \tilde{\sigma} = 0$ 。公式 (2-19) 可以导出拉普拉斯方程：

$$\nabla^2 \phi = 0 \quad (2-20)$$

§ 2.3 EIT 正问题

如果一个物理过程或现象的分布是已知的，那么整个系统的状态变量的变化规律可以根据一些特定的系统条件（例如初始条件、边界条件等）来确定，这就是所谓的正问题（forward problem）^[47]。

EIT 的正问题是已知人体内部的阻抗分布及边界信息，通过求解 Laplace 方程，得到人体内部的电势分布，进而获取边界电压值。图 2-3 所示为 EIT 的正问题求解过程。




图 2-3 EIT 的正问题求解流程图

目前,求解 EIT 正问题的方法主要有两种。一种是解析法,它针对的场域一般是规则的几何图形,且介质在其内部分布均匀。人体的结构比较复杂且介质特性各异,以至于其场域比较复杂,使得正问题求解很难有解析解。另一种是数值算法,一般通过数值算法进行求解 EIT 正问题。常用的数值算法有:

(1) 有限元法 (Finite element method, FEM)^[48]: 将待测场域划分为有限个单元,然后通过计算,求解出场域每个单元的信息,构建出一个单元方程,并对此单元方程组展开求解。

(2) 边界元法 (Boundary element method, BEM)^[49]: 该方法类似于 FEM, FEM 是对整个场域进行划分,而该方法只对边界划分。但是因为 BEM 只划分边界,得到的单元较少,对非线性问题不适用。

(3) 有限差分法 (Finite difference method, FDM)^[50]: 该方法是在待测量的场域中,选择有限数量的点数,使用有限差分方程,来计算每个离散点在场域中的值。

EIT 正问题详细的计算方法以及模型的建立、剖分、求解过程将在第三章进行详细的介绍。

§ 2.4 EIT 逆问题

EIT 成像图像重建即为逆问题求解过程,是相对于正问题而言的。逆问题是 EIT 成像技术的核心^[51]。

EIT 逆问题是根据直接测量得到的边界电压,通过计算得到场域电势分布,再通过一定的成像算法,最后求得场域内的阻抗分布。EIT 逆问题的求解流程图如图 2-4 所示。




图 2-4 EIT 逆问题的求解流程图

由前面章节所述以及公式(2-18)可知,人体的阻抗分布是不均匀的,由此要求人体内部的阻抗分布是一个很困难的逆问题。

根据 Hadamard 定义,如果同时符合以下三个条件,则该问题被认定为适定问题:

- (1) 问题的解存在;
- (2) 问题的解唯一;
- (3) 问题的解稳定。

如果以上有一个条件不能满足,则称为不适定问题^[52]。不适定问题的不适定性大多来源于由解的不稳定性^[5]。

目前, EIT 的求解难点表现为:

(1) 欠定性。由于施加激励的方式有限, EIT 系统测量的电极放置不能无限增加,数目有限,因此测量得到的电压信息量也是有限,这就造成了信息量比要求解的未知量少很多,所以解是不唯一的^[53]。

(2) 非线性:根据前文 2.1 和 2.2 可知,由于场域内的阻抗分布影响着边界电压,因此通过边界电压的测量,反映出二者称非线性关系,也就是说, EIT 逆问题具有非线性^[54]。

(3) 病态性问题: EIT 逆问题求解的一个难点在于场域内的电导率的变化对边界电压影响不大。然而,小小的边界电压变化也会使场域内电导率的分布发生很大的变化,从而导致电导率的求解过程变得很不稳定^[55]。

由此可知, EIT 逆问题是不适定问题。因此,寻求合适的算法来对其进行求解,改善其病态程度,提高解的精确度来提高成像分辨率尤为重要。

目前, EIT 成像有动态和静态成像两种成像方式。动态成像是在两个不同时间点测量电导率,计算电阻抗分布之间的差异,并利用该差异数据重建出阻抗分布图像的过程。因为在相减的同时,其中的干扰和噪声也被消除了,所以它对测量数据的精度要求不高,且成像速度快,计算量较小。但若采集数据的两个时刻数据没变化,则无法成像。静态成像是利用电阻抗绝对值来进行图像重构的一种手段,但静态成像是一个高度病态的非线性逆问题,所以,该算法的计算复杂度高且有较差的抗噪声性能。

§ 2.5 经典的图像重建算法

§ 2.5.1 Newton-Raphson 算法

牛顿-拉夫逊(Newton-Raphson)算法是最具优化思想的图像重建算法,其基本原理是求解最小二乘问题。通常将正问题非线性化,通过迭代修正场域内电导率分布,求得最小的绝对电导率,即目标函数的最小值^[56]。目标函数是电压的真实值和计算值之间的误差的某种函数。

假设将场域剖分为 M 个单元,在场域表面放置 N 个电极。Newton-Raphson 重建算法的具体方法如下:

- (1) 设定场域的电阻率分布为 ρ , 初始值估计值为 $\rho^{(0)}$ 。
- (2) 在电流的注入下,测得的边界电压为 U 。
- (3) 在第 k 步迭代时,电阻率分布设为 $\rho^{(k)}$,用有限元方法计算对应的边界电压 $V(\rho)^{(k)}$ 。
- (4) 将步骤(2)、(3)所得的电压测量值和计算值进行误差计算,求得它们之间的误差 E 。用 $E(\rho)$ 表示电导率 ρ 的公式,即:

$$E(\rho) = \frac{1}{2} \left(\left\| V(\rho)^{(k)} - U \right\|_2 \right)^2 \quad (2-21)$$

(5) 判断是否满足结束条件。结束条件一般包含两方面:一是达到设置的迭代次数,二是达到一定收敛条件,即允许误差范围内。若满足,则结束迭代,得到所需的最优电阻率值,否则继续步骤(6)。

(6) 计算电阻率 $\rho^{(k)}$ 对应的灵敏度矩阵,即 Jacobi 矩阵 $J(\rho^{(k)})$,如公式(2-22)所示。将误差 $E(\rho)$ 对 ρ 求导,根据泰勒公式展开,且只保留线性项,得到公式(2-23)。

$$J_{n,m}(\rho^{(k)}) = \frac{\partial}{\partial \rho_m} \frac{\partial E(\rho^{(k)})}{\partial \rho_n} = \begin{bmatrix} \frac{\partial f_1(\rho^{(k)})}{\partial \rho_1^{(k)}} & \frac{\partial f_1(\rho^{(k)})}{\partial \rho_2^{(k)}} & \dots & \frac{\partial f_1(\rho^{(k)})}{\partial \rho_n^{(k)}} \\ \frac{\partial f_2(\rho^{(k)})}{\partial \rho_1^{(k)}} & \frac{\partial f_2(\rho^{(k)})}{\partial \rho_2^{(k)}} & \dots & \frac{\partial f_2(\rho^{(k)})}{\partial \rho_n^{(k)}} \\ \vdots & \vdots & & \vdots \\ \frac{\partial f_m(\rho^{(k)})}{\partial \rho_1^{(k)}} & \frac{\partial f_m(\rho^{(k)})}{\partial \rho_2^{(k)}} & \dots & \frac{\partial f_m(\rho^{(k)})}{\partial \rho_n^{(k)}} \end{bmatrix} \quad (2-22)$$

$$f'(\rho) = f'(\rho^K) + f''(\rho^K)(\rho - \rho^K) \quad (2-23)$$

式中, $f''(\rho^K)$ 为 Hessian 矩阵。

(7) 根据 Newton 法修正电阻率分布 $\rho^{(k+1)}$, 计算公式如(2-24)所示。然后返

回步骤 (2)，直到 $E(\rho) = \rho^{(k+1)}$ 的精度满足要求。

$$\rho^{(k+1)} = \rho^{(k)} + \Delta\rho^{(k)} \quad (2-24)$$

式中， $\Delta\rho^{(k)}$ 是修正量，公式如下：

$$\Delta\rho^{(k)} = -\left\{\left[f'(\rho^{(k)})\right]^T f'(\rho^{(k)})\right\}^{-1} \left[f'(\rho^{(k)})\right]^T (f(\rho^{(k)}) - U) \quad (2-25)$$

Newton-Raphson 算法存在的问题有：(1) 初始值的选取影响着算法的收敛性；(2) 需要计算 Jacobi 矩阵，计算过程复杂；(3) 需反复迭代，导致计算量大。

§ 2.5.2 NOSER 算法

NOSER 算法以 Newton-Raphson 算法为基础，是 NR 算法的第一步。Cheney 教授认为只要初始电导率选取到合适的值，则可以减少迭代的次数。如果初始值足够接近于真实值，就可能只需一次迭代便可得到场域电阻率分布的近似解。

假设场域剖分后单元的电阻率是均匀分布的，均设为 c ，则 $\rho^{(0)} = c(1, \dots, 1)^T$ 。令：

$$\rho = cl \quad l = (1, \dots, 1)^T \quad (2-26)$$

假设边界电压的测量值与计算值是线性关系，则电压关系可以表示为：

$$V(cl) = cV(l) \quad (2-27)$$

由此可得目标函数：

$$f(cl) = \frac{1}{2} \|U - cV(l)\|^2 \quad (2-28)$$

先对 (2-28) 微分，并令其为 0，得到 (2-29)，该式需满足 (2-30)。

$$\frac{\partial f(cl)}{\partial c} = [V(l)]^T (U - cV(l)) = 0 \quad (2-29)$$

$$(cV(l) - U) = 0 \quad (2-30)$$

上式是一个超定方程组，因为只有一个未知数 c ，用最小二乘法解该方程组，得：

$$c = \frac{[V(l)]^T U}{[V(l)]^T V(l)} \quad (2-31)$$

假设各个单元电导率均为 1，求得 $V(l)$ 的值，代入 (2-31) 得到 c 的值，再将 c 值代入 (2-26)，进行 NR 算法的一步迭代，如公式 (2-32) 所示：

$$\rho = \rho^0 - \left[[J(\rho^0)]^T J(\rho^0) \right]^{-1} [J(\rho^0)]^T [V(\rho^0) - U] \quad (2-32)$$

由于 NOSER 算法无需多次迭代，成像速度较快，但是尽管只是 NR 算法的第一步，其计算还是复杂的，主要原因是需要求解 Jacobi 矩阵和它的逆，且该算法的成像分辨率不高，仍存在伪影。

§ 2.6 本章小结

本章主要介绍了 EIT 成像技术的理论基础。首先从基本理论出发,介绍了电阻抗成像原理,即利用电极在物体表面施加激励,测量边界电压,进而计算出物体的电阻率分布情况,阐述了人体的阻抗特性。描述了 EIT 成像问题的数学模型,然后介绍了 EIT 正问题,即根据已知的电极激励和电阻率分布求解物体的边界电压,这是 EIT 成像技术中最基本的问题。接着,介绍了 EIT 逆问题,即根据已知的电极激励和电压测量值重建物体内部的电阻率分布,这是 EIT 成像技术中研究的重点和难点。最后,介绍了两种经典的图像重建算法,分别是 Newton-Raphson 算法和 NOSER 算法。Newton-Raphson 算法是一种迭代求解方法,可以较快地收敛到真实解,但对初值的依赖性较强,且计算量大。NOSER 算法是 NR 的第一步,求解速度较快,但成像精度不高。本章对 EIT 成像技术的理论基础进行了全面深入的介绍,为后续的研究工作奠定了坚实的理论基础。

第三章 EIT 正问题研究

根据上一章阐述的 EIT 基础理论,本章将进一步对 EIT 正问题进行研究。EIT 正问题是通过给定的边界条件以及建立的场域模型,采用数值计算方法进行求解,从而得出边界电位分布。本章对正问题的求解方法进行介绍,详细阐述有限元法的求解过程,为后续建模提供理论基础。通过 COMSOL 软件进行场域建模、网格划分并进行求解得到边界电压数据,同时,建立不同情况的目标物模型,生成数据集,为后续算法验证和网络模型的训练提供数据。

§ 3.1 EIT 正问题的求解

正问题求解常用的方法在第二章已做介绍,即采用数值计算方法。一般采用有限元法对 EIT 正问题进行求解,因为有限元法相较于其他两种方法具有以下优点^[57]:

- (1) 有限元法是一种经过充分发展和实践验证的数值计算方法。
- (2) 在进行限元剖分的同时,也会对图像进行离散化。
- (3) 能够很好地适应敏感场域的几何形状,具有较高的适应性。
- (4) 适用于介质电导率分布不均匀的场域。

有限元法是基于变分原理,将待求解场域分成多个小的、简单的几何形状,称为有限元素,每个元素由多个节点组成,它们可以是一维、二维或三维的。通过将每个元素近似成一个简单的数学表达式,将其组合成一个方程组,求解出这个方程组得到整个场域的解。其具体流程如图 3-1 所示^[58]。




图 3-1 有限元法具体流程

有限元方法对 EIT 图像重建有着重大的影响，主要表现在^[59]：

(1) 剖分产生误差

有限元方法的剖分过程中，近似解和严格解之间存在精度差异，因此当精度不足时，可能会导致在正问题计算过程中，边界电极处的电压值与真实值存在误差。因此，网格剖分的密度会影响求解精度，通常情况下，网格越密，误差越小，精度越高，成像质量也会更好。

(2) 对计算效率影响

有限元剖分的疏密程度决定了图像重建的矩阵规模，若剖分的网格越细，将会增加矩阵的维数，从而导致计算量增大。

(3) 对求解稳定性影响

网格剖分误差以测量误差的形式引入到重建算法中，从而影响求解结果的稳定性；此外，求解方程的矩阵规模会影响矩阵的条件数，这影响了求解过程的抗干扰能力。

§ 3.1.1 等价变分问题

对于 EIT 的数学模型公式 (2-18) 采用变分方法转化为变分问题：

$$F(\phi) = -\frac{1}{2} \int_{\Omega} \phi (\nabla \cdot (\sigma \nabla \phi)) d\Omega \quad (3-1)$$

根据格林 (Green) 定理，上式可以写成^[60]：

$$F(\phi) = \int_{\Omega} \frac{1}{2} \sigma (\nabla \phi)^2 d\Omega - \int_{\Gamma} \frac{1}{2} \sigma \phi \frac{\partial \phi}{\partial n} dS \quad (3-2)$$

在 EIT 成像过程中，可以通过具有适当边界条件的 Laplace 方程确定电压-电流关系：

$$\begin{cases} S_1 : \phi = \phi_0 \\ S_2 : \sigma \frac{\partial \phi}{\partial n} = -J_n \end{cases} \quad (3-3)$$

将 Neumann 边界条件代入 (3-2)，将公式第二项表示为：

$$-\int_{\Gamma} \frac{1}{2} \sigma \phi \frac{\partial \phi}{\partial n} dS = -\int_{\Gamma} \left(\int_0^{\phi} \sigma \frac{\partial \phi}{\partial n} \delta \phi \right) dS = \int_{S_2} \left[\int_0^{\phi} (-J_n) \delta \phi \right] dS = \int_{S_2} \phi J_n dS \quad (3-4)$$

考虑边界条件后，可将 (3-2) 写成：

$$F(\phi) = \frac{1}{2} \int_{\Omega} \sigma (\nabla \phi)^2 d\Omega - \int_{\Gamma} \phi J_n dS \quad (3-5)$$

由此，对于上式的极值问题，仅需满足狄里克莱 (Dirichlet) 边界条件。利用有限元法将场域剖分为 m 个单元，即：

$$\begin{cases} \Omega: F(\phi) = \sum_{e=1}^m F_e(\phi) \\ S_1: \phi = \phi_0 \end{cases} \quad (3-6)$$

将 (3-6) 场域剖分时, 应该遵循:

- (1) 各个单元最长的边不能与最短的边差值太大。
- (2) 单元与单元之间仅通过顶点相交。
- (3) 不同的单元相同的顶点的电位应该相等。

§ 3.1.2 有限元计算方法

在有限元法中, 经常使用的剖分单元有三角形和四边形。本文以三角形为例来介绍对场域的剖分。如图 3-2 所示为三角形剖分单元。




图 3-2 三角形有限元剖分单元

图 3-2 中标注了三个顶点的坐标, 分别为 (x_i, y_i) 、 (x_j, y_j) 、 (x_m, y_m) , 有限元单元的顶点是按逆时针进行编号的。利用三角形剖分场域后, 选择线性插值多项式为插值函数, 具体表示为:

$$\phi_e(x, y) = \alpha + \beta x + \gamma y \quad (3-7)$$

式中, α 、 β 、 γ 为待定常数。顶点的电位值分别为 ϕ_i 、 ϕ_j 、 ϕ_m , 将顶点坐标代入 (3-7), 得到顶点电位:

$$\begin{aligned} \phi_i &= \phi(x, y) = \alpha + \beta x_i + \gamma y_i \\ \phi_j &= \phi(x, y) = \alpha + \beta x_j + \gamma y_j \\ \phi_m &= \phi(x, y) = \alpha + \beta x_m + \gamma y_m \end{aligned} \quad (3-8)$$

求解 (3-8) 可得系数 α 、 β 、 γ 分别为:

$$\begin{aligned}\alpha &= \frac{a_i\phi_i + a_j\phi_j + a_m\phi_m}{2\Delta} \\ \beta &= \frac{b_i\phi_i + b_j\phi_j + b_m\phi_m}{2\Delta} \\ \gamma &= \frac{c_i\phi_i + c_j\phi_j + c_m\phi_m}{2\Delta}\end{aligned}\quad (3-9)$$

式中, Δ 表示该三角形单元的面积, 其计算公式如 (3-10) 所示, 系数的定义如 (3-11) 所示:

$$\Delta = \frac{1}{2} \begin{vmatrix} x_i & y_i & 1 \\ x_j & y_j & 1 \\ x_m & y_m & 1 \end{vmatrix} \quad (3-10)$$

$$\begin{aligned}a_i &= x_j y_m - x_m y_j, & a_j &= x_m y_i - x_i y_m, & a_m &= x_i y_j - x_j y_i \\ b_i &= y_j - y_m, & b_j &= y_m - y_i, & b_m &= y_i - y_j \\ c_i &= x_m - x_j, & c_j &= x_i - x_m, & c_m &= x_j - x_i\end{aligned}\quad (3-11)$$

令 $\tilde{\phi}_e = [\phi_i, \phi_j, \phi_m]^T$, 任意顶点的电位值与三角形单元内的电位分布函数的关系可表示为:

$$\phi_e(x, y) = \bar{N}(x, y) \tilde{\phi}_e \quad (3-12)$$

式中, $\bar{N}(x, y)$ 、 $\tilde{\phi}_e$ 的表达式分别如下:

$$\bar{N}(x, y) = [N_i(x, y) \quad N_j(x, y) \quad N_m(x, y)] \quad (3-13)$$

$$N_s(x, y) = \frac{1}{2\Delta} (a_s + b_s x + c_s y) \quad (s = i, j, m) \quad (3-14)$$

式中, $N_i(x, y)$ 、 $N_j(x, y)$ 、 $N_m(x, y)$ 称为三角形单元上线性插值的基函数。

§ 3.1.3 变分问题求解

对 (3-12) 求偏导, 可得:

$$\nabla \phi_e = \frac{1}{2\Delta} \begin{bmatrix} b_i & b_j & b_m \\ c_i & c_j & c_m \end{bmatrix} \tilde{\phi}_e \quad (3-15)$$

根据 (3-5), 求得三角形单元是的泛函表达式为:

$$F_e(\phi) = \frac{1}{2} \tilde{\phi}_e^T K_e \tilde{\phi}_e - \tilde{\phi}_e^T J_e \quad (3-16)$$

式中, 总系数矩阵的 K_e [61]、 J_e 的表示式为:

$$K_e = \int_{V_e} \varepsilon_e B_e^T B_e dV \quad (3-17)$$

$$J_e = [J_i \ J_j \ J_m]^T \quad (3-18)$$

最后，场域内的总体泛函可表示为：

$$F(\phi) = \frac{1}{2} \phi^T K \phi - \phi^T J \quad (3-19)$$

式中， ϕ 、 J 以及总系数矩阵 K 的表达式分别为：

$$\phi = [\phi_1 \ \phi_2 \ \cdots \ \phi_k \ \cdots \ \phi_n]^T \quad (3-20)$$

$$J = [J_1 \ J_2 \ \cdots \ J_k \ \cdots \ J_n]^T \quad (3-21)$$

$$K = \sum_e \tilde{K}_e \quad (3-22)$$

其中， n 为场域内剖分的网格的节点总数。

对 $F(\phi)$ 求极值，令 $F(\phi)$ 对有限元的每个节点电位值的一阶偏导数为零：

$$\frac{\partial F(\phi)}{\partial \phi_k} = 0, \quad k = 1, 2, \dots, n \quad (3-23)$$

最后，可得 EIT 正问题计算的有限元方程：

$$K\phi = B \quad (3-24)$$

§ 3.2 基于 COMSOL 建立 EIT 模型

§ 3.2.1 COMSOL 软件的使用

COMSOL Multiphysics 是一款功能强大且可以用于数值模拟仿真的有限元分析软件，它能够模拟电磁场、热传导、流体力学等多种物理现象。利用有限元方法，对由偏微分方程(PDE)表示的各类科学研究和工程应用中的问题进行数值模拟仿真^[62]。该软件具有前处理器、求解器和后处理器三款强大的建模工具。用户可以使用几何模块构建几何实体，并为物体定义边界条件，还具有丰富的物理学模块，用户可以选择适当的模块来模拟电势分布问题^[63]。COMSOL 除了能完成几何图形的建模、网格剖分、设立方程、和设定边界参数外，还提供了多种求解器，用户可以根据需要，选取合适的求解器来解决电势分布问题。此外，该软件还提供了一个很好的后处理工具，使用者可以根据自己的需要，在软件中生成各种图表、曲线、动画等等，并能将结果输出到软件中作进一步的分析。另外，COMSOL 还与 MATLAB 完全兼容，便于对模型进行定制、计算和后处理。由于其可靠性、高效性、易于使用性和强大的可视化和数据分析功能，在研究和解决各种工程和科学问题中得到了广泛的应用^[64]。

本文使用 COMSOL Multiphysics 5.6 来进行正问题求解。通过 COMSOL 软件建立

EIT 正问题的模型,从单元剖分到计算结果,该软件都可以快速完成,极大地提高计算效率。且 COMSOL 软件能够通过 COMSOL with Matlab 与 MATLAB 相连接,从而获得重建图像。

COMSOL 软件进行正问题建模、求解的过程可以分为以下步骤:

(1) 建立模型。该步骤需要建立一个实物模型,这个模型可以是由 COMSOL 内置的几何建模工具绘制,也可以是由其他 CAD 软件导入的。

(2) 物理场设定:在建立完模型后,需要为模型定义参数。为模型选择好材料,然后定义物体的电导率和注入电流的大小和位置,以及其边界条件。

(3) 网格剖分:COMSOL 将模型离散化为有限元网格以进行数值计算。为了确保计算的准确性,需要在模型中定义适当的网格密度。COMSOL 具有自动网格生成工具,也可以手动定义网格。

(4) 求解结果:在步骤中需要选择适当的求解器来求解电势的分布问题。COMSOL 可以将电势分布的可视化结果进行输出,并且可以计算出物体内部的电阻率分布。

§ 3.2.2 建立场域模型

目前,常用的电极数目有 8、16、32、64 个电极。一般来说,物体表面放置的电极越多,则测量到的数据越多,重建的图像随信息量的增加,其分辨率也就越好。但是随电极的数量增加,其电路结构越复杂,不利于安装,影响其便携性。且物体边界长度与面积有限,不能在人体表面放置过多的电极,而随电极数的增加,重建算法的计算量会大大的增加。因此,选择合适的电极数目是否合适不仅决定了成像质量,也影响着其结构。16 电极相对于其他电极,线路不会过多或过少,所测量得到的信息量适中,对成像质量能有一定的保证,因此本文选择 16 个电极进行边界电压的测量。

运用 COMSOL 软件构建场域模型,如图 3-3 所示。圆形部分代表实验容器圆形水槽的横截面,半径设置为 10cm。圆形表面 16 个绿色凸起部分代表了 16 个电极,将其均匀的设置于圆形表面。圆形场域模型建立的具体操作步骤如下:

(1) 在 COMSOL 新建一个空白的模型,选择二维的空间维度。根据 EIT 成像的场域及参数,选择 AD/DC 模块中电场和电流下的电流(ec)物理场。

(2) 将(0,0)选作参考点,绘制圆形场域模型。使用几何体素中的圆绘制一个半径为 10cm 的圆,坐标设为(0,0)。由于采用的是矩形电极,因此选用几何体素中的矩形进行绘制电极,并分别设置 16 个电极的坐标。为确保所有电极的一致性,使用几何操作中的旋转功能绘制剩下的电极,并在设置旋转角度这一栏中分别设置好对应的角度。绘制好的模型如图 3-3 所示。




图 3-3 圆形场域模型

(3) 为圆形场域和电极分别设定物理量。为了模拟真实的人体体内环境，通常仿真的场域模型选取盐水溶液作为介质。选取材料中的 **Water, liquid** 作为场域的介质，并设定其电导率为 1S/m ，相对介电常数的值设置为 1。电极材料选用钛电极 **Titanium beta-21S**。

(4) 选定完材料后，需要对场域和电极的边界条件进行设定。边界条件包括电流守恒、电绝缘、电流流向等。首先，将整个模型的边界条件设置为电绝缘；接着，选择一对电极作为激励电极，将其边界条件设置为“向内电流密度”，法线电流密度分别设置为 $+1\text{A/m}^2$ 和 -1A/m^2 。

通过以上步骤，建立了一个 16 电极的圆形场域，接下来就是对场域进行有限元剖分，将在下一节进行详细介绍。

§ 3.2.3 有限元剖分

COMSOL 软件可以创建自由网格、映射网格，还可以通过拉伸、旋转和扫掠等方式创建网格，甚至可以沿着具体的边界创建边界层网格。利用这些网格剖分工具和方法，可以生成三角形和四边形（2D），四面体、六面体、棱柱（3D）等网格单元，并且可以从四边形切分成三角形（2D），六面体和棱柱切分成四面体（3D）^[64]。

在任何空间维度，COMSOL 的自由网格剖分器都可以应用于任何类型的几何中。自由网格剖分器包括三角形网格和四边形网格，由于三角形具有较好的自适应性，相较于四边形有较好的边界保形性，因此本文采用三角形单元进行剖分。在上一节建立好的模型基础上，对圆形场域进行有限元剖分。

在 COMSOL 软件中，单元大小预定义了九种不同等级的网格。每个等级都有不同的尺寸，其中包含了从极细化到极粗化的剖分程度。若想要指定网格参数，亦可以手动设定。在前文提到，剖分的网格数越多，其结果的准确度越高，但同时计算工作量也会增加，时间也会越长，也将影响了 EIT 的成像速度，从而导致成像的实时性不

高。因此,在进行有限剖分时,应考虑计算时间和选择适当的剖分程度,在保证计算的精度的同时提高效率。图 3-4 所示为不同剖分程度的结果。图 3-4 (a) 为较粗化的剖分结果,该网络包含 174 个域单元; (b) 为较细化的剖分结果,该网络包含 1830 个域单元。




图 3-4 场域不同剖分程度

§ 3.2.4 有限元求解

除了电极的数目和网格剖分密度会对图像重建的分辨率产生影响,电流注入方式和电压测量方式也与其有关。因此,建立好模型以及对其进行网格剖分后,需要选择合适的电流激励模式对模型进行正问题求解。电阻抗的测量普遍采用以下两种测量方式^[65]:

(1) 相邻激励模式^[66]

相邻激励模式也称四电极模式。该模式是将激励电流施加在其中一对相邻电极上,在剩余的所有相邻电极对上进行电压测量,如图 3-5 (a) 所示。该模式的具体操作为:首先在 1、2 号电极施加电流,电压从 3-4, ..., 15-16 电极对连续测量,此测量模式可得到 13 个电压值。接着对下一组相邻电极即 2、3 号电极施加电流,测量在剩余的相邻电极对上的电压。如此重复该过程,直到全部相邻电极对都进行了一轮测量。对于有 N 个电极的 EIT 系统,可以采集到 $N(N-3)$ 个边界电压。因此,16 个电极的系统可以采集到 $16 \times (16-3) = 208$ 个电压值。

(2) 相对激励模式^[67]

相对激励模式是在其中一对相对的电极施加激励电流,在其余相邻电极测量电压,如图 3-5 (b) 所示。该模式的具体操作是:首先在电极 1、9 号上施加电流,从其余 13 个电极对连续测量电压,此测量模式可以得到 12 个电压值。接着切换到剩余的相对电极对施加电流。对于 16 个电极的系统,此模式可以测量得到 $16 \times (16-4) = 192$ 个电压值。




图 3-5 激励模式

经过分析可知，相邻激励模式相较于相对激励模式可以采集到更多的测量数据。但因为是在相邻电极上施加激励，距离比较小，电流分布主要集中在电极附近，难以深入中心区域，电极数目越多，该情况越明显。增加电极数目，反而导致场域中心的灵敏度降低。而相对激励模式的电极距离大，电流能深入中心区域，较之相对激励模式，提高了中心区域的灵敏度。但由于模型的几何对称性，其等位线会发生重叠，只采用相邻激励模式的一半电极，数据量减少，成像的分辨率也会显著降低。通过对比两种激励模式，相邻激励模式有较多的数据，更有利于图像重建，因此本文采用的是 16 电极相邻激励模式。

在 COMSOL 建好的模型中，选择其中一对电极作为激励电极。在前面章节建模时，已经对边界电流的流向和大小进行了设置，因此可以直接对剖分好的场域进行正问题求解，得到圆形场域的表面图，如图 3-6 所示。从图中也可以看出场域中的电势分布，红色电极处的电势较高，为电流注入电极，蓝色电极处的电势较低，为电流流出电极。




图 3-6 圆形场域表面图

COMSOL 软件还可以绘制场域中的电流密度, 如图 3-7 所示。图 3-7 (a) 中的线代表了圆形场域的电流密度, 可以看出, 电极周围的电流密度较大, 越往中心区域, 电流密度越小。图 3-7 (b) 为电流密度的箭头图, 可以看出场域内的电流从红色电极流入, 向蓝色电极流出。




图 3-7 圆形场域的电流密度

上述圆形场域模型只选用了一对激励电极进行仿真, 因此只有 13 个边界电压值。若要获取 208 个边界电压值, 16 个电极系统需要进行 16 次循环测量。然而 COMSOL 软件无法完成循环测量的功能, 因此, 需要联合其他软件使用, 实现激励循环测量以此获得所需的边界电压值。

COMSOL 中包含了 COMSOL with Matlab 接口, 可以与 MATLAB 实现连接。两个软件均可以采用 .m 文件格式存储数据, 相互兼容, 可以通过接口进行数据传输。利用 MATLAB 进行编程, 实现 COMSOL 的建模、计算、后处理等工作^[68]。

COMSO 联合 MATLAB 进行仿真的具体过程如下: 通过 COMSOL 建立模型并进行有限元剖分、求解, 将模型仿真结果保存成 .m 文件。在 MATLAB 软件中打开该文件进行修改来以实现激励循环。在该 .m 文件中添加循环指令, 将修改好的文件通过 COMSOL with Matlab 接口导入 COMSOL 中, 再经过求解运算后, 可以得到圆形场域模型边界上 16 个电极的边界电压值, 即 208 个电压值, 如图 3-8 所示。该组数据将作为后续电阻抗成像重建中逆问题求解所需的空场电压值。




图 3-8 边界电压值

§ 3.3 数据集的获取

§ 3.3.1 有限元区域设置目标物

在空场场域放置目标物以模拟人体组织或器官发生病变。本文设置了一个圆形场域，背景电导率设为 1S/m ，在有限元区域设置不同形状、位置、目标物电导率的目标物，目标物的数量为 1-3 个。为模拟真实情况，目标物的大小、形状以及位置随机生成不同。如图 3-9 所示为部分模型，(a) 为单目标，(b) 为两个目标，(c) 为三个目标。




图 3-9 不同目标物模型

§ 3.3.2 数据集的生成

采用神经网络解决 EIT 逆问题时，网络的学习性能取决于样本的数量以及样本分

布的普遍性，通常需要大量的数据样本对网络进行训练和验证。数据集必须包含代表多样化特征的样本，这些特征需要涵盖了重建方法有可能重建的各种不同电导率分布。

目前 EIT 的实测数据集的样本量较少，不能满足神经网络的训练需求，为了得到大量的数据，同时避免采样不充分和采样集中的特点，满足样本的普遍性的同时增大数据量，本节通过 COMSOL 联合 MATLAB 进行仿真，生成后续工作所需的数据集。

一共生成 12000 组数据，其中包括了不同位置、形状以及目标物数量的模型。将数据集按 1:9 的比例，分成了训练集和测试集，即得到 10800 组训练集和 1200 组测试集。生成数据集的具体流程如图 3-10 所示。




图 3-10 生成数据集具体流程

§ 3.4 本章小结

本章介绍了 EIT 正问题的求解，从等价变分原理、有限元计算方法和变分问题求解入手，详细阐述了有限元方法的求解过程。简单介绍了有限元仿真软件 COMSOL Multiphysics；基于有限元的理论知识，利用 COMSOL 进行场域模型的建立，并对其进行有限元剖分、求解，联合 MATLAB 软件获得场域的边界电压。最后，建立不同位置、形状以及目标物数量的模型，生成后续神经网络的训练所需的数据集。

第四章 基于 PSO-TR 的 EIT 成像算法研究

图像重建算法即为 EIT 逆问题求解过程，是 EIT 成像中极为关键的一步^[69]。在第二章介绍的经典图像重建算法有着较快的成像速度，但因其病态性导致求解的稳定性较差。当前，已有不少智能优化算法用于 EIT 逆问题，粒子群算法（Particle Swarm Optimization, PSO）能进行全局寻优，通过共享群体信息，寻找最优解，因此，本文将用于解决 EIT 逆问题。针对 PSO 算法易陷入局部最优，对初始值敏感，本文通过在目标函数中添加正则化项，提出一种基于 PSO-TR 的 EIT 成像算法。

§ 4.1 粒子群算法

§ 4.1.1 粒子群算法的基本原理

1995 年，Kennedy 和 Eberhart 提出了粒子群算法。他们对粒子群的最初设想主要是通过利用模拟简单的社会互动来产生计算智能，而不是纯粹的个人认知能力^[70]。受到 Heppner 等人的影响，他们模拟了鸟群寻找玉米的过程。鸟群分散在一片栖息地中的各个位置，想要寻找玉米进食，但只知道玉米的大概方向，不知道具体位置。每只鸟根据自己判断的方向进行搜索，并在搜索的过程中记录自己曾经找到过玉米且量最多的位置，同时所有的鸟都共享自己每一次发现玉米的位置以及玉米的量。在接下来的搜索的过程中，每只鸟根据自己记录的和当前鸟群记录的玉米量最多的位置来调整自己搜寻方向和位置。经过一段时间搜索后，鸟群就可以找到玉米量最多的位置。

对一个特定问题寻找最优解类似于鸟类寻找玉米，因此，粒子群算法是将鸟群设为粒子，栖息地为某个问题或函数的搜索空间，玉米则为问题的解，其对应关系如表 4-1 所示。

表 4-1 鸟群觅食与 PSO 算法的对应关系

鸟群寻找玉米	粒子群算法
鸟	粒子
栖息地	求解空间
玉米	解
玉米量	目标函数
每只鸟的位置、方向	粒子位置、方向

综上所述，PSO 算法的基本原理为：将每个可能解看作一个粒子，并随机分布在解空间中，通过目标函数评估当前位置。根据自身最优位置结合种群中最佳的历史位

置，确定运动方位，所有粒子移动后进行下一次迭代。最终，粒子作为一个整体，接近适应度函数的最优值。

§ 4.1.2 粒子群算法流程

在可行解空间中，初始化一群粒子 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 。每个粒子都由三个 D 维向量组成，其中 D 是解空间的维数。三个向量分别为粒子当前位置 $\mathbf{X}_i = (x_{i1}, x_{i2}, \dots, x_{iD})^T$ ，速度 $\mathbf{V}_i = (V_{i1}, V_{i2}, \dots, V_{iD})^T$ 和历史最佳位置 $\mathbf{P}_i = (P_{i1}, P_{i2}, \dots, P_{iD})^T$ 。种群的历史最佳位置为 $\mathbf{P}_g = (P_{g1}, P_{g2}, \dots, P_{gD})^T$ 。由目标函数计算适应度值以判断粒子的优劣。粒子通过跟踪个体最优值 P_{best} 和群体极值 G_{best} 更新个体位置。每次位置的更新都需计算一次适应度值，将新粒子的适应度值与历史个体、群体最优值比较，更新个体最优值 P_{best} 和群体极值 G_{best} 。位置和速度的更新公式如（4-1）、（4-2）所示。

$$V_{id}^{k+1} = \omega V_{id}^k + c_1 r_1 (P_{id}^k - X_{id}^k) + c_2 r_2 (P_{gd}^k - X_{id}^k) \quad (4-1)$$

$$X_{id}^{k+1} = X_{id}^k + V_{id}^{k+1} \quad (4-2)$$

式中： k 为当前迭代次数； ω 为惯性因子；非负常数 c_1 和 c_2 为学习因子； r_1 和 r_2 为 $[0,1]$ 区间的随机数。

公式（4-1）由三部分组成。第一项是惯性部分，表示下一次速度的迭代受当前速度的影响程度。通过调节 ω 的大小，可调整对局部和全局的搜索能力。其值较大时，全局搜寻能力强；反之，局部搜寻能力强。第二项为自我认知部分，表示粒子自身的经验，即向自身最优位置逼近， c_1 是调节粒子飞向自身最好位置方向的步长。第三项为社会经验部分，表示粒子间的信息共享，学习种群中的优秀粒子， c_2 是调节粒子飞向全局最好位置方向的步长。粒子速度新方向的更新过程如图 4-1 所示。




图 4-1 粒子速度方向更新

粒子群算法的具体步骤如下：

- （1） 初始化粒子群，设定初始速度和位置；
- （2） 计算每个粒子的适应度值；
- （3） 将每个粒子与个体的历史最好的位置进行比较，若位置更优，则更新为个体最优位置；
- （4） 将每个粒子与全局的历史最好的位置进行比较，若位置更优，则更新为全局最优位置；

- (5) 根据公式 (4-1)、(4-2) 更新粒子的速度和位置；
 (6) 判断是否满足条件，若满足则停止迭代，否则返回步骤 (2)。
 粒子群算法的流程如图 4-2 所示。




图 4-2 粒子群算法流程图

PSO 算法是一种启发式优化算法，根据上文公式可知，该算法简单，参数较少，不需要大量的调参过程，容易实现和调试，具有很好的全局搜索能力和较快的收敛速度。

由 2.4 章节分析知，EIT 逆问题具有严重的病态性，2.5 章节介绍的传统算法需求解 Jacobi 矩阵，计算复杂且精确度不高。而粒子群算法是利用随机优化的迭代方法搜索最优解，可以将逆问题转换为优化问题，通过优化求解来获得最优解。PSO 算法无需进行大量的矩阵求解，该算法减小了计算复杂度，同时降低了病态性。且粒子间会进行信息共享，可以使粒子更快收敛到最优解。综上，PSO 算法适合用于 EIT 逆问题求解。

§ 4.2 Tikhonov 正则化

在逆问题求解的过程中，其病态问题严重影响了重建图像的空间分辨率。为了克服该问题，一种有效的方法是采用正则化技术。Tikhonov 的基本思想是在不适定问题中加入惩罚项，得到目标函数，并对其求解得到有效解^[71]。

构造目标函数如下 (4-3) 式所示：

$$f(g) = \frac{1}{2} \|Sg - z\|^2 + \alpha R(g) \quad (4-3)$$

式中， α 为正则化参数， $R(g)$ 为惩罚项；常采用二范数形式，即：

$$R(g) = \|L(g - g_0)\|^2 \quad (4-4)$$

式中， L 是正则化矩阵，一般选用单位阵。 ρ 是先验知识获得的估计解，在 EIT 问题中，是待求解的电阻率分布。

对 (4-3) 进行求导，可得：

$$(S^T S + \mu I)g = S^T z \quad (4-5)$$

对公式 (4-5) 求解便可得到 Tikhonov 正则化算法：

$$g = (S^T S + \mu I)^{-1} S^T z \quad (4-6)$$

其迭代形式如 (4-7) 所示：

$$g_{k+1} = g_k - (S^T S + \mu I)^{-1} S^T (Sg_k - z) \quad (4-7)$$

在 EIT 问题中，可将 (4-7) 转化为如下公式：

$$\rho^{k+1} = \rho^k - \left[\left[J(\rho^k) \right]^T J(\rho^k) + \alpha I \right]^{-1} \left\{ \left[J(\rho^k) \right]^T [V(\rho^k) - U] + \alpha \rho^k \right\} \quad (4-8)$$

§ 4.3 基于 PSO-TR 的 EIT 成像算法

PSO 算法由于其随机性较强，对于搜索空间的初始化敏感。如果初始化不当，可能导致算法陷入局部最优。当 EIT 剖分的单元比较多时，PSO 算法需进行大量计算和迭代，且其收敛速度较慢，使得求解时间长。因此，为了求得更好的解，需要对其进行改进。

针对上述问题，本文提出了将 PSO 算法与 Tikhonov 正则化算法进行结合的 PSO-TR 算法。Tikhonov 正则化通过在目标函数加上一个正则化项，限制了解的范围和平滑度，从而控制解向量的波动，克服了 PSO 算法容易陷入局部最优问题。然后，通过粒子群算法的不断迭代更新得到更稳定、精确的解，从而提高算法的鲁棒性和全局最优解的收敛性。PSO-TR 算法的具体步骤为：

(1) 构造 PSO-TR 算法的目标函数：

$$f(\rho) = \frac{1}{2} \|V(\rho) - U\|^2 + \frac{1}{2} \alpha \|L(\rho - \rho^0)\|^2 \quad (4-9)$$

式中, ρ 是电导率, $V(\rho)$ 为计算电压, U 为测量电压。目标函数由两个部分组成: 数据误差项和正则化项。数据误差项用于衡量计算值与真实值之间的误差, 正则化项用于限制解的大小和平滑度。

(2) 确定 PSO 算法和正则化的参数, 包括粒子数目、每个粒子的维数、初始位置和速度、惯性权重和学习因子, 以及正则化参数等。

(3) 根据公式 (4-9) 进行目标函数求解。

(4) 由目标函数评价解的好坏, 更新个体最优解和全局最优解, 调整正则化系数。

(5) 根据公式 (4-1)、(4-2) 更新粒子的速度和位置。

(6) 进行若干次迭代更新, 若得到全局最好的解, 则停止迭代更新, 否则回到步骤 (3), 直到获得最优解。

PSO-TR 算法的流程图如 4-3 所示。




图 4-3 粒子群算法流程图

§ 4.4 实验结果及分析

§ 4.4.1 算法的评价指标

通过选取评价指标,对图像重建的质量进行客观评价。目前采用最多的图像重建评价指标为图像相对误差(Relative Image Error, RIE)。

图像相对误差 RIE 用于来衡量预测值与实际值之间的误差, RIE 的值越小,表明图像的相关性越好,图像重建的质量越高。其计算公式如(4-10)所示。

$$RIE = \frac{\|y - \hat{y}\|_2}{\|y\|_2} \times 100\% \quad (4-10)$$

其中, y 表示真实的场域电导率分布, $\hat{y}$ 表示模型输出的重构图像的电导率分布值。

§ 4.4.2 仿真结果

根据第三章所述,利用 COMSOL 和 MATLAB 建立模型,对进行 PSO-TR 算法仿真验证。

采用 16 电极 EIT 系统仿真电场内部的电导率分布。采用相邻电流激励和相邻电压测量方式,激励电流密度为 $1\text{A}/\text{m}^2$,测量频率为 50kHz 。设置背景和目标物的电导率,分别为 $1\text{S}/\text{m}$ 和 $2\text{S}/\text{m}$ 。在 PSO 算法中,将迭代次数设为 100,种群数量为 30,学习因子均取 1.49,粒子位置限定在 $[1,2]$ 范围内。分别设置了三种情况,每一种情况有不同的目标物。第一种情况为单目标,场域模型和图像重建结果如图 4-4 所示。第二种情况为双目标,场域模型和图像重建结果如图 4-5 所示。第三种情况为三目标,场域模型和图像重建结果如图 4-6 所示。其中,(a)为模型图,(b)为 NOSER 算法,(c)为 PSO 算法,(d)为 PSO-TR 算法。





图 4-4 单目标仿真结果






图 4-5 双目标仿真结果




图 4-6 三目标仿真结果

分析仿真结果可知，在单目标和双目标情况下，三种算法均能大致识别目标物的位置。在单目标情况中，PSO-TR 算法效果最好，定位基本准确，但存在误差；NOSER 算法次之，能识别大概位置，PSO 算法较之定位稍好，但存在严重的伪影。在双目标情况中，NOSER 算法无法准确判断两个目标的位置，只能判别出在附近区域，分析原因可能是由于两个目标距离较近；PSO 算法和 PSO-TR 算法可辨别目标物的位置，

但 PSO 算法的定位较为准确,但也存在一些伪影。在三目标情况下, NOSER 算法和 PSO 算法不能识别到所有目标,可以定位到靠近边界的目標,靠近中心区域的目标没有被识别到;且两种算法的伪迹都比较明显; PSO-TR 算法存在的伪影相较没那么明显,但基本可以准确定位到目标物的位置。

通过仿真结果以及分析可知, PSO 算法可以用来解决 EIT 问题。但 PSO 算法对中心区域的识别不太敏感,边界变化更能影响其成像效果,且图像存在明显的伪影。而 TV 正则项限制了其解的大小和平滑度,改善了 PSO 算法的病态性,提高了成像的质量和准确度。

表 4-2 RIE 评价指标

目标物	NOSER 算法	PSO 算法	PSO-TR 算法
单目标	8.6312	16.9581	4.6192
双目标	29.153	23.1826	14.541
三目标	37.2693	32.8264	21.3648

表 4-2 是三种算法的 RIE 评价指标,根据表中数据可以看出, PSO-TR 算法的 RIE 数值是三种算法中最好的,说明了 PSO-TR 算法通过加入 Tikhonov 正则化项,减少了逆问题病态性的影响,提高了解的稳定性和准确性,从而提高成像结果的质量。

§ 4.5 本章小结

本章首先介绍了粒子群算法的基本原理,并详细介绍了算法的计算流程。针对 EIT 逆问题的特点,改进了 PSO 算法以求得更好的解。通过加入 Tikhonov 正则化,提出了一种基于粒子群算法和 Tikhonov 正则化相结合的 PSO-TR 算法。粒子群算法是一种全局优化算法,能够在复杂的搜索空间中搜索最优解。Tikhonov 正则化是一种经典的正则化方法,能够缓解逆问题的不稳定性。将这两种方法相结合,可以有效提高 EIT 成像的精度和稳定性。通过实验结果表明, PSO-TR 算法相比经典的图像重建算法具有更好的重建效果,能较为准确的定位场域中的目标物,有较好的成像准确性和稳定性。

第五章 基于 FCRN 的 EIT 成像算法研究

神经网络是由大量神经元以及神经元之间的连接构成的。在理论上，神经网络若设有大量神经元，利用足够的数据，便可对复杂函数进行学习。从第二章分析可知，EIT 逆问题是非线性的，因此将神经网络应用到 EIT 逆问题求解中是可行的。在本章，将阐述神经网络的理论基础，包括其构成及训练过程，介绍了全连接神经网络(Full Connect Neural Network, FCNN)，并在其基础上进行改进，提出一种残差全连接神经网络(Fully-Connected Residual Network, FCRN)的 EIT 成像算法。

§ 5.1 神经网络的介绍

§ 5.1.1 感知机与深层神经网络

通过模拟人类神经元细胞结构，W.McCulloch 和 W.Pitts 建立了 M-P 神经元模型(McCulloch-Pitts neuron model) [72]，这是神经网络的基础。随后，F.Rosenblatt 提出了感知机模型(Perceptron) [73-74]。

感知机仅有单个神经元，是最简单的神经网络。图 5-1 是一个 n 维输入的感知机模型。设输入是 X_n ，输出 $Y=\{+1, -1\}$ ，用于对输入进行分类。




图 5-1 感知机模型

感知机用公式表示为：

$$f(x) = \text{sign}\left(\sum_{i=1}^n w_i \cdot x_i + b\right) = \text{sign}\left(\omega^T x + b\right) \quad (5-1)$$

其中， w 、 b 是模型参数，分别为输入与神经元间的权重和神经元的偏置。 sign 是激活函数，它通过将输入进行某种转换，从而将输出结果限定在一个特定的范围内，用公式 (5-2) 表示。

$$\text{sign}(x) = \begin{cases} +1 & x \geq 0 \\ -1 & x < 0 \end{cases} \quad (5-2)$$

感知器结构简单，可解决线性可分的问题。然而实际情况中遇到的问题不全是线性的，当需要解决的问题比较复杂时，单层感知机就无法解决这些非线性问题^[75]，因此需要使用深层次的神经网络。为了使感知机的适用范围更广，可将多个感知机连接，构成多层感知机模型来解决复杂的任务。

单层神经网络是最简单的多层感知机（Multi-Layer Perceptron, MLP）^[76]。如图 5-2 所示，它由一组输入、一层隐藏层和一层输出层组成。




图 5-2 多层感知机

浅层神经网络因结构简单，只有一个隐藏层，对复杂函数的表示能力十分有限，拟合出的函数可能存在很大的误差，且每一层所需要的神经元数量可能会非常多。如图 5-3 所示，增加隐藏层的数量，可以构成深层神经网络（深度学习），使得网络产生更多的连接以实现更复杂的功能。但随着网络层数增加，其参数会显著增多。




图 5-3 深层神经网络

神经网络的工作原理是，通过对信息的多层抽取和加工来完成复杂的功能^[77]。当网络层数增多时，每一层网络都会对上一层的进行更深层次的抽象表示，例如，在第一层隐藏层提取局部较简单的特征，如线条；在第二层隐藏层提取一些更大范围的特征，如形状；在第三层隐藏层可以更大范围更加复杂的特征，如结构；最后一层通过细化的抽取和加工，完成很多复杂的功能。

§ 5.1.2 神经网络的训练

神经网络训练的目的在于调整层与层之间的参数，使网络输出结果尽可能接近真实值称，其过程分为：正向传播和反向传播。

(1) 正向传播

正向传播（也称为前向传播）的基本原理是每一层通过计算参数，经由激活函数得出下一个隐藏层。经过逐层迭代，不断从低层次特征向量提取抽象特征，最终输出目标分类结果。

每个神经网络层的正向传播过程是权重矩阵的转置乘以输入向量得到一个值（即没有进行非线性激活之前的值），再加上偏置 $\mathbf{b}$ ，再通过非线性激活函数得到输出。

假设给定 n 维输入，用 n 维向量表示为 $\mathbf{X} = [x_1, \dots, x_n]$ ；隐藏层有 k 个神经元，用向量 $\mathbf{h} = [h_1, \dots, h_k]$ 表示；输出层有 m 个输出，用向量 $\mathbf{Y} = [y_1, \dots, y_m]$ 表示。权重矩阵用公式（5-3）表示：

$$\mathbf{W}^{(1)} = \begin{bmatrix} \mathbf{w}_{1,1}^{(1)} & \mathbf{w}_{1,2}^{(1)} & \cdots & \mathbf{w}_{1,k}^{(1)} \\ \mathbf{w}_{2,1}^{(1)} & \mathbf{w}_{2,2}^{(1)} & \cdots & \mathbf{w}_{2,k}^{(1)} \\ \vdots & \vdots & \cdots & \vdots \\ \mathbf{w}_{n,1}^{(1)} & \mathbf{w}_{n,2}^{(1)} & \cdots & \mathbf{w}_{n,k}^{(1)} \end{bmatrix} \quad (5-3)$$

隐藏层的每个神经元的处理过程可用公式（5-4）表示：

$$h_i = G\left(\mathbf{W}^{(1)\top} \mathbf{X} + \mathbf{b}_i^{(1)}\right) = G\left(\sum_{j=1}^n \mathbf{w}_{ij}^{(1)} \mathbf{x}_j + \mathbf{b}_i^{(1)}\right) \quad (5-4)$$

式中， $\mathbf{G}(\cdot)$ 是激活函数， $\mathbf{b}^{(1)}$ 是隐含层的偏置值。

从隐藏层计算输出层的过程与计算隐藏层的过程基本类似。

(2) 反向传播^[78]

反向传播的基本原理是，选定一个合适的损失函数来评估网络的性能，计算输出与实际值之间的误差。将误差反向传播给每个神经元，计算出每个神经元对误差的贡献，该值可通过求导计算得到。接下来将误差按照贡献比例分配给每个神经元，最后根据误差的贡献和神经元输入来更新权重，以减小误差。

假设损失函数为 L ，采用链式法则计算 L 对 w_i 的偏导。即计算损失函数 L 对 Y_i 的偏导， Y_i 对 z_i 的偏导， z_i 对 w_i 的偏导，最后将这三项相乘，用公式 (5-5) 表示：

$$\frac{\partial L}{\partial w_i} = \frac{\partial L}{\partial Y_i} \frac{\partial Y_i}{\partial z_i} \frac{\partial z_i}{\partial w_i} \quad (5-5)$$

式中， w_i 是隐藏层与输出层的第 i 个连接权值； z_i 是将隐藏层的输出 h 分别乘以相对应的权重 w 后相加，最后再加上偏置 b 得到的； Y_i 是 z_i 通过激活函数得到的。

设置学习率 α ，范围为 0-1，它可以控制权值大小；采用同样的方法更新隐藏层与输出层之间的其他连接权值，用公式 (5-6) 表示：

$$w_i = w_i - \alpha \frac{\partial L}{\partial w_i} \quad (5-6)$$

§ 5.1.3 激活函数

M. Minsky 已经证明了神经网络中，若无非线性激活函数是难以解决非线性可分问题的^[79]。通过非线性函数对输出进行非线性变换，可以提高网络的拟合性能。为提高网络的表示能力和学习能力，激活函数需要具备以下几点性质^[80]：

(1) 由于神经网络训练算法在反向传播时使用了梯度下降法来优化训练，所以激活函数必须可微；

(2) 激活函数的取值范围应该控制在一个适当的范围内，过小或者过大均会对网络训练的性能、效率和稳定性产生不利的影响；

(3) 为了提高计算效率，激活函数及其导函数应尽可能简单。

若设计的神经网络达不到预期效果，可尝试使用不同的激活函数，常见的激活函数有：

(1) Sigmoid 函数

Sigmoid 函数常被用来解决回归问题，其数学表示为：

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (5-7)$$

Sigmoid 函数的图形如图 5-4 所示。当输入 x 在 0 附近时，Sigmoid 近似于线性函数， x 越大，其值越接近 1； x 越小，其值越趋向于 0。Sigmoid 函数将区间 $(-\infty, \infty)$ 中连续的输入值映射到 $(0,1)$ 区间内，从而可以使神经网络中的每一层权重对应的输入都在一个固定范围内的值，使得权重的取值更加稳定。Sigmoid 函数的优势在于连续性好、易于求导以及结构简单。




图 5-4 Sigmoid 函数

(2) Tanh 函数

Tanh 函数是为了避免 Sigmoid 函数的缺陷所设计的，定义为：

$$\text{Tanh}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = 2\sigma(2x) - 1 \quad (5-8)$$

相对于 Sigmoid 函数，Tanh 函数是中心对称的，它将范围在 $(-\infty, \infty)$ 的连续输入变换到 $(-1, 1)$ 范围内，如图 5-5 所示。Tanh 函数的优势在于它是零均值的，因为在输入趋近于 0 时，函数几乎是线性的，解决了 Sigmoid 函数非零均值问题。但在输入很大或者很小时，其结果是平滑的，且梯度会很小，这对权重的更新是不利的，因此 Tanh 函数仍然没有解决梯度消失的问题。




图 5-5 Tanh 函数

(3) ReLU 函数^[81]

ReLU (Rectified Linear Unit, 修正线性单元) 是目前最常用的激活函数。它是一

种分段线性函数，但在整个定义域范围内，其还属于非线性函数。当输入是负数时，它的输出为 0；否则输出等于输入，定义为公式（5-9）：

$$\text{ReLU}(x) = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases} = \max(0, x) \quad (5-9)$$

ReLU 函数的图像如图 5-6 所示。ReLU 函数的计算简单，避免了 Sigmoid 函数和 Tanh 函数中的指数运算，仅需利用加法、乘法和比较等运算，提高了计算效率。当输入为整数时，ReLU 的导数恒为 1，能保持梯度不衰减，不会出现梯度消失现象。




图 5-6 ReLU 函数

§ 5.2 基于残差全连接神经网络的 EIT 成像算法

§ 5.2.1 全连接神经网络

传统的电阻抗成像方法仍存在一些挑战，例如：精度低、稳定性差、计算复杂度高等，这些正是目前 EIT 技术所面对的问题。因此，需要寻找一种更为高效、准确的方法来解决这些问题。神经网络在解决 EIT 逆问题中有较好的优势，因为深层的网络结构和大量的数据使得它能很好的表征非线性问题。

全连接神经网络（FCNN）^[82]是一种多层感知机，是最基础的深度神经网络，也是深度学习中应用最广泛的模型之一。它由多个全连接层（Fully Connected Layer, FCL）组成，每个 FCL 中的所有神经元都与前一层中的所有神经元相连接，通过矩阵乘法和激活函数的组合来将输入映射到输出。FCL 通常使用非线性激活函数来提升网络的表达能力。FCNN 具有可扩展性和灵活性，能够应用于各种不同的领域和任务，包括图像分类、语音识别等领域。对于训练数据量较大、模型结构较为复杂的任务，

FCNN 往往可以取得很好的效果。

与感知机不同, FCNN 可以处理任意形状的输入数据, 它的结构是由输入、若干个 FCL 和输出层构成, 其中 FCL 的数量和神经元的数量可以根据需要自行设置, 输入层用于接收原始数据, 每个输入特征对应一个神经元; FCL 则用于对输入进行非线性变换, 提取出更高级别的特征表示, 每一层 FCL 中的每一个神经元都与上下层的神经元全部连接; 输出层则用于产生最终的预测结果。

在 EIT 逆问题中, FCNN 可以通过训练来学习将输入数据 (电压和电流测量值) 映射到输出数据 (电阻抗分布)。即 FCNN 接受表面电极的电压和电流测量值作为输入, 并输出物体内部的电阻抗分布, 减少了传统方法中复杂的参数优化和迭代过程。

本文设计了一种全连接神经网络结构, 其网络结构如图 5-7 所示。该网络模型包括输入、三层 FCL 层和一层输出层。




图 5-7 FCNN 结构图

对 FCNN 结构进行说明:

(1) 输入: FCNN 模型输入为边界电压值, 本文采用的是 16 电极系统, 因此有 208 个电压值。由于目标物位置及电导率的影响, 边界电压差的数值有所差别, 需对数据进行预处理, 采用归一化操作将数据归一化到 0-1 之间。

(2) FCNN 模型包含三个隐藏层, 为了增加神经网络的拟合能力, 对第一个隐藏层的输出进行升维, 将输入映射到一个新的特征空间, 这个新的特征空间可以看做是网络学习到的抽象特征表示。第二个 FCL 层对特征空间中的每个元素进行非线性变换, 对数据的特征进行提取和预测。为了确保信息有效, 采用降维的方式进行信息损失, 过滤掉冗余信息, 第三个 FCL 进行降维操作将变换后的特征映射回原始特征空间。

(3) 输出层为电导率信息, 该层的神经元根据网络剖分的个数决定。

该三层 FCNN 结构中 FCL 能够提取分布式特征, 并把特征都整合到一起, 极大

地减少特征位置对结果产生的影响。三层 FCL 加深了网络结构，使得模型的非线性表达能力提高。相对于传统的基于解析算法的 EIT 方法，基于 FCNN 的 EIT 方法具有更好的鲁棒性和适应性，能够处理更多种类的测量数据。但 FCNN 由于参数基数大，随着层数的增加，网络参数量会变得很庞大，存在梯度消失和过拟合等问题，难以训练和优化。因此为了解决这个问题，需要对 FCNN 进行改进。

§ 5.2.2 残差网络

为了加强网络的表达能力，研究者不断采用各种技术来加深网络的层数，但在突破神经网络深度问题上真正具有代表性的技术还是残差网络（Residual Network，ResNet）^[83]。自从 ResNet 提出来之后，神经网络的层数就基本上没有上限了。

ResNet 的提出者何凯明等人在文章中对卷积神经网络进行训练和测试，分别用 20 层和 56 层的卷积层。实验结果表明 56 层的网络训练和测试结果误差都高于 20 层的网络。因为他们在实验中已经使用了 BN（Batch Normalization，批归一化），缓解了梯度消失，至少梯度不会消失，那么排除梯度消失的可能，就可能是网络退化的问题。这意味着随着网络层次的增加，在训练过程中很可能会陷入某些局部最优解，而非全局最优解，从而造成了较大的误差。

为了避免神经网络退化，何凯明等提出了 ResNet，其主要思想是通过跨层连接和捷径结构，实现网络中信息的传递和梯度的流动，使得网络可以更深层次地学习和拟合复杂的函数，其基本单元如图 5-8 所示。ResNet 最大的不同就是增加了一条捷径分支（shortcut connection），这条捷径分支是从输入到输出的直连。输出与输入之间的差异被作为卷积核的拟合目标，即残差。由于输入和输出都做了归一化，符合正态分布，因此输入和输出可以做减法。




图 5-8 ResNet 网络

ResNet 的基本单元(基本块)的处理过程为:输入 x 经过一个卷积层,再做 ReLU,然后经过另一个卷积层得到 $F(x)$,再加上 x 得到输出 $H(x)=F(x)+x$,然后做 ReLU 得到基本块的最终输出 y 。由于输入和输出都做了 BN,都符合正态分布,因此输入和输出可以做减法,当输入的维度与卷积输出 $F(x)$ 的维度不同时,需要先对 x 做线性投影使二者维度一致,然后再加和。

ResNet 的捷径分支将卷积层连接实现了恒等映射,即保证了网络性能不会下降,又使得网络能在输入特征的基础上学习到新的特征,且恒等映射不会使网络增加额外的参数和计算量,不仅加快了模型的训练速度,还优化了训练效果。

§ 5.2.3 残差全连接神经网络模型

鉴于 FCNN 过拟合问题,即模型在训练集上表现良好,但在测试集上表现较差,本文在 FCNN 中引入 ResNet 的捷径分支,提出了一种残差全连接神经网络算法模型,其结构如图 5-9 所示。




图 5-9 FCRN 网络结构

本文借助 ResNet50 的思想,在传统的残差网络中引入 FCL,用于替代卷积层,也即在上文提出的 FCNN 网络的基础上加入捷径分支,构成残差模块。该网络包含三层残差模块以此来加深网络的深度,提高其对于图像的特征表达能力。与传统的深层神经网络不同,残差结构在输入和输出具有相同的维度时,可通过捷径分支将连接

前层和连接后层连接起来。而捷径分支既不会引入额外的参数，也不增加计算的复杂性，该方法有效地降低了梯度损失，并在神经网络加深的情况下防止过拟合性。

FCRN 网络的具体设计为：

(1) 输入：由于本文采用的是 16 电极，测得的边界电压有 208 值，因此输入向量大小为 208。

(2) 数据预处理：对边界电压进行归一化处理，经过零填充(ZeroPadding)将数据变为与输出相同的格式。

(3) 残差模块：每个残差模块中除了包含三层 FCL 层，即 5.2 小节中所述的 FCNN 结构，在其基础上添加了 Dropout 层和 BN 层，其作用是防止过拟合以及加快网络训练速度，其构成如图 5-10 所示。具体包括 FCL 层、BN 层、ReLU 激活函数、Dropout 层。捷径分支将输入与第三层输出进行相加得到输出。




图 5-10 残差模块

§ 5.3 损失函数

神经网络反向传播过程由于涉及误差，因此必须使用损失函数 (Loss function)^[84]。损失函数计算的是实际值与期望值间的差距，可以表示为： $L = f(\hat{y}, y)$ 。在一定程度上，损失函数等价于误差，网络训练是通过不断寻找其最小值来计算更新网络中的参数。若该值越小，网络拟合能力就越强。因此，损失函数的设定对网络有重要的影响。下面介绍常用的损失函数。

(1) 平均绝对误差

平均绝对误差 (Mean Absolute Error, MAE) 也被称为 L1 Loss，用于计算预测值与真实值之间差值的绝对值。在目标检测中，它通常用于计算预测框的置信度得分。对于一个 n 维向量 $X = (x_1, x_2, \dots, x_n)$ ，其一范式可以表示为：

$$L(y, \hat{y}) = \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5-10)$$

式中, y_i 为第 i 个样本的输出值, $\hat{y}_i$ 为第 i 个样本的期望值。

(2) 交叉熵损失函数

交叉熵损失函数 (Cross Entropy, CE) 常用于衡量分类模型预测输出与实际输出之间差距。在二分类问题中, 可以表示为:

$$CE(p, y) = \begin{cases} -\log(p) & y = 1 \\ -\log(1-p) & \text{其他} \end{cases} \quad (5-11)$$

式中, p 表示对样本预测的概率, y 为样本标签值, 如果有以下定义:

$$p_i = \begin{cases} p & y = 1 \\ 1-p & \text{其他} \end{cases} \quad (5-12)$$

则可将上式 (5-13) 表示为:

$$CE(p, y) = -\log(p_i) \quad (5-13)$$

(3) 焦点函数

为解决类别不平衡问题, 何凯明等通过修改 CE, 提出了焦点 (Focal Loss) 损失函数^[85]。该损失函数针对一些难分类的样本, 通过调整样本的权重使其在损失函数中所占比例更大, 从而能够更好地训练模型。Focal Loss 损失函数的公式如 (5-14) 所示:

$$L(p_i) = -\alpha(1-p_i)^\gamma \log(p_i) \quad (5-14)$$

对比 (5-13) 和 (5-14), Focal Loss 比 CE 多了参数 α 和调节因子 $(1-p_i)^\gamma$ 。 α 用于平衡正负样本的数量; γ 为调节系数, 用于减少易样本的损失。当样本分类越准确, 调节因子趋近于 0, 损失越小。

在 EIT 成像过程中, 可将其看作分类问题, 即将场域中正常阻抗和病灶阻抗进行分类。但由于病灶阻抗的数量相对较少, 而正常阻抗的数量较多, 导致了数据集中正常组织样本数量远远超过病灶组织样本数量, 进而导致数据集存在类别不平衡问题, 这会导致在模型训练中, 这些数值的重要性可能会被低估, 从而导致模型对目标物的预测效果不佳。因此, 需要采用一些有效的解决方法来解决该问题。

本文将 Focol Loss 与 L1 Loss 两种损失函数相结合, 提出了一种总损失函数。其中, Focol Loss 损失函数用于计算电导率的置信度 p , L1 Loss 损失函数用于计算预测值与真实值的误差。总损失函数的详细过程如图 5-11 所示。




图 5-11 总损失函数

以图 5-11 为例介绍总损失函数。首先将样本向量 p 映射成标签向量 y ，即将背景场域电导率的标签值设为 0，目标物的电导率的标签值设为 1。通过网络训练得到对电导率的置信度 p ，通过公式 (5-12) 求得 p_t 。该过程为若标签值为 1 时， $p_t = p$ ，否则 $p_t = 1 - p$ 。将 p_t 代入公式 (5-14) 求得 Focal Loss 的值。设定一个阈值用于筛选置信度，如上图设阈值为 0.5，若置信度值大于 0.5，说明该值有目标电阻率的可能性很大，则将其标签值设为 1，否则很大可能是背景值，标签值设为 0。接着，将置信度的标签值与计算值进行运算，通过相乘得到预测值。如上图，标签值为 0 处，预测值均为 0，标签值为 1 处，预测值取该计算值，因场域背景设为 1，因此将预测值加一以保证与样本值匹配。然后，利用 L1 Loss 损失函数计算预测值与样本值之间的误差，将其误差与 Focal Loss 相加得到总损失，通过反向传播更新网络中权重参数，不断重复上述过程来训练网络，寻找最小的损失值，从而得到最优的电导率。

Focal Loss 针对训练数据中目标物数据样本少的不平衡问题，通过降低背景场域样本的权重，加强目标物数据样本的权重，使得模型更加关注目标物样本的训练，从而提高模型的准确性。通过 L1 Loss，可以使网络更倾向于学习对结果影响更大的特征，从而降低过拟合的发生，增强模型的鲁棒性。将 Focal Loss 和 L1 Loss 两个损失函数相结合，可以在保证网络学习到重要特征的前提下，减少过拟合的发生，同时增加难分类样本的权重，提高网络的泛化能力。

§ 5.4 EIT 成像实验结果分析

利用第三章得到的仿真数据集对本文提出的 FCRN 网络进行训练和测试，得到重建结果。

为了更好地展示算法的效果，与前文所用算法，即 NOSER 算法和 PSO-TR 算法进行比较分析。上述几种算法的评价指标 RIE 如表 5-1 所示。

表 5-1 RIE 评价指标

目标物	NOSER 算法	PSO-TR 算法	FRCN 神经网络
单目标	9.6981	5.8176	1.261
双目标	29.6419	12.6515	2.6458
三目标	31.7529	19.4684	4.0713

取测试集中的部分仿真模型如图 5-12 所示，分别为单目标、双目标和三目标模型。同时，与 NOSER 算法和 PSO-TR 算法进行对比。其中，（a）为模型图，（b）为 NOSER 算法，（c）为 PSO-TR 算法，（d）FCRN 为算法。




图 5-12 单目标仿真结果





图 5-13 双目标仿真结果






图 5-14 三种 EIT 仿真模型

从表格 5-1 可以比较得出,FCRN 网络在三种不同情况下的 RIE 均为最好的,从仿真结果中可以看出,FCRN 算法可以准确定位到目标物的大小以及形状。因此,可以验证本文所提出的 FRCN 图像算法有良好的图像重建效果,能够准确的识别目标的位置、数量以及形状。

§ 5.5 本章小结

本章首先介绍了神经网络的基本原理和常用的激活函数。设计了 FCNN 网络模型,FCNN 具有强大的表达能力,但随网络加深会出现梯度消失和过拟合问题。为了解决该问题,提出了一种基于残差全连接神经网络(FRCN)EIT 成像算法,该网络是在 FCNN 的基础上引入捷径分支构成残差网络。具体来说,FCRN 算法通过在 FCNN 中添加跨层连接来构建残差结构。这些跨层连接可以将网络中某些层的输出直接传递给后面的层,从而使网络能够更好地学习输入数据的映射关系。

针对 EIT 成像过程中数据集存在类别不平衡问题,以及为获取模型的精确解,提出 Focol Loss 与一范式相结合的总损失函数。EIT 存在类别不平衡问题,影响了模型的训练效果,通过将两个损失函数相结合,可以在目标检测过程中更好地处理难分类和易分类的样本,从而提高检测精度和鲁棒性。

对本文提出的 FCEN 算法进行仿真训练,得到重建图像,与 NOSER 算法和 PSO-TV 算法进行比较,FCRN 的 RIE 评价指标为 1.261、2.6458、4.0713,是三种算法中最优的,说明 FCRN 有良好的重构性能。

第六章 总结与展望

§ 6.1 本文工作总结

本文首先介绍了电阻抗成像技术重建算法的研究现状以及在生物医学领域的应用,阐述了 EIT 成像技术的基本原理和数学模型。然后对 EIT 正问题进行研究,主要研究了有限元剖分方法以及模型的建立,重点对 EIT 的逆问题进行了研究,由于逆问题的病态性以及严重的不适定性,重建的图像分辨率低,因此需要寻找一种新的成像方法以改善图像重建质量,提出一种残差全连接神经网络,最后对实验结果进行分析。本文主要完成了以下工作:

1. 阐述了有限元求解正问题,运用 COMSOL 软件对 EIT 正问题进行有限元剖分和求解,建立场域模型;之后在场域模型上设置不同的目标物,即放置不同形状、大小、位置以及电导率的目标物,保证训练数据集的合理性和广泛性。联合 MATLAB 求解得到边界电压值,经过循环生成神经网络训练所需的数据集,总共生成 12500 组数据,其中包含 11250 组训练集和 1250 组测试集。

2. 提出了 PSO 算法与 Tikhonov 算法结合的 PSO-TR 算法,在该算法中,粒子群算法用来搜索最优解,Tikhonov 正则化用来约束解的平滑性或稀疏性。通过这种结合,PSO-TR 算法能够在保持搜索效率的同时,更好地保持重建图像的准确性和稳定性。

3. 建立神经网络的 EIT 重建模型,设计了全连接神经网络结构,并在其基础上进行改进,提出一种残差全连接神经网络算法。该网络模型是在全连接神经网络基础上引入残差网络,通过跨层连接和捷径分支结构,加深了网络,实现了更深层次的网络训练和更高精度的结果预测。

4. 针对 EIT 场域模型样本不平衡的问题,采用 Focal Loss 和 L1 Loss 结合的损失函数,使得网络训练过程中能更好地处理难易分类样本,提高检测精度。

5. 为了验证 PSO-TR 算法和 FCRN 算法,本文进行了仿真实验,并与经典图像重构算法 NOSER 算法进行比较,对算法进行 RIE 计算并分析,实验结果表明,PSO-TR 算法有较好的图像重建效果,FCRN 算法相较于其他算法,能更准确的定位目标区域,且成像清晰无伪影。

§ 6.2 未来工作展望

基于 PSO-TR 算法和 FCRN 算法的研究虽然取得了不错的效果,但仍存在不足之处和改进的空间。

(1) PSO-TR 算法的求解精度不够,重建图像仍存在伪影,对于靠近中心区域、目标物较多的情况,无法准确识别目标物,该算法还有待改进。

(2) FRCN 算法对目标物的电导率值识别不精确,若电导率值趋近于场域背景电导率,可能出现识别不到的情况,因此,还需对网络的识别精度进一步提高。

(3) 该算法仅进行了仿真实验,并未在人体上进行实验,因为人体的复杂度更高,对实验和算法要求更高,所以还需对逆问题还需进一步研究。

参考文献

- [1] 侯旭剑. 海上平台作业人员健康危害因素[J]. 职业与健康, 2017 (21): 3013-3015.
- [2] 杨阳. 基于北斗的海上作业人员体征监测系统研究[D]. 中北大学, 2019.
- [3] 肖理庆等. 电阻层析成像有限元模型与图像重建算法[M]. 北京: 科学出版社, 2019.
- [4] 何为, 罗辞勇, 徐征等. 电阻抗成像原理[M]. 科学出版社, 2009.
- [5] 魏颖. 电阻层析成像技术 (ERT) 及其在两相流测量中的应用研究[D]. 东北大学, 2001.
- [6] 徐桂芝, 李颖, 杨顾等. 生物医学电阻抗成像技术[M]. 北京: 机械工业出版社, 2010.
- [7] 王欢. 面向机器人柔性皮肤的电阻抗成像方法研究[D]. 南京航空航天大学, 2021. DOI:10.27239/d.cnki.gnhhu.2021.001167.
- [8] Avis N J, Barber D C, Brown B H, et al. Back-projection distortions in applied potential tomography images due to non-uniform reference conductivity distributions[J]. Clinical Physics and Physiological Measurement, 1992, 13(A): 113.
- [9] 罗辞勇, 朱清友. 改进的电阻抗反投影成像算法[J]. 重庆大学学报: 自然科学版, 2009, 32(3): 243-246.
- [10] 左从磊, 李静. 基于混合全变差正则化算法的电阻抗成像技术研究[J]. 传感器与微系统, 2021, 40(11): 5.
- [11] Murai T, Kagawa Y. Electrical impedance computed tomography based on a finite element model[J]. IEEE Transactions on Biomedical Engineering, 1985 (3): 177-184.
- [12] Geselowitz D B. An application of electrocardiographic lead theory to impedance plethysmography[J]. IEEE Transactions on biomedical Engineering, 1971 (1): 38-41.
- [13] Cheney M, Isaacson D, Newell J C, et al. NOSER: An algorithm for solving the inverse conductivity problem[J]. International Journal of Imaging systems and technology, 1990, 2(2): 66-75.
- [14] Yorkey T J, Webster J G, Tompkins W J. An improved perturbation technique for electrical impedance imaging with some criticisms[J]. IEEE transactions on biomedical engineering, 1987 (11): 898-901.
- [15] 张贵华. 电阻抗成像逆问题的正则化方法研究[D]. 河北工业大学, 2008.
- [16] Fang W. A nonlinear image reconstruction algorithm for electrical capacitance tomography[J]. Measurement Science and Technology, 2004, 15(10): 2124.
- [17] 黄嵩, 何为. 电阻抗成像中混合罚函数正则化算法的仿真研究[J]. 计算机仿真, 2006, 23(4): 94-98.
- [18] 张玲玲, 王化祥, 范文茹. 基于 1 范数的电阻层析成像图像重建算法[J]. 天津大学学报,

- 2011, 44(9): 786-790.
- [19] 范文茹, 王化祥, 郝魁红. 基于两步迭代 TV 正则化的电阻抗图像重建算法[J]. 仪器仪表学报, 2012, 33(3): 625-630.
- [20] Clarke C J S, Janday B S. The solution of the biomagnetic inverse problem by maximum statistical entropy[J]. Inverse Problems, 1989, 5(4): 483.
- [21] Kim H C, Boo C J, Kang M J. Image reconstruction using genetic algorithm in electrical impedance tomography[C]//Neural Information Processing: 13th International Conference, ICONIP 2006, Hong Kong, China, October 3-6, 2006. Proceedings, Part III 13. Springer Berlin Heidelberg, 2006: 938-945.
- [22] 石天明, 张亮, 肖理庆, 等. 用组合算法逐步提高电阻层析成像的分辨率[J]. 仪器仪表学报, 2008, 29(12): 2587-2593.
- [23] 肖理庆, 邵晓根, 李子龙等. 基于遗传算法的组合 ERT 图像重建算法研究[J]. 仪器仪表学报, 2010 (2): 305-311.
- [24] Zhang Y, Chen H, Yang L, et al. A proportional genetic algorithm for image reconstruction of static electrical impedance tomography[J]. IEEE sensors journal, 2020, 20(24): 15026-15033.
- [25] 魏颖, 赵进创, 王师等. 基于 RBF 神经网络的电阻层析成像算法的研究[J]. 仪器仪表学报, 2001, 22(4): 369-371.
- [26] 谢莉莉, 汪鹏, 陈丽. PSO 算法优化 BP 神经网络的 EIT 图像重建算法[J]. 制造业自动化, 2011, 33(2): 45-46.
- [27] Fernández-Fuentes X, Mera D, Gómez A, et al. Towards a fast and accurate eit inverse problem solver: A machine learning approach[J]. Electronics, 2018, 7(12): 422.
- [28] Tan C, Lv S, Dong F, et al. Image reconstruction based on convolutional neural network for electrical resistance tomography[J]. IEEE Sensors Journal, 2018, 19(1): 196-204.
- [29] 徐桂芝, 李颖, 杨硕等. 生物医学电阻抗成像技术[M]. 北京: 机械工业出版社, 2010.
- [30] Smith R W M, Freeston I L, Brown B H. A real-time electrical impedance tomography system for clinical use-design and preliminary results[J]. IEEE Transactions on Biomedical Engineering, 1995, 42(2): 133-140.
- [31] Wilson A J, Milnes P, Waterworth A R, et al. Mk3. 5: a modular, multi-frequency successor to the Mk3a EIS/EIT system[J]. Physiological Measurement, 2001, 22(1): 49.
- [32] Newell J C, Gisser D G, Isaacson D. An electric current tomograph[J]. IEEE Transactions on Biomedical Engineering, 1988, 35(10): 828-833.
- [33] Cook R D, Saulnier G J, Gisser D G, et al. ACT3: a high-speed, high-precision electrical impedance tomograph[J]. IEEE Transactions on Biomedical Engineering, 1994, 41(8): 713-722.
- [34] Halter R, Hartov A, Paulsen K D. Design and implementation of a high frequency electrical impedance tomography system[J]. Physiological measurement, 2004, 25(1): 379.

- [35] Zhu Q S, McLeod C N, Denyer C W, et al. Development of a real-time adaptive current tomograph[J]. *Physiological Measurement*, 1994, 15(2A): A37.
- [36] McLeod C N, Shi Y, Denyer C, et al. High speed in vivo chest impedance imaging with OXBACT Mark III[C]//Proc. 18th Int. Conf. IEEE EMBS. 1996.
- [37] Yue X, McLeod C. FPGA design and implementation for EIT data acquisition[J]. *Physiological measurement*, 2008, 29(10): 1233.
- [38] Kim D Y, Wi H, Yoo P J, et al. Performance evaluation of KHU Mark2 parallel multi-frequency EIT system[C]//Journal of Physics: Conference Series. IOP Publishing, 2010, 224(1): 012013.
- [39] 董秀珍, 付峰, 尤富生等. 一个基于物理模型的生物电阻抗断层成像系统的研究[J]. *中国医学物理学杂志*, 2004, 21(4): 226-229.
- [40] 董秀珍, 史学涛, 付峰等. 脑 EIT 中边界电压随颅内电阻率扰动变化情况的仿真研究[J]. *中国生物医学工程学报*, 2008, 27(5): 644-649.
- [41] 王化祥, 王春艳. 肺部电阻抗成像系统[J]. *医疗卫生装备*, 2006, 27(4): 3-4.
- [42] 张静. 无线 MEIT 系统及图像改善方法研究[D]. 天津科技大学, 2013.
- [43] Barceló J A, Vega L, Zubeldia M. The forward problem for the electromagnetic Helmholtz equation with critical singularities[J]. *Advances in Mathematics*, 2013, 240: 636-671.
- [44] 徐桂芝. 基于 EIT 技术的脑内电特性与功能成像研究[D]. 天津: 河北工业大学, 2002.
- [45] Surowiec A, Stuchly S S, Eidus L, et al. In vitro dielectric properties of human tissues at radiofrequencies[J]. *Physics in Medicine & Biology*, 1987, 32(5): 615.
- [46] 倪光正, 钱秀英等. 电磁场数值计算[M]. 北京: 高等教育出版社, 1996.
- [47] Marashdeh Q, Warsito W, Fan L S, et al. Nonlinear forward problem solution for electrical capacitance tomography using feed-forward neural network[J]. *IEEE Sensors Journal*, 2006, 6(2): 441-449.
- [48] Baumann C E, Oden J T. A discontinuous hp finite element method for convection—diffusion problems[J]. *Computer Methods in Applied Mechanics and Engineering*, 1999, 175(3-4): 311-341.
- [49] Fuchs M, Drenckhahn R, Wischmann H, et al. An improved boundary element method for realistic volume-conductor modeling[J]. *IEEE Transactions on biomedical engineering*, 1998, 45(8): 980-997.
- [50] Liszka T, Orkisz J. The finite difference method at arbitrary irregular grids and its application in applied mechanics[J]. *Computers & Structures*, 1980, 11(1-2): 83-95.
- [51] 王化祥. 电学层析成像[M]. 北京: 科学出版社, 2013.
- [52] Babaeizadeh S, Brooks D H, Isaacson D, et al. Electrode boundary conditions and experimental validation for BEM-based EIT forward and inverse solutions[J]. *IEEE transactions on medical imaging*, 2006, 25(9): 1180-1188.
- [53] 韩丰泽. 基于电阻抗图像重建的乳腺异物定位方法研究[D]. 天津科技大学, 2019.

- [54] 李森. 基于电阻抗成像的肺功能数据采集系统[D]. 西安理工大学, 2019.
- [55] 荆会敏. 基于磁共振的电阻抗成像技术研究[D]. 中国计量大学, 2019.
- [56] 肖理庆. 一种改进牛顿-拉夫逊 ERT 绝对图像重建算法[J]. 天津大学学报: 自然科学与工程
技术版, 2015, 48(8): 734-741.
- [57] 林群, 杨一都. 有限元方法的插值和校正[J]. 数学的实践与认识, 1991, 3.
- [58] 金建铭, 王建国, 物理. 电磁场有限元方法[M]. 西安电子科技大学出版社, 1998.
- [59] Dorn O, Bertete-Aguirre H, Berryman J G, et al. A nonlinear inversion method for 3D
electromagnetic imaging using adjoint fields[J]. Inverse problems, 1999, 15(6): 1523.
- [60] Drucker H, Burges C J, Kaufman L, et al. Support vector regression machines[J]. Advances in
neural information processing systems, 1996, 9.
- [61] 胡健伟, 汤怀民. 微分方程数值方法[M]. 科学出版社, 1999.
- [62] 赵延文, 郭绍伟, 臧春艳等. 基于 Comsol 的变压器绕组短路力分布研究[J]. 华北电力技术,
2017 (1): 40-44.
- [63] 侯雪. 基于 Comsol 的肺部电阻抗断层成像仿真研究[D]. 硕士学位论文. 天津: 天津大学,
2012.
- [64] 马慧, 王刚. COMSOL Multiphysics 基本操作指南和常见问题解答[J]. 2009..
- [65] 刘锐岗, 董秀珍, 秦明新. 电阻抗断层成像的驱动模式[J]. 国外医学: 生物医学工程分册,
1999, 22(1): 20-24.
- [66] 罗辞勇. 基于快速牛顿一步误差重构的电阻抗成像算法和实验研究[D]. 重庆大学, 2005.
- [67] 徐管鑫. 电阻抗成像技术理论及应用研究[D]. 重庆大学, 2004.
- [68] 赵晓磊, 齐秋菊, 郭春超. COMSOL 与 MATLAB 联合仿真的实现方法[J]. 中国新技术新产
品, 2014 (24): 17-19.
- [69] 胡海涛. 电阻层析成像图像重建算法的研究[D]. 哈尔滨: 哈尔滨理工大学, 2009.
- [70] Kennedy J, Eberhart R. Particle swarm optimization[C]//Proceedings of ICNN'95-international
conference on neural networks. IEEE, 1995, 4: 1942-1948.
- [71] Scherzer O. The use of Morozov's discrepancy principle for Tikhonov regularization for solving
nonlinear ill-posed problems[J]. Computing, 1993, 51(1): 45-60.
- [72] McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The
bulletin of mathematical biophysics, 1943, 5: 115-133.
- [73] Rosenblatt F. The perceptron, a perceiving and recognizing automaton Project Para[M]. Cornell
Aeronautical Laboratory, 1957.
- [74] Rosenblatt F. The perceptron: a probabilistic model for information storage and organization in the
brain[J]. Psychological review, 1958, 65(6): 386.
- [75] Minsky M, Papert S. An introduction to computational geometry[J]. Cambridge tiass., HIT, 1969,
479: 480.

-
- [76] Cui Z, Wang Q, Xue Q, et al. A review on image reconstruction algorithms for electrical capacitance/resistance tomography[J]. Sensor Review, 2016, 36(4): 429-445.
- [77] Matthew Zeiler D, Rob F. Visualizing and understanding convolutional neural networks[C]. ECCV, 2014.
- [78] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.
- [79] Minsky M. Steps toward artificial intelligence[J]. Proceedings of the IRE, 1961, 49(1): 8-30.
- [80] 陈云霁. 智能计算系统[M]. 机械工业出版社, 2020.
- [81] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 807-814.
- [82] 李峰, 谭超, 董峰. 全连接深度网络的电学层析成像算法[J]. 工程热物理学报, 2019, 40(7): 1526-1531.
- [83] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [84] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.
- [85] Dewa C K. Suitable CNN weight initialization and activation function for Javanese vowels classification[J]. Procedia computer science, 2018, 144: 124-132.