

深度 D-bar: 基于深度神经网络的实时电阻抗断层成像

S. J. Hamilton and A. Hauptmann

摘要—电导率断层成像 (EIT) 的数学问题是高度非线性的病态逆问题, 需要精心设计的重构方法以确保可靠图像生成。D-bar 方法基于严格的数学分析, 通过使用相关非线性傅里叶数据的低通滤波, 提供稳健的直接重构。与线性傅里叶数据的低通滤波类似, 仅在图像恢复过程中使用低频信息会导致图像模糊, 缺乏清晰的特征, 例如明确的器官边界。卷积神经网络为后处理此类卷积后的直接重构提供了强大的框架。在本研究中, 我们展示了这些 CNN 技术即使在 EIT 的高度非线性逆问题中也能实现清晰且可靠的重构。网络在模拟样本的数据集上进行训练, 随后直接应用于实验数据, 无需进行额外的迁移训练。结果针对绝对 EIT 图像使用来自 ACT4 和 KIT4 EIT 系统的实验 EIT 数据进行了展示。

Index Terms—电阻抗断层成像, D-巴方法, 深度学习, 导电性成像

I. 引言

E电导率断层成像 (EIT) 图像传统上显示患者在附着测量电极平面内的组织依赖性电导率分布, 从而能够可视化心脏和肺部功能以及损伤情况 [1]–[6]。生成的图像具有高对比度, 数据采集通过无害的电学测量完成, 无需使用对比剂或电离辐射。然而, 从电流/电压测量数据恢复图像的过程是一个严重不适定的非线性逆问题, 因此需要具备噪声鲁棒性的正则化策略以保证稳定性。‘D-bar 方法’是唯一被证明适用于完整非线性问题的正则化策略 [7], 它通过使用相关非线性傅里叶数据的低通滤波器实现实时噪声鲁棒的图像重

建。然而, 这会导致图像出现特征模糊, 而这些特征在医学成像应用中往往至关重要。在本研究中, 我们提出将 D-bar 与深度学习相结合, 特别是与卷积神经网络结合, 以“学习”并消除图像模糊效应, 从而实现实时清晰的 EIT 图像。

EIT 重构通常通过基于最小化惩罚泛函 (如 [8], [9]) 的迭代算法来计算。由于能够灵活地融入先验知识, 这类方法在重构质量方面表现优异, 但需要在正向问题的重复仿真中对边界形状进行仔细建模。文献 [10], [11] 提出了克服边界敏感性的方法, 但往往计算成本较高。另一方面, 直接 (非迭代) 重构算法无需重复进行正向算子的仿真。其中一种方法称为 D-bar 算法, 其基于测量表面电流/电压数据的非线性傅立叶变换。该方法采用对变换后数据进行低通滤波作为正则化策略, 以抑制测量数据中的噪声对图像重构过程的影响。因此, 这种滤波导致重构图像显著损失锐度。已有研究表明, 直接 D-bar 方法对电极位置的错误或不完整知识以及边界形状的误差具有鲁棒性, 参见例如 [12] 及第 II-B 节的讨论。而迭代方法则要么对正确的正向模型极为敏感, 要么依赖于复杂的建模来应对模型中的不确定性, 例如未知的电极位置、边界形状或接触阻抗 [10], [11], [13]。

近年来, 在图像重构这一更广泛领域的进展表明, 深度学习和神经网络在提升低质量或受损图像方面具有强大能力。特别是, 将快速直接的重构过程与深度神经网络相结合, 能够在低延迟条件下提供高质量图像, 从而在许多应用中实现潜在的实时成像。卷积神经网络 (CNN) 特别适用于对基于傅立叶变换或与其相关的算法所产生的初始重构结果进行后处理, 如 [14] 所示。这类初始重构通常由于某种形式的低通滤波而导致空间分辨率下降, 并伴随额外的欠采样伪影。针对医学成像中的多个线性逆问题, 已研究通过训练 CNN 来消除这些伪影, 以提高重构图像的信息含量, 包括 CT [14], [15], MRI [16] 以及 PAT [17], [18]。尽管 EIT 问题本

Copyright (c) 2017 IEEE. Personal use of this material is permitted. However, permission to use this material for any other purposes must be obtained from the IEEE by sending a request to pubs-permissions@ieee.org.

S. J. Hamilton is with the Department of Mathematics, Statistics, and Computer Science, Marquette University, Milwaukee, WI, 53233 USA (e-mail: sarah.hamilton@marquette.edu).

A. Hauptmann is with the Department of Computer Science; University College London, London, United Kingdom, (email: a.hauptmann@ucl.ac.uk)

Accompanying codes will be made available: <https://github.com/asHauptmann/DeepDbar>

质上是非线性的，但低通滤波的 D -bar 方法所生成的图像自然符合这一情景。

在本研究中，我们构建了一种具备实时能力的重构算法，该算法通过将 D -bar 算法与卷积神经网络 (CNN) 的后续处理相结合，生成高质量、清晰的 absolute EIT 图像。针对该任务，我们采用一种成熟的 CNN 架构 (即 U-net)，并对其进行调整以适应 D -bar EIT 重构中的典型图像结构。我们使用模拟训练数据对网络进行训练，并直接将训练好的网络应用于实验数据，而不直接在实验数据上进行训练。这种成功的转移到实验数据突显了 D -bar 算法的鲁棒性，这一点尤为重要，因为对优质训练数据的需求往往是此类基于网络的方法在其他成像模式中取得成功的瓶颈，[14], [18], [19]。

本文组织如下。第 II 节简要回顾了 EIT 的数学问题及 D -bar 求解方法。第 III 节介绍了用于 D -bar 的深度学习卷积神经网络 (CNN)，称为“Deep D -bar”。第 IV 节描述了实验设置以及训练数据的仿真过程，第 V 节展示了实验结果。第 VI 节对结果进行了讨论，第 VII 节得出结论。建议读者在电脑屏幕上阅读本文，因为图像对比度的细节在打印版本中可能会被遮蔽。

II. 电阻抗断层成像与 D -BAR 重构方法

电阻抗断层成像是一种非线性逆问题，其目标是从边界上的电流-电压测量值确定内部的电导率。该问题可表述为广义拉普拉斯方程。

$$\begin{cases} \nabla \cdot \sigma \nabla u = 0 \text{ in } \Omega, \\ \sigma \partial_\nu u = \varphi \text{ on } \partial, \end{cases} \quad (1)$$

在给定电导率 σ 的情况下，对域 $\Omega \subset \mathbb{R}^n$ 内的电势 u 进行建模，其中 Neumann 边界条件描述了施加的平均自由电流 φ 引起的边界电压。测量数据由电流和电压的测量对组成，并通过电流到电压映射 $\mathcal{R}_\sigma$ 来建模，该映射定义为

$$\mathcal{R}_\sigma \varphi := u|_\partial.$$

该测量算子也称为诺伊曼到狄利克雷 (ND) 映射，掌握该映射即可预测对于任意注入电流模式 $n = 2, 3$ 所产生的电压结果。在实际应用中，通过施加一组电流模式基并跟踪电压响应，可形成对 ND 映射的近似。我们下面使用的 D -bar 算法需要相应的狄利克雷到诺伊曼 (DN) 映射，该映射可通过 ND 映射的逆得到， $\Lambda_\sigma = (\mathcal{R}_\sigma)^{-1}$ ，适用于完整边界数据（而非部分边界数据）的情形。在本研究中，我们考虑 $n = 2$ 情况，因为 D -bar 重构

框架在二维中已得到进一步发展。然而，我们预计其自然扩展至三维 [20]。

A. 使用近似 D -bar 方法的实时重构

通过 D -bar 方法，我们指的是基于 [21] 中给出的理论证明的正则化 D -bar 方法 [7]。该方法使用一种非线性傅立叶变换，称为散射变换，专为 EIT 问题设计，将其应用于以 DN 映射 Λ_σ 形式表示的测量电流/电压数据。然后将该散射数据作为输入数据用于一个偏微分方程，即 $\bar{\partial}_k$ 或“ D -bar”方程，从而得名该方法。请注意，导数算子 ∂_z 和 $\bar{\partial}_z$ 定义为 $\partial_z = \frac{1}{2}(\partial_{z_1} - i\partial_{z_2})$ 和 $\bar{\partial}_z = \frac{1}{2}(\partial_{z_1} + i\partial_{z_2})$ ，其中 $z = z_1 + iz_2 \in \mathbb{C}$ 。随后，电导率 σ 可直接从 D -bar 方程的解中恢复。

D -bar 方法 [21] 是将物理电导率方程 $\nabla \cdot \sigma \nabla u = 0$ 转换为一个非物理的 Schrödinger 方程，然后使用 Beals 和 Coifman 推广的 D -bar 方法 [22] 求解该问题，再转换回物理情景。变量变换 $\tilde{u} = \sigma^{1/2}u$ 和 $q(z) = \sigma^{-1/2}(z)\Delta\sigma^{1/2}(z)$ 产生所需的 Schrödinger 方程 $[-\Delta + q(z)]\tilde{u}(z) = 0$ ，其中 $z \in \Omega$ 。若 $\sigma(z)$ 在边界附近为常数，则不失一般性地假设 $\sigma = 1$ 在 ∂ 附近成立，电导率可从 Ω 扩展到整个平面，通过设定 $\sigma(z) \equiv 1$ 对于 $z \in \mathbb{C} \setminus \Omega$ 成立。注意这使得势函数 $q(z)$ 在 Ω 中具有紧支集。我们利用 Schrödinger 方程的特殊解 $\psi(z, k)$

$$[-\Delta + q(z)]\psi(z, k) = 0, \quad z \in \mathbb{C}, \quad k \in \mathbb{C} \setminus \{0\}, \quad (2)$$

称为复几何光学 (CGO) 解，其在大 $|z|$ 或 $|k|$ 时具有特定的渐近行为， $\psi(z, k) \sim e^{ikz}$ 。注意，我们通过映射 $z = (z_1, z_2) \mapsto z_1 + iz_2$ 将 $\mathbb{R}^2$ 与 $\mathbb{C}$ 关联起来，因此 $kz = (k_1 + ik_2)(z_1 + iz_2)$ 表示复数乘法。CGO 解 $\mu(z, k) = e^{-ikz}\psi(z, k) \sim 1$ 在非物理散射变量 k 中满足一个 D -bar 方程

$$\bar{\partial}_k \mu(z, k) = \frac{1}{4\pi k} \mathbf{t}(k) e(z, -k) \overline{\mu(z, k)}, \quad (3)$$

其中 $e(z, k) := \exp\{i(kz + \bar{k}\bar{z})\}$ 和 $\mathbf{t}(k)$ 是由以下定义的非线性散射数据

$$\mathbf{t}(k) := \int_{\mathbb{C}} e(z, k) q(z) \mu(z, k) dz. \quad (4)$$

注意到，通过以下观察可将此散射数据 $\mathbf{t}$ 视为非线性傅里叶数据。将 (4) 中的 CGO 解 $\mu(z, k)$ 替换为渐近行为 1，得到

$$\mathbf{t}^{\exp}(k) = \int_{\mathbb{C}} e(z, k) q(z) (1) dz = \hat{q}(-2k_1, 2k_2),$$

因此, 'Born' 近似 $\mathbf{t}^{\text{exp}}$ 本质上是势函数 q 的平移傅立叶变换。通过 Alessandrini 恒等式 [23] 可以建立与测量数据 Λ_σ 之间的联系。

$$\mathbf{t}^{\text{exp}}(k) = \int_{\mathbb{C}} e(z, k) q(z) dz = \int_{\partial} e^{i\bar{k}z} (\Lambda_\sigma - \Lambda_1) e^{ikz} dz.$$

在本工作中, 我们使用了该 'Born' 近似 $\mathbf{t}^{\text{exp}}$, 该近似首次提出于 [24], 因其能使 D-bar 方法快速求解 EIT 问题, 达到可视为“实时”的程度 [25], 且对噪声数据具有鲁棒性。该算法的主要步骤如下所述:

$$\begin{array}{ccccc} \text{Current/Voltage Data} & \xrightarrow{1} & \text{Scattering Data} & \xrightarrow{2} & \text{Conductivity} \\ (\Lambda_\sigma, \Lambda_1) & & \mathbf{t}^{\text{exp}}(k) & & \sigma(z) \end{array}$$

第一步: 对每个 $k \in \mathbb{C} \setminus \{0\}$, 计算近似散射数据

$$\mathbf{t}^{\text{exp}}(k) = \begin{cases} \int_{\partial} e^{i\bar{k}z} (\Lambda_\sigma - \Lambda_1) e^{ikz} dS(z), & 0 < |k| \leq R \\ 0 & |k| > R. \end{cases} \quad (5)$$

步骤 2: 对每个 $z \in \Omega$, 使用积分方程求解 D-bar 方程 (3)

$$\mu^{\text{exp}}(z, \kappa) = 1 + \frac{1}{4\pi^2} \int_{\mathbb{C}} \frac{\mathbf{t}^{\text{exp}}(k) e(z, -k)}{(\kappa - k)\bar{k}} \mu^{\text{exp}}(z, k) d\kappa_1 d\kappa_2, \quad (6)$$

并恢复近似的电导率

$$\sigma^{\text{exp}}(z) = [\mu^{\text{exp}}(z, 0)]^2. \quad (7)$$

B. 基于 D-bar 方法的 EIT 鲁棒性

近期研究 [12], [26] 表明, 基于 D-bar 的二维 EIT 重构方法对电极位置和边界形状的误设具有鲁棒性。这种鲁棒性在绝对成像和时差成像中均成立, 且两种图像对边界形状和电极位置的误设表现出相似的行为。这可能是由于错误的域建模会导致从 DN 映射得到的 EIT 数据仅可能对应于各向异性电导率, 即使真实的电导率是各向同性的。尽管无法唯一恢复各向异性电导率, 但可以唯一恢复矩阵值各向异性电导率的各向同性化, $\sqrt{\det(\sigma)}$, 可解释为通过等温坐标对真实各向异性电导率进行变形。在 [27], [28] 中, 已证明 D-bar 重构方法中的方程对于各向异性和各向同性 EIT 数据是相同的, 这有助于解释为何即使在各向异性电导率和边界形状不精确已知的情况下, D-bar 方法仍能产生高质量的图像。本文重点关注绝对图像。

III. 深度 D-BAR

本研究的目的是提出一种用于电气阻抗断层成像的实时重构算法, 以生成清晰且稳健的绝对 EIT 图像。为了实现这一目标, 我们将第 II-A 节中描述的 D-bar 算法与卷积神经网络 (CNN) 相结合。该思路依赖于一种称为 U-Net [29] 的网络结构, 最初用于图像分割。已有研究表明, 对于多个线性逆问题 [14]–[18], 这种特定的网络结构可以被修改, 以成功消除医学图像重构中的伪影。其基本方法是使用快速而简单的重构算法获得存在噪声的图像, 然后训练网络以去除这些伪影。与电气阻抗断层成像相关的另一项研究为 [30], 其中作者使用人工神经网络 (ANNs) 对线性高斯-牛顿算法的一步初始重构结果进行后处理, 用于三维时间差分 EIT 成像。我们的方法从根本上不同, 因为它恢复的是绝对 EIT 图像。

我们选择的网络结构基于已有的 U-Net [29], 其包含多层级分解和多个跳跃连接, 以避免训练过程中的奇异情况, 具体架构如图 1 所示。U-Net 的原始设计目的是图像分割。这与我们的应用非常相似, 我们的主要目标是识别器官边界并反卷积重构结果, 因此网络的输出一张锐化后的图像。因此, 我们认为 U-Net 架构非常适合用于 EIT 成像, 因为其多层级结构能够高效处理大范围图像区域的非线性和锐化问题。此外, 如 [31] 所讨论, 池化层可带来平移不变性, 这对于减少重构过程中的位置偏差以及检测训练集中未出现的损伤至关重要。作为对原始架构的改进, 我们需要将卷积核大小增加至 5×5 (相较于 3×3), 这可能是为了应对重构过程中的非线性并增强重构的一致性。需要说明的是, 与 [14]–[18] 中的研究不同, 后者作者学习初始重构的残差更新, 而我们训练网络直接生成输入的单一锐化版本。

A. 网络的训练

给定真实电导率 σ , 我们模拟测量数据, 如第 IV-A 节所述, 并利用 II-A 中概述的 D-bar 方法重构近似电导率 σ^{exp} 。由于 D-bar 算法中的重构步骤 (6) 可以对任意 $z \in \mathbb{R}^2$ 进行, 因此我们在方阵 $[-1, 1]^2$ 上重构 σ^{exp} , 以获得作为网络输入的方阵图像。分辨率选择为 64×64 。真实值 σ 也通过扩展背景电导率的方式扩展至 $[-1, 1]^2$ 。

在获得训练集 $\{\sigma_i, \sigma_i^{\text{exp}}\}_i$ 后, 我们对深度 D-bar 网络 (记为 $\mathcal{D}_\theta$) 进行训练, 以确定网络参数 θ , 即每个卷积层中的卷积滤波器和偏置。给定网络的输出




图 1. 深度 D-bar 网络结构。输入由 D-bar 重构 σ^{exp} 给出，分辨率为 64×64 ，输出记为 $\tilde{\sigma}$ 。蓝色条形上方的数字表示每层的通道数。多级分解的分辨率以灰色显示在左侧。每个卷积层均配备整流线性单元作为非线性激活函数，表达式为 $\text{ReLU}(x) = \max(0, x)$ 。

$\tilde{\sigma} = \mathcal{D}_{\theta}(\sigma^{\text{exp}})$ ，我们旨在最小化网络输出与幻影之间的 ℓ^2 -误差，该误差由损失函数定义

$$\text{loss}(\tilde{\sigma}) := \|\tilde{\sigma} - \sigma\|_2^2.$$

该网络使用 Python 库 TensorFlow 实现，以 16 为批量进行 1,000 轮次的最优化，采用 TensorFlow 提供的 Adam 算法，初始学习率为 10^{-4} 。在配备 12GB 内存的单个 Titan XP GPU 上，训练过程 仅需 4 小时。如下一节将讨论的，我们无需进行迁移训练即可将训练好的 Deep D-bar 网络应用于实验数据，模拟数据上的训练已足够。

IV. 实验设置与计算说明

我们将使用来自两种不同 EIT 设备的实验数据来演示新的 Deep D-bar 方法：来自伦斯勒理工学院 (RPI) 的 ACT4 [32], [33] 以及来自东芬兰大学 (UEF) 的 KIT4 [34]。

ACT4 数据使用含有 4% 琼脂的目标，其中添加了 10% 石墨以模拟心脏、双肺、主动脉和脊柱。所有图像均以 DICOM 方向显示，即右肺对应于观察者的左侧，仿佛我们正从患者脚部向上观察。通过移除部分右 (DICOM) 肺并进行以下操作来模拟损伤：(1) 使用与心脏导电性相同的琼脂/石墨块替换缺失部分，以模拟胸腔积液等损伤；(2) 在缺失区域放置三根塑料管，以模拟导电性极低的区域，如气胸；(3) 使用三根金属管替

换缺失部分。实验结果如图 2 所示。各目标的近似导电率见表 I。琼脂/石墨目标的导纳谱是使用 Impedimed 公司的 SFB-7 生物阻抗仪在测试单元上测得的。¹。需要注意的是，ACT4 系统施加电压并测量电流，而非相反。在这些实验中，对半径为 15 厘米的圆形水槽施加了最大幅值为 0.5 伏（频率为 3.3 千赫）的三角函数电压模式，水槽内有 32 个电极（宽度 2.5 厘米），并填充了电导率为 0.3 西门子/米的盐水至 2.25 厘米高度。

表 I
ACT4 目标在 3.3kHz 下的电导率值

	MEASURED VALUES (S/m)	SIMULATED VALUES Ranges (S/m)
HEART/AORTA	0.67781	[0.5, 0.8]
LUNGS/SPINE	0.056714	[0.01, 0.2]
SALINE BACKGROUND	0.3	[0.29, 0.31]
INJURY 1: AGAR/GRAPHITE	0.67781	[0.01, 1.5]
INJURY 2: PLASTIC TUBES	0	[0.01, 1.5]
INJURY 3: COPPER TUBES	infinite	[0.01, 1.5]

KIT4 数据是在半径为 14 厘米的圆形水槽中采集的，水槽内有 16 个宽 2.5 厘米的电极，注入了电导率在 0.03 S/m 之间的自来水，液面高度为 7 厘米。如图 3 所示，在水槽中放置了导电（金属）和阻性（塑料）目标，并施加了相邻电流模式，幅值为 2 mA，频率为 1 kHz。我们指出，尽管该数据可能不满足人体成像的安全标准，但其包含在此处仅用于说明目的以及潜在的工

¹<https://www.impedimed.com/products/sfb7-for-body-composition/>




图 2. 在罗切斯特理工学院 (RPI) 的 ACT4 系统上对测试体模进行的实验设置。使用琼脂/石墨目标来模拟包含心脏、双肺、主动脉和脊柱的胸部体模。第一幅图像显示健康体模。探索了三种损伤情况：‘损伤 1’，用与心脏目标电导率相同的琼脂/石墨替换右肺的切口部分，以模拟可能的胸腔积液；‘损伤 2’，用三根塑料管替换右肺的切口部分；‘损伤 3’，用三根铜管替换右肺的切口部分。

业应用。




图 3. 在 UEF 的 KIT4 EIT 系统上，设置导电和电阻性目标的实验装置。白色物体由实心塑料制成，具有电阻性。空心圆形物体为导电金属环。

A. 二维电阻率成像数据仿真

边界条件 (1) 假设边界测量遵循连续体模型，完全忽略了电极的离散位置。在模拟训练数据时，我们使用了连续体模型的一个改进版本，称为连续体电极模型，该模型由 [35] 提出，旨在于连续体设置下模拟真实的电极数据。本质上，连续体电流/电压迹被最优地投影到对应于电极位置的边界子集上。虽然训练也可以采用更复杂的电极模型，例如完全电极模型 (CEM) [36]，但我们的简化连续体电极模型在此概念验证研究中已足够有效。

我们旨在将 ND 映射表示为关于边界上标准正交基的矩阵近似 $\mathbf{R}_\sigma$ 。设 L 为电极的偶数个数，则基函数选择为 $n \in \{-L/2, \dots, -1, 1, \dots, L/2\}$ 。

$$\varphi_n(\theta) = \begin{cases} \frac{1}{\sqrt{\pi}} \sin(n\theta) & \text{if } n < 0, \\ \frac{1}{\sqrt{\pi}} \cos(n\theta) & \text{if } n > 0. \end{cases}$$

ACT4 系统使用 $L = 32$ 个电极，KIT4 系统使用 $L = 16$ 个电极。测得的电压随后被投影到连续迹 g_n ，见 [35]，[37]，我们通过 $L^2(\partial)$ 中计算内积得到 ND 矩阵 $\mathbf{R}_\sigma$ ，如下所示

$$(\mathbf{R}_\sigma)_{n,\ell} = (g_n, \varphi_\ell) = \int_{\partial} g_n(s) \varphi_\ell(s) ds. \quad (8)$$

DN 映射的矩阵近似， $\mathbf{L}_\sigma$ ，通过求逆 ND 矩阵得到，即 $\mathbf{L}_\sigma = (\mathbf{R}_\sigma)^{-1}$ 。如果定义域的最大半径 r 不为 1，则 DN 矩阵可以通过 r 缩放，以对应于半径为 1 时获得的数据。类似地，如果 $\sigma = \sigma_0 \neq 1$ 在 ∂ 附近，DN 矩阵通过 $\frac{1}{\sigma_0}$ 缩放，以产生对应于 $\sigma = 1$ 在边界附近的 DN 矩阵。如果无法获得 σ_0 的估计值，则可以按照 [24] 所述方法形成对数据的最佳常电导率近似。在 D-bar 算法结束时，通过乘以 σ_0 来取消缩放。用于通过 (5) 计算散射数据所需的 DN 映射 Λ_1 的矩阵近似 $\mathbf{L}_1$ ，使用常电导率 $\sigma = 1$ 模拟。

B. 训练数据的仿真

神经网络的训练数据仅使用模拟数据生成：一组用于 ACT4 数据，另一组用于 KIT4 数据。

ACT4 的训练数据创建过程如下。使用图 2（左上角）所示的“健康”图像，通过在图像中点击目标周围区域来提取器官边界，包括心脏、主动脉、左肺、右肺和脊柱（图 4，右上角）。通过生成随机数决定每个目标是否被包含：心脏 (95%)、主动脉 (95%)、左肺 (90%)、右肺 (90%)、脊柱 (100%)。若某目标被包含，则使用

MATLAB 中的 `awgn` 命令向该目标的近似边界点添加白高斯噪声 (25dB), 以生成“噪声”边界位置。图 4 (底部) 展示了白噪声对边界位置的影响。每种目标/器官的噪声独立添加。对于每个被包含的目标, 其电导率通过在表 I 最后一列所示值域内生成均匀分布的随机数进行分配。通过在肺部生成一条水平分割线, 并将分割后的两部分肺组织分别赋予来自区间 $[0.01, 1.5]$ 的均匀分布随机数值, 来仿真基本损伤, 见图 4 右下角。左侧肺有独立的损伤概率 (30%)。更复杂的损伤虽可仿真, 但超出了本研究的范围。共进行了 4,096 次仿真用于 ACT4 训练。




图 4. 图 2 中 ACT4 实验的训练数据仿真的示意图。第一幅图像显示了健康幻影, 从中提取出“真实边界”(黑点)和“近似边界”(红星), 如第二幅图像所示。第三和第四幅图像展示了用于训练数据的样本仿真幻影, 分别包含和不包含损伤情况, 并叠加了真实边界(黑点)。

构造每个电导率幻影后, 使用包含 65,536 个三角形单元的有限元法网格求解数学上的正问题 (1), 以根据第 IV-A 节中描述的连续电极模型恢复相应的理论边界电压和电流。在测量电压上添加了方差为 10^{-4} 的相对白噪声。由此产生的模拟电压/电流用于通过第 II-A 节中描述的 D-bar 方法求解反问题, 在散射域中采用 $R = 4.5$ 的低通滤波半径, 并按照 [38] 中概述的流程, 在 $[-4.5, 4.5]^2$ 上使用均匀间隔的 64×64 个 k 和 z -网格, 步长分别为 $h_k = 0.3234$ 和 $[-1, 1]^2$, $h_z = 0.0317$ 。对于频率满足 $\mathbf{t}^{\text{exp}}(k) = 0$ 的情况, 对散射数据施加非均匀截断阈值, 若 $|\Re(\mathbf{t}^{\text{exp}}(k))|$ 或 $|\Im(\mathbf{t}^{\text{exp}}(k))|$ 超过 24,

则进行处理。随后, 将 4,096 对以“真实值”和“低通 D-bar 重构”形式的数据用于训练第 III 节中描述的卷积神经网络。

KIT 4 SAMPLE PHANTOMS



图 5. 图 3 中 KIT4 实验的训练数据仿真实例展示。所显示的图像为训练数据中包含的样本仿真结果。每个仿真中允许存在 0 至 3 个非重叠的圆形夹杂物。

KIT4 实验的训练数据以类似的方式进行了仿真。在此情况下, 模拟了 1 至 3 个圆形包含物, 其半径从 $[0.2, 0.4]$ 上的均匀分布中抽取, 中心位置在 $[0, 0.6]$ 内, 角度范围为 $[0, 2\pi]$ 。包含物不允许相互重叠, 每个包含物有相等的概率被设定为“导电”或“电阻”, 相应的电导率值分别从 $[0.05, 0.12]$ 和 $[0.005, 0.015]$ (单位: S/m) 的均匀分布中选取。背景介质的电导率从 $[0.027, 0.033]$ (单位: S/m) 中抽取。包含物的电导率范围是根据对 KIT4 电流/电压数据进行初始高通 (散射域中滤波半径较大) D-bar 重构的结果确定的。虽然我们注意到无限 (金属) 导体应具有更高的电导率, 但在此初步测试中观察到的范围已足够用于在本研究中将物体分类为导体/电阻器。需要注意的是, 此类无限导体/电阻器违反了 D-bar 理论的要求, 该理论要求包含物的电导率必须非负且远离零和无穷大。尽管如此, 该方法仍能提供有用的导体/电阻器信息。与 ACT4 示例相同, D-bar 重构中使用了相同的 k 和 z 网格。然而, 我们将散射数据的非均匀截断阈值从 24 降低至 8, 以减少因高频散射数据中的噪声导致的振荡伪影。图 5 展示了用于 KIT4 示例训练数据的样本幻影。共进行了 4,096 次仿真, 并使用“真实值”与“低通 D-bar 重构”配对来训练网络。

C. 基于实验 EIT 数据的 D-bar 重构计算说明

在第 IV-B 节中所述的模拟数据情况下, 实验的 ACT4 和 KIT4 数据的 D-bar 重构是以相同方式计算的, 唯一的区别在于 DN 矩阵 $\mathbf{L}_\sigma$ 和 $\mathbf{L}_1$ 的形成, 它们现在来自离散与连续测量。为了方便起见, 对于 ACT4 和 KIT4 数据, 我们通过基变换, 合成了若应用了 $\mathbf{L}_1$ 标准正交三角电流模式时可能发生的电流/电压测量值。

定义 t_ℓ^m 为第 m 个规范化的三角函数电流模式在第 ℓ 个电极上的值, 遵循 Isaacson 等人 [24],

$$t(\ell, m) = t_\ell^m := \begin{cases} \sqrt{\frac{2}{L}} \cos(m\theta_\ell), & m = 1, \dots, \frac{L}{2} - 1 \\ \sqrt{\frac{1}{L}} \cos(m\theta_\ell), & m = \frac{L}{2} \\ \sqrt{\frac{2}{L}} \sin((m - L/2)\theta_\ell), & m = \frac{L}{2} + 1, \dots, L - 1 \end{cases}$$

对于 $\ell = 1, \dots, L$. 这确保了电流模式矩阵是正交的, 从而允许使用 DeAngelo 和 Mueller [39] 的求解方法。也可以采用基于 Gram-Schmidt 的方法生成一组标准正交电流矩阵。相应的电压通过一个基变换矩阵来形成, 该矩阵关联了物理电流与规范化的三角函数电流。由于 ACT4 是施加电压并测量电流, 我们必须保证电流的正交性。类似地, KIT4 数据中使用的相邻电流模式并非正交, 必须进行转换。

使用 [24] 中介绍的方法, ND 矩阵 $\mathbf{R}_\sigma$ 的 (m, n) 项被构造成为离散内积

$$\mathbf{R}_\sigma(m, n) = \sum_{\ell=1}^L \frac{\phi_\ell^m v_\ell^n}{|e_\ell|}, \quad \begin{matrix} 1 \leq m, n \leq L-1 \\ 1 \leq \ell \leq L \end{matrix} \quad (9)$$

其中 ϕ^m 表示第 m 个规范化的当前模式, v^n 表示施加第 m 个电流模式所产生的电压 (规范化为电压和为零, 并按施加的电流模式的 ℓ^2 范数进行缩放), $|e_\ell|$ 表示第 ℓ 个电极的面积。该公式适用于包含 L 个电极的系统, 其中施加了 $L-1$ 个线性无关的电流模式。

离散 DN 矩阵 $\mathbf{L}_\sigma$ 随后由 $\mathbf{L}_\sigma = (\mathbf{R}_\sigma)^{-1}$ 形成并按上述方法被 $\frac{r}{\sigma_0}$ 缩放。由于散射数据 $\mathbf{t}^{\text{exp}}$ (5) 需要 DN 矩阵的差值 $(\mathbf{L}_\sigma - \mathbf{L}_1)$, 因此必须分别针对具有 $L = 32$ 和 $L = 16$ 电极的 ACT4 和 KIT4 系统形成离散 DN 矩阵 $\mathbf{L}_1$ 。为此, 电导率方程在 (1) 中被求解, using $\sigma = 1$, 边界条件由完整电极模型 [36] 给出, 该模型基于具有三角形单元 (ACT4: 4,149; KIT4: 3,493) 的有限元网格 (FEM mesh), 模拟幅值为 1mA 的注入三角电流模式以及未优化的恒定接触阻抗 ($0.00024 \Omega \cdot \text{mm}$)。

散射数据 $\mathbf{t}^{\text{exp}}$ (5) 以简单的辛普森法则近似进行评估, 参考 [39]

$$\mathbf{t}^{\text{exp}}(k) \approx \begin{cases} \frac{2\pi}{L} \left[e^{ik\bar{\mathbf{z}}} \right]^T \phi [\mathbf{L}_\sigma - \mathbf{L}_1] \mathbf{e}^\psi(k) & 0 < |k| \leq R \\ 0 & |k| > R \end{cases}$$

其中 $\mathbf{z}$ 是电极中心位置的向量, T 表示传统的矩阵转置, 以及

$$\mathbf{e}_\ell^\psi(k) := \sum_{\ell} a_j(k) \phi_\ell^j \approx e^{ikz_\ell}$$

是渐近行为 $\psi \sim e^{ikz}$ 在第 ℓ 个电极中心 z_ℓ 处的展开, 以规范化的外加电流模式 ϕ 为基。然后, d-bar 方程(6)可以利用 Vainikko 方法 [40] 通过快速傅立叶变换求解。感兴趣的读者可参考 [38] 以获取更多细节。

V. 结果

我们现在展示 Deep D-bar 方法对模拟, 以及实验, 数据用于绝对 EIT 成像的效果。

A. 模拟数据的重构

我们从 ACT4 和 KIT4 示例的纯模拟数据开始。对于 ACT4 情景, 我们考虑三种情形, 如图 6 所示: 一种与训练数据一致但未用于训练 (顶部), 以及两种违反训练数据的情形——一种是左肺中有三个水平划分的区域 (中间), 另一种是左肺中有一个垂直划分 (底部)。请注意, “低通 D-bar” 和 “深度 D-bar” 图像以相同尺度显示, 以便视觉比较。CNN 的完整 “输入” 和 “输出” 位于单位方阵 $[-1, 1]^2$ 上。此处的重构仅为了可视化目的而裁剪到圆盘内。接下来, 图 7 展示了新算法在 KIT4 示例的模拟数据上的结果。展示了三种与训练数据一致但未用于训练的情形。




图 6. 来自 ACT4 几何结构的模拟测试数据结果。第一行中的幻影符合训练数据, 第二行和第三行中的幻影包含训练数据不支持的病理情况。将初始 D-bar 图像与 Deep D-bar 图像进行比较。在完整方阵上的 D-bar 图像用作 CNN 的 “输入” 图像。此处图像仅为展示目的, 在水箱的圆形几何结构上显示。每行均使用独立的尺度进行绘制。




图 7. 基于 KIT4 几何结构的模拟测试数据结果。所有幻影均来自与训练数据相同的分布。将初始 D-bar 图像与 Deep D-bar 图像进行比较。在完整方阵上的 D-bar 图像用作 CNN 的“输入”图像。此处仅用于展示，图像在水箱的圆形几何结构上显示。每行均独立缩放绘制。

结构相似度指数 (SSIMs) 针对仿真的 ACT4 和 KIT4 样本计算结果分别如图 8 和 9 所示。此外，我们通过计算从与训练数据相同分布中抽取的 16 个样本组成的测试集的平均相对误差，评估了最小化的 ℓ^2 -损失。对于 ACT4 仿真，相对 ℓ^2 -误差由 28.05% 改进至 9.92%；对于 KIT4 测试数据，相对 ℓ^2 -误差由 16.82% 改进至 9.12%。

B. 实验数据的重构

接下来，我们进行实验数据的重构。图 10 展示了使用 *Deep D-bar* 方法对 ACT4 数据中四个实验的结果：如图 2 所示的 HEALTHY 与 INJURIES 1-3。黑色点表示从照片中提取的“健康”器官的大致边界。除了具有无限电导率（铜管）的 INJURY 3 外，其余实验重构结果均计算了 SSIM（见图 11）。SSIM 比较所用的近似“真实”图像，是通过将各区域测得的电导率值（表 I）分配到相应区域而形成的。

最后，图 12 展示了该方法在图 3 所示的四个 KIT4 场景中的结果。叠加的黑色点表示从相应照片中提取的目标的近似“真实”位置。由于物体为无限导体和电阻器，此处未计算 SSIM。关于与采用总变差先验的迭代

SSIM COMPARISON FOR ACT4 SIM. RECONS




图 8. SSIM 测量值对 ACT4 重构的模拟数据（如图 6 所示）中 D-bar 方法与新的 ‘Deep D-bar’ 方法进行了比较。

SSIM COMPARISON FOR KIT4 SIM. RECONS




图 9. SSIM 测量结果对比了 D-bar 方法与新的 ‘Deep D-bar’ 方法在 KIT4 重构中的模拟数据表现，如图 7 所示。

方法 [9] 在相同 KIT4 数据上的对比，读者可参阅文档 [34]。

VI. 讨论

图 6、7、10 和 12 中展示的重构表明，*Deep D-bar* 提供了更优的重构，在视觉和定量上均有改进。特别地，SSIM（图 8、9 和 11）显示，*Deep D-bar* 相比 *Low-pass D-bar* 的 SSIM 有显著提升。需要注意的是，在对 ACT4 损伤 2（塑料管）的 SSIM 计算中，尽管塑料管并未完全填满该区域，但“真实”图像在右肺下部区域被不切实际地设为零。

我们提醒读者，网络的训练过程中并未使用任何实验（真实值、重构）数据对，也无需对实验系统进行额




图 10. ACT4 各种测试场景的结果：健康状态、损伤 1-3 分别对应导电琼脂、塑料管和导电铜管。初始的 D-bar 图像与深度 D-bar 图像进行比较。在完整方阵上的 D-bar 图像用作 CNN 的“输入”图像。此处图像仅为展示目的，显示在水箱的圆形几何形状上。每一行均独立缩放显示。

外调整，除了系统中的电极数量外。训练完全基于模拟数据完成。在大多数应用中，通常需要进行迁移训练 [18] 或使用同一系统的黄金标准进行训练。这体现了我们方法的鲁棒性。此外，我们预计若在训练中引入更复杂的损伤情况，ACT4 重构结果将进一步提升，并提醒读者，*Low-pass D-bar* 和 *Deep D-bar* 重构结果均采用相同的值域显示，这掩盖了单个图像的真实动态范围。

我们回顾了在我们的过程中使用的额外简化：1) 我们在训练数据的边界条件中使用了连续电极模型，2) 用于形成 L_1 的有限元法 (FEM) 求解器在 ACT4 和 KIT4 实验数据示例中并未针对任一 EIT 设备进行精细调优（这对基于迭代最小化的方法是必需的），以及 3) D-bar 求解器并未针对相应的 ACT4/KIT4 数据进行优化。相反，它仅用于提供作为 CNN 输入的低通重构结果。这些简化被用来展示该方法对数据中的噪声以

SSIM COMPARISON FOR ACT4 RECONS




图 11. SSIM 测量值针对图 10 所示的 ACT4 实验数据重构结果，对 D-bar 方法和新的 ‘Deep D-bar’ 方法进行了比较。请注意，由于铜包体具有无限电导率，无法为 ‘Injury 3’ 计算有意义的 SSIM 值。

及在重构过程多个阶段的建模误差的鲁棒性。

最初的实验使用原始的 U-Net 架构，即卷积核大小为 3×3 ，结果表现不佳，因此本研究中我们增加了滤波器大小至 5×5 。这当然导致参数从 $8.6 \cdot 10^6$ 增加到 $2.4 \cdot 10^7$ ，从而增加了训练时间。由于图像尺寸相对较小，我们的训练过程中无需批量规范化，每网络的训练时间仅为 4 小时。

在 GPU 上对 CNN 的评估非常高效，平均单个样本仅需 7.65 ms，因此我们预计 Deep D-bar 具备实时处理能力。这可以通过将如 [25] 所述的 D-bar 重构与 CNN 的应用整合到统一框架中来实现，从而减少数据传输带来的开销。

A. 泛化能力

医学成像的一个重要方面是重构结果的鲁棒性和一致性。成功过渡到实验数据表明，所提出的 *Deep D-bar* 方法具备足够的鲁棒性以实现转化成像。此外，图 6 和 10 (ACT4) 展示了网络能够处理与训练数据不一致的幻影重构。然而，尽管我们能够在图 12 (幻影 2.2, KIT4) 中定位包含区域，但当仅使用圆形包含物的训练数据时，三角形目标的锐利角边界未能被恢复。初步测试表明，通过增加对三角形包含物的显著训练，这一问题可以得到改善。在 [41] 中也观察到了恢复三角形形状的挑战。在图像质量方面，我们的 Deep D-bar 方法与基于 KIT4 系统的类似数据的（较慢的）迭代方法结果




图 12. 各类幻影 (包含导电和/或电阻性目标) 的 KIT4 结果, 如第一列所示。初始 D-bar 图像与深度 D-bar 图像进行比较。在完整方阵上的 D-bar 图像用作 CNN 的“输入”图像。此处图像仅用于展示, 显示在水箱的圆形几何结构上。每行均独立缩放绘制。

相当, 见 [9], [34], [41]。此外, 由于我们在模拟 ACT4 损伤时采用的是简单模型 (仅使用水平分割线而非真实的对角切割和不完全的区域替换), 我们预计若引入更复杂的损伤情况, 重构效果将进一步提升。对于人体目标, 可采用更大规模的训练数据数据库, 该数据库可基于解剖学图谱或包含正常与异常/损伤情况的 CT/MR 扫描集合构建。

后处理网络成功的关键在于输入重构的一致性。为了提高网络的灵活性, 可以在不同截断半径的散射数据重构上训练网络。这使得用户可以根据当前测量数据的质量来决定截断半径, 并根据需要调整输入网络的重构。初步测试表明, 该方法确实提高了重构的一致性和稳定性, 如图 13 所示, 我们使用不同截断半径训练了 ACT4 网络 $R \in [4, 5]$ 。尽管 SSIM 保持一致, 但新引入可变半径网络后, 损伤的定位和恢复电导率均得到改

善。

尽管本研究选择将 D-bar 与 CNNs 匹配, 这是由于 D-bar 在绝对成像和时差成像中具有鲁棒性, 且 D-bar 重构结果具有卷积特性, 但也可使用其他重构方法作为输入图像的重构手段。




图 13. 对两种不同 CNN 的 ACT4 ‘Injury 1’ (肺部导电琼脂) 数据集结果的比较。‘旧’网络表示使用固定散射数据截止半径训练的网络 ($R = 4.5$), 而‘新’网络则使用变化的截止半径 (在区间 $[4, 5]$ 内随机化)。将原始固定半径 $R = 4.5$ 网络的结果与新网络中使用 $R = 4$ 和 $R = 4.5$ 输入图像的结果进行对比。SSIM 值保持一致: 从左到右分别为 0.6405、0.6397 和 0.6459。

VII. 结论 s

二维电阻断层成像 (EIT) 的 D-bar 方法能够提供可靠的电导率重构, 但其由于散射数据的低通滤波导致图像模糊。通过将 D-bar 重构方法与卷积神经网络 (CNN) 相结合, 可以显著提升绝对 EIT 图像的质量。我们证明了仅使用模拟数据训练的 CNN 能够有效学习去模糊过程, 并且在不包含任何实验数据参与训练的情况下仍能成功应用于实验数据。由于训练可在事前离线完成, 而 D-bar 方法可实现实时电导率重构 [25], 因此经训练的 CNN 进行后处理步骤对整体图像恢复过程增加的时间极少, 这得益于在 GPU 上的高效计算。尽管本工作展示的是二维情况, 但我们预期该方法在 D-bar 计算框架进一步完善后可推广至三维。

致谢

我们衷心感谢英伟达公司捐赠的 Titan Xp GPU, 为本研究提供了支持。作者感谢剑桥大学牛顿数学科学研究所对本次论文工作的支持与接待, 该工作是在“成像与视觉的变分方法及有效算法”项目期间完成的, 项目得到 EPSRC 资助, 编号为 EP/K032208/1。AH 感谢 EPSRC 项目 EP/M020533/1 (“面向下一代医疗技术的医学图像计算”) 的支持。此外, 我们还感谢伦敦斯勒理工学院的 EIT 团队。² 感谢他们的协助以及提供 ACT4 水箱的数据。

²<https://www.ecse.rpi.edu/homepages/saulnier/eit/eit.html>

参考文献

- [1] Gilda Cinnella, Salvatore Grasso, Pasquale Raimondo, Davide D'Antini, Lucia Mirabella, Michela Rauso, and Michele Dambrosio. Physiological effects of the open lung approach in patients with early, mild, diffuse acute respiratory distress syndrome: an electrical impedance tomography study. *The Journal of the American Society of Anesthesiologists*, 123(5):1113–1121, 2015.
- [2] C.A. Grant, T. Pham, J. Hough, T. Riedel, C. Stocker, and A. Schibler. Measurement of ventilation and cardiac related impedance changes with electrical impedance tomography. *Critical Care*, 15(1):R37, 2011.
- [3] Christian Karagiannidis, Andreas D. Waldmann, Carlos Fernando Ortolá, Manuel Muñoz Martínez, Anxela Vidal, Arnoldo Santos, Peter L. Róka, Manuel Pérez Márquez, Stephan H. Bohm, and Fernando Suarez-Spimann. Position-dependent distribution of ventilation measured with electrical impedance tomography. *European Respiratory Journal*, 46(suppl 59), 2015.
- [4] Antonio Pesenti, Guido Musch, Daniel Lichtenstein, Francesco Mojoli, Marcelo B. P. Amato, Gilda Cinnella, Luciano Gattinoni, and Michael Quintel. Imaging in acute respiratory distress syndrome. *Intensive Care Medicine*, 42(5):686–698, 2016.
- [5] H. Reinius, J. B. Borges, F. Fredén, L. Jideus, E. D. L. B. Camargo, M. B. P. Amato, G. Hedenstierna, Larsson A., and F. Lennmyr. Real-time ventilation and perfusion distributions by electrical impedance tomography during one-lung ventilation with capnotherax. *Acta Anaesthesiologica Scandinavica*, 59(3):354–368, 2015.
- [6] A. Schibler, T.M.Y. Pham, A.A. Moray, and C. Stocker. Ventilation and cardiac related impedance changes in children undergoing corrective open heart surgery. *Physiological Measurement*, 34:1319–1327, 2013.
- [7] K. Knudsen, M. Lassas, J.L. Mueller, and S. Siltanen. Regularized D-bar method for the inverse conductivity problem. *Inverse Problems and Imaging*, 3(4):599–624, 2009.
- [8] Zhou Zhou, Gustavo Sato dos Santos, Thomas Dowrick, James Avery, Zhaolin Sun, Hui Xu, and David S Holder. Comparison of total variation algorithms for electrical impedance tomography. *Physiological measurement*, 36(6):1193, 2015.
- [9] Gerardo González, Ville Kolehmainen, and Aku Seppänen. Isotropic and anisotropic total variation regularization in electrical impedance tomography. *Computers & Mathematics with Applications*, 2017.
- [10] Jérémie Dardé, N Hyvönen, A Seppänen, and Stratos Staboulis. Simultaneous reconstruction of outer boundary shape and admittivity distribution in electrical impedance tomography. *SIAM Journal on Imaging Sciences*, 6(1):176–198, 2013.
- [11] A. Nissinen, V. Kolehmainen, and J. P. Kaipio. Compensation of modelling errors due to unknown domain boundary in electrical impedance tomography. *IEEE Transaction on Medical Imaging*, 30(2):231–242, 2011.
- [12] E. K. Murphy and J. L. Mueller. Effect of domain-shape modeling and measurement errors on the 2-d D-bar method for electrical impedance tomography. *IEEE Transactions on Medical Imaging*, 28(10):1576–1584, 2009.
- [13] V. Kolehmainen, M. Lassas, and P. Ola. Electrical impedance tomography problem with inaccurately known boundary and contact impedances. *Medical Imaging, IEEE Transactions on*, 27(10):1404–1414, oct. 2008.
- [14] Kyong Hwan Jin, Michael T McCann, Emmanuel Froustey, and Michael Unser. Deep convolutional neural network for inverse problems in imaging. *IEEE Transactions on Image Processing*, 26(9):4509–4522, 2017.
- [15] Eunhee Kang, Junhong Min, and Jong Chul Ye. A deep convolutional neural network using directional wavelets for low-dose x-ray ct reconstruction. *Medical Physics*, 44(10), 2017.
- [16] Christopher M Sandino, Neerav Dixit, Joseph Y Cheng, and Shreyas S Vasanawala. Deep convolutional neural networks for accelerated dynamic magnetic resonance imaging. In *NIPS 2017, Medical Imaging Meets NIPS Workshop.*, 2017.
- [17] Stephan Antholzer, Markus Haltmeier, and Johannes Schwab. Deep learning for photoacoustic tomography from sparse data. *arXiv preprint arXiv:1704.04587*, 2017.
- [18] A. Hauptmann, F. Lucka, M. Betcke, N. Huynh, J. Adler, B. Cox, P. Beard, S. Ourselin, and S. Arridge. Model based learning for accelerated, limited-view 3d photoacoustic tomography. *IEEE Transactions on Medical Imaging*, 2018.
- [19] Jonas Adler and Ozan Öktem. Solving ill-posed inverse problems using iterative deep neural networks. *Inverse Problems*, 33(12):124007, 2017.
- [20] Fabrice Delbary, Per Christian Hansen, and Kim Knudsen. Electrical impedance tomography: 3d reconstructions using scattering transforms. *Applicable Analysis*, 91(4):737–755, 2012.
- [21] A. I. Nachman. Global uniqueness for a two-dimensional inverse boundary value problem. *Annals of Mathematics*, 143:71–96, 1996.
- [22] Richard Beals and Ronald R. Coifman. Multidimensional inverse scatterings and nonlinear partial differential equations. In *Pseudodifferential operators and applications (Notre Dame, Ind., 1984)*, pages 45–70. Amer. Math. Soc., Providence, RI, 1985.
- [23] G. Alessandrini. Stable determination of conductivity by boundary measurements. *Applicable Analysis*, 27:153–172, 1988.
- [24] D. Isaacson, J. L. Mueller, J. C. Newell, and S. Siltanen. Reconstructions of chest phantoms by the D-bar method for electrical impedance tomography. *IEEE Transactions on Medical Imaging*, 23:821–828, 2004.
- [25] Melody Dodd and Jennifer L Mueller. A real-time D-bar algorithm for 2-D electrical impedance tomography data. *Inverse problems and imaging*, 8(4):1013–1031, 2014.
- [26] S. J. Hamilton, J. L. Mueller, and T. R. Santos. Robust computation of 2d EIT absolute images with d-bar methods. (under review, arXiv preprint: 1712.00379).
- [27] Gennadi Henkin and Matteo Santacesaria. On an inverse problem for anisotropic conductivity in the plane. *Inverse Problems*, 26(9):095011, 2010.
- [28] S. J. Hamilton, M. Lassas, and S. Siltanen. A Direct Reconstruction Method for Anisotropic Electrical Impedance Tomography. *Inverse Problems*, 30:(075007), 2014.
- [29] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 234–241. Springer, 2015.
- [30] Sébastien Martin and Charles TM Choi. A post-processing method for three-dimensional electrical impedance tomography. *Scientific Reports*, 7, 2017.

- [31] Thomas Wiatowski and Helmut Bölcskei. A mathematical theory of deep convolutional neural networks for feature extraction. *IEEE Transactions on Information Theory*, 2017.
- [32] N. Liu, G.J. Saulnier, J.C. Newell, D. Isaacson, and T.-J. Kao. Act4: a high-precision, multi-frequency electrical impedance tomograph. Presented at 6th Conference on Biomedical Applications of Electrical Impedance Tomography, June 2005. London, U.K.
- [33] G. Saulnier, N. Liu, C. P. Tamma, H. Xia, T.-J. Kao, J. Newell, and D. Isaacson. An electrical impedance spectroscopy system for breast cancer detection. *Proc. 29th Int. Conf. IEEE Eng. Med. Biol. Soc.*, (1):4154–4157, Aug. 2007.
- [34] Andreas Hauptmann, Ville Kolehmainen, Nguyet Minh Mach, Tuomo Savolainen, Aku Seppänen, and Samuli Siltanen. Open 2d Electrical Impedance Tomography data archive. *arXiv:1704.01178*, 2017.
- [35] Andreas Hauptmann. Approximation of full-boundary data from partial-boundary electrode measurements. *Inverse Problems (accepted)*, *arXiv preprint arXiv:1703.05550*, 2017.
- [36] Erkki Somersalo, Margaret Cheney, and David Isaacson. Existence and uniqueness for electrode models for electric current computed tomography. *SIAM Journal on Applied Mathematics*, 52(4):1023–1040, 1992.
- [37] N. Hyvönen. Approximating idealized boundary data of electric impedance tomography by electrode measurements. *Mathematical Models and Methods in Applied Sciences*, 19(07):1185–1202, 2009.
- [38] J. Mueller and S. Siltanen. *Linear and Nonlinear Inverse Problems with Practical Applications*, volume 10 of *Computational Science and Engineering*. SIAM, 2012.
- [39] M. DeAngelo and J. L. Mueller. 2d D-bar reconstructions of human chest and tank data using an improved approximation to the scattering transform. *Physiological Measurement*, 31:221–232, 2010.
- [40] Gennadi Vainikko. Fast solvers of the Lippmann-Schwinger equation. In *Direct and inverse problems of mathematical physics (Newark, DE, 1997)*, volume 5 of *Int. Soc. Anal. Appl. Comput.*, pages 423–440. Kluwer Acad. Publ., Dordrecht, 2000.
- [41] D. Liu, A. K. Khambampati, and J. Du. A parametric level set method for electrical impedance tomography. *IEEE Transactions on Medical Imaging*, 37(2):451–460, Feb 2018.