

学校代码 10345

研究类型 综合研究



浙江师范大学
ZHEJIANG NORMAL UNIVERSITY

硕士专业学位论文

题 目: 面向电阻抗成像技术的深度神经网络算法研究

专业学位类别: 工程硕士

学 科 领 域: 软件工程

年 级: 2020 级 学 号: 202025201068

研 究 生: 石淇皓 指导教师: 温建明

中图分类号: TP311.5 论文提交时间: 2023 年 6 月 15 日

面向电阻抗成像技术的深度神经网络算法研究

DEEP NEURAL NETWORK ALGORITHM
FOR ELECTRICAL IMPEDANCE TOMOGRAPHY

作者姓名	石淇皓
Author	QiHao Shi
学科专业	软件工程
Subject	Software
指导教师	温建明
Supervisor	JianMing Wen
学位类别	工程硕士
Degree	Master of Engineering
学位授予单位	浙江师范大学
Degree Unit	Zhejiang Normal University

面向电阻抗成像技术的深度神经网络算法研究

摘 要

电阻抗断层成像技术 (Electrical Impedance Tomography, EIT) 是一项新兴的非侵入式医疗成像技术, 相较于传统成像系统而言, 它具备构造简单、生产成本低、无辐射等优势, 近几年来在国内外都受到广泛关注, 是当今生物医学成像技术研究的热点课题。但 EIT 重建的过程, 涉及到严重病态和复杂不确定性的逆问题, 在传统重建算法中, 需要很高的运算成本。为了能够解决当前存在的问题, 并且提升成像质量, 本文提出了面向电阻抗成像技术的深度神经网络模型 SAE-LR, 以及加入后处理模块优化的模型 SL-W, 它们将深度神经网络的方法与传统 EIT 成像技术相结合, 能够有效地提高图像精度, 同时也能够降低运算成本。该方法利用深度神经网络强大的非线性拟合能力, 可以对电阻抗分布进行有效重构。

本文的主要研究内容如下:

(1) 求解 EIT 的正问题, 利用有限元法模拟 EIT 正问题仿真, 并制作试验数据集。本文设定了三种不同数量和三种不同形状的目标物体, 并通过有限元仿真计算, 对 EIT 正问题进行求解, 收集边界电压数据, 记录电导率分布并使二者一一对应, 从而构建数据集。

(2) 设计并改进了一个堆栈式自编码器(Stacked Auto Encoder, SAE)与逻辑回归(logistic Regression)模型相结合的深度神经网络结构, 用于 EIT 图像的重建。它能够通过深度神经网络强大的学习能力, 建立边界电压差与电阻抗分布之间的映射关系, 在其训练后, 设计实验进行优化调参, 使其能够一定程度的拟合电阻抗成像的逆问题, 本文将其称之为 SAE-LR 模型。

(3) 基于电阻抗断层成像的实验系统, 改进了一种生成式对抗网络(Generative Adversarial Network, GAN), 用于优化 SAE-LR 的成像能力, 使其与 SAE-LR 部分结

合，进而得到面向电阻抗成像技术的深度神经网络模型 SL-W。

(4) 设计并通过仿真试验和实测试验，从多个角度对 SAE-LR 以及 SL-W 方法与传统的 GVSPM 算法、ANN 等方式的图像重建效果进行比较。试验结果表明，在图像重建方面，智能重建算法要优于传统算法，它们能够更准确、更快速的完成图像重建任务。基于仿真和实测试验数据，通过比较 SAE-LR、SL-W、ANN 和传统 GVSPM 四种算法的重建结果，SAE-LR 算法重建的图像中，伪影出现的概率显著减少，并且在目标物体的大小、位置以及电导率分布的重建结果上也表现出显著的提升。与传统 GVSPM 算法相比较，它的相对标准差 (RSD) 平均减少了 40.11%，位置误差 (PE) 平均降低了 44.17%，均方误差 (MSE) 相对减少了 99.42%，而 SL-W 方法则能够在 SAE-LR 方法原有的良好基础上进一步提升图像重建质量，三项评判指标相对 GVSPM 分别减少了 46.48%、48.12%、99.47%。

关键词：电阻抗断层成像；医学图像重建；图像质量控制；深度学习；神经网络

DEEP NEURAL NETWORK ALGORITHM FOR ELECTRICAL IMPEDANCE TOMOGRAPHY

ABSTRACT

Electrical Impedance Tomography (EIT) is a new non-invasive medical imaging technology. Compared with the traditional imaging system, it has the advantages of simple construction, low production cost and no radiation. In recent years, it has been widely concerned at home and abroad. It is a hot topic in biomedical imaging research. However, the process of EIT reconstruction, which involves the inverse problem of severe pathology, requires high computing cost in the traditional reconstruction algorithm. In order to solve this problem and improve imaging accuracy and operation speed, this thesis proposes the deep neural network model SAE-LR, which is oriented to electrical impedance imaging technology, and the model SL-W, which is optimized with post-processing module. They combine the deep neural network method with the traditional EIT imaging technology, which can effectively improve the image accuracy. It also reduces computing costs. This method can effectively reconstruct electrical impedance distribution by virtue of the excellent nonlinear fitting ability of neural network.

The main contents of this thesis are as follows:

(1) The Electrical Impedance Tomography positive problem is simulated by the finite element method, i.e., the EIT positive problem simulation is performed. We set up target features of various sizes, dimensions and shapes and solve the EIT positive problem by simulation to calculate their boundary voltage data to construct the data set required for training the neural network.

(2) A deep neural network model combining Stacked Auto Encoder (SAE) and logistic regression (LR) model is designed and improved for the reconstruction of EIT

images. It is able to establish the connection between the boundary voltage difference and impedance distribution through the neural network, and after the training and tuning of the network, it enables the deep neural network to fit the inverse problem of electrical impedance imaging, which we call the SAE-LR model.

(3) An experimental system based on electrical impedance tomography improves a Generative Adversarial Network with Wasserstein distance and gradient penalty (WGAN-gp) for Optimize the imaging capability of SAE-LR. By combining it with SAE-LR, a deep neural network model SL-W for electrical impedance imaging can be obtained. Through adversarial training between the generator and discriminator, the post-processed impedance distribution can be made closer to the actual situation, which can reduce the error and artifact of EIT image reconstruction results and improve the reconstruction efficiency.

(4) Through simulation and actual test, the image reconstruction effects of SAE-LR and SL-W methods, traditional GVSPM algorithm and ANN methods are compared from multiple perspectives. The experimental results show that in terms of image reconstruction, the intelligent reconstruction algorithm is better than the traditional algorithm, and they can complete the image reconstruction task more accurately and more quickly. Based on the simulation and measured test data, by comparing the reconstruction results of SAE-LR, SL-W, ANN and traditional GVSPM algorithms, the probability of artifact occurrence in the image reconstructed by SAE-LR algorithm is significantly reduced, and the reconstruction results of the size, location and conductivity distribution of the target object are also significantly improved. Compared with the traditional GVSPM algorithm, the relative standard deviation (RSD), position error (PE) and mean square error (MSE) are reduced by 40.11% on average, 44.17% on average and 99.42% respectively. The SL-W method can further improve the image reconstruction quality on the basis of the original good SAE-LR method, and the three evaluation indexes are reduced by 46.48%, 48.12% and 99.47% respectively compared with GVSPM.

KEY WORDS: electrical impedance tomography; medical image reconstruction technology; Image quality control technology; deep learning; neural network

目 录

第 1 章 绪论.....	1
1.1 电阻抗成像技术综述.....	1
1.2 电阻抗成像技术国内外研究现状	4
1.3 本课题主要研究内容.....	8
1.4 本文章节安排.....	9
第 2 章 电阻抗成像技术理论基础	11
2.1 电阻抗敏感场数学描述.....	11
2.2 电阻抗成像正问题.....	13
2.3 电阻抗成像逆问题.....	14
2.4 EIT 图像的非智能重建算法	15
2.4.1 线性反投影算法.....	16
2.4.2 Tikhonov 正则化算法	16
2.4.3 GVSPM 算法	16
2.5 EIT 图像的智能重建算法	18
2.5.1 支持向量机.....	18
2.5.2 粒子群算法.....	18
2.5.3 人工神经网络.....	18
2.6 小结.....	26
第 3 章 面向电阻抗成像技术的深度神经网络模型构建	27
3.1 构建 EIT 图像重建映射模型	27
3.2 生成数据集.....	27
3.2.1 有限元区域设置及目标物体.....	28
3.2.2 数据预处理.....	31
3.3 构建面向电阻抗成像技术的深度神经网络模型	31
3.3.1 堆栈式自编码器与逻辑回归.....	32
3.3.2 WGAN-gp	34
3.4 优化神经网络模型.....	42
3.4.1 学习率分析.....	43
3.4.2 堆栈式自编码器模块的网络层数分析	44
3.4.3 逻辑回归模块的网络层数分析.....	46
3.5 评判指标.....	47
3.5.1 相对标准差.....	47
3.5.2 均方误差.....	48
3.5.3 位置误差.....	48

3.6 仿真试验.....	48
3.6.1 仿真试验的图像重建结果分析.....	49
3.6.2 仿真试验的评判指标结果分析.....	56
3.7 小结.....	60
第4章 试验研究与分析	61
4.1 试验条件.....	61
4.2 试验结果与分析.....	62
4.3 小结.....	68
第5章 结论与展望	69
5.1 结论.....	69
5.2 研究展望.....	70
参考文献.....	72

第 1 章 绪论

随着我国社会的现代化进程不断发展，平均寿命的不断增长、出生率的不断下降以及人们对健康的关注度日益增加等各种社会现象和状况出现，现代社会迫切需要一个更加便捷、更加精准、更加完善的医疗体系。近年来，国内外科学研究人员们对人工智能领域的研究如火如荼，伴随着研究成果的不断涌现，智能元素也正被应用于普通百姓生活的各个领域之中，供普通人了解、接触和使用。

在我国新医改的大背景下，随着政策的推进和科技的发展，医疗系统的智慧化正在走进普通人的生活中^[1]。可以预见的是，在不久的将来，医疗行业将与传感技术、深度监测、人工智能等更多前沿技术相融合，实现医疗服务领域的智能化^[2]，为我国医疗事业的繁荣发展做出有力贡献。

因此，如何将科研成果和新兴技术越来越合适地应用于医学领域，从而最大限度地提升医务人员对于病患疾病的诊断能力，是广大科研人员们关注的焦点。

1.1 电阻抗成像技术综述

医学影像是用于医疗诊断的监测、成像手段，它通过一些特殊介质（例如超声波、电磁场、X 光等）与人体接触^[3]，以取得患者机体内部组织、器官的病症信息，最后以图像的形式呈现。医疗人员可以依据医学影像提供的医学信息，来对病患的病症进行更细致、更加准确的诊断，下图 1.1 为部分传统医学成像设备。



图 1.1 部分传统医学影像设备（从左到右依次为 X-ray、超声、核磁共振）

然而传统的成像技术，大多存在一些不可忽视的缺陷。例如辐射大伪影多、造价昂贵、操作复杂等^[4]。人们需要一种无创、便捷、响应迅速、实时监测的成像手段，使得病患群体具有更多、更合适的医疗监测手段可供选择。

电阻抗断层成像技术^[5] (Electrical Impedance Tomography, EIT) 作为兴起不久的无损功能成像技术, 为科学研究和医学应用提供了新的思路和方法。EIT 技术通过对不同介质的电导率进行计算, 给被测场域施加电流或电压刺激, 再通过电学特性推导出被测场域内的电导率分布信息^[6], 进而推断其在该被测场域内的分布。电阻抗断层成像有电压激励、电流测量与电流激励、电压测量两种工作方式, 目前的研究中一般使用电流激励、电压测量。电导率分布发生变化, 就会引起被测场域内电流场的变化, 电势分布随之的改变, 最终影响信号传播到被测场域边界的电压, 使其产生变化^[7]。即通过测量边界电压, 可以间接得到被测场域内在电导率的变化信息。电阻抗断层成像技术的本质, 就是利用特定的图像重建算法, 从被测物场的边界电压中推断出该域内的电导率分布, 从而反映出该被测场域的特性^[8]。

人体各组织器官之间的阻抗特性本身存在一定程度的差异, 在某些组织病变后, 阻抗特性也会发生相应的变化^[9]。表格 1.1 为人体内部分组织在直流电下测得的电导率, 通过分析这些信息, 我们可以推断出人体组织、器官的基本状态。换句话说, 如果能够收集到人体组织器官内部的阻抗分布信息, 实际上就可以推测出人体组织、器官的生理信息。EIT 技术就是利用这一特性, 通过监测生物体内某些组织、器官的电阻抗值随生物活动的变化^[10], 来评估组织、器官的状态, 这种方法不仅对人体无害^[11], 而且成本低廉。

表 1.1 直流电下部分人体组织的电导率

Table1.1 Conductivity of human tissues with DC power

组织器官	电导率 (S/m)
骨骼	0.01-0.06
脂肪	0.02-0.04
肺	0.024-0.09
心脏	0.06-0.4
肿瘤	0.22-0.4
肌肉	0.3-0.8

EIT 控制系统的原理如图 1.2 所示。一个完整的 EIT 成像系统通常由 3 个部分组成, 电极阵列、数据信息采集与处理过程、图像重构^[12]。




图 1.2 EIT 系统原理图

其中，电极阵列通过产生正弦电压、电流等场域外部激励，从而在被测场域内产生某个敏感场^[13]，并通过改变测量条件，使得该敏感场内部电导率分布发生变化，从而使得测量电极阵列输出相应的控制信息^[14]。

数据信息采集与处理过程的部分，其主要功能是收集电极阵列的输出信号，这些输出信号反映了被测场域内部的电导率分布，对收集到的电极阵列输出信号进行数据处理后，得到表达了被测场域内部变化信息的测量数据^[15]。

图像重构部分则是根据某种特定的图像重建算法，利用采集、处理被测物场内在电导率的信息，对被测场域内部的进行断层图像，并将其直观的显示在终端上，从而获取被测场域发生变化的相关特征信息^[16]。此外，还可以更直观地分析被测物场的电导率分布特征信息，图 1.3 展示了 EIT 成像的过程。




图 1.3 EIT 成像过程

EIT 技术与传统的结构成像技术相比, 具有显著的优势, 详细情况如下:

(1) 非侵入性。EIT 在成像的过程中, 系统设备(例如电极阵列等)不与被测物体直接接触, 不会对测量目标的结构产生任何影响, 在此基础上, 仍能够提取出被测物体内部的信息。

(2) 实时性。EIT 系统具有出色的成像速度和实时性, 即可以实现对被测物场的长期、连续、动态的监测^[17], 从而提高工作效率。这也是 EIT 最具竞争力的优势之一。

(3) 设备简单, 易携带, 成本低廉。EIT 硬件系统是一种简单、易携带的设备, 它主要由计算机、信号发生器件和数据采集装置组成。与其他的医学成像技术相比较, EIT 硬件系统的尺寸更小, 生产成本更低, 更容易制作成便携式的设备, 可以应用于多种场合、多种情况。

(4) 属于功能性成像而且无需进行辐射。在生物医学上, 生命体内组织、器官的电阻抗会因为生理功能的转变或是组织脏器的损害、病变而发生变化, 然而 EIT 技术可以利用这一点, 精确地反应出人体组织、器官的健康状况^[18], 因此, 对于某些疾病症状的早期诊断方面, 它有着得天独厚的优势^[19]。与此同时, 由于施加在患者身体上的电流激励是低频的微弱电流^[20], 因此, 在不会给身体带来任何辐射危害和安全隐患的情况下, 仍然可以有效地获取身体内部器官、组织的病理信息^[21]。


基于上述优点, EIT 系统因其出色的性能和独特的优势, 已经被广泛应用于海洋工程、生物医疗、工业生产流程和地质学勘查等多个领域^[22]。

1.2 电阻抗成像技术国内外研究现状

EIT 技术最早可以追溯到二十世纪三十年代, 那时电阻抗断层成像技术开始被应用于地质学研究与分析。当时, 研究人员将电极伸入地壳内部, 利用注入电流的方法来测定地壳的边界电压, 并利用这些信息来推算地下物体的阻抗分布, 从中得到矿物质分布情况, 这也是电阻抗成像技术的雏形。

1976 年, 美国 Wisconsin 大学的 Henderson R.P、Webster J.G 以及 Swanson D.K 首次提出了电阻抗成像技术^[23], 并设计了阻抗成像的实验装置, 在 1978 年重建出了第一幅人体胸腔的电阻抗图像, 图像可以清晰地显示人体胸腔中, 肺脏的位置。这标

标志着 EIT 系统硬件的发展正式开始。1984 年, D.C.BarBer 和 B.H.Brown 教授在英国 Sheffield 大学, 采用等位线反投影的方法完成了对人体手臂的电阻抗断层成像实验^[24], 这不仅真正意义上获得了生物体组织的电阻抗断层成像图, 更标志着电阻抗成像技术的研究进入了一个崭新的阶段, 他们的研究成果也正式掀起了 EIT 研究的热潮。不久之后的 1987 年, D.C Barber 和 B.H Brown 教授设计开发出了一台单频激励的、四路复用器的 EIT 系统 Mark 1^[25], 在当时它具有卓越的性能和可靠性。在 1988 年, Rose II 提出了三种可行的使用电阻抗技术成像的数据采集系统。1989 年, Griffiths 和 Zhang 给出了一种全新的双频成像系统, 它能够在 40.96kHz 和 81.92kHz 频段下运行, 这一发现为电阻抗成像技术的实际应用提供了新的思路和方法^[26]。



a) 弗莱堡大学双腔管位置监测

b) 亚琛工业大学肺部成像实验

图 1.4 国外 EIT 技术部分研究成果

2001 年, Sheffield 大学 D.C Barber 和 B.H Brown 教授研制的单频 EIT 系统已经升级为多频激励的 EIT 系统, Mark 3.5。2005 年, 美国 Rensselaer Polytechnic Institute 基于 ACT3 系统, 研发了可以实现二维三维成像的 72 通道系统^[27], 即 ACT4。2010 年左右, 德国弗莱堡大学和亚琛工业大学分别进行了双腔管位置观测实验和人体肺部成像实验, 在成像质量上获得了较大的提高^[28]。韩国分别在 2011 年和 2015 年研发出可以用于呼吸、心脏的生理变化快速检测的 EIT 系统和便携式的、实时监测的肺通气监测系统, 应用于临床试验中。

由于 EIT 技术的蓬勃发展, 许多优秀的 EIT 图像重建算法也不断涌现。1985 年, 来自日本的科学家 Murai 及其团队在灵敏度理论基础上, 提出了灵敏度系数算法, 它是一种基于有限元模型的电阻抗成像算法, 它可以利用有限元的方法去处理 EIT 的正

问题，并且取得了良好的效果。在 1987 年，Yorkey 和 Webster 根据牛顿—拉夫逊算法对其做出了改良，并采用 Marquardt 方法来去除病态矩阵中的一些固有误差，从而较大程度地提高了计算效率和准确度。在 1991 年，Somersalo 团队提出了一种用于近似场域内部电导率分布的数值求解法，称之为层剥法。1992 年，E.J 和 WooP Hua 等人利用奇异值分解操作，在获得最优电流模式的基础上计算电阻率。在 1997 年，Jain 和 Isaacson 提出了一个新的迭代方法，可以有效地处理复杂形态物体的图像重构，他们采用边界元法来模拟非圆形边界区域内的非均匀电导率分布。

2004 年，Kyung Youn Kim 提出了一种自适应网格的划分方案，大大提高了高斯牛顿法在空间分辨率方面的表现，并通过处理边界电流和电压数据，重建出物体截面的电导率分布情况。2006 年，Mueller 团队提出了 D-bar 算法，这种算法根据二维逆问题的全局唯一性，把对非线性的逆问题的求解转化为对两个线性的积分方程求解，并以此实现了胸腔的 EIT 图像重构。在 2011 年，C. Jin 和 van Schaik 在 EIT 图像重构过程中应用了 L1 范数的正则化方式，取得了较为显著的效果，提高了重构的效率和准确性。

由于科学技术发展的限制，我国在 EIT 图像领域的研究起步较晚。二十世纪 80 年代，清华大学率先组建了 EIT 的科研队伍，而如今，第四军医大学、河北工业大学、中国医学科学院、电子科技大学、天津理工大学、重庆大学、南京航空航天大学等越来越多的高校、科研机构也纷纷开始组建团队，共同推动国内 EIT 技术的发展。迄今为止，许多国内的研究团队也都已经成功搭建出属于自己的 EIT 系统和相对应的实验平台，并且在图像重建算法、硬件设备甚至是临床应用等方面都有了令人振奋的研究成果。

在 2002 年，重庆大学的田海燕首次提出了 4 种可用作 EIT 图像重构的算法，并将其应用于脑血肿患者的监测阶段，以此开展了模拟分析与仿真研究。除此之外，第四军医大学与重庆大学联合开发的高精度 EIT 实验平台，为 EIT 技术在医学成像临床试验中的应用奠定了基础。2008 年，河北工业大学的秦转萍进一步探究了 EIT 正问题的计算模式，采用边界元法和有限元法，构建了动脉血管的三维空间建模，并开展了仿真运算，获得了令人满意的成果。2015 年，涂戈团队开发了一个采用盐水槽作为测量物场的电阻抗数据采集系统，物场周围置放 16 个电极，提高了成像质量。此

外，天津大学与天津工业大学联合开发的 MEIT_TJPU 已经可以实现检测人体肺部呼吸过程的电阻抗成像，系统达到国际先进水平。2016 年，天津科技大学的陈晓艳等人利用神经网络的方法对 EIT 成像技术进行了研究，并取得了一定的进展^[29]。2018 年李佳，岳士弘等人通过胸腔器官分布结构,对肺部癌变组织进行了 EIT 的图像重建，改善了癌变组织成像的质量,降低了图像相对误差^[30]。2021 年，南京邮电大学的戎舟等人基于多层人工神经网络的方法，对 EIT 成像技术进行了进一步的研究，提高了成像质量^[31]。2022 年，Wang Na 等人对电阻抗断层扫描和超声评估的两种肺部合并区域通气灌注模式进行了探究，在此过程中取得了一定的进展。同年，Virsilas Ernestas 等人通过电阻抗成像的方式研究无创呼吸支持类型之间关于叹气频率的差异，并评估叹气前后的区域通气分布、 ΔZ 和呼气末肺阻抗差异。2023 年，Tuffet Samuel 等人利用 EIT 技术对肺内通气、灌注(V/Q)的不匹配情况进行了研究。并提出了相应的解决办法。同年，Rifai Isnain Nur 以及其团队成员通过带有空间电压阈值（SVT）的方波开放式电阻抗断层扫描（SW-oEIT）对真皮层的钠浓度进行了成像。




图 1.5 国内 EIT 技术部分研究成果

由于计算机科学技术的发展，尤其是机器学习领域的兴起，越来越多的 EIT 研究人员们纷纷试图将其应用于 EIT 技术的发展中，并获得了效果优异的重建图像。1994 年，Adler 等人首次提出利用神经网络的思想对电阻抗数据进行图像重构，但他们提出的神经网络结构并不能解决逆问题的病态性。直到 1999 年，Lampinen 等人提出基于 Bayesian 神经网络对 EIT 的逆问题进行求解的思路，通过主成分投影法分解图像

的重建过程,使其成为低维度表示,再利用 Bayesian 神经网络学习其数据特征,从而得到较为准确的电导率的分布。2005 年, Ho-Chan Kim 团队提出使用模拟退火方法来提高 EIT 重建图像的空间分辨率。2006 年,武优西利用支持向量机法求解了 EIT 的正逆问题。2009 年,汪鹏等人提出了一个采用改进粒子群算法的重建方法,它不仅可以有效地解决 BP 算法收敛迟缓和易于进入局部极值的问题,而且还可以更好地提高 EIT 技术的性能和准确性。2010 年, S.Pravin Kumar 等人提出了一种基于粒子群优化的方法,对 EIT 逆问题进行求解效果良好并以此重建了人脑电导率分布图像。2013 年, Hui Zhang 等人将修改后的粒子群算法与修改后的 Newton-Raphson 法结合起来,准确地反映了电导率的分布。在 2018 年, Xosé Fernández 和 David Mera 等人利用机器学习技术设计了一个即时重构阻力抗分布的精细计算,与牛顿法和偶极点法相比,该算法具有更高的定性和定量精度,可以有效地替代更繁杂、计算更慢的算法。在 2019 年, Tan Chao 等人首次提出了一个采用卷积神经网络的阻力抗图像重建技术,利用数值模拟技术生成训练数据,并且进行了抗噪和泛化测试,结果表明,这种技术比传统方法更加有效地实现了图像重建。同年, Sébastien Martin 和 Charles 利用机器学习的方法,精确计算出 EIT 目标物体的方位和尺寸,并根据对目标区域进行有限元分析,进一步提升重建的准确性和精度。2020 年,南京航空航天大学的姚佳烽团队提出了一种径向基函数神经网络(RBFNN)用于图像重建,这种方法基于自适应粒子群优化算法,具备优秀的泛化能力^[32],对包含多目标的样本重建结果令人满意。2022 年,丁亚等人提出了一种 O-Net 深度卷积神经网络的反演方法,该研究通过截断奇异值分解方法对测量值进行图像重建,同时在输入与输出之间添加跳层连接,并进行 1×1 卷积,实现输入与输出的动态连接,有效地减少了电阻抗成像的计算成本、提高了成像质量。2023 年,杨琳等人利用电阻抗成像技术对高过载暴露与人体肺通气功能之间的关系进行了研究。

1.3 本课题主要研究内容

本文在前人的研究成果和理论上,对面向电阻抗成像的深度神经网络算法进行了研究。本文的研究内容如下:

首先,通过有限元法求解 EIT 正问题,并获得深度神经网络训练所需要的数据信

息,组成相应的数据集。为了使得训练所得的神经网络模型能够更好地应用于实际情况,在测量物场内随机生成不同大小、不同形状、不同数量的目标物体,并设定它们的电导率分布。随后,我们通过有限元模型运算出这些目标物体的边界电压数据,从而构建出神经网络训练所需的数据集。

其次,设计并构建了堆栈式自编码器与逻辑回归模型相结合的电阻抗成像模型 SAE-LR。改进了一种生成式对抗网络,使其具备 Wasserstein 距离和梯度惩罚,并将其加入 SAE-LR,形成最终的 SL-W 模型。通过设计不同组别的试验,调整神经网络的各项参数,使模型具备足够的拟合能力,并在后续的仿真试验和实际实验中根据电导率分布重建出效果优异的图像,以期将此方法应用于 EIT 图像重建。最后针对仿真数据和实际试验数据分别设计了多组不同类别的图像重建试验,从成像效果以及相对标准差、均方误差、位置误差等多个角度分析实验结果并最终得出结论。

1.4 本文章节安排

第一章,绪论。本章主要探讨了电阻抗断层成像技术研究的历史背景及其意义,并对国内外关于 EIT 断层成像技术的科学研究进行了综述,在章节最后介绍本文研究内容的章节安排。

第二章,电阻抗成像技术理论基础。本章将探讨 EIT 成像系统与技术的原理及其具体流程,在 EIT 成像技术部分详细描述了其数学模型、正问题和逆问题,对此提出了一些常见的解决方案,以及他们相互之间的关联。

第三章,面向电阻抗成像技术的深度神经网络模型构建。本章旨在探讨基于深度神经网络模型的 EIT 图像重构方案。首先阐述了深度神经网络与 EIT 图像重构之间的相互映射关联,并根据这一点建立了一个深度神经网络系统的模型;紧接着,针对该模型,提出了一些关键性的问题,以期获得更好的结果。接下来,我们将讲述如何生成训练神经网络所需要的数据集。首先,在正问题模型的背景区域内随机地生成待测目标物,并设定目标物体电阻抗分布,以便更好地模拟实际情况。接着,通过对正问题的求解,计算出仿真样本的边界电压值。本文主要利用动态成像技术,即使用电压差数据和电阻抗差作为训练数据,以此减小测量误差对求解结果的负面影响。通过对九种不同形状和数量的仿真模型进行重构,并与 GVSPM 和 ANN 的方法进行图像重

构对比分析，并证明了采用深度神经网络模型（SAE-LR）以及优化模型（SL-W）的 EIT 图像重建计算的切实可行和有效。对于评估该方法的重构效率，我们进行了仿真试验和实物数据试验，并进行了数据分析，从多个角度对比二者与传统 EIT 重建方法的差异，从定性和定量两个方面证明了两种模型结构的优化结果令人满意。

第四章，试验研究与分析。本章通过真实数据检验深度神经网络模型在实际试验中的图像重构效果，并且将试验结果分别与 GVSPM 和 ANN 方法进行比较，以验证改进后的方法的有效性。

第五章，总结与展望。本章对本文的研究内容进行总结与分析，对本文建立的两类深度神经网络模型优缺点进行评价，并展望将来的研究方向，以期将其成像效果进一步优化提升，为未来的研究提供参考。

第 2 章 电阻抗成像技术理论基础

EIT 成像技术的方法重点关注电压场的讨论, 即当被测物场内部的电导率分布发生明显变化时, 会导致被测场域内部电流的改变。因此, 分析 EIT 问题的理论必须确立在电磁场理论的基础上。

本章将着重介绍和描述电阻抗成像技术中敏感场的数学模型、成像过程中的正问题和逆问题。

2.1 电阻抗敏感场数学描述

借助成像系统中收集的激励电流数据、边界条件信息等, 通过特定的方式, 建立边界电压与电导率分布之间的映射关联, 据此实现 EIT 图像重建过程的求解, 这就是 EIT 成像技术的数学模型。

由于 EIT 问题与电磁场问题可以等效, 因此 EIT 敏感场的数学模型能够依据电磁场的麦克斯韦尔 (Maxwell) 方程组来推导求出, 其微分形式表示为:

$$\nabla \times \mathbf{H} = \mathbf{J} + \frac{\partial \mathbf{D}}{\partial t} \dots\dots\dots (2.1)$$

$$\nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t} \dots\dots\dots (2.2)$$

$$\nabla \cdot \mathbf{B} = 0 \dots\dots\dots (2.3)$$

$$\nabla \cdot \mathbf{D} = \rho \dots\dots\dots (2.4)$$

在上述公式中, 各个物理量之间的关系如下:

$$\mathbf{B} = \mu \mathbf{H} \dots\dots\dots (2.5)$$

$$\mathbf{D} = \varepsilon \mathbf{E} \dots\dots\dots (2.6)$$

$$\mathbf{J} = \sigma \mathbf{E} \dots\dots\dots (2.7)$$

其中 ∇ 为矢量微分算子 (哈密顿算子), $\mathbf{H}$ 为磁场强度, $\mathbf{J}$ 是电流密度, $\partial \mathbf{D} / \partial t$ 是位移电流密度。 $\mathbf{E}$ 代表电场强度, $\mathbf{B}$ 代表磁通密度, 即磁感应强度, 单位为 T ;

D 是电位移, 单位为 C/m^3 , ρ 是电荷密度, C/m^3 ; μ 是介电常数, ε 是磁导率, σ 为电导率分布。

由于对上述方程及其未知数进行直接处理非常复杂困难, 为简化 EIT 问题的求解过程, 我们可以在适当情况下做出如下假设^[33]:

(1) 当系统中施加的激励电流频率低于某个阈值时, 敏感场中介电常数、位移电流的影响可以被忽略, 因此, EIT 敏感场可以等效于稳场, 那么 EIT 敏感场内的电流可以处处视作同步变化。

(2) 电流密度的散度为零, 物场中不存在涡流效应。

(3) 测量电极的面积忽略不计。

(4) EIT 系统中, 激励电流不会被介质分散, 仅仅通过注入点平面。通过测量单层电极的激励电流, 可以将 EIT 问题从三维空间转换为二维平面, 从而简化了问题, 并大大降低了问题的计算量。

根据 EIT 成像系统的实际情况, 上述提出的四条假设均可成立。将 EIT 系统中建立的敏感场数学模型视作静态似稳场。即在 EIT 图像重建过程中, 可以采用静态场的理论来描述, 并对正问题、逆问题进行求解。

根据上述假设并结合实际情况, 可以将建立的 EIT 模型视为一个准静态电磁场。在这种情况下, 电流的传导遵循以下公式:

$$\mathbf{J} = \sigma \mathbf{E} \dots\dots\dots (2.8)$$

电流连续性方程为:

$$\nabla \cdot \mathbf{J} = 0 \dots\dots\dots (2.9)$$

电场强度和电位 ϕ 关系为:

$$\mathbf{E} = -\nabla \phi \dots\dots\dots (2.10)$$

根据上述三个公式, 电导率与电位之间存在的关联如下:

$$\nabla \cdot (\sigma \nabla \phi) = 0 \dots\dots\dots (2.11)$$

在实际情况中, 本质上是一个复杂的三维问题, 但是考虑到上述的第四条假设, 当电导率分布在较大的纵向范围内变化较小时, 可以将其简化为一个二维问题^[34]。由此我们可以得到:

$$\nabla \cdot (\sigma(x, y) \nabla \phi(x, y)) = 0 \quad \dots\dots\dots (2.12)$$

2.2 电阻抗成像正问题

要求解 EIT 的正问题, 需要得到两个重要信息, 一个是被测场域内的电导率分布, 另一个是敏感场的边界条件。在这两个已知条件下, 可以推导被测场域内的电势分布, 从而求解出被测场域的边界测量电压以及其与被测场域内电导率分布之间的映射关联, 即灵敏度矩阵, 如图 2.1。




图 2.1 EIT 正问题

EIT 技术的正问题是对逆问题进行求解的基本要求和前提, 它求解的是电磁场边值问题^[35]。而场域形状、电阻抗分布、以及电极位置等因素, 都会影响电磁场边值问题的结果。

目前的研究现状下, 为了解决 EIT 逆问题, 许多基于 EIT 的成像算法都建立在正问题的基础上, 为此, 通常将求解 EIT 正问题的方法大致分成解析法和近似法进行求解, 以期获得更好的基础数据。

在特定的情况下, 例如针对单一几何的场域形状, 解析法能够快速且精确地求解问题, 它能够有效地解决 EIT 正问题, 解析计算法首先依据被测物场形成的数学模型, 推算出物场内电势分布的解析表示, 进而推导出被测物场边界电流值。然而, 由于该方式只适合于场域形态极为规范且电导率分布极为均衡的情形, 假如被测场域形状较复杂或被测目标物的形状不规则, 那么在这种情况下, 解析法的应用价值就比较低了。因此解析法在现实应用中具有相当的局限性, 而且解析解也难以进行。

所以, 考虑到应用的普适性, 通常采用数值分析法对 EIT 正问题进行求解。其中常见的包括有限差分法、有限元法、边界元素法等。

(1) 有限差分法

有限差分法（FDM）是一种早期的数值分析方法，它将复杂的求解场域规划为差分网络，用限制数量的网络节点来替代连续的计算域，有限差分法是一种有效的代数方法，它将网格节点上的信息离散，用以构建一组值不确定的代数方程组，进而将微分问题的解转变为代数问题的近似解。这个方法操作比较简单，常被用于 EIT 正问题的早期研究中，但是由于其对复杂被测场域的适应性较弱，故而在现实应用中并不能满足要求。

（2）有限元法（FEM）

有限元法是目前 EIT 正问题求解中最常见的技术手段^[36]，基于变分原理，有限元法可以将被测物场离散为由大量小三角形拼接的集合体。它通过对每个小型单元的试验分析，并建立有限元方程与之一一相对应，最终得出总体有限元方程组，并对其加以计算，从而获得准确的结果。有限元法是一个十分高效的方法，它最大的优势就是几乎不受测量场域形态的约束，并对任何敏感场加以解析。目前，有限元仿真程序如 ANSYS、COMSOL、MATLAB 等不断涌现，为 EIT 正问题的解决提供了更多的便利性。

（3）边界元素法

边界元素法也是一种有效的数值分析方法，它可以模拟多种媒质的场中边界，并将其转化为代数方程组，从而更准确地求解 EIT 的正问题。然而，由于边界元素法需要分别取每种媒质区域边界，计算量大且耗时长，因此考虑到现实因素，它在 EIT 正问题中的应用比较少。

2.3 电阻抗成像逆问题

EIT 成像过程中的逆问题是电阻抗成像技术发展和研究的关键问题，它有着严重的病态性和复杂的不确定性，使得求解问题的过程变得极其艰难。通常来说，对 EIT 逆问题过程中的数据采集处理方式将其分为了静态和动态两种成像方式。静态成像基于当前时刻的绝对电势，在不考虑测量误差的情况下，静态成像能够获得更加准确的电阻抗分布，但是考虑到实际因素，由于采集硬件、运算资源等条件的限制，实时性无法保证。动态成像技术，是通过当前时刻电势与空载电势之差作为重建依据来进行图像重构，这种方法能够兼顾实时性，并能够有效地减少成像过程中的测量误差，从

而提高重建图像的质量。

EIT 成像技术的逆问题是典型的数学物理反问题，它需要根据被测场域的边界电压值与边界条件，求解被测场域内部的电导率分布，如图 2.2 所示。实际上，EIT 逆问题的求解过程就是 EIT 的图像重建的过程，即通过图像重建算法来推理出反映被测场域内电导率分布情况的图像像素值。




图 2.2 EIT 逆问题

EIT 逆问题求解的过程中，主要存在以下几个难点：

(1) 研究场域的非线性。EIT 技术研究的敏感场“软场”与“硬场”有着显著的不同，它可以检测到物场内介质分布对电势的作用，从而导致边界检测压力与被测物场内的电导率分配之间存在不确定性问题。“软场”的特性导致敏感场的灵敏度在远离电极的区域中最低，从而导致重建图像的精度和分辨率也最低。

(2) 逆问题的欠定性。由于 EIT 逆问题的复杂特性，在实际测量过程中，由于被测物场边界上的电极数量有限，通常会导致解的唯一性受到影响，原因是采集到的边界电压数据通常远远少于需要求解的像素点数，这又使得图像的重建过程存在不确定性。

(3) 逆问题的病态性。EIT 逆问题具有明显的病态性，即边界测量获得的数据只要出现细微的改变，可能就会使得重构图像的像素值发生剧烈改变，从而使得设计求解流程变得混乱，因此，边际测试信息中的噪音和错误信息会对重构图像造成极大的干扰，从而使得重构图像失真。EIT 技术的研究者们正在努力克服上述难点，以提高图像重建的分辨率。

2.4 EIT 图像的非智能重建算法

EIT 图像的非智能重建技术大致可以分成两类：非迭代算法和迭代算法。

非迭代方法中常见的有敏感矩阵法、线性反投影法、Tikhonov 正则化法等。而迭代方法中常见的有 Landweber 迭代法、分裂 Bregman 方法、Newton-Raphson 算法、GVSPM 算法和、共轭梯度法等。

下面将列举一些常见的非智能重建算法。

2.4.1 线性反投影算法

线性反投影算法是一项应用较早并且使用较为简单的 EIT 图像重建算法,它通过有效地模拟被测物场内的电导率变化,从而更准确地反映出场域内的分布特征。它可以根据“硬场”特性,不讨论逆矩阵 $\mathbf{S}^{-1}$,取而代之的是转置矩阵 $\mathbf{S}^T$,将边界电压等信息收集,并投射到场域内部的像素点上,更新其中的像素值,从而有效地解决 EIT 逆问题。尽管 LBP 法的计算简单易行,但是它构建在“硬场”假定的基石上,理论缺乏严谨性,从而使得重建图像的质量不高,只能作为定性分析的工具。

2.4.2 Tikhonov 正则化算法

Tikhonov 正则化算法是一个有效的求解病态问题的办法,它采用最小目标函数,限制解的范数,以确保解的唯一和稳定性,将 EIT 逆问题转换成一个稳态的问题来求解,从而达到更好的效果。

2.4.3 GVSPM 算法

GVSPM 算法,又叫广义矢量采样模式匹配,它是一种传统非智能重建算法中的迭代类算法,它可以反复迭代,计算出 EIT 逆问题的病态线性系统矩阵,由此得到电导率变化的信息^[37]。其计算过程如下:

$$\mathbf{u} = \mathbf{S}\boldsymbol{\sigma} \dots\dots\dots (2.13)$$

在公式 2.13 中, $\mathbf{u}$ 是一个向量,它代表了 m 阶边界电压的输入, $\boldsymbol{\sigma}$ 是输出向量同时它也代表了 n 阶电导率的解。在计算过程中, m 和 n 通常以矩阵的形式表示。 m 取边界电压数量, n 取电导率未知数个数。 $\mathbf{S}$ 通过有限元方法计算得到,它代表 $m \times n$ 的敏感矩阵。在计算过程中,可将 (2.13) 改写为:

$$\begin{cases} \mathbf{u} = \sum_{i=1}^n \sigma_i \mathbf{S}_i \\ \boldsymbol{\sigma} = [\sigma_1, \sigma_2, \sigma_3, \dots, \sigma_n]^T, \quad \mathbf{S} = [\mathbf{S}_1, \mathbf{S}_2, \mathbf{S}_3, \dots, \mathbf{S}_n] \end{cases} \quad \dots\dots\dots (2.14)$$

公式 (2.14) 表明矩阵 $\mathbf{S}_i$ 由 n 列向量组成。 $\mathbf{u}$ 由 $\mathbf{S}_i$ 向量的线性组合表示。

将公式 (2.14) 中的向量 $\mathbf{u}$ 用向量 2 范数进行归一化, 得到的结果如下 (2.15):

$$\mathbf{u}' = \frac{\mathbf{u}}{|\mathbf{u}|} = \sum_{i=1}^n \sigma_i \frac{|\mathbf{S}_i|}{|\mathbf{u}|} \frac{\mathbf{S}_i}{|\mathbf{S}_i|} = \mathbf{S}' \boldsymbol{\sigma}' \quad \dots\dots\dots (2.15)$$

这里 (') 表示对向量进行归一化。通过矩阵的运算, 初步得到了物体的内部电导率分布。其关系如下:

$$\boldsymbol{\sigma}'^{(1)} = \mathbf{S}'^T \mathbf{u}' \quad \dots\dots\dots (2.16)$$

这里 $\boldsymbol{\sigma}'^{(1)}$ 代表了第一次迭代计算得到的被测区域的内部电导率, $\mathbf{S}'^T$ 表示敏感矩阵归一化的转置。将 $\boldsymbol{\sigma}'^{(1)}$ 代入公式 (2.17-2.19) 进行计算和归一化, 得到:

$$\mathbf{u}'^{(1)} = \frac{\mathbf{S}' \boldsymbol{\sigma}'^{(1)}}{|\mathbf{S}' \boldsymbol{\sigma}'^{(1)}|} \quad \dots\dots\dots (2.17)$$

$$\Delta \mathbf{u}'^{(1)} = \mathbf{u}' - \mathbf{u}'^{(1)} \quad \dots\dots\dots (2.18)$$

$$\mu = \mathbf{u}'^T \mathbf{u}'^{(1)} \quad \dots\dots\dots (2.19)$$

μ 是 GVSPM 的目标函数值。假设 $\mathbf{u}'^T$ 与 $\mathbf{u}'^{(1)}$ 之间的内积等于 1 或无限趋近于 1, 则 $\boldsymbol{\sigma}'^{(1)}$ 是逆问题的解。然而, 在实际运算的过程中, 通常会发现, 经过计算, $\boldsymbol{\sigma}'^{(1)}$ 是否为逆问题的解是不确定的。在 EIT 重建的过程中所需要的电导率分布, 就是由此不断迭代最后得出。而解 $\boldsymbol{\sigma}'^{(k)}$ 即代表了 EIT 逆问题在经过 k 次迭代之后趋近于 1 的条件下的解, 其公式推理如下所示:

$$\boldsymbol{\sigma}'^{(2)} = \boldsymbol{\sigma}'^{(1)} + \mathbf{S}'^T \Delta \mathbf{u}'^{(1)} \quad \dots\dots\dots (2.20)$$

$$\mathbf{u}'^{(2)} = \frac{\mathbf{S}' \boldsymbol{\sigma}'^{(2)}}{|\mathbf{S}' \boldsymbol{\sigma}'^{(2)}|} \quad \dots\dots\dots (2.21)$$

$$\Delta \mathbf{u}'^{(2)} = \mathbf{u}' - \mathbf{u}'^{(2)} \quad \dots\dots\dots (2.22)$$

$$\mu = \mathbf{u}'^T \mathbf{u}'^{(2)} \quad \dots\dots\dots (2.23)$$

.....

$$\sigma^{(k)} = \sigma^{(1)} + \sigma^{(2)} + \sigma^{(3)} + \dots + S^T \Delta u^{(k-1)} \dots\dots\dots (2.24)$$

虽然 GVSPM 在有限次的迭代计算下, 结果可以趋于收敛, 但由于其用于成像的结果得不到优化, 所以使用 GVSPM 算法重建后的图像质量不高, 并且伪影现象非常严重, 是个难以解决的难题。

2.5 EIT 图像的智能重建算法

目前, EIT 技术领域常见的智能重建算法有支持向量机、卷积神经网络方法、粒子群算法、人工神经网络等方法^[38], 可以实现高效的图像重建。

以下介绍几种常用的智能重建算法:

2.5.1 支持向量机

支持向量机是一种高效的机器学习技术。它对于处理样本容量较小的非线性问题效果出色, 因此也被用于求解 EIT 逆问题。支持向量机主要利用核函数变换, 将原始输入空间映射到高维特征空间, 从而达到对复杂问题的有效解决, 具备较强的能力。使用这种方法学习的结果通常具备出色的泛化能力和高度的稳健性, 但是在处理大规模训练样本时, 它的适用性可能会受到限制。

2.5.2 粒子群算法

粒子群算法是一种过程优化算法, 它基于飞鸟集群的运动规则, 通过使用种群中个体微粒之间的共享信息, 使得种群的运动规律问题可以从无序到有序地演变, 从而获得最佳解决方案。通过采用随机优化的迭代方法, 可以有效地解决 EIT 逆问题, 从而获得最佳的阻抗重建结果。然而, 粒子群算法极易陷入局部最优解, 从而降低了重建图像的质量。

2.5.3 人工神经网络

1943 年, 美国心理学家 W. McCulloch 和数学家 W. Pitts 提出了神经元的数学模型, 通过这个数学模型, 可以表达生物神经元信号的传播方式, 这就是著名的 M-P 模型。神经元信息的传播得到了有效的描述, 神经元的数学模型也在后续的研究中得

到了广泛的应用。M-P 模型是整个神经网络乃至深度学习的基石，本文中后续提到的人工神经网络（Artificial Neural Network, ANN）^[39]就是由大量的神经元所构成的。




图 2.3 神经元结构及其工作原理

图 2.3 展示了人工神经元的结构，其中， $x_1, x_2, x_3, \dots, x_n$ 代表输入向量； $w_1, w_2, w_3, \dots, w_n$ 代表神经元对于输入数据的权值；通过求和公式 Σ 将神经元输入 x_i 与相应权值 w_i 相乘并求和； b 代表神经元的偏置值； $f(\cdot)$ 代表神经元的激活函数，它通过数学变换，修改输入数据，从而控制输出结果，使其保持在预定的区域内； y 是神经元的真实输出，其表达式如下所示。

$$y = f\left(\sum_{i=1}^n W X + b\right) \dots\dots\dots (2.25)$$

其中， $X=[x_1, x_2, \dots, x_n]$ ， $W=[w_1, w_2, \dots, w_n]^T$ 。

对于这种收到多维输入，通过计算和激活函数得到单个输出的网络，被称作感知机^[40]，也被称作感知器。由于感知机的构造比较简单，仅适用于线性的情况，所以通常使用人工神经网络^[41]来解决非线性的问题。

神经网络是一种以多个神经节点为基础，以权重和阈值进行数据传输的人工神经网络，当权重阈值发生变化时，可以模拟生物神经网络的各种行为特性。神经网络中的节点也叫人工神经元，其作用是模拟生物神经元的活动。所以，神经网络也常常被称作“人工神经网络”（Artificial Neural Network, ANN），主要起到分类和拟合等作用^[42]。在适当且足够的样本下，ANN 可以从原理上近似任何一个非线性的函数。结果表明，将人工神经网络与 EIT 技术相结合，是一种切合实际的方案。

人工神经网络是一种在对人脑神经元构造与功能的仿真基础上,通过对神经元行为的数学建模来对神经元行为实现仿真的数据信息处理系统^[43]。ANN 分为多层网络和单层结构,每个层次都由一定数量的神经元组成,每个神经元都由具有不同权值的有向弧所相连,以便不断学习和训练,从而实现处理信息、模拟输入输出相互之间的关联,并且能够根据需要调节神经元的联系权重。它利用对已有信息进行重复的学习,并采用逐渐调节变化神经元连接权值的方式,来实现对信息进行处理,模拟输入输出间的相互影响。该方法无需精确的相互影响数值,也无需繁杂的参量,仅需捕捉到导致系统结果发生改变的不稳定因子,也就是所谓的非恒定因素。所以,相对于常规数据处理,神经网络技术在处理模糊数据、随机性数据和非线性数据方面有着显著的优点,尤其适合于规模庞大、结构复杂和信息不清晰的体系^[44]。

其中,误差反向传播算法(Error Back Propagation Training)是最为常用的神经网络训练方式,BP 算法目前在各种神经网络的训练中都广为应用,它从后向前,将输出信号反向传递,通过误差倒推来修正神经网络中各个节点的权重,使得人工神经网络的学习结果更加贴近实际^[45]。




图 2.4 ANN 结构及其工作原理

最常见结构最简单的 ANN 模型通常由三个部分组成,分别是输入层、隐含层和输出层,如图 2.4。输入层是一组独立的层,而隐藏层则可以设置为多个层,这样可以提高网络的运算效率,但也会增加计算时间和复杂度。那么将边界测量电压序列样

本和电导率分布作为神经网络的输入和输出, ANN 模型就可以有效地描述 EIT 问题中边界电压序列与电导率分布中间的非线性映射关系。通过使用未经训练的边界电压序列来检测 ANN 模型, 能够得出该边界测量电压所相应的电导率变化分布的估算值, 从而重构图形的像素值。

神经网络的运算通常分为正向传播和反向传播两个步骤。

(1) 正向传播

正向传播是指神经网络训练的前向过程。输入数据由输入层输入, 经过隐藏层的运算以及激活函数的变换, 将信息处理的结果传递给输出层。整个过程包括多个步骤, 逐层向前, 如下所示。

$$z_k = f_{in} \left(\sum_{i=1}^n w_{in,i} x_i + b_{in} \right) \cdots \cdots \cdots (2.26)$$

其中, z_k 为隐藏层输入, $w_{in,i}$ 代表隐藏层对输入层的权重, $in=1, 2, \cdots, k$; b_{in} 是隐藏层的偏置值, $f_{in}(\cdot)$ 是隐藏层的激活函数。

$$y_j = f_{out} \left(\sum_{j=1}^t w_{out,j} z_j + b_{out} \right) \cdots \cdots \cdots (2.27)$$

其中, y 是输出数据, $w_{out,j}$ 是隐藏层和输出层之间的权值, $out=1, 2, 3, \cdots, m$; b_{out} 是输出层的偏置值, f_{out} 是输出层激活函数。

最后, 对神经网络的输出层的输出结果 Y 与真实情况之间的误差进行计算, 随后网络训练进入反向传播的过程。通常情况下, 神经网络的输出误差总会存在, 因而可以手动设置训练参数以终止神经网络的训练。

$$e = \sum e_m = \frac{1}{2} \sum \sum_j^m (y_{rj} - y_j)^2 \cdots \cdots \cdots (2.28)$$

(2) 反向传播

反向传播通过将计算结果与实际输出进行比较, 来减小误差。在这个过程中, 隐藏层中的神经元会按照误差调整重量和阈值, 以便更准确地预测输出。

更新参数的方式通常采用梯度下降^[46], 公式如下。

$$w_i^{new} = w_i - \alpha \frac{\partial e}{\partial w_i} \dots\dots\dots (2.29)$$

$$b_j^{new} = b_j - \alpha \frac{\partial e}{\partial b_j} \dots\dots\dots (2.30)$$

输出层权值的更新公式为:

$$w_{out,j}^{new} = w_{out,j} - \alpha \sum_j^m (y_{rj} - y_j) f'_{out} z_j \dots\dots\dots (2.31)$$

计算输出层偏置值的偏导:

$$\frac{\partial e}{\partial b_{out}} = \frac{\partial e}{\partial y_j} \cdot \frac{\partial y_j}{\partial b_{out}} = \frac{\partial \left(\frac{1}{2} \sum_j^m (y_{rj} - y_j)^2 \right)}{\partial y_j} \cdot \frac{\partial f_{out} \left(\sum_{j=1}^l w_{out,j} z_j + b_{out} \right)}{\partial b_{out}} = \sum_j^m (y_{rj} - y_j) f'_{out} \dots\dots (2.32)$$

偏置值的更新公式为:

$$b_{out}^{new} = b_{out} - \alpha \sum_j^m (y_{rj} - y_j) f'_{out} \dots\dots\dots (2.33)$$

接下来, 我们需要自动更新隐藏层的权值, 这个自动更新方法与输出层相同。具体步骤如下:

$$\frac{\partial e}{\partial w_{in,i}} = \frac{\partial e}{\partial y_j} \cdot \frac{\partial y_j}{\partial w_{in,i}} = \frac{\partial e}{\partial y_j} \cdot \frac{\partial y_j}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_{in,i}} = - \sum_j^m (y_{rj} - y_j) \cdot f'_{out} w_{out,j} \cdot f'_{in} x_i \dots\dots (2.34)$$

隐藏层的权值更新公式:

$$w_{in,i}^{new} = w_{in,i} - \alpha \sum_j^m (y_{rj} - y_j) \cdot f'_{out} w_{out,j} \cdot f'_{in} x_i \dots\dots\dots (2.35)$$

计算隐藏层偏置值的偏导:

$$\frac{\partial e}{\partial b_{in}} = \frac{\partial e}{\partial y_j} \cdot \frac{\partial y_j}{\partial b_{in}} = \frac{\partial e}{\partial y_j} \cdot \frac{\partial y_j}{\partial z_j} \cdot \frac{\partial z_j}{\partial b_{in}} = - \sum_j^m (y_{rj} - y_j) \cdot f'_{out} w_{out,j} \cdot f'_{in} \dots\dots (2.36)$$

隐藏层偏置值的更新公式为:

$$b_{in}^{new} = b_{in} - \alpha \sum_j^m (y_{rj} - y_j) f'_{out} w_{out,j} \cdot f'_{in} \dots\dots\dots (2.37)$$

(3) 激活函数

网络结构对神经网络模型的性能固然有着较大的影响，但除此之外，激活函数也是关联着神经网络性能的重要因素。不恰当的激活函数可能会对网络的整体性质和输出产生巨大的负面影响。

以下是一些常见的激活函数：

ReLU(Rectified Linear Unit)，也被叫做线性整流函数，它是一种应用比较广泛的分段函数。ReLU 将输入数据中比 0 小的数值取 0，与此同时令大于 0 的数值保持不变。ReLU 函数的计算公式如 (2.38) 所示，ReLU 函数能够高效地运算已经被归一化为-1 到 1 的输入数据。

$$ReLU = \max(0, x) \dots\dots\dots (2.38)$$

ReLU 函数仅有两步运算，故而计算效率很高，在使得神经网络运算量大大降低的同时，由于自身强大的非线性特征，能够有效地避免梯度消失对神经网络带来的负面影响^[47]。

其函数曲线如图 2.5 所示。




图 2.5 函数 ReLU 图线

然而，当输入数据小于零时，ReLU 函数或许会造成部分神经元永久不被激活的情况，也就是常说的神经元“死亡”。

LeakyReLU 函数是一种改良的 ReLU 函数。它可以有效地减少 ReLU 的不足，原因是它在输入数值小于 0 的情况下，提供了一个非常小的斜率，这个斜率对整体输出影响不明显，但却能够让部分受影响的神经元保持一定的活性，其函数图线如图 2.6。

$$\text{LeakyReLU} = \max(\alpha x, x) \dots\dots\dots (2.39)$$




图 2.6 函数 LeakyReLU 图线

Sigmoid 函数是神经网络训练、乃至整个深度学习领域中最常用的函数之一^[48]。它能够将在输入信息映射到(0,1)范围内，从而有效地解决二分类问题。不过，虽然 Sigmoid 函数易于求导，但是由于其计算量较大，很容易导致训练的过程中出现梯度消失的问题，因此在实际应用中，需要进行更加缜密的参数调整，其函数图线如图 2.7 所示。

$$S(x) = \frac{1}{1 + e^{-x}} \dots\dots\dots (2.40)$$




图 2.7 函数 Sigmoid 图线

Tanh 函数与 Sigmoid 函数有着相似的特性，它被称为双曲正切函数，其函数图线如图 2.8。但与 Sigmoid 函数不同，Tanh 可以将输入映射到(-1,1)的区间范围内，从而优化了 Sigmoid 函数的局限性。

$$t(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \dots\dots\dots (2.41)$$




图 2.8 函数 Tanh 图线

ANN 有着良好的非线性逼近能力、一定程度的泛化能力和容错能力，但是由于

其过程中很容易出现过拟合的情况,收敛速率也较慢,对数据特征的表现力仍然有限,因此无法充分反映输出结果所包含的数据特征信息^[49]。

2.6 小结

本章旨在探讨 EIT 技术在系统流程和算法理论知识,并给出其敏感场的数学描述,以及正向和逆向问题的原理,接着描述了传统的非智慧重构方法,如线性反投影、Tikhonov 正则化和 GVSPM,最后,讲述了几种智能重建方法,如支持向量机、粒子群算法和 ANN 的方法,以期更好地理解 EIT 技术。其中重点描述了两种本文用以对照的算法,即传统非智能重建算法 GVSPM 和智能重建算法 ANN。

第 3 章 面向电阻抗成像技术的深度神经网络模型构建

EIT 图像重构是一个复杂的非线性问题，它的逆现象往往难以解决，因此，我们给出了一个采用深度神经网络的 EIT 图像重构技术，它将 EIT 逆问题转化为一个可以有效地解决的非线性映射模型，从而大大提高了图像重建的质量。

3.1 构建 EIT 图像重建映射模型

由于 EIT 逆问题的病态性十分严重。为了解决这一实际情况，本文没有使用结构简单的单层网络，而是选择具有多个隐藏层并且结构变化的深度神经网络，以期有效地解决 EIT 逆问题。

本文设计的用深度神经网络求解 EIT 逆问题的具体流程和映射模型如图 3.1 所示。




图 3.1 EIT 图像重建映射模型

研究方法可以分为两个步骤：第一步，生成并收集整理训练数据，组成神经网络训练所需要的数据集；第二步，构建具体的深度神经网络，设定训练参数，调整网络参数，直至重建结果达到预期要求。

3.2 生成数据集

神经网络训练数据集的样本的大小和泛化性对于神经网络的拟合能力有着非常大的影响，因此，本文在数据集中设置的目标物体具有不同数量、不同大小、不同形状，以确保训练得到的神经网络模型具备一定程度的泛化能力。

首先基于 MATLAB 平台中的 EIDORS 工具编写用于生成数据集的代码程序，正问题的求解使用有限元法。

3.2.1 有限元区域设置及目标物体

通过有限元分析，将研究的背景区域定为圆形场域，并在此圆形场域中生成目标物体。圆形场域的直径为 32 个有限元仿真单位。

其次确定设置的目标物体的大小、数量、以及形状。目标物体的个数为 1-3 个，通过程序代码，目标物体的位置以及大小在背景区域内随机生成。

为了使得生成数据集中的数据与实际应用中的情况更接近，更改生成目标物体的形状是重点，因此本文分别设计了圆形、正方形、三角形三种不同形状的目标物体，设计方式如下。

(1) 圆形目标

要在设定的背景区域内准确重建出圆形目标，需要先保证其圆心在背景区域上，继而才能通过后续的代码设计，保证整个圆形目标都在被测物场内。

因此，需要先界定研究背景区域的内接正方形区域大小，而生成目标物体的圆心应当在这个正方形区域内。

将圆心在背景区域内的坐标设为 (x, y) ，则其满足如下公式 (3.1)：

$$\begin{cases} -8\sqrt{2} \leq x \leq 8\sqrt{2} \\ -8\sqrt{2} \leq y \leq 8\sqrt{2} \end{cases} \dots\dots\dots (3.1)$$

在本文的研究过程中，仿真目标的圆形物体半径 r 设置为 3 ± 1 。计算研究场域内每个有限元的中心坐标到圆心坐标的距离 k ，则所有 k 小于圆形目标半径 r 的有限元都视为该圆形目标的一部分，统计整合，获得圆形目标的具体信息。生成结果实例如图 3.2 所示，其中绿色部分为介质，粉红色部分为目标对象。




图 3.2 圆形目标（单目标、双目标、三目标）

（2）三角形目标

生成三角形目标物体需要确定其三个顶点，并以此确定目标物体在物场内的具体位置，并且还必须要先保证目标物体的三个顶点均在背景区域之内，继而才能保证整个三角形目标都在被测物场内。

代码程序设定过程与圆形目标物体的设定过程类似。由于当仿真目标物体的三角形边长随机为 2 时，目标呈现过小，故而在该处设置三角形目标的边长 k 为 5 ± 1 ，以保证生成目标的大小合适。

首先在规定的区域内生成随机顶点 A，并延伸出长度为 k 的边长 ab，并将边长 ab 的另一端定为第二个顶点 B，连接 AB，再将其顺时针或逆时针旋转 60° 角，得到三角形目标物的第三个顶点 C，连接 AC，BC，即获得一个等边三角形目标 ABC。

最后只需通过 MATLAB 软件中的 `inpolygon` 函数对生成的三角形目标物内各个有限元进行判定，当生成的目标物所有单元均在研究背景区域内时，认为该次生成结果合格，可在软件程序中预览结果并保存数据。生成结果实例如图 3.3 所示，其中绿色部分为介质，粉红色部分为目标对象。




图 3.3 三角形目标（单目标、双目标、三目标）

（3）正方形目标

生成正方形目标物体需要确定其四个顶点，并以此确定目标物体在物场内的具体位置，并且还必须要先保证目标物体的四顶点均在背景区域之内，继而才能保证整个正方形目标都在被测物场内。

代码程序设定过程与圆形目标物体的设定过程类似。由于当正方形的边长随机为 2 时，目标呈现过小，故而在此处设置正方形目标的边长 k 为 5 ± 1 ，以保证生成目标的大小合适。

生成正方形的代码操作和步骤与三角形目标物体的操作步骤类似，这里就不过多赘述。最后只需使用前面提到过的 MATLAB 软件中 `inpolygon` 函数判断生成的正方形目标物的所有单元的位置，确保整个目标物包含在研究背景区域内即可。生成结果实例如图 3.4 所示，其中绿色部分为介质，粉红色部分为目标对象。




图 3.4 正方形目标（单目标、双目标、三目标）

3.2.2 数据预处理

为了有效地抑制样本数据中的异常值,我们将边界电压值排序数据和实际电导率分配数据进行归一化处理后,将其限定在 0~1 之间,以此来减少异常值对深度神经网络模型的不利影响,防止网络训练不收敛。归一化公式可以表示为:

$$y = \frac{(y_{max} - y_{min}) * (x - x_{min})}{(x_{max} - x_{min})} + y_{min} \dots\dots\dots (3.2)$$

公式中,向量 $\mathbf{x}$ 代表测量得到的未经归一化的边界电压数据以及电导率分布,通过前文中 MATLAB 程序代码的设定,在保存数据时,所有边界电压数据及其电导率分布均已被拉直,并一一对应,为后续的归一化以及神经网络的训练提供便利;向量 $\mathbf{x}$ 归一化后的结果为 $\mathbf{y}$,它代表了经过归一化后的边界电压数据以及电导率分布; $\mathbf{x}_{max}$ 代表向量 $\mathbf{x}$ 中的最大值, $\mathbf{x}_{min}$ 为向量 $\mathbf{x}$ 中的最小值; $\mathbf{y}_{max}=1$, $\mathbf{y}_{min}=0$ 。

训练集样本用于仿真模型,由真实电导率分布样本和对应的边界电压序列样本组成。在训练网络模型时,需要将训练样本分批训练。为了使训练样本被分成完整的批量,我们从训练集中随机抽取五千个样品,并将其归一化,以此作为神经网络的输入,具体可以表示为 $\mathbf{V}=\{\mathbf{V}^{(1)},\mathbf{V}^{(2)}\dots\mathbf{V}^{(5000)}\}$,其中 $\mathbf{V}^{(k)}\in[0,1]^{40}$,并将其对应的电导率分布样本进行归一化,作为标签,表示为 $\mathbf{R}=\{\sigma^{(1)},\sigma^{(2)}\dots\sigma^{(5000)}\}$,其中 $\sigma^{(k)}\in[0,1]^{1024}$ 。

为了评估 EIT 重构图像的效果,采用了一部分测试集数据来验证已训练好的网络模型。测试集中的数据组全部未经神经网络训练,在将其归一化后对网络模型进行检验,表示为 $\mathbf{V}_I=\{\mathbf{V}'^{(1)},\mathbf{V}'^{(2)}\dots\mathbf{V}'^{(5000)}\}$,其中 $\mathbf{V}'^{(k)}\in[0,1]^{40}$ 。

将数据送入经过训练后的深度神经网络模型,经过推导拟合,从输出层输出的结果即为对该样本电压数据下物场内电导率分布的估测值,可以凭借输出的电导率分布数据作为依据,实现 EIT 图像的重建,电导率分布数据可以表示为 $\mathbf{R}_I=\{\sigma'^{(1)},\sigma'^{(2)}\dots\sigma'^{(5000)}\}$,其中 $\sigma'^{(k)}\in[0,1]^{1024}$ 。

3.3 构建面向电阻抗成像技术的深度神经网络模型

本节将从结构、参数、试验三部分展示本文构建面向电阻抗成像技术的深度神经网络模型。

3.3.1 堆栈式自编码器与逻辑回归

自编码器（Auto-encoder, AE）是一种特殊的人工神经网络。作为深度神经网络的一种构建模块，它目前主要被应用于图片处理领域的特征检测，其训练的过程是学习近似恒等函数，目的是从输入图片等数据中，学习压缩表示^[50]，并重构出输入数据特征的高级表示。从原理层面上来看，这一点与 EIT 图像的某些智能重建算法不谋而合。

为了提升自编码器的实用性能，限制 AE 提取输入数据中更抽象的特征，也防止网络结构仅仅学习简单的输入数据^[51]，通常需要对结构中的隐藏层神经元进行稀疏性限制，而存在稀疏性限制的自编码器结构通常被称为稀疏自编码器。其基本结构如图 3.5 所示，其由输入、隐藏和输出层构成。




图 3.5 单个自编码器结构图

AE 可以用于处理复杂且无明显规律的数据，输入数据 X 通过前向传播，进入特征层，被编码器编码，特征层将输入数据编码为低维表达 Y ，再通过隐藏层送入解码器，将低维表达 Y 进行数据解码，将解码后的数据输出并与输入数据比对，再经过反向传播，对编码器、解码器以及隐藏层中的部分网络参数、权重进行更新迭代。

其训练过程类似于恒等变换，其目的是使解码器的输出结果 Z 与输入数据 X 接近。在这个反向传播过程中，会使得编码器对输入数据的特征提取更加精准。

AE 的原理如图 3.6 所示。




图 3.6 自编码器工作原理图

计算机领域中的科学研究者们为了更强大的特征提取能力，增加了其隐藏层深度，将多个编码器彼此堆叠，形成了堆栈式自编码器^[52]（Stacked Auto-encoder, SAE）的结构，堆栈式自编码器在应用中也称作深度自动编码器（Deep Auto-encoder, DAE），本文采用了堆栈式自编码器作为神经网络模型的一部分。

本文所使用的 SAE 在训练时，会拆除前一个自编码器的解码层，只保留输入层、特征层、隐藏层，而隐藏层的输出将会被送入后续 SAE 模块的输入层。

在这样的训练过程中，输入数据的特征被逐步压缩，从而为后续的重建步骤建立基础。

本文使用的深度神经网络模型中 SAE 部分工作原理如图 3.7 所示。




图 3.7 SAE 工作原理图

EIT 的逆问题有着严重的病态性和欠定性，它涉及到物场内部电导率分布的推导，

因此,边界电压与电导率分布相互之间具有特定的函数映射关系。将边界电压输入后,通过SAE强大的特征提取能力,其分布特征将被层层压缩提取,然后拟合出物场内部电导率分布的特征,并且每个隐藏层的输出数据,都是前一个隐藏层中数据的更高维特征,从而使得重构过程更加有效、更加精确^[53],最后一层隐藏层的输出是边界电压的最低维表征,它可以揭示物场内部电导率分布的复杂特征^[54]。

然而逐层训练的方式使得单纯的自编码器模型的训练时间变得冗长,因此,本文设计的深度神经网络模型主体部分在堆栈式自编码器中融合了一个逻辑回归模型。

逻辑回归模型的训练速度较快^[55],并且其可解释性非常好,从特征的权重中可以分析出不同特征信息对于最后训练结果的影响。而逻辑回归的部分劣势,又被堆栈式自编码器所解决,总体来说二者相辅相成,最终获得本文提出的深度神经网络模型的主体部分,即SAE-LR模型。

3.3.2 WGAN-gp

近几年以来,深度神经网络和机器学习在各个领域大放异彩,但人们慢慢开始注意到,那些在深度神经网络中取得突破性进展的研究,大多数都是判别模型相关。

终于,由博弈论中零和博弈得到灵感的Goodfellow等人,开创性地提出了生成式对抗网络模型(GAN)^[56]。GAN主要由两部分组成,分别是生成器(generator, G)和判别器(discriminator, D)两种神经网络模型。

将带有噪声或其他干扰因素的输入数据送入生成器中,生成器通过模拟根据输入数据生成一个与其相似的输出,并送入判别器。

判别器负责判定生成器的输出数据是真实数据还是由生成器生成的虚拟数据。

这二者的关系类似于售卖商品的商店与购买商品的消费者,商店同时出售赝品与真实商品给消费者,消费者需要判断和鉴别购买商品的真实性,并反馈给商店。当消费者的鉴别能力提高,商店制作赝品的能力也需要提高,二者博弈优化,最终商店制作赝品的真实程度达到与真实商品接近一致。

GAN通过固定其中一个模型的参数,对另一个模型的参数进行更新迭代,从而提高整个模型处理数据的能力^[57]。最终当判别器无法准确判断真实数据和生成器生成数据时,即认为生成器具备生成近乎真实数据的能力。

目前,GAN网络的应用主要在于图片处理领域,然而,电导率分布是在EIT成

像过程中,最为重要的一部分,那么假如将被测场域内电导率分布视为一张未经处理的图片,那么便可以将生成式对抗网络的能力应用于 EIT 图像重建的过程之中。

本文将基于 WGAN-gp 的 EIT 成像后处理模块加入 SAE-LR 模型之中,以经过 SAE-LR 模型处理后得到的与真实图像具有偏差的电导率分布输入 WGAN-gp,通过网络的数据处理最终取得更贴近于真实情况的输出,同时确立了面向电阻抗成像技术的 SL-W 方法。

(1) GAN 网络结构及其原理

含有随机噪声的数据 x 作为生成器的输入,经过处理,生成器生成与真实数据 y 分布相类似的输出 $G(x)$,随后,将输出信息送入判别器 D ,判别器经过对比判断,输出一个代表了生成器的输出数据属于真实数据的概率,概率越大表明输入数据越接近真实数据^[58]。在一般的训练过程中,判别结果的数值设定为 0-1 之间。

GAN 网络的结构及其原理如图 3.8 所示。




图 3.8 生成对抗网络结构

在训练的早期阶段,判别器能够轻易且准确地辨别出虚假的生成数据和真实数据,并且能够提供准确的概率分布。

然而,随着训练数据的增多,生成器模型的能力不断提高,其生成的虚拟数据也跟真实数据逐渐接近。与此同时,判别器会变得越来越难以判断其二者的真假,给出的判别概率不断接近,最终给出 0.5 的判别结果,也就是 50%的概率为真,50%的概率为假,称之为纳什均衡。当然,在实际训练的情况中,真正保持纳什均衡的生成式对抗网络模型只是理想状态,因此只要模型的判别概率稳定在接近 0.5 时,就认为生

成器模型的参数已经接近纳什均衡^[59]。

生成器和判别器的损失函数如下所示。

$$G_{loss} = \min[\log(1 - D(G(x)))] \dots\dots\dots (3.3)$$

$$D_{loss} = \min[\log(1 - D(G(x))) + \max[\log(D(y))]] \dots\dots\dots (3.4)$$

根据损失函数来看,生成器和判别器相互之间存在着一种对抗性,即生成器期望降低判别器对产生数据的识别能力,而判别器则希望生成器减少对真实数据的拟合能力。因此,这种对抗性使得生成器和判别器相互之间的损失函数变得更加复杂。

可以通过极大极小问题,来表示生成式对抗网络的总体损失函数,如公式(3.5)所示:

$$\min_G \max_D L_{GAN}(D, G) = E_{y \sim p_r}[\log D(y)] + E_{x \sim p_x}[\log(1 - D(G(x)))] \dots\dots (3.5)$$

(2) 基于 Wasserstein 距离的生成对抗网络

生成对抗网络具有很多优点,例如不需要过多的训练数据、适用性广泛^[60]等,但同样存在一些难以避免的缺陷,例如训练困难、网络训练效果评判指标模糊、容易出现模式崩塌^[61]等等。

为了优化上述训练 GAN 时容易出现的缺陷,2017 年,Arjovsky M、S Chintala、L Bottou 等人提出了一种使用 Wasserstein 距离损失函数^[62],并且具备梯度惩罚的 GAN 算法,一定程度上避免了 WGAN 梯度消失或梯度爆炸的可能性发生。

以下列举了两种 GAN 的生成器损失函数表达式:

$$E_{x \sim p_x}[\log(1 - D(G(x)))] \dots\dots\dots (3.6)$$

$$E_{x \sim p_x}[-\log D(G(x))] \dots\dots\dots (3.7)$$

在使用公式(3.6)这一类损失函数时,会在训练过程中产生一些阻碍。假设 X 为输入样本,判别器损失函数的影响如下:

$$-P_r(X) \log D(X) - P_x(X) \log(1 - D(X)) \dots\dots\dots (3.8)$$

对 $D(X)$ 求导:

$$D^*(X) = \frac{P_r(X)}{P_r(X) + P_x(X)} \dots\dots\dots (3.9)$$

代入公式(3.4)之中,得到:

$$D_{loss} = E_{x \sim p_r} \log \frac{P_r(X)}{\frac{1}{2}[P_r(X) + P_x(X)]} + E_{x \sim p_x} \log \frac{P_x(X)}{\frac{1}{2}[P_r(X) + P_x(X)]} - 2 \log 2 \dots\dots (3.10)$$

KL 散度(Kullback-Leibler divergence)又叫相对熵,是生成对抗网络中用以衡量分布相似度的重要指标之一。

它表示了两个概率分布 P 和 Q 之间的差异,二者越相似,则 KL 散度的值越低。KL 散度具有非负性和非对称性,运算时交换两个分布的位置,得到的结果不同。

其定义如下:

$$D_{KL}(P|Q) = E_{x \sim P} \log \frac{P(i)}{Q(i)} \dots\dots\dots (3.11)$$

JS 散度(Jensen-Shannon divergence)是 KL 散度的变体之一,其基本原理和 KL 散度相似,两个概率分布越相似,JS 散度越低。但 JS 散度的值域范围为[0,1],相较于 KL 散度,它的判别更精准,并且 JS 散度具有对称性,观察公式可知,交换分布 P 和 Q 的位置,计算结果相同。

$$D_{JS}(P|Q) = \frac{1}{2} D_{KL}\left(P \middle| \frac{P+Q}{2}\right) + \frac{1}{2} D_{KL}\left(Q \middle| \frac{P+Q}{2}\right) \dots\dots\dots (3.12)$$

根据上述定义公式(3.12):

$$D_{loss} = 2JS(P_r | P_x) - 2 \log 2 \dots\dots\dots (3.13)$$

在常见的生成式对抗网络中,JS 散度会根据生成数据与真实数据分布之间的重叠部分变化而产生相应的变化。但如果假设二者之间无重叠部分,或者重叠部分占全部数据信息的比重比较小,小到可以忽略不计,则将出现以下可能情况:

$$\begin{cases} P_1(x) = 0, P_2(x) = 0 \\ P_1(x) \neq 0, P_2(x) \neq 0 \\ P_1(x) = 0, P_2(x) \neq 0 \\ P_1(x) \neq 0, P_2(x) = 0 \end{cases} \dots\dots\dots (3.14)$$

x 为生成式对抗网络的输入。在这四种情况下,JS 散度的值为 0 或 $\log 2$,也就说

明损失函数 D_{loss} 对训练梯度贡献为 0, 对 GAN 的训练没有任何收益。

当使用公式 (3.8) 作为损失函数时, 训练过程中会出现梯度不稳定输出结果多样性不足等缺陷, 使得出现模式崩塌的可能。

可以将 KL 散度变换为公式 (3.15) :

$$KL(P_x \| P_r) = E_{x \sim P_x} \log \frac{P_x(x)}{P_r(x)} = E_{x \sim P_x} \log[1 - D^*(x)] - E_{x \sim P_x} \log D^*(x) \cdots \cdots (3.15)$$

根据公式 (3.7) (3.13) (3.15) 可得:

$$E_{x \sim P_x} [-\log D^*(x)] = KL(P_x \| P_r) - E_{x \sim P_x} \log[1 - D^*(x)] = KL(P_x \| P_r) - 2JS(P_r \| P_x) + 2\log 2 + E_{x \sim P_x} \log D^*(x) \cdots \cdots (3.16)$$

$2\log 2 + E_{x \sim P_r} \log D^*(x)$ 与生成器部分无关, 因此最小化公式 (3.8) 等价于最小化公式 (3.17) :

$$E_{x \sim P_x} [-\log D^*(x)] = KL(P_x \| P_r) - 2JS(P_r \| P_x) \cdots \cdots (3.17)$$

通过最小化 KL 散度和 JS 散度, GAN 的梯度变得不稳定, 这是由于它们之间存在着矛盾和相互影响的关系。

对于 KL 散度而言, 当 $P_x(x) \rightarrow 0$, $P_r(x) \rightarrow 1$ 时, $P_x \log P_x(x)/P_r(x) \rightarrow 0$, 对 KL 散度的贡献趋向于 0; 当 $P_x(x) \rightarrow 1$, $P_r(x) \rightarrow 0$ 时, $P_x \log P_x(x)/P_r(x) \rightarrow +\infty$, 对 KL 散度的贡献趋向于正无穷。

然而由于 KL 散度对神经网络参数惩罚的一些特性, GAN 网络通常会选择生成重复的数据来进行判别, 以使得训练结果看上去趋于稳定, 但这可能会导致它们缺乏多样性。

为此, Arjovsk 提出了一种新的方法来处理 KL 散度和 JS 散度的问题, 这种方法就是利用 Wasserstein 距离。

其定义如下:

$$W(P_r, P_x) = \inf_{\gamma \in \Pi(P_r, P_x)} E_{(x,y) \sim \gamma} [\|y - x\|] \cdots \cdots (3.18)$$

公式中, $\Pi(P_r, P_x)$ 表示 P_r 和 P_x 分布的所有可能组合的集合。 γ 表示真实数据与输出数据的联合分布, (x, y) 为 γ 中的一对样本, 其中 x 为生成器生成样本, y 为真实样本。 $E_{(x,y) \sim \gamma}$ 表示距离的期望值。 $\inf$ 表明将这一期望值设定为最低限度。

与 JS 散度和 KL 散度一样, Wasserstein 距离能够在两种分布缺少重合区域的情形下准确地描述它们相互之间的差距, 但是由于无法直观计算期望值的下界, 因此需

要将其转换为更加复杂的形式。

$$W(P_r, P_x) = \frac{1}{K} \|f\|_L \leq K E_{x \sim p_r}[f(x)] - E_{x \sim p_x}[f(x)] \cdots \cdots (3.19)$$

Wasserstein 距离惩罚通过引入参数 w ，从而得出如下公式。

$$L = E_{x \sim p_r}[f_w(x)] - E_{x \sim p_x}[f_w(x)] \cdots \cdots (3.20)$$

$$G_{loss} = -E_{x \sim p_x}[f_w(x)] \cdots \cdots (3.21)$$

$$D_{loss} = E_{x \sim p_x}[f_w(x)] - E_{x \sim p_r}[f_w(x)] \cdots \cdots (3.22)$$

$$D_{loss} = E_{x \sim p_x}[f_w(x)] - E_{x \sim p_r}[f_w(x)] + \lambda E_{x \sim p_x} \left[\left(\|\nabla_x\|_2 - 1 \right)^2 \right] \cdots \cdots (3.23)$$

由此，WGAN-gp 技术是一种更易于训练的生成式对抗网络。生成式对抗网络的纳什均衡^[63]只是理想化状态，实际情况中得到的结果都是中间态^[64]，这导致随着训练次数的增加，判别器 D 的能力越来越强，可以一直将 G 输出的样本区分开来。

而在 WGAN-gp 算法中，原本的判别器功能从判断，转换为了计算两个分布集合的距离，故而实际上称之为评价计算器更为合适一些。

WGAN-gp 有效地解决了 GAN 梯度不稳定的情况，降低了训练难度，并且优化了其多样性不足的缺陷，除此之外，在 WGAN 的基础上还能有效地避免梯度消失或爆炸的现象出现。

将 WGAN-gp 模块与 SAE-LR 相结合，得到本文提出的面向电阻抗成像技术的深度神经网络模型，SL-W。

本节将从生成器 G 和判别器 D 两部分来介绍本文所提出的 WGAN-gp 网络结构。

生成器 G 结构如图 3.9 所示。一共设定了 4 层反卷积神经网络。所有反卷积层使用 4×4 的 kernels 以及 1×1 的 padding，Stride 设定为 2，并使用 ReLU 作为激活函数。




图 3.9 WGAN-gp 生成器网络结构

下表 3.1 罗列了生成器的部分网络参数设置。

表 3.1 对抗生成网络中生成器的网络参数设置

Table3.1 Network parameters setting of generator in Generative adversarial networks			
参数名称	数值	参数名称	数值/类型
input size	1024	Optimizer	RMSprop
hidden layer 1	2×2×256	activate function	ReLU
deconv layer 1	128	activate function	ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
deconv layer 2	64	activate function	ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
deconv layer 3	32	activate function	ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
deconv layer 4	1	activate function	Tanh
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
epoch	200	batch size	128
learning rate	1×10 ⁻⁴	normalization	[-1, 1]
train dataset	21600	valid dataset	5400

值得一提的是，在试验进行的中期，经过调试试验后发现，在当前试验系统以及实验数据中，优化器 RMSprop 与目前深度学习领域内使用最广泛的优化器 Adam 得出的试验结果相当，甚至在部分情况下效果更好，最终基于本试验系统下的对抗生成网络模型优化器选用 RMSprop。

另一部分判别器 D 的结构如下图 3.10 所示。




图 3.10 WGAN-gp 判别器网络结构

它的结构与生成器G相对应,设定4个卷积层,4×4的卷积核以及1×1的padding, Stride 设定为 2, 各隐藏层激活函数为 LeakyReLU。卷积层之后全连接输出, 由于常用的 Sigmoid 函数会对 WGAN 的输出结果产生不利影响, 故而使用 Tanh 取代 Sigmoid 函数。

下面罗列了判别器的部分网络参数设置。

表 3.2 对抗生成网络中判别器的网络参数设置

Table3.2 Network parameters setting of discriminator in Generative adversarial networks			
参数名称	数值	参数名称	数值/类型
input layer	$32 \times 32 \times 1$	Optimizer	RMSprop
convolution layer 1	32	activate function	Leaky ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
convolution layer 2	64	activate function	Leaky ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
convolution layer 3	128	activate function	Leaky ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
convolution layer 4	256	activate function	Leaky ReLU
kernel size、padding	(4, 4)、(1, 1)	Stride	(2, 2)
output layer	1	activate function	add
epoch	200	batch size	128
learning rate	1×10^{-4}	normalization	[-1, 1]
train dataset	21600	valid dataset	5400

3.4 优化神经网络模型

在本文的研究中，为了提高深度神经网络模型对 EIT 数据的重建能力，考虑了多种影响神经网络性能的参数，包括网络层数、隐藏层节点数、训练学习率、训练次数、迭代轮数甚至是批量大小等。最终，在确定了模型基础参数的情况下，通过设定不同的网络的层数，以及不同的学习率来设计并进行试验，用以优化网络模型。

试验中，采用均方误差（Mean-Squared Error, MSE）来可视化训练过程中的网络性能，其公式如下：

$$MSE(\sigma^*) = \frac{\|\sigma^* - \sigma\|_2^2}{N} \dots\dots\dots (3.24)$$

上述公式 (3.24) 中， σ^* 为真实电导率分布，由前文中数据集生成程序记录所得， σ 为电导率分布的估计值，由神经网络处理后得出， N 为像素个数。在相同条件下，均方误差越小，则代表训练效果越好，网络模型的性能越强。

本文分别设计了 SAE 部分的四种不同数量隐藏层的网络模型以及 LR 部分的三种不同隐藏层数量的网络模型，学习率变化的范围为 0.0001~0.001，并设计了多组试验，研究讨论在 epoch 设定为 500、批量大小设定为 128 的情况下，隐藏层层数与学习率 a 对网络模型性能的影响。

则未优化的 SAE-LR 模型的其他参数设置情况如表 3.3 所示。


表 3.3 未优化前部分网络参数设置

Table3.3 Partial network parameter settings before optimization


参数设置	
SAE（整体）	输入层节点个数：40；
	隐藏层节点个数：96、32、96；
	输出层节点个数：40
LR	输入层节点个数：32；
	隐藏层节点个数：96、128；
	输出层节点个数：1024

3.4.1 学习率分析

为确定一个训练效果更好的学习率，首先在表 3-2 中神经网络结构参数设置的前提下，更改学习率进行试验，分别设置 0.0001、0.0003、0.0005、0.0007、0.0009、0.001 六种学习率，试验结果如图 3.11（a）、3.11（b）所示。



a) 训练集



b) 验证集

图 3.11 两种数据集上六种不同学习率下网络模型的试验效果

观察图 3.11 (a) 和图 3.11 (b) 中的图线可知，在当前试验系统下，学习率为 0.0005 时，无论是在训练集上还是在验证集上的训练效果，都是最好的，所以在后续的深度学习模型层数分析阶段，将会固定学习率为 0.0005。

3.4.2 堆栈式自编码器模块的网络层数分析

为确定深度学习模型中自编码器 (SAE) 部分的最优隐藏层数量，设计如图 3.12 所示的，A、B、C、D 四种网络模型。






图 3.12 SAE 部分四种不同层数下的网络模型结构

在固定 LR 部分隐藏层为 1、学习率设定为 0.0005 的前提下，分别对 A、B、C、

D 四种网络模型，用 5400 组仿真数据集样本进行试验，得到不同网络层数下，电导率分布重建结果的均方误差随迭代次数变化的曲线，如图 3.13 所示。



a) 训练集上 MSE 的变化曲线



b) 验证集上 MSE 的变化曲线

图 3.13 两种数据集上 SAE 部分四种模型的 MSE 随迭代次数的变化曲线图

观察图 3.13 (a) 和图 3.13 (b) 中的图线可知，在当前试验系统下，SAE 部分的特征层数量为 1 时，效果最差；特征层数量为 2 时效果提升比较明显；特征层数量为 3 时，效果进一步提升，然而当特征层数量增加至 4 层时，虽然均方误差相较 3 层更低，但随着迭代次数的增加出现了比较明显的波动，说明在当前试验系统下，存在的问题，故而综合上述情况最终择优选择模型 C，即特征层数量为 3。

3.4.3 逻辑回归模块的网络层数分析

为确定深度神经网络模型中逻辑回归（LR）部分的最优隐藏层数量，设计如图 3.14 所示的，X、Y、Z 三种网络模型。






图 3.14 LR 部分三种不同层数的网络模型结构

在固定 SAE 部分特征层数量为 3、学习率设定为 0.0005 的前提下，分别对 X、Y、Z 三种网络模型，用 5400 组仿真数据集样本进行试验。得到不同网络层数下，电导率分布重建结果的均方误差随迭代次数变化的曲线，如图 3.15 所示。



a) 训练集上 MSE 的变化曲线



b) 验证集上 MSE 的变化曲线

图 3.15 在两种数据集上 LR 部分三种模型 MSE 随迭代次数变化的曲线图

观察图 3.15 (a) 和图 3.15 (b) 中的图线可知, 在当前试验系统下, LR 模块隐藏层数量为 2 时, 效果最差, 并且伴随着迭代次数的增加, 在验证集上出现了比较明显的波动, 稳定性比较差。隐藏层数量为 2, 3 时, 效果相差不大, 基于运算成本和训练时间角度考虑, 择优选择 3 层隐藏层, 也就是模型 Y。

3.5 评判指标

为了更加客观地对基于 SAE-LR 以及 SL-W 方法对 EIT 图像重建的效果进行分析, 本文将在后续的仿真试验与实际试验中采用相对标准差、均方误差以及位置误差三种评判指标, 用以验证其二者的重建效果。

3.5.1 相对标准差

标准偏差系数, 又叫相对标准差 (Relative standard deviation, RSD), 它代表了标准偏差占总体数据平均值的百分率。在本试验系统中, 反映的是 EIT 重建结果对电导率重建的准确度。RSD 越小, 说明该方法下重构的电导率值越更贴近实际情况。

$$RSD = \sqrt{\frac{\|\rho_p - \rho_r\|}{\|\rho_r\|}} \dots\dots\dots (3.25)$$

其中, ρ_p 为重建结果中的电导率值, ρ_r 为实际情况中的电导率值。

3.5.2 均方误差

在之前优化神经网络模型的小节中，曾经提到过评判神经网络性能指标的一个常用评判指标，均方误差（Mean-Square Error, MSE）。

在深度学习领域中，MSE 通常用作回归问题的损失函数，它在相当程度上表明测量预测值与某些真实数值的匹配程度，是反映估计值与被估计值的真实值之间差异程度的一种常用度量指标。

由于在前文中给出过具体的公式，在这里就不过多赘述。

在本试验系统下，它同样是评价重建结果的重要指标之一。

3.5.3 位置误差

位置误差（Position Error, PE）可以用来衡量重建图象中的目标物体与实际情况中的目标物体之间的位置偏差，从而反映出图像中物体的位置变化情况。

$$PE = \frac{|d_r - d_p|}{R} \dots\dots\dots (3.26)$$

其中， R 是背景区域的半径，在本试验系统中这个数值为 16。 d_r 和 d_p 分别为目标物体中心点到背景区域中心的距离，以及实际检测物体的中心点到背景区域中心的距离。

3.6 仿真试验

本节将展示本文所提出两种的面向电阻抗成像技术的深度神经网络成像方法，SAE-LR 及其后处理版本 SL-W 方法在训练后，对仿真数据的重建效果。并选择迭代类传统算法 GVSPM、以及智能算法 ANN 进行相同试验，用以对比 SAE-LR 以及 SL-W 方法的优势与劣势。

本文中选用对比的 ANN 结构为四层网络结构：输入层、两个隐藏层、输出层，神经元数量分别为 40、128、256、1024。各层激活函数均为 Sigmoid。

本文设计并制作了如下数据集用以训练并验证 SAE-LR 以及 SL-W 方法的重建效果以及其二者的泛化能力。如表 3.4 所示。

表 3.4 数据集参数

Table3.4 Dataset parameters

数据集	半径	形状	目标数量	样本大小
单目标圆形	3 ± 1	圆形	1	3000
双目标圆形	3 ± 1	圆形	2	3000
三目标圆形	3 ± 1	圆形	3	3000
单目标正方形	3 ± 1	正方形	1	3000
双目标正方形	3 ± 1	正方形	2	3000
三目标正方形	3 ± 1	正方形	3	3000
单目标三角形	3 ± 1	三角形	1	3000
双目标三角形	3 ± 1	三角形	2	3000
三目标三角形	3 ± 1	三角形	3	3000
小型目标	1 ± 1	正方形	2 ± 1	300
大型目标	5 ± 1	三角形	2 ± 1	300

为了研究目标物体的形状与数量对试验中将要比对的四种方法成像效果的影响，本文分别生成了圆形、正方形、三角形目标各 9000 组，其中各个形状三种不同数量的三种仿真数据各 3000 组。与此同时，为了保证 SAE-LR 以及 SL-W 方法的泛化能力，再额外生成小型目标的测试集和大型目标的测试集各 300 组。

3.6.1 仿真试验的图像重建结果分析

为了使得四种成像方法的对比差异更加直观，本节将一部分仿真试验中的实例集中展示。




图 3.16 单目标物体（圆形）重建效果对比

如图 3.16。该样例的场域中只有一个目标物体，从真实仿真图像中可以看出，目标物为圆形。该目标位于背景区域右下半边，靠近边缘处。四种方法都能够重建出该目标的大致位置，但只有三种智能重建算法能够较为精准地重建出图像。

其中传统的非智能算法 GVSPM 虽然能够大致重建出目标的位置，但成像效果较差，且成像区域存在大量伪影。三种智能算法中，ANN 的重建结果能够比较精准地体现被测目标的位置，但与实际情况存在一定的偏差，并且伪影部分面积也比较多，目标物体的形状比较模糊。SAE-LR 的重建结果目标物体面积较大且形状与真实情况非常接近，但目标物周围仍然存在少量伪影。SL-W 方法的成像效果最为优异，不仅重建大小形状较为准确，并且目标物体周围的轮廓相对更加清晰，几乎没有伪影。




图 3.17 双目标物体（正方形）重建效果

图 3.17 是一个双目标正方形物体的测试样本，两个目标物体均位于左半边，其中一个目标在左半边偏上的位置。

在双目标下，四种方法的重建结果都出现了不同程度的伪影，四种方法都能够重建出该目标的大致位置，但只有三种智能重建算法能够较为精准地重建出目标物。

其中 GVSPM 算法能够大致呈现出目标物体的位置，但成像区域大片连接，无法区分目标物体的数量。相比 SAE-LR，ANN 的重建结果一般，在这个样例之中，ANN 似乎与 GVSPM 一样，无法区分两个彼此距离较近的独立目标物体，并且周围也存有较多伪影。SAE-LR 方法成像结果令人满意，能够比较直观地判断出存在两个不同目标物体，但目标物周围仍然存在少量伪影。SL-W 方法的重建结果与 SAE-LR 方法的结果相差不多，但周边伪影更少。




图 3.18 双目标物体（圆形）重建效果

图 3.18 是一个双目标圆形物体的测试样本，两个目标物体分别处于左上和左下，其中左上部的目标较大，左下部的目标较小。

GVSPM 算法的成像结果虽然隐约能够将两个目标物体区分，但成像效果实在太差，几乎无法辨别目标物体的大小，并且伪影较多。

三种智能重建算法都能精确地重建出目标物体的数量以及位置，但 ANN 的算法对于左下方目标物体的成像面积较小，并且比较模糊，对于左上部分物体的重建面积也小于真实情况，整个图像伪影也仍然比较多。SAE-LR 方法对位于两个不同目标物体的重建结果基本与原物体相当，伪影也相对更少，但左下方目标物体的重建结果稍微有些模糊。SL-W 方法的成像效果仍然最为优异，虽然相较于单个物体的目标，对两个被测物的形状重建效果稍稍有所下降，但无论是较大的目标物体还是较小的目标物体，都有比较清晰的轮廓，伪影也是四种方法中最少的。




图 3.19 三目标物体（圆形）重建效果

图 3.19 是一个三目标圆形物体的仿真样例，其中，面积最大的目标物体位于背景中间偏左下，位于背景右下部的物体面积仅次于中间物体，面积最小的物体位于背景左上方。

GVSPM 算法未能重建出最小目标物体的位置，并且由于中间物体与右下部分物体比较接近，导致中部物体成像也受到了影响。ANN 方法仅能较明显地重建出中部物体的位置，并且重建面积相比于实际情况较小，同时对于左上部较小物体与右下部分物体的重建效果比较糟糕，仅仅能够勉强分辨出三个物体，并且伪影同样比较严重。SAE-LR 方法能够将背景区域上的多个目标物体一一重建，成像的效果尚可，相对于 ANN，减少了大量伪影，对目标的重建也更为清晰，但中部物体和右下部的目标物体仍然存在连接的情况，并且右下部的物体似乎出现了分裂的情况。SL-W 方法能够重建出全部的三个物体，而且对于面积最大的物体重建效果仍然相对更清晰，伪影比较少，尽管中间与右下部的物体仍然存在连接情况，但已经可以明显区分。

图 3.20、3.21、3.22、3.23、3.24，分别是单目标物体（正方形）实例、三目标物体（正方形）实例、单目标物体（三角形）实例、双目标物体（三角形）实例、三目标物体（三角形）实例。




图 3.20 单目标物体（正方形）重建效果




图 3.21 三目标物体（正方形）重建效果




图 3.22 单目标物体（三角形）重建效果




图 3.23 双目标物体（三角形）重建效果




图 3.24 三目标物体（三角形）重建效果

由图 3.20、3.21、3.22、3.23、3.24 五组试验的重建图像可知，GVSPM 算法只能够重建出目标物体的大致位置，对于其他成像结果都不是太好。

ANN 和 SAE-LR 都难以重建目标物体的形状，但 SAE-LR 的重建结果相对更为优秀，伪影更少，形状更清晰。而 SL-W 方法的成像结果，已经可以比较清晰地呈现出部分目标物体的轮廓，并且成像精度高，伪影数量少。

根据上述试验可以看出，SAE-LR 对于 EIT 成像的电阻抗分布具有相当的泛化能力。SAE-LR 和 ANN 虽然都难以重建目标物体形状的边缘轮廓，但其中 SAE-LR 的重建结果更优，ANN 的重建结果稍差。SL-W 方法的重建结果能够较为清晰地展现出目标物的轮廓。

3.6.2 仿真试验的评判指标结果分析

在前面的 3.6 节中，本文展示了判断 EIT 成像效果优劣的三种常用评判指标，在数据集上的重建结果如表 3.5 所示。表格中加粗部分为四种不同方法在三种评判指标下实验中出现的最优数据。

表 3.5 四种不同方法上仿真数据集的效果

Table3.5 The effect of simulation dataset under four different methods

方法	RSD	PE	MSE
GVSPM	0.910	0.1089	0.2057
ANN	0.681	0.0745	0.0674
SAE-LR	0.545	0.0608	0.0012
SL-W	0.487	0.0565	0.0012

由计算得到的三项评判指标可以看出，SAE-LR 方法相比传统 ANN、GVSPM 算法，有显著的优势。SAE-LR 对于测试集的电阻抗分布的相对标准差、位置误差和均方误差的重建效果要好于 ANN 方法和 GVSPM 方法，其中 GVSPM 的重建效果最不乐观。

以 GVSPM 为比较对象，SAE-LR 方法在 RSD 上减少了 40.11%，PE 降低了 44.17%，MSE 减少了 99.42%。SL-W 方法在 RSD 上减少了 46.48%，PE 降低了 48.12%，MSE 减少了 99.47%。

以 ANN 方法为比较对象，SAE-LR 方法在 RSD 上减少了 19.97%，PE 降低了 18.39%，MSE 减少了 98.22%。SL-W 方法在 RSD 上减少了 28.49%，PE 降低了 24.16%，MSE 减少了 98.29%。

以 SAE-LR 为比较对象，拥有后处理模块的 SL-R 方法同样有所提升，在 RSD 上减少了 10.64%，PE 降低了 7.07%，MSE 减少了 1.3%。

下表 3.6 展示了四种方法对于不同数量目标物体的重建结果比较。表格中加粗部分为四种研究方法在三种评判指标下对于不同目标物体数量的实验中出现的最优数据。

表 3.6 不同数量目标物体下的试验结果

Table3.6 Experimental results under different number of target objects

方法		GVSPM	ANN	SAE-LR	SL-W
RSD	单目标	0.978	0.690	0.517	0.462
	双目标	0.923	0.696	0.561	0.500
	三目标	1.076	0.684	0.570	0.509
PE	单目标	0.0861	0.0453	0.0208	0.0191
	双目标	0.1013	0.0831	0.0675	0.0621
	三目标	0.1081	0.0896	0.0657	0.0604
MSE	单目标	0.1980	0.0303	0.0006	0.0005
	双目标	0.1768	0.0445	0.0009	0.0009
	三目标	0.2423	0.1274	0.0022	0.0019

观察表 3.6 中的试验结果，当目标物体的数量变化，四种方法的重建效果均出现了不同程度的变化。

对于 SAE-LR 方法，单目标物体的重建结果最好，RSD 仅为 0.517，MSE 仅有 0.0006，双目标物体与三目标物体的重建结果相差不大。单目标物体的平均 PE 仅为 0.208，明显优于双目标和三目标物体，而双目标和三目标的数据差别较小，PE 分别为 0.675 和 0.657，这一点从重建图像上也可以比较直观地分析出结论。

对于 GVSPM 算法，在 RSD 与 MSE 两项数值上，都是双目标的效果最好，单目标次之，三目标的效果最差，再观察 PE 数据，单目标却要稍好于二目标和三目标。

综合分析四种重建方法的数据，由于同为智能重建算法，原理同根同源，故而目标物体数目对 ANN、SAE-LR 和 SL-W 方法的重建图像效果的影响近似，但对 GVSPM 的影响有所不同。

表 3.7 不同形状目标物体下的试验结果

Table 3.7 Experimental results under different shapes of target objects

方法		GVSPM	ANN	SAE-LR	SL-W
RSD	圆形	0.954	0.687	0.524	0.468
	三角形	0.919	0.708	0.583	0.521
	正方形	0.922	0.699	0.561	0.501
PE	圆形	0.0906	0.0305	0.0183	0.0170
	三角形	0.1023	0.0783	0.0457	0.0425
	正方形	0.0935	0.0657	0.0401	0.0373
MSE	圆形	0.1673	0.0233	0.0006	0.0006
	三角形	0.1869	0.0437	0.0011	0.0010
	正方形	0.1757	0.0413	0.0009	0.0009

表格中加粗部分为四种研究方法在三种评判指标下对于不同目标物体形状的实验中出现的最优数据。观察表 3.7 中的试验结果，当目标物体的形状发生变化，四种方法的重建效果均出现了不同程度的变化。

其中 GVSPM 算法，对于圆形目标的电导率重建结果反而稍差一些，三角形目标的重建效果最好，正方形目标的重建效果与三角形相差不大。位置方面，圆形目标的效果比较好，正方形物体次之，三角形物体较差。从均方误差上看，GVSPM 算法的重建效果远不如三种智能重建算法。

对于 SAE-LR 与 SL-W 方法，对于圆形目标物体的重建效果远好于另外两种形状的目标，正方形次之，三角形的重建效果最差，位置方面也同样如此。而均方误差上来看，三种形状目标物的重建效果总体都很不错。

对于 ANN，三种形状目标物体的重建效果从数值上看相差不大，位置重建方面，圆形目标效果最好，正方形目标次之，三角形的重建效果最差。均方误差上看，ANN 的重建效果相较于前两者稍差。

此外,仿真试验的过程中还比较了四种重建方法的运行速度,SAE-LR 及其后处理方法对单个样本的重建时间约为 0.48s,ANN 方法的重建时间约为 0.29s,GVSPM 的重建时间约为 2.8s 左右。

可以看出智能算法在图像重建的速度上,也有比较大的优势。

3.7 小结

本章提出了面向电阻抗成像技术的深度神经网络重建算法以及其成像过程与映射模型,详细介绍了本文用于训练神经网络模型的仿真数据集生成及预处理,构造了深度神经网络模型 SAE-LR 与 SL-W,用于电阻抗图像重建,并通过三组试验,对深度神经网络模型的网络层数与学习率进行了优化,最后使用 GVSPM、ANN 与 SAE-LR 及 SL-W 四种方法,分别对三种不同形状、三种不同数量的仿真数据集进行成像,并分析试验结果,得出结论,验证了本文提出的面向电阻抗断层成像技术的 SAE-LR 与 SL-W 方法重建图像的可行性与优越性。

第 4 章 试验研究与分析

4.1 试验条件

为了检测 SAE-LR 方法及其优化后的 SL-W 方法对于实际数据的重建效果，本章设计并搭建了用于实际试验的 EIT 图像重建系统。

系统中 EIT 数据使用 8 电极采集系统采集电压数据，设置的待测场域为圆形亚克力杯，激励电流大小为 1mA，频率 10kHz。物场内的背景介质选用液态水，随后进行不同组别的试验。以三种不同形状的有机玻璃棒为目标物体，设置三种不同目标数量。三种有机玻璃棒分别为圆形（圆柱体）、三角形（正三棱柱）、正方形（正四棱柱）。

试验的硬件系统为嵌入式八电极系统。信号采集控制器给出一个测量协议，然后它根据测量协议进行切换和驱动切换。信号采集控制器使测量通道开启或关闭，间接实现外部电流源励磁输入的控制和数据采集。试验系统包括 PC 机、路由器、模拟多路复用器、压控电流源（VCCS）和矩阵电极。每个组件都由一些屏蔽线连接。




图 4.1 EIT 试验系统图

试验中测量对象为固体有机玻璃棒，背景材料为生活中普通的液态水溶液。测量物场亚克力杯的外壁直径 D_1 为 90 毫米，内壁直径 D_2 为 84 毫米。固体有机玻璃棒直径 d_1 为 20 毫米。在试验系统中，有 8 个矩阵电极，它们以等距固定在物场亚克力

杯周围。驱动电流由 VCCS 获得，PC 控制信号采集控制器间接控制驱动和测量通道的状态。信号采集控制器获得边界电压并将其反馈给 PC，然后利用 PC 实现图像重建。

4.2 试验结果与分析

在完成了试验系统的搭建后，分别进行了二十五组试验进行验证和分析，在本节中将选择最有代表性的七组试验实例进行结果展示和分析。

七组试验实例中有三组单目标圆形物体的试验、一组单目标三角形物体的试验、一组双目标三角形物体的试验，以及两组混合圆形、三角形、正方形物体的三目标试验。试验结果分别如图 4.2、4.3、4.4、4.5、4.6、4.7、4.8 所示。




图 4.2 单目标圆形物体试验（1）结果

图 4.2 是一组单目标圆形物体的试验结果，目标物体（圆柱形有机玻璃棒）被放置在亚克力杯（被测物场）的正中央。

观察试验图像，GVSPM 算法的重建结果比较模糊，目标物体的位置和形状出现了较大的变化，并且成像区域存在大量伪影，效果不尽如人意。ANN 算法已经去除了绝大部分伪影，对于目标的位置已经比较准确、清晰，但目标的形状仍然出现了一些变化，并且目标周围仍然存在部分伪影。SAE-LR 的成像结果十分优异，不仅从位

置上重建出良好的效果，并且成像结果与实际目标物体的大小、形状都十分接近。观察 SL-W 方法的图像重建结果，在 SAE-LR 的基础上，经过 WGAN-gp 后处理后，成像精度进一步提升，伪影更少。




图 4.3 单目标圆形物体试验（2）结果

为了检验四种算法的稳定性，在 first 组试验完成后，保持位置不变的情况下，将有机玻璃棒旋转一周，并再次进行试验。

观察两组试验的结果，GVSPM 算法的重建图像变化较大，目标物体的位置形状均有一定幅度的变动，除此之外，ANN 的成像结果也有小幅度的变化。

反观 SAE-LR 算法以及加入 WGAN-gp 的深度学习模型 SL-W，在成像结果上几乎没有变化，展现出极好的稳定性。

观察两组试验四组算法的试验重建结果，SAE-LR 方法的重建效果无疑是优秀的，在目标物体之外，不依靠数据分析，仅凭肉眼观察几乎已经找不到伪影，并且目标物体的位置呈现的也很精确，目标物体的大小方面重建结果也较好；GVSPM 的重建结果的目标物体面积与真实情况有着相当大的出入，并且位置出现了较大的偏移，其形状也跟目标物体有非常大的差距，除此之外伴有较大的伪影，ANN 的成像效果一般，相比于 GVSPM，它去掉了大部分伪影，对目标物体的位置重建比较准确，但在目标物体内部的阻抗呈现效果比较模糊。而 SL-W 方法的成像效果更加令人满意，目标物

不仅具有较为清晰的轮廓，并且物体周围的伪影大大减少。

在保持单目标圆形物体试验系统的基础上，将圆柱形有机玻璃棒的位置从正中央移动至亚克力杯，即物场的右下角，再次进行试验，试验结果如图 4.4 所示。




图 4.4 单目标圆形物体试验（3）结果

观察四种算法的重建结果，GVSPM 算法的图像虽然大致可以看清目标物体的位置，但物体的形状与真实情况有比较大的出入，并且边缘轮廓也很模糊，整个图像上充斥着大量的伪影。

ANN 的成像结果比之 GVSPM 较好一些，具备清晰的大小和形状，但目标物体的边缘轮廓稍显模糊，图像中还存在一些伪影。SAE-LR 算法的成像结果令人满意，图像中的伪影已经比较少，目标物体的轮廓比较清晰，但目标物体的边缘还存在部分伪影。用 SL-W 方法重建的图像，已经几乎看不到伪影，目标物体的边缘轮廓非常清晰。

在保持原有的试验系统的基础上，将圆形有机玻璃棒更换为正三棱柱（相同材质的正三角形有机玻璃棒），再次进行试验，试验结果如图 4.5 所示。




图 4.5 单目标三角形物体试验结果

观察四种算法的重建结果，GVSPM 算法的图像仍然是大致可以看清目标物体的位置，但物体的形状与真实情况有比较大的出入，并且边缘轮廓也很模糊。整个图像上充斥着大量的伪影，然而相较于单目标圆形物体的试验结果，又稍好一些。

ANN 的成像结果比之 GVSPM 稍好，但只能大致体现目标物体的大小和位置，在目标物体的形状上结果较差，但目标物体的边缘轮廓稍显模糊，图像中还存在一些伪影。SAE-LR 算法的成像结果令人满意，图像中的伪影比较少，目标物体的轮廓比较清晰，然而目标物体的形状仍然偏向于圆形并且周边存在部分伪影。观察 SL-W 方法的图像重建结果，已经几乎看不到伪影，目标物体的边缘轮廓非常清晰，并且目标物体的形状也跟真实图像更接近。

在保持原有的试验系统的基础上，将正三棱柱的数量更改为两个，并且再次进行试验，试验结果如下图 4.6 所示。




图 4.6 双目标三角形物体试验结果

观察四种算法的重建结果，GVSPM 算法的图像仍然是大致可以看清目标物体的位置，但物体的形状与真实情况有比较大的差距，并且边缘轮廓也很模糊，两个目标物体甚至连接在一起，无法被区分，图像周围充斥着大量的伪影。

ANN 的成像结果比之 GVSPM 较好，但只能大致体现目标物体的位置，成像结果中的目标物体比实际情况稍小一些，并且在目标物体的形状上结果较差，目标物体的边缘轮廓稍显模糊，图像中还存在一些伪影。SAE-LR 算法的成像结果相较于 ANN 稍好一些，图像中的伪影比较少，目标物体的轮廓比较清晰，但目标物体的形状仍然与真实情况有着比较大的出入，在重建目标的大小上与实际情况的差距也比较大。而在此基础上经过 WGAN-gp 后处理的 SL-W 方法的图像重建结果来看，重建区域已经几乎看不到伪影，目标物体的边缘轮廓也比较清晰，然而目标物体的形状跟真实情况有一定的出入。

在保持原有的试验系统的基础上，将目标物体的数量更改为三个，并且将三种形状不同的目标物体（圆柱、正三棱柱、正四棱柱）同时加入，并进行两组试验，试验结果如图 4.7、4.8 所示。




图 4.7 三目标混合物体试验 (1) 结果




图 4.8 三目标混合物体试验 (2) 结果

观察两组试验、四种算法的重建结果，GVSPM 算法的图像大致可以看清目标物体的位置，但物体的形状与真实情况有比较大的差距，并且边缘轮廓也很模糊，独立目标物体之间连接在一起，无法被区分，与此同时，图像周围充斥着大量的伪影。

值得一提的是，虽然 ANN 的成像结果比之 GVSPM 较好，但同样存在独立的目

标物体缺失、连接的情况,并且只能大致体现目标物体的位置,成像结果中的目标物体比实际情况稍小,在目标物体的形状上结果较差,目标物体的边缘轮廓稍显模糊,图像中存在伪影。SAE-LR 算法的成像结果相较于 ANN 则要好得多,独立的目标物体大致可以区分,并且图像中的伪影比较少,目标物体的轮廓比较清晰,但目标物体的形状仍然与真实情况有着比较大的出入。使用 SL-W 方法重建的图像上,已经几乎看不到伪影,目标物体的边缘轮廓也比较清晰,然而目标物体的形状仍然跟真实情况有一定的出入。从上述七组试验的结果来看,GVSPM 算法虽然能够大致呈现目标物体的位置,但是在大小、形状、清晰程度以及检测多个目标物体时,独立目标区分的情况来看,结果不尽如人意。ANN 相对于传统的 GVSPM 算法来说,成像情况要好得多,伪影大量减少,目标物体清晰程度也有所提高,但仍然存在大小和形状模糊的情况。而本文提出的 SAE-LR 算法以及在此基础上优化加入 WGAN-gp 后处理算法得到的 SL-W 网络,则比之 ANN 的成像结果更进一步,无论是大小、形状、清晰程度以及检测多个目标物体时,独立目标区分的情况,都有不同程度的提升。

然而纵观七组试验中 SAE-LR 以及 SL-W 方法的试验结果,圆形目标的试验结果最好,无论是正三角形和正方形的试验结果都有所下降,数量上分析,单目标时效果最好,双目标和三目标的效果相差不大,双目标的试验结果稍好一些。

4.3 小结

本章的主要内容,是利用试验中的测量数据对本文提出的两种面向电阻抗成像技术的深度神经网络算法的有效性进行验证。首先对试验条件及试验数据的获取进行了简要介绍。其次用独立于训练数据之外的试验测量数据对本文提出的两种成像方法进行测试,实现图像重建,并与 GVSPM 算法和 ANN 方法得到的图像进行比对。

从重建得到的图像分析,SAE-LR 对目标的重建结果令人满意,在此基础上的 SL-W 方法的重建结果则更进一步。试验结果证明,本文提出的 SAE-LR 算法以及 SL-W 方法能够应用于 EIT 成像过程,并且相较于传统的非智能重建算法,其二者对图像的重建能力大大提高,验证了 SAE-LR 以及 SL-W 方法的优越性。

第5章 结论与展望

5.1 结论

本文首先探讨了 EIT 技术的研究价值、发展过程以及一些应用场景，并对其成像原理进行深入分析。具体来说，本文描述了 EIT 数学模型的建立、EIT 正问题的计算以及智能、非智能两类不同的图像重建算法，两类算法都举出了一些常见的例子，并进行了简要的介绍，其中 GVSPM 与 ANN 两种算法为后续试验提供了参考。

其次，描述了本文如何使用正问题有限元法来构建足够的数据集以供神经网络模型的训练，并介绍了本文用于构建深度神经网络模型的部分结构及其背后的原理，随后经过多组试验，确定了本文提出的面向电阻抗成像技术的深度神经网络结构 SAE-LR 和 SL-W 方法，最后通过仿真试验，探讨了四种方法重建图像的效果，并结合数据分析了四种重建方法的优劣。

本文对于深度学习领域以及 EIT 成像技术领域的主要研究工作如下：

(1) 生成并制作用于训练深度神经网络模型的训练数据集。

通过有限元法，将本文研究的背景区域划分为 1024 个单元，为了保证训练数据集的合理性与泛用性，设定在背景区域上随机生成目标物体，除此之外在生成目标的程序代码中设定了不同数量、不同大小、不同位置的目标物体，并设置目标物体的电导率以及被测场域的电导率。通过 MATLAB 平台的 EIDORS 工具，凭借电导率信息数据来推导、求解 EIT 正问题，并计算出边界电压数据。为降低测量数据噪声对成像效果的影响，本文使用动态成像的技术，将边界电压差值作为推导电导率分布的依据。最终，对得到的大量数据进行数据清洗等预处理，组成边界电压差与目标物体电导率分布一一对应组成的数据集，该数据集可以用于深度神经网络模型的训练。本文研究中制作的用于神经网络训练的数据集中共有 21600 组数据，测试数据集共 5400 组，以及 600 组额外的特殊数据，用以测试深度神经网络模型的泛化能力，该特殊数据集并非奇异样本，只是目标物体的大小与正常数据集差异较大。

(2) 构建了面向电阻抗成像的深度神经网络模型并进行仿真、实物试验与分析。

首先设计了用神经网络求解 EIT 逆问题的具体流程和映射模型,介绍了几种本文使用的神经网络结构自编码器、逻辑回归、生成式对抗网络等,并提出了基于堆栈式自编码器和逻辑回归的神经网络模型 SAE-LR,以及在此基础上增加 WGAN-gp 后处理模块的 SL-W 方法,并设计了实验,确定了神经网络的部分重要影响参数,给出了包括数据归一化方法、学习率、隐藏层数量、神经元个数、激活函数、优化器等参数的选择和调整,介绍了 SAE-LR 和 SL-W 的训练过程。

为了检验本文提出的 SAE-LR 方法及其优化 SL-W 方法对 EIT 图像重建的效果,本文分别设计了仿真试验与实物试验,对比了 GVSPM 和 ANN 两种智能、非智能重建算法,并从数据和图像等多个角度去分析、比较。本文使用了相对标准差(RSD)、均方误差(MSE)、位置误差(PE)三种不同的评判指标,根据三种指标的数据对比,来判断四种不同重建方法的重建效果。

经过试验验证,两种神经网络模型 SAE-LR 与 SL-W 的图像重建效果令人满意。相比 ANN、GVSPM 算法,SAE-LR 对目标物体的电导率数值、相对位置等的重建效果有着显著优势,并且重建伪影较少,图像相对清晰,重建质量更高。SL-W 方法在 SAE-LR 的基础上更进一步,无论是伪影情况还是电导率分布,重建结果都更好,只是由于 SAE-LR 方法的图像重建结果在数值上已经相当优异,所以 SL-W 方法在数值上的优化不算太明显。

5.2 研究展望

面向电阻抗成像技术的神经网络模型 SAE-LR 和 SL-W 在试验结果下都取得了远超传统非智能重建算法的效果,但是深入探讨试验结果,二者仍然有其不足之处与进步空间。

对于 SAE-LR 方法来说,虽然它对圆形目标的成像效果已经令人满意,但对另外几种形状的目标物体,在形状上辨别能力稍差,况且正三角形和正方形的形状已经相对规则,可以预想,将目标物体的形状扩展到不规则物体的情况下,这个成像效果可能会再次降低。另外,对于多个目标的成像效果稍差。

因此,有必要在后续的研究和试验中,采取有效措施来改善这一问题,以提高成像效果,例如:

(1) 扩充训练数据集，并在生成数据集时设定更多数量的不规则形状目标物体的数据。

(2) 扩充总体样本容量，尽可能增加数据集的大小，为神经网络的训练提供足够的支持。

对于 SL-W 方法，能够有效地重构目标物体的电导率分布，但由于训练数据的多方面局限性，它仍然必须根据实际应用场景来调整训练数据集。并且观察试验结果，虽然相对于另外三种方法，它的重建效果最为优异，但面对被测物场内存在多个目标物时，它的重建效果相较于自身对单个目标的重建效果出现了幅度较大的下降。

在后续的试验和研究中，可以尝试优化训练样本，在保证训练效果的情况下逐步增加数据集的样本，以期实现图像处理的最佳效果。

参考文献

- [1] 黄瑞贤,汪保灿.人工智能在肝脏疾病中的应用[J].胃肠病学和肝病学杂志,2023,32(01):110-113.
- [2] 王卉,冯玉婷,于永沛,胡陈华,陶立元.基于临床试验注册平台的脑卒中后康复运动治疗:近 20 年特征分析[J].康复学报,2022,32(05):455-461.
- [3] Polydorides N, Lionheart W, Mccann H. Krylov subspace iterative techniques: on the detection of brain activity with electrical impedance tomography.[J]. IEEE Transactions on Medical Imaging, 2002, 21(6):596-603.
- [4] Tao S, Tsuda S, Zauner K P, et al. On-chip electrical impedance tomography for imaging biological cells[J]. Biosensors & Bioelectronics, 2010, 25(5):1109-1115.
- [5] 裴飞霸,张和华,颜乐先,尹军.电阻抗断层成像技术研究[J].中国医疗器械杂志,2016,40(01):52-54.
- [6] Alberti G S, Ammari H, Jin B, et al. The Linearized Inverse Problem in Multi frequency Electrical Impedance Tomography[J]. Siam Journal on Imaging Sciences, 2016, 9(4):1525-1551.
- [7] Karsten J, Meier T, Heinze H. Bedside-measurements of electrical impedance tomography and functional residual capacity during positioning therapy in a case of acute respiratory failure[J]. Applied Cardiopulmonary Pathophysiology, 2011, 15(2):81-86.
- [8] Schultz M J, Haitisma J J. How to detect tidal recruitment and/or alveolar hyperinflation--computed tomography, electrical impedance tomography, or stress index?[J]. Critical Care Medicine, 2008, 36(3):1020-1021.
- [9] 姚佳烽.微尺度电阻抗成像在肿瘤细胞检测中的应用进展[J].现代医学与健康研究

- 电子杂志,2022,6(02):6-9.
- [10]肖理庆. 电阻层析成像有限元模型优化与图像重建算法研究[D].天津大学,2014.
- [11]代月霞. 基于深度学习的 EIT 图像重建算法研究[D].天津工业大学,2017.
- [12]侯海岭,王化祥,陈晓燕.应用于肺部 EIT 系统的激励电流源设计[J].自动化仪表,2014,35(01):81-83+87.
- [13]王化祥,黄文瑞,范文茹.三维电阻抗成像的测量模式[J].天津大学学报,2012,45(08):729-734.
- [14]王琦,张鹏程,汪剑鸣,李秀艳,连志杰,陈庆良,陈彤云,陈晓静,贺静,段晓杰,王化祥.基于块稀疏的电阻抗成像算法[J].电子与信息学报,2018,40(03):676-682.
- [15]贺静. 基于压缩感知和结构化稀疏先验信息的电阻抗成像方法研究[D].天津工业大学,2019.
- [16]黄嵩,何为,罗辞勇.开放式电阻抗成像中变差正则化重构算法[J].重庆大学学报,2011,34(10):1-7.
- [17]罗辞勇,王平,何为,陈民铀.交叉测量协议对电阻抗成像病态性的影响[J].中国生物医学工程学报,2010,29(02):185-189.
- [18]Jimenez J V, Weirauch A J, Culter C A, et al. Electrical Impedance Tomography in Acute Respiratory Distress Syndrome Management[J]. Critical care medicine, 2022, 11(8): 50.
- [19]孙博, Prima Asmara Sejati, 姚佳烽.运动训练对人类小腿肌肉生理响应的电学特性研究[J/OL].生物化学与生物物理进展,2023,12(1):1-12.
- [20]Cardinale M, Boussen S, Cungi P J, et al. Lung-Dependent Areas Collapse, Monitored by Electrical Impedance Tomography, May Predict the Oxygenation Response to Prone Ventilation in COVID-19 Acute Respiratory Distress Syndrome [J]. Critical care medicine, 2022, 1(7): 50-52.
- [21]Wicaksono R, Darma P N, Inoue A, et al. Wearable sectorial electrical impedance tomography and k-means clustering for measurement of gastric processes[J]. Measurement Science & Technology, 2022, 1(9): 33-37.
- [22]Isaacson D. Distinguishability of Conductivities by Electric Current Computed T

- omography[J]. IEEE Transactions on Medical Imaging, 1986, MI-5(2):91-95.
- [23]Henderson R P, Webster J G. An Impedance Camera for Spatially Specific Measurements of the Thorax[J]. IEEE Transactions on Biomedical Engineering, 2007, BME-25(3):250-254.
- [24]Seagar A D, Barber D C, Brown B H. Electrical impedance imaging[J]. Science, Measurement and Technology, IEE Proceedings A, 1987, 134(2):201-210.
- [25]Harris N D, Suggett A J, Barber D C, et al. Applied potential tomography: a new technique for monitoring pulmonary function[J]. Clinical Physics and Physiological Measurement, 1988, 9 Suppl A(4A):79-85.
- [26]Wei J, Ruan S. Stability and bifurcation in a neural network model with two delays[J]. Physica D Nonlinear Phenomena, 1999, 130(3-4):255-272.
- [27]A J N T, A M E, A C J, et al. L1 regularization method in electrical impedance tomography by using the L1-curve (Pareto frontier curve)[J]. Applied Mathematical Modelling, 2012, 36(3):1095-1105.
- [28]Liu N, Langguth L, Weiss T, et al. Plasmonic analogue of electromagnetically induced transparency at the Drude damping limit[J]. Nature Materials, 2009, 8(9):758-762.
- [29]陈晓艳,师波,褚猛丽,杨涛.采用神经网络提高 EIT 成像质量的方法研究[J].天津科技大学学报,2016,31(04):74-78.
- [30]李佳,岳士弘,王亚茹.基于先验信息的人体肺癌电阻抗层析成像[J].传感器与微系统,2018,37(10):22-24.
- [31]戎舟,李若愚,方滔.基于多层人工神经网络的电阻抗成像算法[J].国外电子测量技术,2021,40(01):80-86.
- [32]吴阳,刘凯,陈柏,李芳,姚佳烽.自适应粒子群优化算法优化径向基函数神经网络用于电阻抗成像图像重建[J].仪器仪表学报,2020,41(06):240-249.
- [33]李若愚. 基于神经网络的电阻抗成像算法研究[D].南京邮电大学,2021.
- [34]高越. 电阻抗断层成像系统设计与算法研究[D].上海交通大学,2020.
- [35]卢阳. 用于 EIT 图像重建的深度神经网络模型构建方法[D].天津工业大学,2018.

- [36]张宇展,钟航宇,梁坤,桑子豪,孙犇渊.三维电阻抗层析成像的跨层激励研究[J].科技风,2022(28):55-57.
- [37]Takei, Masahiro. GVSPM image reconstruction for capacitance CT images of particles in a vertical pipe and comparison with the conventional method[J]. Measurement Science & Technology, 2006, 17(8):2104.
- [38]谈伟峰. 基于深度学习的视频动作识别方法研究与应用[D].南京邮电大学,2022.
- [39]罗玲,田智立,张涛,刘雷波,李卓达,李丽英.基于人工神经网络的热固性树脂基复合材料固化变形预测研究综述[J].复合材料科学与工程,2022(11):120-127+132.
- [40]尹宝才,王文通,王立春.深度学习研究综述[J].北京工业大学学报,2015,41(01):48-59.
- [41]李彦冬,郝宗波,雷航.卷积神经网络研究综述[J].计算机应用,2016.
- [42]A A K, B V I U. Comparison of neural network, conditional demand analysis, and engineering approaches for modeling end-use energy consumption in the residential sector[J]. Applied Energy, 2008, 85(4):271-296.
- [43]张震添. 基于神经网络的大容量图像隐写技术研究[D].南京信息工程大学,2022.
- [44]Zhou Z H, Wu J, Wei T. Ensembling Neural Networks: Many Could Be Better Than All[J]. Artificial Intelligence, 2002, 137(1-2):239-263.
- [45]张蕾,章毅.大数据分析的无限深度神经网络方法[J].计算机研究与发展,2016,53(01):68-79.
- [46]Gevrey M, Dimopoulos , Lek S. Review and comparison of methods to study the contribution of variables in artificial neural network models[J]. Ecological Modelling, 2003, 160(3):249-264.
- [47]Tokar A S, Johnson P A. Rainfall-Runoff Modeling Using Artificial Neural Networks[J]. Journal of Hydrologic Engineering, 1999, 4(3):232-239.
- [48]Kim J Y, Bu S J, Cho S B. Zero-day malware detection using transferred generative adversarial networks based on deep autoencoders[J]. Information sciences, 2018:83-102.
- [49]Genton M G. Classes of Kernels for Machine Learning: A Statistics Perspective

- [J]. Journal of Machine Learning Research, 2002, 2(2):299-312.
- [50]郑胤,陈权崎,章毓晋.深度学习及其在目标和行为识别中的新进展[J].中国图象图形学报,2014,19(02):175-184.
- [51]樊浩杰. 基于人工智能算法的示功图智能识别研究[D].河南科技大学,2019.
- [52]Shin, Hoo-Chang, Orton, et al. Stacked Autoencoders for Unsupervised Feature Learning and Multiple Organ Detection in a Pilot Study Using 4D Patient Data [J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2013, 35(8): 1930-1943.
- [53]张润,王永滨.机器学习及其算法和发展研究[J].中国传媒大学学报(自然科学版),2016,23(02):10-18+24.
- [54]Ali A, Yangyu F, Liu S. Automatic modulation classification of digital modulation signals with stacked autoencoders[J]. Digital Signal Processing, 2017, 71:108-116.
- [55]Lakhani P, Sundaram B. Deep Learning at Chest Radiography: Automated Classification of Pulmonary Tuberculosis by Using Convolutional Neural Networks[J]. Radiology, 2017:574-582.
- [56]高文波,孔慧华,连祥媛.基于多尺度生成对抗网络的低剂量 CT 去噪算法[J].国外电子测量技术,2021,40(08):1-6.
- [57]周乐. 基于对抗生成网络的反射去除算法[D].华南理工大学,2017.
- [58]Shin H C, Roth H R, Gao M, et al. Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning[J]. IEEE Transactions on Medical Imaging, 2016, 35(5):1285-1298.
- [59]谢川,王勇超,林志洁,郑秋岚,钱飞,赵磊.基于对抗生成网络的蒙特卡罗噪声去除算法[J].模式识别与人工智能,2018,31(11):1047-1060.谭宏卫,王国栋,周林勇,张自力.基于一种条件熵距离惩罚的生成式对抗网络[J].软件学报,2021,32(04):1116-1128.
- [60]Ranzato M, Boureau Y L, Lecun Y. Sparse feature learning for deep belief networks[J]. Advances in Neural Information Processing Systems, 2008, 20:1185-1

192.

- [61]Lv Y, Duan Y, Kang W, et al. Traffic Flow Prediction With Big Data: A Deep Learning Approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(2):865-873.
- [62]Envelope H, Envelope N A, Envelope F C, et al. Uncertainty quantification in a mechanical submodel driven by a Wasserstein-GAN[J]. IFAC-PapersOnLine, 2022, 55(20):469-474.
- [63]Zhang Y, Lu Z, Ma D, et al. Ripple-GAN: Lane line detection with Ripple Lane Line Detection Network and Wasserstein GAN[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 18(99):1-11.
- [64]Bach C W, Perea A. Generalized Nash equilibrium without common belief in rationality[J]. Economics letters, 2020, 186(Jan.):108526.1-108526.6.